

Inferencia Bayesiana en Regresión Lineal Simple

Verosimilitud, distribución previa y estimación MAP
(Continuación de la clase anterior)

Apuntes de clase — Estadística

Resumen

Estas notas retoman el análisis bayesiano del modelo de regresión lineal simple $y_i = a + bx_i + \varepsilon_i$. Se construye la función de verosimilitud, se especifica una distribución previa no informativa para los parámetros (a, b) , y se combinan ambas mediante el teorema de Bayes para obtener la densidad posterior. Finalmente se deduce el estimador de Máximo a Posteriori (MAP) resolviendo un sistema lineal $M\vec{\theta} = \vec{Z}$, y se muestra que la posterior completa de (a, b) es, de hecho, una distribución normal bivariada.

Índice

1. Modelo y función de verosimilitud	2
1.1. Especificación del modelo	2
1.2. Distribución de cada observación	2
1.3. Verosimilitud conjunta	2
2. Distribución previa	3
2.1. Prior no informativo para a y b	3
2.2. Distribución previa conjunta	3
3. Distribución posterior	3
3.1. Teorema de Bayes	3
3.2. Núcleo de la posterior	3
3.3. Probabilidades posteriores	4
4. Estimación MAP	4
4.1. Logaritmo de la posterior	4
4.2. Condiciones de primer orden	4
4.3. Sistema lineal y forma matricial	5
5. Solución computacional del sistema	5
5.1. Solución numérica con NumPy	6
5.2. Solución simbólica con SymPy	6
6. La posterior completa: conexión con la normal bivariada	6
6.1. Forma general de la normal bivariada	6
6.2. Identificación de los coeficientes	7
6.3. Matriz de precisión y matriz de covarianza posterior	7

1. Modelo y función de verosimilitud

1.1. Especificación del modelo

Se considera el modelo de regresión lineal simple

$$y_i = a + bx_i + \varepsilon_i, \quad i = 1, \dots, n, \quad (1)$$

donde a (intercepto) y b (pendiente) son los **parámetros** del modelo, y los errores se suponen independientes e idénticamente distribuidos:

$$\varepsilon_i \sim \mathcal{N}(0, \sigma^2), \quad \sigma = 0,3 \text{ (conocido)}. \quad (2)$$

Nota. A diferencia de a y b , que son desconocidos y sobre los cuales se hará toda la inferencia, σ se trata aquí como una *constante conocida*, fijada en 0,3. Por ello, en lo que sigue $\theta = (a, b)$ denota el vector de parámetros desconocidos del modelo.

1.2. Distribución de cada observación

Escribimos $M(a, b)$ para referirnos al modelo evaluado en x_i , es decir $M(a, b) \equiv a + bx_i$. Como y_i es una traslación de ε_i (ecuación (1)) y $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$, se sigue que

$$y_i \mid M(a, b) \sim \mathcal{N}(a + bx_i, \sigma^2). \quad (3)$$

Por lo tanto, el *núcleo* de la densidad de cada observación (es decir, la densidad sin su constante de normalización, que no depende de a, b) es

$$f(y_i \mid M(a, b)) \propto \exp\left(-\frac{(y_i - (a + bx_i))^2}{2\sigma^2}\right). \quad (4)$$

1.3. Verosimilitud conjunta

Si las observaciones $y_1, \dots, y_n$ son condicionalmente independientes dado el modelo, la verosimilitud conjunta es el producto de las densidades individuales:

$$L(y \mid M(a, b)) = \prod_{i=1}^n f(y_i \mid M(a, b)). \quad (5)$$

Como el producto de exponenciales es la exponencial de la suma de los exponentes, sustituyendo (4) en (5):

$$L(y \mid M(a, b)) \propto \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - (a + bx_i))^2\right). \quad (6)$$

2. Distribución previa

2.1. Prior no informativo para a y b

A cada parámetro se le asigna una distribución previa normal centrada en cero, con una desviación estándar grande, es decir, poco informativa, ya que asigna probabilidad apreciable a un rango muy amplio de valores:

$$a \sim \mathcal{N}(0, \sigma_a^2), \quad b \sim \mathcal{N}(0, \sigma_b^2), \quad \sigma_a = \sigma_b = 10. \quad (7)$$

Los núcleos de estas densidades son

$$g(a) \propto \exp\left(-\frac{a^2}{2\sigma_a^2}\right), \quad g(b) \propto \exp\left(-\frac{b^2}{2\sigma_b^2}\right). \quad (8)$$

2.2. Distribución previa conjunta

Suponiendo independencia a priori entre a y b , la densidad previa conjunta es el producto de las marginales:

$$f(a, b) = g(a) g(b) \propto \exp\left(-\frac{a^2}{2\sigma_a^2}\right) \exp\left(-\frac{b^2}{2\sigma_b^2}\right). \quad (9)$$

Como $\sigma_a = \sigma_b = 10$, se tiene $2\sigma_a^2 = 2\sigma_b^2 = 2 \times 10^2 = 200$, de modo que (9) se simplifica a

$$f(a, b) \propto \exp\left(-\frac{a^2 + b^2}{200}\right). \quad (10)$$

3. Distribución posterior

3.1. Teorema de Bayes

La densidad posterior conjunta de (a, b) dados los datos $y = (y_1, \dots, y_n)$ es proporcional al producto de la verosimilitud (6) y la previa (10):

$$P(M(a, b) \mid y) \propto L(y \mid M(a, b)) \cdot f(a, b). \quad (11)$$

3.2. Núcleo de la posterior

Sustituyendo (6) y (10) en (11):

$$P(a, b \mid y) \propto \exp\left(-\frac{1}{2\sigma^2} \sum_i (y_i - a - bx_i)^2\right) \cdot \exp\left(-\frac{a^2 + b^2}{200}\right), \quad (12)$$

o, de forma equivalente, agrupando ambos factores en un solo exponente:

$$P(a, b \mid y) \propto \exp\left(-\frac{1}{2\sigma^2} \sum_i (y_i - a - bx_i)^2 - \frac{a^2 + b^2}{200}\right). \quad (13)$$

3.3. Probabilidades posteriores

Una vez conocida (al menos como núcleo) la densidad posterior de un parámetro θ , las probabilidades de interés se obtienen como áreas bajo dicha densidad. Por ejemplo, la probabilidad de que θ supere un valor de referencia θ_1 es

$$P(\theta > \theta_1 | x) = \int_{\theta_1}^{\infty} f(\theta | x) d\theta, \quad (14)$$

que corresponde gráficamente al área sombreada de la Figura 1.




Figura 1: Densidad posterior de un parámetro θ . El área sombreada a la derecha de θ_1 representa $P(\theta > \theta_1 | x)$, mientras que $\bar{\theta}$ indica la media (o moda) posterior.

4. Estimación MAP

4.1. Logaritmo de la posterior

Para encontrar el estimador de Máximo a Posteriori (MAP) conviene trabajar con el logaritmo de la posterior: el logaritmo es una función estrictamente creciente, por lo que no cambia la ubicación del máximo, y transforma el producto (12) en una suma, mucho más fácil de derivar.

$$\ell(\theta | y) = \ln(\text{Post}). \quad (15)$$

Tomando el logaritmo del núcleo (13):

$$\ell(\theta | y) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - a - bx_i)^2 - \frac{a^2 + b^2}{200}. \quad (16)$$

4.2. Condiciones de primer orden

El estimador MAP $(\hat{a}, \hat{b})$ es el punto donde $\ell(\theta | y)$ alcanza su máximo, es decir, donde sus derivadas parciales se anulan.

Derivada respecto de a .

$$\frac{\partial \ell}{\partial a} = \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - a - bx_i) - \frac{a}{100}. \quad (17)$$

Igualando a cero en $(\hat{a}, \hat{b})$:

$$\frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \hat{a} - \hat{b}x_i) - \frac{\hat{a}}{100} = 0. \quad (18)$$

Derivada respecto de b .

$$\frac{\partial \ell}{\partial b} = \frac{1}{\sigma^2} \sum_{i=1}^n x_i(y_i - a - bx_i) - \frac{b}{100}. \quad (19)$$

Igualando a cero:

$$\frac{1}{\sigma^2} \sum_{i=1}^n x_i(y_i - \hat{a} - \hat{b}x_i) - \frac{\hat{b}}{100} = 0. \quad (20)$$

Nota. El factor $1/100$ que aparece en (18) y (20) proviene de derivar el término de la previa, $-\frac{a^2 + b^2}{200}$: como $\frac{\partial}{\partial a} \left(-\frac{a^2}{200} \right) = -\frac{2a}{200} = -\frac{a}{100}$ (y análogamente para b), el 2 del numerador se cancela con el 2 del denominador 200, dejando $1/100$.

4.3. Sistema lineal y forma matricial

Las ecuaciones (18) y (20) son **lineales** en $\hat{a}$ y $\hat{b}$. Multiplicando ambas por σ^2 , distribuyendo las sumatorias y agrupando los términos en $\hat{a}$ y $\hat{b}$ a la izquierda:

De (18):

$$\left(n + \frac{\sigma^2}{100} \right) \hat{a} + \left(\sum_i x_i \right) \hat{b} = \sum_i y_i. \quad (21)$$

De (20):

$$\left(\sum_i x_i \right) \hat{a} + \left(\sum_i x_i^2 + \frac{\sigma^2}{100} \right) \hat{b} = \sum_i x_i y_i. \quad (22)$$

Este sistema de dos ecuaciones lineales en $(\hat{a}, \hat{b})$ se escribe en forma matricial $M\vec{\theta} = \vec{Z}$ como

$$\underbrace{\begin{bmatrix} n + \frac{\sigma^2}{100} & \sum_i x_i \\ \sum_i x_i & \sum_i x_i^2 + \frac{\sigma^2}{100} \end{bmatrix}}_M \underbrace{\begin{bmatrix} \hat{a} \\ \hat{b} \end{bmatrix}}_{\vec{\theta}} = \underbrace{\begin{bmatrix} \sum_i y_i \\ \sum_i x_i y_i \end{bmatrix}}_{\vec{Z}}. \quad (23)$$

Nota (Interpretación: regularización tipo *ridge*). Si en (23) se ignoraran los términos $\sigma^2/100$ (lo que equivaldría a $\sigma_a, \sigma_b \rightarrow \infty$, es decir, una previa totalmente plana), la matriz M se reduciría a la matriz normal $X^\top X$ de mínimos cuadrados ordinarios, y $\vec{Z}$ sería $X^\top y$. Los términos $\sigma^2/100$ añaden una penalización a valores grandes de a y b —exactamente el mecanismo de la regresión *ridge*— con parámetro de regularización efectivo $\lambda = \sigma^2/100$.

5. Solución computacional del sistema

El sistema (23) puede resolverse en Python de manera **numérica** (con NumPy) o **simbólica** (con SymPy).

5.1. Solución numérica con NumPy

```
1 import numpy as np
2
3 sigma = 0.3
4
5 # n, sum_x, sum_x2, sum_y, sum_xy: estadísticos calculados a partir de
   los datos
6 M = np.array([
7     [n + sigma**2 / 100,          sum_x],
8     [sum_x,                      sum_x2 + sigma**2 / 100]
9 ])
10 Z = np.array([sum_y, sum_xy])
11
12 a_map, b_map = np.linalg.solve(M, Z)
```

5.2. Solución simbólica con SymPy

```
1 import sympy as sp
2
3 a, b = sp.symbols('a b')
4 n, sigma = sp.symbols('n sigma', positive=True)
5 sum_x, sum_x2, sum_y, sum_xy = sp.symbols('sum_x sum_x2 sum_y sum_xy')
6
7 eq1 = sp.Eq((n + sigma**2/100) * a + sum_x * b, sum_y)
8 eq2 = sp.Eq(sum_x * a + (sum_x2 + sigma**2/100) * b, sum_xy)
9
10 solucion = sp.solve([eq1, eq2], [a, b])
11 a_map_expr = solucion[a]
12 b_map_expr = solucion[b]
```

Nota. La ventaja de resolver el sistema simbólicamente es obtener $\hat{a}$ y $\hat{b}$ como expresiones en función de $n, \sigma, \sum x_i, \sum x_i^2, \sum y_i$ y $\sum x_i y_i$. Esto permite, por ejemplo, verificar que en el límite $\sigma_a, \sigma_b \rightarrow \infty$ (previa "plana") se recupera el estimador de mínimos cuadrados ordinarios.

6. La posterior completa: conexión con la normal bivariada

Hasta ahora se obtuvo únicamente el punto $(\hat{a}, \hat{b})$ que maximiza la posterior (su *moda*, o MAP). Sin embargo, la expresión (13) permite caracterizar **toda** la distribución posterior de (a, b) , no solo su moda.

6.1. Forma general de la normal bivariada

La densidad normal bivariada tiene un núcleo de la forma (ver, por ejemplo, Devore, capítulo de distribuciones conjuntas continuas):

$$f(x, y) \propto \exp\left(-\frac{1}{2}\left(Ax^2 + 2Bxy + Cy^2 - 2Dx - 2Ey + F\right)\right). \quad (24)$$

6.2. Identificación de los coeficientes

Expandiendo el cuadrado en (13):

$$\sum_i (y_i - a - bx_i)^2 = \sum_i y_i^2 - 2a \sum_i y_i - 2b \sum_i x_i y_i + n a^2 + 2ab \sum_i x_i + b^2 \sum_i x_i^2, \quad (25)$$

y sustituyendo en (13), agrupando los términos en a^2 , ab , b^2 , a , b y las constantes, el exponente de la posterior toma la forma (24) con $(x, y) \rightarrow (a, b)$ y

$$A = \frac{n}{\sigma^2} + \frac{1}{100}, \quad (26)$$

$$B = \frac{\sum_i x_i}{\sigma^2}, \quad (27)$$

$$C = \frac{\sum_i x_i^2}{\sigma^2} + \frac{1}{100}, \quad (28)$$

$$D = \frac{\sum_i y_i}{\sigma^2}, \quad (29)$$

$$E = \frac{\sum_i x_i y_i}{\sigma^2}. \quad (30)$$

Nota. Comparando (26)–(28) con la matriz M de (23), se observa que

$$M = \sigma^2 \begin{bmatrix} A & B \\ B & C \end{bmatrix},$$

es decir, el sistema $M\vec{\theta} = \vec{Z}$ es simplemente el sistema $\begin{bmatrix} A & B \\ B & C \end{bmatrix} \vec{\theta} = \begin{bmatrix} D \\ E \end{bmatrix}$ multiplicado por σ^2 en ambos lados (lo cual no altera la solución).

6.3. Matriz de precisión y matriz de covarianza posterior

En la forma (24), la matriz de coeficientes cuadráticos es la **matriz de precisión** (la inversa de la matriz de covarianza) de la distribución:

$$\Sigma^{-1} = \begin{bmatrix} A & B \\ B & C \end{bmatrix}. \quad (31)$$

Invirtiendo esta matriz 2×2 se obtiene la **matriz de covarianza** de la posterior:

$$\Sigma = \frac{1}{AC - B^2} \begin{bmatrix} C & -B \\ -B & A \end{bmatrix}, \quad (32)$$

con A , B y C dados por (26)–(28).

Nota (Resultado principal). Como tanto la verosimilitud (6) como la previa (10) son gaussianas, la posterior también lo es: este es un caso de **previa conjugada normal-normal**.

$$(a, b) | y \sim \mathcal{N}_2((\hat{a}, \hat{b}), \Sigma), \quad (33)$$

donde $(\hat{a}, \hat{b})$ es la solución de (23) (para una distribución normal la media y la moda coinciden) y Σ es la matriz (32). Esto permite no solo dar una estimación puntual de (a, b) , sino también cuantificar la incertidumbre asociada a ellos (varianzas σ_a^2, σ_b^2 en la diagonal de Σ y covarianza $\sigma_{\hat{a}\hat{b}}$ fuera de ella), y calcular probabilidades posteriores o regiones de credibilidad para los parámetros.

7. Resumen del procedimiento

1. Especificar el modelo $y_i = a + bx_i + \varepsilon_i$, con $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ y $\sigma = 0,3$.
2. Construir la verosimilitud $L(y \mid M(a, b)) \propto \exp\left[-\frac{1}{2\sigma^2} \sum_i (y_i - a - bx_i)^2\right]$.
3. Especificar la previa $a, b \sim \mathcal{N}(0, 10^2)$ independientes, con núcleo $f(a, b) \propto \exp\left[-\frac{a^2+b^2}{200}\right]$.
4. Multiplicar verosimilitud por previa para obtener el núcleo de la posterior, dado en la ecuación (13).
5. Tomar logaritmo y derivar respecto de a y b para hallar el MAP, resolviendo el sistema lineal $M\vec{\theta} = \vec{Z}$ de (23).
6. Reconocer que la posterior es normal bivariada, con matriz de precisión (31) y matriz de covarianza (32).
7. Usar la distribución posterior completa para describir la incertidumbre de los parámetros y construir intervalos o regiones de credibilidad.