

Universidad de Antioquia

Facultad de Ciencias Exactas y Naturales

Instituto de Física

Astroestadística

Daniel Soto Villada

Estudiante del pregrado de astronomía

2 de agosto de 2026

Índice general

1. Clase 1	1
1.1. Espacios Muestrales	1
1.1.1. Ejemplo 1: Clasificación Morfológica de Galaxias	1
1.1.2. Ejemplo 2: Espacio Muestral Infinito en el Seguimiento de Cometas	1
1.1.3. Extensión Analítica: Espacios Muestrales Continuos en Coordenadas Celestes	2
1.2. Eventos	2
1.2.1. Ejemplo 1: Clasificación Taxonómica de Asteroides	3
1.2.2. Ejemplo 2: Modelado Gravitacional en Operaciones de Proximidad	4
1.3. Probabilidad	6
1.4. Axiomas de probabilidad	6
1.4.1. Propiedades Fundamentales Derivadas de los Axiomas	7
1.4.2. Ejemplo 1: Demostración de la Probabilidad del Evento Nulo	8
1.4.3. Ejemplo 2: Clasificación de Señales en Astronomía de Ondas Gravitacionales	8
1.4.4. Ejemplo 3: Análisis de Modos de Falla en un Rover de Exploración	9
2. Clase 2	12
2.1. Probabilidad condicional	12
2.1.1. Ejemplo 1: Caracterización de Asteroides mediante Albedo Radar	12
2.1.2. Ejemplo 2: Regla de Multiplicación en Pipelines de Transitorios Astrofísicos	13
2.2. Independencia de eventos	14
2.2.1. Ejemplo 1: Confiabilidad de Subsistemas Críticos en una Sonda Interplanetaria	14
2.2.2. Ejemplo 2: Discriminación de Señales en la Red de Interferómetros de Ondas Gravitacionales	15
2.3. Teorema de Bayes	16
2.3.1. Ejemplo 1: Demostración del Teorema de Actualización Secuencial	17
2.3.2. Ejemplo 2: Clasificación Mineralógica mediante Espectroscopia de Reflexión	18
2.3.3. Ejemplo 3: Aislamiento de Fallas en el Sistema de Control de Actitud	19
2.3.4. Ejemplo 4: Clasificación Orbital de Cometas (Parabólico vs. Hiperbólico)	20
3. Clase 3	22
3.1. Conteos	22
3.1.1. Ejemplo 1: Configuración de Carga Útil en una Sonda Espacial	22
3.1.2. Ejemplo 2: Matriz de Observación Fotométrica en un Telescopio Robótico	23
3.2. Permutaciones	24
3.2.1. Ejemplo 1: Secuencia de Apuntamiento en un Telescopio Espacial	24
3.2.2. Ejemplo 2: Secuencia de Análisis en un Espectrómetro de Masas Planetario	25
3.3. Combinaciones	25
3.3.1. Ejemplo 1: Selección de Sitios de Aterrizaje en Ciencia Planetaria	26
3.3.2. Ejemplo 2: Configuración de Sub-arrays en Radio Interferometría	27
4. Clase 4	28
4.1. Variables aleatorias	28

4.1.1.	Ejemplo 1: Variable Aleatoria Discreta en la Adquisición de Estrellas Guía .	28
4.1.2.	Ejemplo 2: Variable Aleatoria Continua en la Espectroscopia de Velocidad Radial	29
4.2.	Funciones de densidad de probabilidad	30
4.2.1.	Ejemplo 1: Tiempo de Permanencia de un Cometa en el Sistema Solar Interior	30
4.2.2.	Ejemplo 2: Error de Apuntamiento de la Antena de Alta Ganancia en una Sonda	31
4.3.	Función de distribución acumulativa	32
4.3.1.	Ejemplo 1: Perfil de Densidad de Polvo en un Disco Protoplanetario	33
4.3.2.	Ejemplo 2: Error Radial en el Elipse de Aterrizaje de un Rover	34
4.4.	Valor esperado	36
4.5.	Varianza	36
4.5.1.	Ejemplo 1: Demostración de la Fórmula Abreviada de la Varianza	37
4.5.2.	Ejemplo 2: Propagación de Error en el Sistema de Magnitudes Fotométricas	37
5.	Clase 5	40
5.1.	Distribución de probabilidad binomial	40
5.1.1.	Ejemplo 1: Demostración de la Moda de la Distribución Binomial	40
5.1.2.	Ejemplo 2: Demostración del k -ésimo momento factorial de la distribución binomial	41
5.1.3.	Ejemplo 3: Momentos de Orden Superior en la Integración de Señales de Radar Planetario	43
5.1.4.	Ejemplo 4: Interferometría de Línea de Base Larga con Enjambre de Nano-satélites	45
6.	Clase 6	47
6.1.	Distribución de Poisson	47
6.2.	Distribuciones continuas	48
6.2.1.	Ejemplo 1: Demostración de la Propiedad de Reproductividad en Procesos de Poisson	48
6.2.2.	Ejemplo 2: Del Conteo de Fotones al Tiempo de Espera y la Función Gamma	49
6.3.	Percentiles	51
6.4.	Distribución normal	51
6.4.1.	Ejemplo 1: Percentiles en la distribución de concentración de isótopos en un núcleo de meteorito	52
6.4.2.	Ejemplo 2: Distribución normal y percentiles en la navegación de una sonda interplanetaria	53
6.4.3.	Ejemplo 3: Control de Calidad Óptica y Razón de Strehl en Telescopios Espaciales	54
7.	Clase 7	57
7.1.	Funciones de varias variables	57
7.2.	Distribuciones de probabilidad conjunta	57
7.3.	Distribuciones marginales	58
7.4.	Combinación de variables aleatorias	58
7.4.1.	Ejemplo 1: Abundancia Mineralógica en una Sección Delgada de Meteorito .	59
7.4.2.	Ejemplo 2: Detección Multi-banda de Tránsitos Exoplanetarios	61

8. Clase 8	64
8.1. Valores esperados en varias variables	64
8.2. Funciones de correlación	64
8.3. Covarianza	65
8.4. Combinación de variables aleatorias	65
8.4.1. Ejemplo 1: Propagación de Errores Correlacionados en Transformaciones de Observación Radar	65
8.4.2. Ejemplo 2: Incertidumbre Conjunta en Perturbaciones No Gravitacionales para Orbitografía de Precisión	67
8.4.3. Ejemplo 3: Espectroscopia de Mezclas Minerales y el Índice de Diferenciación Redox	69
9. Clase 9	72
9.1. Muestras	72
9.2. Estadísticos	72
9.3. Distribución de estadísticos	73
9.4. Teorema central del límite	74
9.5. Estimación puntual: Método de momentos	74
9.5.1. Ejemplo 1: Acumulación de Errores de Navegación y el Significado del Teorema Central del Límite	76
9.5.2. Ejemplo: Estimación de Parámetros de Albedo en Poblaciones de Asteroides mediante el Método de Momentos	78
10. Clase 10	81
10.1. Método de Mínimos Cuadrados	81
10.1.1. Fundamento Matemático y Función de Costo	81
10.1.2. Formulación Matricial y Ecuaciones Normales	81
10.1.3. Extensión a Sistemas No Lineales: Determinación de Órbitas	82
10.1.4. Verificación Computacional	83
10.2. Estimación de Máxima Verosimilitud	83
10.2.1. Equivalencia Formal con la Minimización de χ^2	84
10.2.2. Propiedades Asintóticas y el Principio de Invarianza	85
10.2.3. Ejemplo 1: Estimación de Trayectoria en Descenso Planetario	86
10.2.4. Ejemplo: Estimación de la Pendiente de la Función Inicial de Masas en un Cúmulo Estelar	88
10.2.5. Ejemplo: Estimación de Máxima Verosimilitud en Funciones de Luminosidad con Umbral de Detección Desconocido	91
11. Clase 11	95
11.1. Límite de Cramer-Rao	95
11.1.1. Enunciado del Teorema	95
11.1.2. Eficiencia y Conexión con la Máxima Verosimilitud	96
11.1.3. Implicaciones en Astrodinámica y Navegación Espacial	96
11.1.4. Ejemplo: Límite Fundamental de Precisión en Velocidades Radiales de Exoplanetas	97
11.2. Introducción a los intervalos de confianza	99

12.Clase 12	101
12.1. Intervalos de confianza	101
12.1.1. Formulación general y el método de la cantidad pivotal	101
12.1.2. Interpretación frecuentista	101
12.1.3. Intervalos clásicos para una sola muestra	102
12.1.4. Propiedades de precisión y determinación del tamaño de muestra	103
12.1.5. Ejemplo: Intervalo de Confianza para el Parámetro de una Distribución Uniforme	103
12.1.6. Ejemplo: Determinación de la Distancia a un Cúmulo Globular mediante Variables RR Lyrae	105
12.1.7. Ejemplo: Evaluación de Jitter de Apuntamiento en Telescopios Espaciales . .	108
13.Clase 13	111
13.1. Inferencia Estadística: Introducción	111
13.1.1. Ejemplo: Velocidad de Recesión en un Cúmulo de Galaxias	112
14.Clase 14	113
14.1. Técnicas de prueba de hipótesis de una muestra Parte 1	113
14.1.1. Lógica y estructura de una prueba de hipótesis	113
14.1.2. Errores de Tipo I y Tipo II	113
14.1.3. Pruebas para la media poblacional (Varianza conocida: Prueba Z)	114
14.1.4. Pruebas para la media poblacional (Varianza desconocida: Prueba t)	114
14.1.5. Pruebas para una proporción poblacional	115
14.1.6. El valor P como medida de evidencia	115
14.1.7. Potencia de la prueba y determinación del tamaño de muestra	116
14.1.8. Ejemplo: Manipulación Integral de las Herramientas de Prueba de Hipótesis	116
14.1.9. Ejemplo: Prueba de Hipótesis sobre la Metalicidad de un Flujo Estelar Recién Descubierto	119
15.Clase 15	122
15.1. Técnicas de prueba de hipótesis de una muestra Parte 2	122

Clase 1

1.1. Espacios Muestrales

El espacio muestral de un experimento denotado por S , es el conjunto de todos los posibles resultados de dicho experimento.

Cada resultado individual se denomina *evento simple*. Un *evento compuesto* es cualquier subconjunto del espacio muestral que contenga más de un resultado.

1.1.1. Ejemplo 1: Clasificación Morfológica de Galaxias

Un telescopio espacial apunta hacia un campo profundo del universo y detecta una galaxia previamente no catalogada. El experimento consiste en analizar su perfil de brillo superficial y asignarle una clase morfológica.

El resultado de esta observación debe caer en una de cuatro categorías macroscópicas mutuamente excluyentes:

- E : Galaxia Espiral.
- L : Galaxia Elíptica.
- I : Galaxia Irregular.
- D : Galaxia Lenticular (de disco, sin brazos espirales evidentes).

El espacio muestral S para este experimento es simplemente el conjunto:

$$S = \{E, L, I, D\}$$

1.1.2. Ejemplo 2: Espacio Muestral Infinito en el Seguimiento de Cometas

Los espacios muestrales infinitos son fundamentales cuando modelamos procesos de 'espera' o 'búsqueda' en astronomía. Para determinar la órbita de un cometa recién descubierto, un observatorio necesita obtener imágenes astrométricas de alta calidad (libres de nubes y con un *seeing* atmosférico adecuado) en múltiples noches.

Definamos el experimento como: *Intentar obtener una imagen usable del cometa noche tras noche hasta lograr el primer éxito*. Los resultados básicos para cada noche son:

- E : Noche despejada, imagen exitosa (Éxito).
- F : Noche nublada o con mal *seeing*, imagen descartada (Falla).

A diferencia del ejemplo anterior, aquí no fijamos un número finito de intentos de antemano. El experimento termina en el momento en que se obtiene el primer éxito. Por lo tanto, el espacio muestral S contiene un número infinito de resultados posibles:

$$S = \{E, FE, FFE, FFFE, FFFFE, \dots\}$$

Cada elemento de S representa una secuencia única de noches. Por ejemplo, el resultado $FFFE$ significa que el astrónomo sufrió tres noches consecutivas de mal clima antes de lograr captar el cometa en la cuarta noche.

Podemos construir eventos compuestos para analizar la eficiencia del observatorio. Sea C el evento *lograr la imagen exitosa en un número par de noches*. Analíticamente, este evento se expresa como:

$$C = \{FE, FFFE, FFFFFFE, \dots\}$$

O sea, $C = \{F^{2k-1}E \mid k = 1, 2, 3, \dots\}$.

Este tipo de espacio muestral infinito discreto es la base para modelar distribuciones de probabilidad como la Geométrica, la cual es sumamente útil en la astronomía observacional para calcular el tiempo esperado (o número de noches) que un telescopio debe invertir para caracterizar un objeto transitorio débil, como un cometa de órbita parabólica (Duffett-Smith y Zwart, Sección 62) o un evento de microlente gravitacional.

1.1.3. Extensión Analítica: Espacios Muestrales Continuos en Coordenadas Celestes

Aunque los ejemplos anteriores son discretos, es vital notar que la mayoría de las mediciones astronómicas generan espacios muestrales continuos. Por ejemplo, al calcular las coordenadas ecuatoriales (Ascensión Recta α y Declinación δ) de un planeta exterior como Júpiter (Duffett-Smith y Zwart, Sección 54), el resultado de una medición sujeta a error instrumental no es un punto exacto, sino un vector continuo.

Si definimos el experimento como *medir la posición aparente de un astro*, el espacio muestral es un subconjunto de $\mathbb{R}^2$:

$$S = \{(\alpha, \delta) \in \mathbb{R}^2 \mid 0 \leq \alpha < 24^h, -90^\circ \leq \delta \leq 90^\circ\}$$

En este escenario continuo, la probabilidad de obtener un resultado exacto (un evento simple) es estrictamente cero. Los eventos de interés (como que el planeta esté en una región específica de la eclíptica para estudiar sus perturbaciones orbitales) se definen como regiones o áreas dentro de este espacio muestral continuo, requiriendo el uso de funciones de densidad de probabilidad y cálculo integral para su evaluación.

1.2. Eventos

Un evento es cualquier recopilación o subconjunto de resultados contenidos en el espacio muestral S .

Si un evento consiste en exactamente un resultado, se denomina *evento simple*; si consiste en más de un resultado, se denomina *evento compuesto*. Dado que un evento es simplemente un conjunto, las

operaciones y resultados de la teoría elemental de conjuntos se utilizan para estudiar las relaciones entre ellos. Las operaciones primarias incluyen:

- **Unión** ($A \cup B$): El evento que consiste en todos los resultados que están en A , en B , o en ambos.
- **Intersección** ($A \cap B$): El evento que consiste en todos los resultados que están tanto en A como en B .
- **Complemento** (A'): El conjunto de todos los resultados en S que no están en A .
- **Eventos mutuamente excluyentes (disjuntos)**: Dos eventos son mutuamente excluyentes si no tienen resultados en común (es decir, $A \cap B = \emptyset$).

La correcta formulación de eventos permite traducir preguntas físicas o astronómicas complejas a lenguaje matemático riguroso, sentando las bases para el cálculo de probabilidades y la inferencia estadística.

1.2.1. Ejemplo 1: Clasificación Taxonómica de Asteroides

Un sondeo astronómico detecta dos asteroides cercanos a la Tierra. Basado en sus espectros de reflexión, cada asteroide se clasifica en uno de tres complejos taxonómicos principales:

- C : Complejo-C (Carbonáceos).
- S : Complejo-S (Silicáceos).
- X : Complejo-X (Metálicos).

El experimento consiste en registrar la clasificación del par de asteroides. El espacio muestral S está compuesto por $3^2 = 9$ eventos simples, representados como pares ordenados:

$$S = \{CC, CS, CX, SC, SS, SX, XC, XS, XX\}$$

A partir de este espacio muestral, podemos definir eventos compuestos que representen escenarios de interés para la ciencia planetaria y la defensa planetaria:

Sea A el evento en el que *ambos asteroides pertenecen al mismo complejo taxonómico*:

$$A = \{CC, SS, XX\}$$

Sea B el evento en el que *al menos uno de los asteroides es de tipo S (silicáceo)*:

$$B = \{CS, SC, SS, SX, XS\}$$

Podemos analizar las operaciones entre estos eventos para extraer conclusiones analíticas:

- **Intersección** ($A \cap B$): El evento en que ambos son del mismo tipo *y* al menos uno es tipo S . Esto solo ocurre si ambos son silicáceos.

$$A \cap B = \{SS\}$$

- **Unión ($A \cup B$):** El evento en que ambos son del mismo tipo o al menos uno es tipo S.

$$A \cup B = \{CC, CS, SC, SS, SX, XS, XX\}$$

- **Complemento (A'):** El evento en que los asteroides *no* son del mismo tipo (población taxonómicamente diversa).

$$A' = \{CS, CX, SC, SX, XC, XS\}$$

Finalmente, para ilustrar la exclusión mutua, definamos el evento D como *exactamente un asteroide es de tipo X y el otro es de tipo C*:

$$D = \{CX, XC\}$$

Los eventos A y D son *mutuamente excluyentes* (o disjuntos), ya que es lógicamente imposible que ambos asteroides sean del mismo tipo (A) y que al mismo tiempo sean de tipos diferentes (D).

$$A \cap D = \emptyset$$

1.2.2. Ejemplo 2: Modelado Gravitacional en Operaciones de Proximidad

Los espacios muestrales y sus eventos también son cruciales en la ingeniería aeroespacial y la navegación de naves autónomas (Capítulo 4, *Modern Spacecraft Guidance, Navigation, and Control*, sección ‘Irregular solar system bodies’).

Cuando una nave espacial (chaser) se aproxima a un asteroide, el campo gravitacional es altamente irregular. Los modelos de Armónicos Esféricos (SHE) son computacionalmente rápidos pero solo son válidos fuera de la ‘esfera de Brillouin’ (la región que engloba todo el cuerpo). Para operar dentro de esta esfera, el sistema de navegación debe cambiar a un modelo de Mascones o Poliedros, el cual es más preciso pero computacionalmente costoso.

Definamos el experimento como: *La nave ejecuta 3 pasadas de aproximación consecutivas. En cada pasada, el sistema de navegación a bordo selecciona el modelo gravitacional a utilizar para el filtro de navegación.* Los resultados básicos para cada pasada son:

- H : Se utiliza el modelo de Armónicos Esféricos (SHE).
- M : Se utiliza el modelo de Mascones.

El espacio muestral S está compuesto por $2^3 = 8$ eventos simples:

$$S = \{HHH, HHM, HMH, MHH, HMM, MHM, MMH, MMM\}$$

Definamos los siguientes eventos compuestos para evaluar la estrategia de navegación:

Sea A el evento en el que *el modelo SHE se utiliza exactamente en dos de las tres pasadas*:

$$A = \{HHM, HMH, MHH\}$$

Sea B el evento en el que *el modelo de Mascones se utiliza en la primera pasada* (lo que indicaría que la nave penetró la esfera de Brillouin de manera temprana o agresiva):

$$B = \{MHH, MHM, MMH, MMM\}$$





Figura 1.1: Representación física de las operaciones de proximidad. La nave realiza pasadas alrededor de un asteroide irregular; fuera de la esfera de Brillouin puede usar Armónicos Esféricos (H), mientras que al entrar en la región cercana debe cambiar a Mascones (M).



Clave: H denota Armónicos Esféricos (SHE) y M denota Mascones. Los colores resaltan los eventos $A = \{HHM, HMH, MHH\}$, $B = \{MHH, MHM, MMH, MMM\}$, $C = \{HHH\}$ y la intersección $A \cap B = \{MHH\}$.

Figura 1.2: Diagrama jerárquico del espacio muestral para tres pasadas de aproximación. Cada rama representa la elección del modelo gravitacional en una pasada y cada hoja corresponde a uno de los ocho eventos simples.

La intersección de estos eventos, $A \cap B$, representa el escenario donde la nave usó Mascones en la primera pasada, pero logró revertir al modelo SHE (más ligero computacionalmente) en las dos siguientes (probablemente porque la trayectoria de aproximación la alejó temporalmente de la esfera de Brillouin):

$$A \cap B = \{MHH\}$$

Por último, consideremos el evento C definido como *el modelo de Mascones nunca es utilizado en las tres pasadas* (la nave se mantuvo estrictamente fuera de la esfera de Brillouin):

$$C = \{HHH\}$$

Los eventos B y C son *mutuamente excluyentes*. Físicamente, la nave no puede haber utilizado el modelo de Mascones en la primera pasada (B) y al mismo tiempo no haberlo utilizado nunca (C). Por lo tanto, $B \cap C = \emptyset$. La modelación de estos eventos como subconjuntos del espacio muestral dota a los ingenieros de GNC de un marco analítico riguroso para cuantificar el riesgo de saturación del ordenador de a bordo (OBC). A través de esta representación, es posible estimar la probabilidad de que la exigencia computacional —derivada de la conmutación entre los distintos modelos de navegación— rebase los umbrales de seguridad del hardware durante las críticas fases de operaciones de proximidad, vinculando directamente esta métrica de riesgo con la geometría de la trayectoria relativa planificada.

1.3. Probabilidad

La probabilidad es la rama de las matemáticas que proporciona un marco riguroso para cuantificar la incertidumbre y el azar en cualquier situación donde pueden ocurrir diversos sucesos. En el contexto de la astronomía y la exploración espacial, la probabilidad es una herramienta fundamental para modelar desde la distribución de materia en el universo hasta la confiabilidad de los sistemas de navegación de una sonda interplanetaria.

La probabilidad asigna a cada evento A un número $P(A)$ que representa una medida precisa de la oportunidad de que A ocurra (Devore, Capítulo 2, Sección 2.2). En la práctica astronómica, esta asignación puede basarse en la interpretación frecuentista (por ejemplo, la tasa de ocurrencia de supernovas en un volumen dado, o la fracción de estrellas que poseen planetas) o en la interpretación geométrica/combinatoria (como la probabilidad de que un exoplaneta esté alineado con nuestra línea de visión).

1.4. Axiomas de probabilidad

Para garantizar que las asignaciones de probabilidad sean matemáticamente consistentes y respeten las nociones intuitivas de la frecuencia y la certeza, la teoría moderna se fundamenta en los Axiomas de Kolmogorov. Estos axiomas establecen las reglas inquebrantables que gobiernan la medida de probabilidad P sobre un espacio muestral S (Devore, Capítulo 2, Sección 2.2):

- **AXIOMA 1:** Para cualquier evento A , $P(A) \geq 0$. (La probabilidad no puede ser negativa).
- **AXIOMA 2:** $P(S) = 1$. (La probabilidad del espacio muestral completo, es decir, de que ocurra algún resultado, es la certeza absoluta).

- **AXIOMA 3:** Si $A_1, A_2, A_3, \dots$ es un conjunto (finito o infinito) de eventos mutuamente excluyentes (disjuntos), entonces la probabilidad de su unión es la suma de sus probabilidades individuales:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

A partir de estos tres axiomas, se pueden derivar rigurosamente todas las demás propiedades y teoremas de la probabilidad, como la probabilidad del complemento o la probabilidad de la unión de eventos no disjuntos.

1.4.1. Propiedades Fundamentales Derivadas de los Axiomas

A partir de los tres axiomas de Kolmogorov, se pueden demostrar rigurosamente las siguientes propiedades (Devore, Capítulo 2, Sección 2.2). Sea S el espacio muestral y $A, B, C \subseteq S$ eventos cualesquiera:

1. **Probabilidad del evento nulo:**

$$P(\emptyset) = 0$$

2. **Cota superior de la probabilidad:** Para todo evento A ,

$$P(A) \leq 1$$

3. **Regla del complemento:**

$$P(A') = 1 - P(A)$$

4. **Monotonicidad:** Si $A \subseteq B$, entonces

$$P(A) \leq P(B)$$

5. **Regla de adición para dos eventos:**

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

6. **Regla de adición para tres eventos (Principio de Inclusión-Exclusión):**

$$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) - P(B \cap C) + P(A \cap B \cap C)$$

7. **Desigualdad de Boole (cota de la unión):** Para cualesquiera eventos $A_1, A_2, \dots, A_n$,

$$P\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n P(A_i)$$

8. **Leyes de De Morgan aplicadas a la probabilidad:**

$$P((A \cup B)') = P(A' \cap B')$$

$$P((A \cap B)') = P(A' \cup B')$$

1.4.2. Ejemplo 1: Demostración de la Probabilidad del Evento Nulo

Consideremos una sucesión infinita de eventos donde cada evento es el conjunto vacío:

$$A_1 = \emptyset, \quad A_2 = \emptyset, \quad A_3 = \emptyset, \quad \dots$$

Primero, notamos que estos eventos son mutuamente excluyentes, ya que la intersección de cualquier par de ellos es el conjunto vacío ($A_i \cap A_j = \emptyset \cap \emptyset = \emptyset$).

Segundo, la unión de todos estos eventos es simplemente el conjunto vacío:

$$\bigcup_{i=1}^{\infty} A_i = \emptyset$$

Aplicando el **Axioma 3** (aditividad para eventos mutuamente excluyentes), tenemos:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

Sustituyendo la unión y los eventos individuales por $\emptyset$, la ecuación se convierte en:

$$P(\emptyset) = \sum_{i=1}^{\infty} P(\emptyset) = P(\emptyset) + P(\emptyset) + P(\emptyset) + \dots$$

Por el **Axioma 1**, sabemos que $P(\emptyset) \geq 0$, y por el **Axioma 2**, sabemos que cualquier probabilidad debe ser un número finito (acotado superiormente por 1). La única forma en que una suma infinita de un mismo valor no negativo converge a un número finito es si dicho valor es estrictamente cero. Si $P(\emptyset)$ fuera mayor que 0, la suma divergiría al infinito, violando la definición de probabilidad.

Por lo tanto, concluimos que:

$$P(\emptyset) = 0$$

1.4.3. Ejemplo 2: Clasificación de Señales en Astronomía de Ondas Gravitacionales

En el campo emergente de la astronomía de ondas gravitacionales, los interferómetros como LIGO y Virgo detectan continuamente candidatos a señales transitorias. Históricamente, tras años de ciclos de observación, la colaboración científica ha catalogado la naturaleza de estos eventos. Definamos el espacio muestral S para la clasificación de un nuevo candidato a señal como:

- A : Fusión de agujeros negros binarios (BBH).
- B : Fusión de estrellas de neutrones binarias (BNS).
- C : Artefacto instrumental o ruido sísmico (falso positivo).

Estos tres eventos son mutuamente excluyentes y exhaustivos. Basándonos en la frecuencia relativa histórica de los catálogos de eventos (como los catálogos GWTC de la colaboración LIGO-Virgo-KAGRA), podemos asignar las siguientes probabilidades a priori para un candidato genérico no validado:

$$P(A) = 0,78, \quad P(B) = 0,07, \quad P(C) = 0,15$$




Figura 1.3: Representación visual del experimento de clasificación de una señal candidata de ondas gravitacionales. La red de interferómetros produce una alerta, y el candidato se asigna a una de tres clases mutuamente excluyentes: fusión de agujeros negros binarios (A), fusión de estrellas de neutrones binarias (B) o artefacto instrumental (C).

Supongamos que el sistema de alerta temprana dispara una notificación para un nuevo evento candidato. Nos interesa calcular la probabilidad de que esta señal corresponda a una coalescencia binaria compacta genuina de origen astrofísico. Definamos este evento compuesto como $E = A \cup B$.

Dado que los eventos A y B son mutuamente excluyentes (un evento no puede ser simultáneamente una fusión de agujeros negros y de estrellas de neutrones), la probabilidad de su unión es simplemente la suma de sus probabilidades individuales:

$$P(E) = P(A) + P(B) = 0,78 + 0,07 = 0,85$$

Alternativamente, este mismo resultado puede obtenerse de manera más directa utilizando la regla del complemento. El evento de que la señal sea una coalescencia genuina (E) es exactamente el complemento del evento de que sea un artefacto instrumental (C). Por lo tanto:

$$P(E) = 1 - P(C) = 1 - 0,15 = 0,85$$

Estas asignaciones probabilísticas son críticas para los algoritmos de filtrado que procesan las alertas en tiempo real, priorizando aquellas candidatas con una probabilidad de ser astrofísicas ($P(E)$) lo suficientemente alta como para activar telescopios de seguimiento electromagnético en todo el mundo.

1.4.4. Ejemplo 3: Análisis de Modos de Falla en un Rover de Exploración

Los axiomas de probabilidad son la base para evaluar la confiabilidad de sistemas críticos en la ingeniería aeroespacial. Tomemos como referencia los análisis de modos de falla y efectos críticos (FMECA) utilizados en la operación de rovers en superficies planetarias (*Modern Spacecraft Guidance, Navigation, and Control*, y *Planetary Geology*).

Considere el mecanismo de perforación y muestreo de un rover marciano. Durante un ciclo operativo de 1 hora, el sistema puede experimentar uno de tres modos de falla críticos. Definimos los eventos mutuamente excluyentes (ya que el diagnóstico del sistema identifica la causa raíz primaria de manera única):

- A : Atasco mecánico del motor del taladro.
- B : Sobrecarga térmica en la electrónica de control.
- C : Pérdida de sincronización en el bus de comunicación.

Basado en datos históricos de pruebas en cámaras de vacío térmico, se han asignado las siguientes probabilidades para un ciclo operativo dado:

$$P(A) = 0,04, \quad P(B) = 0,03, \quad P(C) = 0,01$$




Figura 1.4: Escena conceptual de un ciclo de perforación de un rover marciano. La barra superior resume la confiabilidad del ciclo: la mayor parte corresponde al evento complementario F' (operación nominal), mientras que el segmento rojo agrupa los modos de falla A , B y C .

Sea F el evento compuesto definido como *que ocurra cualquier tipo de falla durante el ciclo*. Matemáticamente, F es la unión de los tres eventos:

$$F = A \cup B \cup C$$

Dado que A , B y C son mutuamente excluyentes, podemos aplicar directamente el **Axioma 3** para calcular la probabilidad de falla total del sistema:

$$P(F) = P(A) + P(B) + P(C) = 0,04 + 0,03 + 0,01 = 0,08$$

El evento de interés para la misión es que el rover complete el ciclo de perforación *sin fallas*, lo cual corresponde al evento complemento F' . Utilizando la propiedad derivada de los Axiomas 2 y 3 (donde $P(F) + P(F') = 1$), calculamos la probabilidad de éxito:

$$P(F') = 1 - P(F) = 1 - 0,08 = 0,92$$

Este cálculo indica que el rover tiene un 92 % de confiabilidad por ciclo. Los ingenieros de vuelo utilizan este valor para propagar la incertidumbre a través de la planificación de la misión, determinando cuántos ciclos redundantes deben programarse para asegurar que la probabilidad acumulada de obtener al menos una muestra geológica supere el umbral requerido para los objetivos científicos de la misión.

Clase 2

2.1. Probabilidad condicional

En la práctica astronómica y astrofísica, rara vez se evalúan los eventos de manera aislada. Frecuentemente, se dispone de información parcial o de observaciones preliminares que restringen el universo de posibilidades. La probabilidad condicional es la herramienta analítica que permite cuantificar cómo cambia la probabilidad de un evento cuando se tiene la certeza de que otro evento relacionado ya ha ocurrido.

Si A y B son dos eventos tales que $P(B) > 0$, la probabilidad condicional de A dado que B ha ocurrido se define como:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Conceptualmente, esta definición refleja un cambio fundamental en el espacio muestral. El nuevo espacio muestral ya no es el conjunto original S , sino que se reduce exclusivamente al evento B (el evento condicionante). La probabilidad $P(A|B)$ mide la fracción de B que también pertenece a A .

A partir de esta definición, se deriva una de las herramientas más poderosas para el modelado de procesos observacionales secuenciales: la **regla de multiplicación**. Si reordenamos la ecuación anterior, obtenemos la probabilidad de la intersección de dos eventos:

$$P(A \cap B) = P(A|B) \cdot P(B)$$

Esta regla es esencial para calcular la probabilidad de que ocurran múltiples etapas en un proceso de observación o navegación, donde el éxito de una etapa depende condicionalmente del resultado de la etapa previa.

2.1.1. Ejemplo 1: Caracterización de Asteroides mediante Albedo Radar

Un radiotelescopio realiza un sondeo de 200 Asteroides Cercanos a la Tierra (NEAs) para estudiar su composición superficial.

Definimos los siguientes eventos para un asteroide seleccionado al azar de esta muestra:

- M : El asteroide es de tipo espectral M (metálico, compuesto principalmente de hierro y níquel).
- R : El asteroide presenta una alta reflectividad (albedo) en las observaciones de radar.

Tras procesar los datos del sondeo, se obtienen las siguientes frecuencias conjuntas:

- 40 asteroides son de tipo M: $P(M) = 40/200 = 0,20$.
- 60 asteroides tienen alta reflectividad radar: $P(R) = 60/200 = 0,30$.

- 30 asteroides son de tipo M y además tienen alta reflectividad radar: $P(M \cap R) = 30/200 = 0,15$.

Pregunta 1: Si el sistema de radar detecta que un asteroide tiene alta reflectividad (R), ¿cuál es la probabilidad de que sea metálico (M)?

$$P(M|R) = \frac{P(M \cap R)}{P(R)} = \frac{0,15}{0,30} = 0,50$$

Esto significa que, dado que el asteroide brilla intensamente en el radar, hay un 50 % de probabilidad de que su composición sea metálica. El espacio muestral se ha reducido a los 60 asteroides con alta reflectividad.

Pregunta 2: Si un asteroide ya ha sido clasificado espectroscópicamente como de tipo M (M), ¿cuál es la probabilidad de que presente alta reflectividad radar (R)?

$$P(R|M) = \frac{P(M \cap R)}{P(M)} = \frac{0,15}{0,20} = 0,75$$

Aquí, el espacio muestral se reduce a los 40 asteroides metálicos. La probabilidad es notablemente distinta (75 %). Este ejemplo resalta una de las advertencias más importantes en la inferencia estadística: la probabilidad de que un asteroide sea metálico dado su radar ($P(M|R)$) no es la misma que la probabilidad de que tenga alto radar dado que es metálico ($P(R|M)$).

$$P(M|R) \neq P(R|M)$$

2.1.2. Ejemplo 2: Regla de Multiplicación en Pipelines de Transitorios Astrofísicos

La regla de multiplicación es indispensable para modelar cadenas de eventos dependientes. En la astronomía de grandes sondeos temporales (como los realizados por el Observatorio Vera C. Rubin), los "pipelines" de reducción de datos deben filtrar miles de alertas nocturnas. Analicemos la detección de transitorios.

Definimos el experimento como el procesamiento de una alerta nocturna por parte del pipeline automatizado.

- V : El evento astrofísico es *verdadero* y genuino (ej. una kilonova o supernova real).
- V' : El evento es un *artefacto* instrumental o ruido cósmico (falso astrofísico).
- F : El pipeline de software etiqueta la alerta como 'Candidato de Alta Prioridad' (Flag).

Basado en el rendimiento histórico del telescopio y la naturaleza de los falsos positivos, sabemos que:

- La probabilidad a priori de que una alerta aleatoria sea un evento genuino es baja: $P(V) = 0,10$. Por lo tanto, $P(V') = 1 - 0,10 = 0,90$.
- Si el evento es genuino (V), el pipeline es muy eficiente detectándolo: $P(F|V) = 0,90$.
- Si el evento es un artefacto (V'), el pipeline aún puede ser engañado y etiquetarlo erróneamente como candidato (tasa de falsos positivos): $P(F|V') = 0,15$.

Escenario 1: Detección Exitosa (Verdadero Positivo) ¿Cuál es la probabilidad de que una alerta sea un evento genuino y que el pipeline la etiquete correctamente como candidato?

$$P(V \cap F) = P(F|V) \cdot P(V) = 0,90 \cdot 0,10 = 0,09$$

Esto indica que el 9% de todas las alertas procesadas serán descubrimientos científicos reales y confirmados por el software.

Escenario 2: Falso Positivo ¿Cuál es la probabilidad de que una alerta sea un artefacto y que el pipeline la etiquete erróneamente como candidato?

$$P(V' \cap F) = P(F|V') \cdot P(V') = 0,15 \cdot 0,90 = 0,135$$

Esto revela que el 13.5% de todas las alertas procesadas serán falsos positivos que consumirán tiempo valioso de seguimiento telescópico.

Este análisis condicional y multiplicativo permite a los arquitectos de misiones evaluar el 'costo' de falsas alarmas frente a la tasa de descubrimientos reales, justificando analíticamente la necesidad de introducir filtros secundarios (como la verificación de movimiento propio o el análisis de la forma del punto, PSF) antes de enviar alertas a la comunidad astronómica global.

2.2. Independencia de eventos

Dos eventos A y B se consideran independientes si la ocurrencia de uno de ellos no proporciona ninguna información sobre la ocurrencia del otro.

Analíticamente, esta noción se formaliza a través de la probabilidad condicional. Si A y B son independientes, entonces la probabilidad de A dado que B ha ocurrido es simplemente la probabilidad marginal de A :

$$P(A|B) = P(A)$$

Sustituyendo la definición de probabilidad condicional $P(A|B) = \frac{P(A \cap B)}{P(B)}$ en la ecuación anterior y reordenando, obtenemos la **regla de multiplicación para eventos independientes**, que es la definición operativa más utilizada en la práctica:

$$P(A \cap B) = P(A) \cdot P(B)$$

Es crucial destacar una distinción analítica fundamental: la independencia y la exclusión mutua son conceptos radicalmente distintos. Si dos eventos son mutuamente excluyentes ($A \cap B = \emptyset$), saber que A ocurrió garantiza que B no ocurrió ($P(B|A) = 0$), lo cual implica una dependencia extrema. Por el contrario, si son independientes, la ocurrencia de A no altera en absoluto la probabilidad de B .

2.2.1. Ejemplo 1: Confiabilidad de Subsistemas Críticos en una Sonda Interplanetaria

Modern Spacecraft Guidance, Navigation, and Control (Capítulo 4, "Fault Detection and Isolation").

Considere una sonda espacial que viaja hacia los planetas exteriores. Para mantener su actitud y orientación, la nave depende de dos subsistemas físicamente separados y eléctricamente aislados:

- A : El evento en el que el rastreador de estrellas principal (Star Tracker) sufre un bloqueo temporal por radiación cósmica.
- B : El evento en el que la unidad de medición inercial (IMU) experimenta una deriva térmica fuera de los límites de tolerancia.

Basado en los datos de pruebas en tierra y modelos de entorno espacial, se han estimado las siguientes probabilidades marginales para una ventana de misión de 30 días:

$$P(A) = 0,04$$

$$P(B) = 0,02$$

Dado que el rastreador de estrellas (óptico) y la IMU (mecánico-inercial) operan bajo principios físicos distintos y están blindados contra fallas en cascada, el modelo de confiabilidad asume que estos eventos son *mutuamente independientes*.

Podemos calcular la probabilidad de que la sonda experimente una pérdida total de referencia de actitud (el evento $A \cap B$, donde ambos sensores fallan simultáneamente) aplicando la regla de multiplicación para eventos independientes:

$$P(A \cap B) = P(A) \cdot P(B) = 0,04 \cdot 0,02 = 0,0008$$

Si hubiéramos asumido erróneamente que los eventos eran dependientes (por ejemplo, si una tormenta de radiación afectara a ambos por igual), la probabilidad de falla catastrófica sería mucho mayor. La independencia analítica permite a los ingenieros de vuelo demostrar que la probabilidad de pérdida de control (0,08 %) cumple con los estrictos requisitos de riesgo de la misión. Además, se puede verificar que $P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{0,0008}{0,02} = 0,04 = P(A)$, confirmando que la falla de la IMU no altera la probabilidad de fallo del rastreador de estrellas.

2.2.2. Ejemplo 2: Discriminación de Señales en la Red de Interferómetros de Ondas Gravitacionales

En la astronomía de multi-mensajeros y la astrofísica de altas energías, la independencia es la piedra angular para distinguir señales astrofísicas genuinas de ruido instrumental local. Tomemos como referencia los principios de detección de señales y análisis de ruido en redes de observatorios (*Astronomical Measurement*, Capítulo 6, "Signal-to-Noise and Detection").

Considere la red de interferómetros láser (como LIGO), compuesta por detectores separados geográficamente miles de kilómetros. Definimos los siguientes eventos para un intervalo de tiempo de 1 milisegundo:

- N_1 : El detector 1 (ej. Hanford) registra un transitorio de ruido sísmico/instrumental que supera el umbral de activación.
- N_2 : El detector 2 (ej. Livingston) registra un transitorio de ruido que supera el umbral.
- W : El paso de una onda gravitacional real proveniente de una fusión de agujeros negros.

Las fuentes de ruido local (microsismos, ruido térmico en los espejos, fluctuaciones láser) en el detector 1 son físicamente independientes de las del detector 2. Por lo tanto, los eventos de ruido

N_1 y N_2 son *independientes*. Si la tasa de falsas alarmas (ruido superando el umbral) en cada detector es $P(N_1) = 10^{-3}$ y $P(N_2) = 10^{-3}$, la probabilidad de que *ambos* detectores registren un falso positivo simultáneamente por puro azar es:

$$P(N_1 \cap N_2) = P(N_1) \cdot P(N_2) = 10^{-3} \cdot 10^{-3} = 10^{-6}$$

Esta drástica reducción en la probabilidad de error (de 10^{-3} a 10^{-6}) es la base de la *coincidencia de red*.

Sin embargo, analicemos qué ocurre si el evento W (una onda gravitacional real) ocurre. Una onda gravitacional real afecta el espacio-tiempo local en ambos detectores casi simultáneamente. En este escenario, los eventos de 'detección de un umbral cruzado' en el detector 1 y el detector 2 **ya no son independientes**. La ocurrencia de la señal real condiciona fuertemente a ambos detectores:

$$P(\text{Umbral}_1 \cap \text{Umbral}_2 | W) \neq P(\text{Umbral}_1 | W) \cdot P(\text{Umbral}_2 | W)$$

De hecho, si W ocurre, la probabilidad de que ambos detectores se activen es cercana a 1 (dependiendo de la polarización y ubicación de la fuente), mientras que el producto de sus probabilidades marginales condicionadas a W no reflejaría esta correlación física. Este contraste analítico entre la independencia del ruido local ($N_1 \perp N_2$) y la dependencia inducida por una señal astrofísica común (W) es el mecanismo estadístico fundamental que permite a los astrónomos confirmar el descubrimiento de nuevos fenómenos cósmicos, filtrando el ruido instrumental aleatorio de las verdaderas perturbaciones del universo.

2.3. Teorema de Bayes

El Teorema de Bayes constituye la piedra angular del razonamiento estadístico inverso. Mientras que la probabilidad condicional tradicional nos permite calcular la probabilidad de una observación (efecto) dado un estado físico conocido (causa), el Teorema de Bayes invierte esta lógica: nos permite actualizar la probabilidad de una causa hipotética a la luz de una nueva evidencia observacional.

Si $A_1, A_2, \dots, A_k$ son eventos mutuamente excluyentes y exhaustivos (una partición del espacio muestral S), y B es cualquier evento con $P(B) > 0$, la probabilidad posterior de A_i dado B se calcula mediante (Devore, Capítulo 2, Sección 2.4):

$$P(A_i | B) = \frac{P(B | A_i) P(A_i)}{\sum_{j=1}^k P(B | A_j) P(A_j)}$$

En esta formulación analítica, $P(A_i)$ se denomina *probabilidad a priori*, representando nuestro conocimiento o creencia sobre el estado del sistema antes de realizar la observación B . El término $P(B | A_i)$ es la *verosimilitud* (likelihood), que cuantifica la probabilidad de observar la evidencia B asumiendo que la hipótesis A_i es verdadera. El denominador, calculado mediante la Ley de Probabilidad Total, actúa como una constante de normalización. El resultado, $P(A_i | B)$, es la *probabilidad a posteriori*.

En la astronomía moderna, este marco es fundamental. Como se discute en *Astronomical Measurement* (Apéndice A.12.1, *Prior and Posterior Probability Distributions*), el enfoque bayesiano

permite a los astrofísicos combinar conocimientos teóricos previos (como modelos de formación planetaria) con datos observacionales ruidosos (como fotones detectados en un CCD) para refinar rigurosamente los parámetros del universo.

2.3.1. Ejemplo 1: Demostración del Teorema de Actualización Secuencial

En la astronomía observacional y la exploración espacial, los datos rara vez llegan en un solo lote; las observaciones son secuenciales. Un telescopio toma una imagen, luego otra, y cada nueva medición debería refinar nuestro conocimiento del sistema. El Teorema de Bayes posee una propiedad matemática profunda y elegante que justifica este proceso: la *Actualización Secuencial*.

A continuación, demostraremos un teorema fundamental que establece que actualizar una hipótesis H con un primer conjunto de datos D_1 y utilizar el resultado como la nueva probabilidad a priori para un segundo conjunto de datos D_2 , es matemáticamente idéntico a actualizar la hipótesis original con ambos conjuntos de datos $D_1 \cap D_2$ simultáneamente.

Teorema de Actualización Secuencial: Sean H una hipótesis, y D_1, D_2 dos conjuntos de datos observacionales. La probabilidad posterior de H dado ambos conjuntos de datos satisface:

$$P(H|D_1 \cap D_2) = \frac{P(D_2|H \cap D_1)P(H|D_1)}{P(D_2|D_1)}$$

Demostración: La probabilidad de H dado que han ocurrido tanto D_1 como D_2 es:

$$P(H|D_1 \cap D_2) = \frac{P(H \cap D_1 \cap D_2)}{P(D_1 \cap D_2)}$$

Para el numerador, aplicamos la regla de multiplicación para la intersección de tres eventos. Podemos expandir $P(H \cap D_1 \cap D_2)$ condicionando secuencialmente:

$$P(H \cap D_1 \cap D_2) = P(D_2|H \cap D_1) \cdot P(H \cap D_1)$$

A su vez, el término $P(H \cap D_1)$ puede expandirse nuevamente usando la regla de multiplicación:

$$P(H \cap D_1) = P(H|D_1) \cdot P(D_1)$$

Sustituyendo esto en la expresión del numerador, obtenemos:

$$P(H \cap D_1 \cap D_2) = P(D_2|H \cap D_1) \cdot P(H|D_1) \cdot P(D_1)$$

Para el denominador, aplicamos la regla de multiplicación para la intersección de D_1 y D_2 :

$$P(D_1 \cap D_2) = P(D_2|D_1) \cdot P(D_1)$$

Ahora, sustituimos el numerador y el denominador expandidos en la ecuación original de la probabilidad condicional:

$$P(H|D_1 \cap D_2) = \frac{P(D_2|H \cap D_1) \cdot P(H|D_1) \cdot P(D_1)}{P(D_2|D_1) \cdot P(D_1)}$$

Dado que $P(D_1) > 0$ (asumiendo que la primera observación es posible), podemos cancelar $P(D_1)$ en el numerador y el denominador, lo que nos deja con el resultado deseado:

$$P(H|D_1 \cap D_2) = \frac{P(D_2|H \cap D_1)P(H|D_1)}{P(D_2|D_1)}$$

Análisis del resultado: Esta demostración revela que el término $P(H|D_1)$ actúa exactamente como la *nueva probabilidad a priori* para el segundo paso, y $P(D_2|H \cap D_1)$ actúa como la *nueva verosimilitud*. Esto garantiza que el orden en que procesamos las observaciones astronómicas (por ejemplo, medir la posición de un asteroide noche tras noche) no altera el resultado final, siempre que se aplique rigurosamente el Teorema de Bayes.

2.3.2. Ejemplo 2: Clasificación Mineralógica mediante Espectroscopia de Reflexión

Para ilustrar la actualización bayesiana en la ciencia planetaria, nos inspiramos en los principios de identificación mineralógica a través de firmas espectrales (*Planetary Geology*, Capítulo sobre *Spectroscopy and Mineralogy*).

Un rover marciano utiliza su espectrómetro de infrarrojo cercano para analizar un afloramiento rocoso. Basado en el contexto geológico de la cuenca de impacto, el equipo científico establece las siguientes probabilidades a priori para la composición de la roca:

- A_1 : La roca es basáltica (rica en piroxeno). $P(A_1) = 0,20$.
- A_2 : La roca es una condrita carbonácea (rica en arcillas). $P(A_2) = 0,60$.
- A_3 : La roca es metálica (hierro-níquel). $P(A_3) = 0,20$.

El espectrómetro detecta una profunda banda de absorción centrada en $1 \mu\text{m}$, una firma característica de los enlaces Fe-O en el piroxeno. Definimos este evento observacional como B . Conociendo las calibraciones instrumentales y las propiedades físicas de los minerales, establecemos las verosimilitudes:

- $P(B|A_1) = 0,90$ (El basalto casi siempre muestra esta banda).
- $P(B|A_2) = 0,10$ (Las condritas raramente la presentan).
- $P(B|A_3) = 0,05$ (Los metales no tienen bandas de absorción silicatadas).

Nos interesa calcular la probabilidad a posteriori de que la roca sea basáltica dado que se detectó la banda de $1 \mu\text{m}$, es decir, $P(A_1|B)$. Primero, calculamos la probabilidad total de observar la banda (el denominador):

$$P(B) = P(B|A_1)P(A_1) + P(B|A_2)P(A_2) + P(B|A_3)P(A_3)$$

$$P(B) = (0,90)(0,20) + (0,10)(0,60) + (0,05)(0,20) = 0,18 + 0,06 + 0,01 = 0,25$$

Aplicando ahora el Teorema de Bayes:

$$P(A_1|B) = \frac{P(B|A_1)P(A_1)}{P(B)} = \frac{0,18}{0,25} = 0,72$$

Analíticamente, este resultado es revelador. Aunque la creencia a priori de encontrar basalto en esa zona era baja (20 %), la fuerte evidencia espectral (una verosimilitud del 90 %) actualiza nuestra certeza a un 72 %. Este es el poder del razonamiento bayesiano (*Astronomical Measurement*, Sección A.12.2): los datos observacionales pueden dominar y corregir drásticamente las suposiciones iniciales derivadas de modelos geológicos contextuales.

2.3.3. Ejemplo 3: Aislamiento de Fallas en el Sistema de Control de Actitud

El Teorema de Bayes también es vital en la ingeniería de sistemas autónomos para la toma de decisiones en tiempo real. Tomemos como referencia los algoritmos de Detección y Aislamiento de Fallas (FDI) en naves espaciales (*Modern Spacecraft Guidance, Navigation, And Control*, Capítulo sobre *Fault Detection and Isolation*).

Durante una maniobra de giro, el ordenador de vuelo detecta un pico de torque anómalo en la rueda de reacción principal (Evento B). El sistema debe diagnosticar la causa raíz para seleccionar el modo de contingencia adecuado. Las causas hipotéticas mutuamente excluyentes son:

- A_1 : Ruido transitorio en el sensor de efecto Hall (falsa alarma). $P(A_1) = 0,70$.
- A_2 : Impacto de micrometeorito en el panel solar adyacente, generando una vibración estructural. $P(A_2) = 0,20$.
- A_3 : Falla mecánica real en los rodamientos de la rueda. $P(A_3) = 0,10$.

Para discriminar entre estas causas, el sistema cruza la información con un sensor independiente: el rastreador de estrellas secundario. Si hay una vibración estructural real (A_2) o una falla mecánica (A_3), el rastreador de estrellas debería detectar un "jitter" (temblor) de alta frecuencia en la línea de visión. Definimos este evento corroborativo como C . Las verosimilitudes de detectar el jitter en el rastreador de estrellas son:

- $P(C|A_1) = 0,05$ (El ruido del sensor de la rueda no afecta al rastreador de estrellas).
- $P(C|A_2) = 0,85$ (La vibración estructural se propaga y es claramente visible en el rastreador).
- $P(C|A_3) = 0,40$ (La falla mecánica genera algo de vibración, pero menos acoplada a la estructura general).

El sistema de FDI necesita calcular la probabilidad a posteriori de que se trate de un impacto de micrometeorito (A_2) dado que *ambos* sensores reportaron la anomalía. Asumiendo independencia condicional de los sensores dado el estado de la nave, el evento observacional combinado es la intersección del pico de torque (B) y el jitter óptico (C). Para simplificar el modelo bayesiano directo sobre la causa, actualizamos las probabilidades usando la nueva evidencia C sobre las creencias a priori de las causas.

La probabilidad total de observar el jitter C es:

$$P(C) = P(C|A_1)P(A_1) + P(C|A_2)P(A_2) + P(C|A_3)P(A_3)$$

$$P(C) = (0,05)(0,70) + (0,85)(0,20) + (0,40)(0,10) = 0,035 + 0,170 + 0,040 = 0,245$$

Aplicando el Teorema de Bayes para encontrar $P(A_2|C)$:

$$P(A_2|C) = \frac{P(C|A_2)P(A_2)}{P(C)} = \frac{0,170}{0,245} \approx 0,694$$

Antes de la observación del rastreador de estrellas, la hipótesis más probable era un simple error de sensor (70 %), lo que habría llevado al software a ignorar la alerta. Sin embargo, la evidencia cruzada (C) invierte la situación: la probabilidad de un impacto de micrometeorito salta al 69.4 %. Con esta probabilidad a posteriori, el algoritmo de *Modern Spacecraft GN&C* puede justificar matemáticamente la transición a un modo de control de actitud que filtre las frecuencias de resonancia estructurales, evitando así que el sistema de control entre en inestabilidad por realimentación positiva de la vibración.

2.3.4. Ejemplo 4: Clasificación Orbital de Cometas (Parabólico vs. Hiperbólico)

Practical Astronomy with your Calculator (Duffett-Smith y Zwart, Sección 61).

Cuando se descubre un nuevo cometa, determinar su excentricidad orbital (e) es crucial para entender su origen. Si $e = 1$, la órbita es parabólica (el cometa está gravitacionalmente ligado al sistema solar o en el límite de escape). Si $e > 1$, la órbita es hiperbólica, lo que indicaría un objeto interestelar (como 'Oumuamua o Borisov) que solo está de paso.

Sin embargo, las mediciones astrométricas (Ascensión Recta y Declinación) tienen errores inherentes. Definamos el evento M como: *la excentricidad medida es $\hat{e} \geq 1,0$* .

Tenemos dos hipótesis mutuamente excluyentes sobre la verdadera naturaleza del cometa:

- H_P : El cometa tiene una órbita verdaderamente parabólica ($e = 1$).
- H_H : El cometa tiene una órbita verdaderamente hiperbólica ($e > 1$).

Basado en el catálogo histórico de cometas, la inmensa mayoría de los cometas de período largo provienen de la nube de Oort y tienen órbitas parabólicas. Por lo tanto, establecemos las siguientes probabilidades a priori:

$$P(H_P) = 0,95$$

$$P(H_H) = 0,05$$

Conociendo la precisión típica de los telescopios terrestres y la propagación de errores en el cálculo de elementos orbitales (Duffett-Smith y Zwart, Sección 62), estimamos las siguientes verosimilitudes de obtener una medición $\hat{e} \geq 1,0$:

- $P(M|H_P) = 0,10$: Si el cometa es realmente parabólico, hay un 10 % de probabilidad de que el ruido observacional empuje la excentricidad medida a $\geq 1,0$ (falso positivo de hiperbolicidad).
- $P(M|H_H) = 0,90$: Si el cometa es realmente hiperbólico, hay un 90 % de probabilidad de que la medición lo refleje correctamente como $\geq 1,0$.

El pipeline de reducción de datos reporta que para el nuevo cometa C/202X, la excentricidad calculada es $\hat{e} = 1,03$. Es decir, el evento M ha ocurrido. Nos interesa calcular la probabilidad a posteriori de que sea un objeto interestelar, $P(H_H|M)$.

Primero, calculamos la probabilidad total de observar M (el denominador del Teorema de Bayes):

$$P(M) = P(M|H_P)P(H_P) + P(M|H_H)P(H_H)$$

$$P(M) = (0,10)(0,95) + (0,90)(0,05) = 0,095 + 0,045 = 0,140$$

Ahora, aplicamos el Teorema de Bayes para encontrar la probabilidad posterior:

$$P(H_H|M) = \frac{P(M|H_H)P(H_H)}{P(M)} = \frac{0,045}{0,140} \approx 0,3214$$

Conclusión: A pesar de que la medición directa sugiere una órbita hiperbólica ($\hat{e} = 1,03$), el Teorema de Bayes nos revela que la probabilidad real de que el cometa sea interestelar es de apenas un 32.14 %. La fuerte probabilidad a priori de que los cometas sean parabólicos (95 %), combinada con una tasa de falsos positivos del 10 % debido al error instrumental, hace que sea estadísticamente más probable (67.86 %) que el cometa sea en realidad parabólico y que la medición $\hat{e} \geq 1,0$ sea solo una fluctuación del ruido. Este ejemplo demuestra por qué en la astrometría moderna, nunca se debe confiar ciegamente en un parámetro orbital derivado sin un análisis bayesiano riguroso que contemple las tasas base y los errores de medición.

Clase 3

3.1. Conteos

En el desarrollo de la teoría de la probabilidad, antes de poder asignar valores numéricos a los eventos, es imperativo determinar el tamaño del espacio muestral, es decir, el número total de resultados posibles. Cuando los resultados de un experimento son numerosos, enumerarlos uno por uno se vuelve una tarea impracticable. Para resolver esto, la estadística se apoya en principios fundamentales de conteo.

El principio más elemental y poderoso es la **Regla del Producto** (Devore, Capítulo 2, Sección 2.3). Esta regla establece que si un proceso o experimento puede describirse como una sucesión de k etapas, donde la primera etapa tiene n_1 resultados posibles, la segunda tiene n_2 resultados (independientemente de lo que haya ocurrido en la primera), y así sucesivamente, entonces el número total de resultados en el espacio muestral S es el producto de las posibilidades de cada etapa:

$$N(S) = n_1 \times n_2 \times \cdots \times n_k$$

Complementariamente, la **Regla de la Suma** se utiliza cuando un evento puede descomponerse en categorías mutuamente excluyentes, sumando simplemente el número de resultados de cada categoría (Devore, Sección 2.3).

3.1.1. Ejemplo 1: Configuración de Carga Útil en una Sonda Espacial

Para ilustrar la Regla del Producto en un contexto de ingeniería espacial, nos inspiramos en la arquitectura modular de los subsistemas de naves no tripuladas (*Modern Spacecraft Guidance, Navigation, and Control*, Capítulo sobre *Spacecraft Subsystems and Payloads*).

Durante la fase de diseño preliminar de una misión a asteroides, el equipo de sistemas debe definir la configuración base del bus de la nave. El proceso de configuración se divide en tres etapas secuenciales e independientes, donde cada etapa representa la selección de un subsistema crítico:

- **Etapla 1 (Propulsión):** Se debe elegir entre 3 tipos de sistemas de propulsión disponibles (Propulsión química bipropelente, Propulsión iónica de efecto Hall, Propulsión eléctrica de plasma).
- **Etapla 2 (Navegación):** Se debe seleccionar el conjunto de sensores primarios entre 4 arquitecturas distintas (Solo rastreador de estrellas, Rastreador de estrellas + IMU, Navegación óptica relativa, Navegación por radio de espacio profundo).
- **Etapla 3 (Comunicación):** Se debe elegir la banda de frecuencia para el enlace de telemetry entre 2 opciones (Banda X, Banda Ka).

El experimento consiste en definir una configuración única para la sonda. Aplicando la Regla del Producto (Devore, Sección 2.3), el número total de configuraciones posibles (el tamaño del espacio muestral S) es:

$$N(S) = 3 \times 4 \times 2 = 24$$

Desde una perspectiva analítica, este espacio muestral de 24 elementos define el universo de configuraciones que los ingenieros deben evaluar mediante simulaciones de Monte Carlo para garantizar que al menos una configuración satisfaga los requisitos de masa, potencia y ΔV de la misión. Si se quisiera calcular la probabilidad de seleccionar al azar una configuración que utilice propulsión iónica (asumiendo que todas las configuraciones son igualmente probables en un sorteo de diseño), el conteo preciso de $N(S)$ es el denominador indispensable para aplicar la definición clásica de probabilidad.

3.1.2. Ejemplo 2: Matriz de Observación Fotométrica en un Telescopio Robótico

En la astronomía observacional, la planificación de las tomas de datos implica la configuración de múltiples parámetros instrumentales. Tomemos como referencia los sistemas de adquisición de datos y la fotometría de precisión (*Practical Astronomy with your Calculator*, Sección sobre *Photometry and the UBVRI System*, y *Astronomical Measurement*, Capítulo sobre *Detectors and Instruments*).

Un telescopio robótico está programado para ejecutar una secuencia de observación de un cúmulo estelar. El pipeline de control del telescopio debe configurar el instrumento para cada exposición individual. La configuración de un "frame" (cuadro) de imagen se realiza en tres etapas secuenciales:

- **Etapas 1 (Filtro):** La rueda de filtros selecciona una banda espectral entre 5 opciones estándar del sistema Johnson-Cousins (U, B, V, R, I).
- **Etapas 2 (Tiempo de exposición):** El controlador de la cámara CCD establece el tiempo de integración entre 3 opciones predefinidas (Corto: 10s, Medio: 60s, Largo: 300s).
- **Etapas 3 (Modo de lectura):** Se elige la velocidad de lectura del CCD para equilibrar el ruido de lectura y el tiempo muerto entre 2 opciones (Modo Rápido, Modo Lento).

El experimento consiste en generar un tipo único de cuadro fotométrico. Utilizando la Regla del Producto, el número total de configuraciones de cuadro distintas que el telescopio puede producir es:

$$N(S) = 5 \times 3 \times 2 = 30$$

Este resultado analítico nos indica que el espacio muestral de posibles configuraciones de un solo cuadro está compuesto por 30 eventos simples. Por ejemplo, un resultado simple sería la tupla ($V, \text{Medio}, \text{Lento}$).

Si el telescopio toma una secuencia de 3 cuadros consecutivos para promediar y reducir el ruido cósmico, y cada cuadro se configura de manera independiente, la Regla del Producto se aplica nuevamente a nivel de la secuencia. El número total de secuencias de 3 cuadros posibles sería $30 \times 30 \times 30 = 27,000$. Comprender la magnitud de estos espacios muestrales discretos es fundamental para los astrónomos al diseñar estrategias de observación (dithering) y para los estadísticos que modelan la probabilidad de que ciertos errores sistemáticos instrumentales (como el ruido de lectura en el modo rápido) se correlacionen con bandas espectrales específicas.

3.2. Permutaciones

En muchas situaciones experimentales, no solo nos interesa seleccionar un subconjunto de objetos o eventos de una población mayor, sino que el *orden* en el que estos elementos son seleccionados o dispuestos es fundamental para el resultado del experimento. Cuando el orden de los elementos importa, estamos tratando con permutaciones.

Una permutación es un subconjunto ordenado de tamaño k que se puede formar a partir de n individuos u objetos en un grupo (Devore, Capítulo 2, Sección 2.3). El número de permutaciones de tamaño k que se pueden formar con n objetos se denota como $P_{k,n}$.

Analíticamente, la fórmula para calcular el número de permutaciones se deriva directamente de la Regla del Producto. Para la primera posición hay n opciones, para la segunda hay $n - 1$ opciones (ya que un objeto ha sido utilizado y no hay reemplazo), y así sucesivamente hasta la k -ésima posición, donde quedan $n - k + 1$ opciones. Esto se expresa de manera compacta utilizando la notación factorial:

$$P_{k,n} = n(n-1)(n-2) \cdots (n-k+1) = \frac{n!}{(n-k)!}$$

La distinción analítica crucial entre permutaciones y combinaciones (que se verá en la siguiente sección) radica estrictamente en la relevancia del orden.

3.2.1. Ejemplo 1: Secuencia de Apuntamiento en un Telescopio Espacial

Para ilustrar la aplicación de las permutaciones en la planificación orbital, consideremos la programación de un telescopio espacial en órbita baja terrestre (LEO). El telescopio tiene una lista de 10 objetivos astrofísicos de alta prioridad (por ejemplo, exoplanetas específicos en tránsito). Sin embargo, debido a las estrictas restricciones de presupuesto térmico y a las ventanas de comunicación con la red de espacio profundo, el telescopio solo puede realizar observaciones consecutivas de 3 de estos 10 objetivos durante una órbita específica.

Definamos el experimento como: *Seleccionar y ordenar 3 objetivos de una lista de 10 para ser observados en secuencia.*

Es imperativo modelar esto como una permutación y no como una simple combinación. En la dinámica de naves espaciales (*Modern Spacecraft Guidance, Navigation, and Control*, Capítulo sobre *Attitude Control Systems*), el orden de apuntamiento (slew) altera drásticamente el perfil térmico de la nave. Observar el objetivo A, luego el B y finalmente el C requiere un gasto de combustible y una disipación de calor completamente diferentes que observar C, luego B y luego A, debido a la inercia del telescopio y la exposición diferencial de sus radiadores al Sol.

Por lo tanto, calculamos el número total de secuencias de observación posibles (el tamaño del espacio muestral S) utilizando la fórmula de permutaciones con $n = 10$ y $k = 3$:

$$P_{3,10} = \frac{10!}{(10-3)!} = \frac{10!}{7!} = 10 \times 9 \times 8 = 720$$

Existen 720 secuencias ordenadas distintas. Si el planificador de la misión quisiera calcular la probabilidad de que una secuencia generada aleatoriamente cumpla con un perfil térmico específico

(asumiendo que todas las permutaciones son igualmente probables en un sorteo ciego), el denominador de su modelo probabilístico sería rigurosamente 720. Ignorar el orden y usar combinaciones ($\binom{10}{3} = 120$) subestimaría el espacio muestral real y destruiría la validez física del modelo de probabilidad.

3.2.2. Ejemplo 2: Secuencia de Análisis en un Espectrómetro de Masas Planetario

En la ciencia planetaria, el análisis in situ de muestras geológicas requiere instrumentación de altísima precisión. Tomemos como referencia los procedimientos de los laboratorios de muestras en rovers marcianos, como el instrumento SAM (Sample Analysis at Mars) (*Planetary Geology*, Capítulo sobre *In Situ Instrumentation and Analytical Techniques*).

Un rover ha recolectado polvo y regolito de 7 ubicaciones geológicas distintas. El laboratorio a bordo debe procesar 4 de estas muestras en una secuencia de horneado dentro del espectrómetro de masas. Debido a la física del instrumento, el orden en que las muestras se introducen en la cámara de vacío es crítico: las muestras procesadas primero pueden dejar residuos de memoria" (gases adsorbidos en las paredes) que contaminan las lecturas de las muestras procesadas posteriormente.

Definimos el experimento como: *Seleccionar y ordenar 4 muestras geológicas de un total de 7 para la secuencia de análisis.*

Dado que la secuencia de horneado afecta los resultados científicos (la contaminación cruzada depende de qué muestra precede a cuál), el orden es una variable de estado fundamental. Aplicamos la fórmula de permutaciones (Devore, Sección 2.3) con $n = 7$ y $k = 4$:

$$P_{4,7} = \frac{7!}{(7-4)!} = \frac{7!}{3!} = 7 \times 6 \times 5 \times 4 = 840$$

El espacio muestral consta de 840 secuencias de análisis únicas. Desde una perspectiva de diseño de experimentos, el equipo científico debe evaluar estas 840 permutaciones para encontrar aquella que minimice el sesgo analítico (por ejemplo, colocando las muestras más 'prístinas' al final de la secuencia o intercalando muestras de limpieza). La modelación permutacional permite cuantificar la incertidumbre introducida por el orden de procesamiento y justificar analíticamente la secuencia óptima antes de comandar el instrumento en Marte.

3.3. Combinaciones

En muchas aplicaciones de la estadística y la probabilidad, el interés analítico no radica en el orden de los elementos seleccionados, sino únicamente en *cuáles* elementos conforman el subconjunto resultante. Cuando se seleccionan k objetos de un grupo de n objetos sin reemplazo y el orden de selección es irrelevante, el número de subconjuntos posibles se denomina combinaciones (Devore, Capítulo 2, Sección 2.3).

La fórmula para calcular el número de combinaciones de tamaño k que se pueden extraer de un conjunto de tamaño n se denota como $\binom{n}{k}$ y se expresa analíticamente mediante factoriales:

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

Es crucial establecer la distinción analítica entre permutaciones y combinaciones. Dado que cada combinación de k elementos puede ser ordenada internamente de $k!$ formas distintas, el número de combinaciones es siempre una fracción del número de permutaciones. La relación que las vincula es:

$$\binom{n}{k} = \frac{P_{k,n}}{k!}$$

3.3.1. Ejemplo 1: Selección de Sitios de Aterrizaje en Ciencia Planetaria

Para ilustrar el uso de combinaciones en la planificación de misiones, nos inspiramos en los criterios de selección de regiones de interés y sitios de aterrizaje discutidos en *Planetary Geology* (Capítulo sobre *Landing Site Selection and Geological Context*).

Durante la Fase 0/A de una misión de retorno de muestras marcianas, el equipo científico ha identificado un total de $n = 15$ sitios candidatos que poseen alto valor geológico (por ejemplo, lechos de antiguos lagos o depósitos de arcillas). Sin embargo, debido a las limitaciones estrictas de presupuesto, tiempo de computación y ventanas de lanzamiento, la ingeniería de sistemas solo puede realizar un estudio de factibilidad detallado para un subconjunto de exactamente $k = 4$ sitios.

Definimos el experimento como: *Seleccionar un grupo de 4 sitios de aterrizaje de los 15 candidatos disponibles*.

Dado que en esta etapa el objetivo es simplemente formar un *conjunto* de 4 sitios para ser evaluados en paralelo por los equipos de ingeniería, el orden en el que los sitios son nominados o extraídos de la lista original es completamente irrelevante. El resultado del experimento es la composición del grupo, no su secuencia. Por lo tanto, aplicamos la fórmula de combinaciones (Devore, Sección 2.3):

$$\binom{15}{4} = \frac{15!}{4!(15-4)!} = \frac{15!}{4! \cdot 11!} = \frac{15 \times 14 \times 13 \times 12}{4 \times 3 \times 2 \times 1} = \frac{32760}{24} = 1365$$

El espacio muestral S consta de 1365 configuraciones únicas de sitios.

Desde una perspectiva analítica, si hubiéramos cometido el error de modelar esto como una permutación (asumiendo que el orden de prioridad de los 4 sitios importa), habríamos calculado $P_{4,15} = 32760$ resultados. Esto habría sobreestimado el espacio muestral en un factor de $4! = 24$, introduciendo una asimetría inexistente en el problema físico y haciendo que cualquier cálculo de probabilidad clásica (como la probabilidad de que un sitio específico con una mineralogía particular sea incluido en el estudio) fuera matemáticamente erróneo. El uso correcto de combinaciones garantiza que la asignación de probabilidades a los eventos refleje fielmente la naturaleza del proceso de selección.

3.3.2. Ejemplo 2: Configuración de Sub-arrays en Radio Interferometría

En la astronomía observacional de altas resoluciones, la disposición geométrica de los telescopios define la calidad de la imagen final. Tomemos como referencia los principios de síntesis de apertura y diseño de arreglos en *Astronomical Measurement* (Capítulo sobre *Interferometry and Aperture Synthesis*).

Considere un observatorio de radio interferometría (análogo al VLA o ALMA) que cuenta con una configuración base de $n = 10$ antenas parabólicas distribuidas a lo largo de una pista en forma de "Y". Debido a una falla temporal en el sistema de criogenia de los receptores, 4 de las antenas han sido desconectadas de la red de correlación, dejando únicamente $k = 6$ antenas operativas para una campaña de observación crítica de un disco protoplanetario.

Definimos el experimento como: *Determinar la configuración del arreglo de observación seleccionando las 6 antenas que formarán la red activa.*

En la interferometría, la calidad de la imagen (el haz sintetizado y la cobertura del plano uv) depende exclusivamente de *cuáles* antenas están activas y de las distancias geométricas entre ellas (las líneas base). El orden temporal o la secuencia en la que el software de control 'activa' o 'selecciona' las antenas no altera en absoluto la respuesta física del interferómetro. Por lo tanto, el problema es estrictamente de combinaciones.

Calculamos el número total de configuraciones de sub-arrays posibles que el observatorio podría haber formado con 6 antenas de un total de 10:

$$\binom{10}{6} = \frac{10!}{6!(10-6)!} = \frac{10!}{6! \cdot 4!} = \frac{10 \times 9 \times 8 \times 7}{4 \times 3 \times 2 \times 1} = \frac{5040}{24} = 210$$

Existen 210 sub-arrays únicos posibles.

Este resultado es fundamental para los astrónomos que realizan simulaciones de rendimiento antes de la observación. Dado que cada una de las 210 combinaciones produce un patrón de interferencia (y por ende, artefactos de imagen o "sidelobes") ligeramente distinto, el equipo científico debe evaluar este espacio muestral de 210 elementos para determinar si la configuración específica de 6 antenas que quedó operativa es suficiente para cumplir con los requisitos de dinámica de contraste necesarios para detectar un exoplaneta en formación dentro del disco. Nuevamente, la correcta delimitación del espacio muestral mediante combinaciones (Devore, Sección 2.3) es el prerrequisito para cualquier inferencia estadística sobre la confiabilidad de los datos astronómicos obtenidos.

Clase 4

4.1. Variables aleatorias

Una variable aleatoria (v.a.) es una regla o función que asocia un valor numérico a cada resultado de un experimento cuyo espacio muestral es S (Devore, Capítulo 3, Sección 3.1).

Analíticamente, si denotamos un resultado individual del espacio muestral como ω , una variable aleatoria X es una función que mapea el espacio muestral al conjunto de los números reales:

$$X : S \rightarrow \mathbb{R}$$

El valor observado de la variable aleatoria después de realizar el experimento se denomina valor realizado y se denota con la letra minúscula correspondiente (por ejemplo, x). Las variables aleatorias se clasifican fundamentalmente en dos tipos:

- **Variables aleatorias discretas:** Sus posibles valores constituyen un conjunto finito o una secuencia infinita numerable (Devore, Sección 3.1).
- **Variables aleatorias continuas:** Sus posibles valores comprenden un intervalo continuo en la línea de los números reales, y la probabilidad de que asuman un valor exacto es estrictamente cero (Devore, Sección 3.1 y Capítulo 4).

4.1.1. Ejemplo 1: Variable Aleatoria Discreta en la Adquisición de Estrellas Guía

(*Modern Spacecraft Guidance, Navigation, and Control*, Capítulo sobre *Attitude Determination Systems*).

Un rastreador de estrellas (Star Tracker) a bordo de un satélite de observación terrestre toma una imagen del cielo nocturno para determinar la orientación de la nave. El catálogo interno del instrumento espera encontrar exactamente $N = 8$ estrellas guía brillantes dentro de su campo de visión (FOV) para esa coordenada de apuntamiento específica. Sin embargo, debido a la presencia de ruido cósmico, luz parásita (stray light) o la magnitud límite del sensor, no todas las estrellas esperadas son necesariamente identificadas por el algoritmo de extracción de centroides.

Definimos el experimento como: *Ejecutar un ciclo de adquisición de actitud con el rastreador de estrellas*. El espacio muestral S está compuesto por todas las combinaciones posibles de estrellas identificadas y no identificadas (un total de $2^8 = 256$ resultados cualitativos distintos, como "se identificaron las estrellas 1, 3, 5, 7, 8", etc.).

En lugar de trabajar con estos 256 resultados textuales, definimos la variable aleatoria discreta X como:

X = el número de estrellas guía exitosamente identificadas por el rastreador.

El conjunto de posibles valores para X es finito y numerable:

$$D_X = \{0, 1, 2, 3, 4, 5, 6, 7, 8\}$$

Esta variable aleatoria transforma un problema de reconocimiento de patrones complejos en un escalar discreto. El sistema de control de actitud (ADCS) utiliza el valor realizado x para calcular un índice de confianza. Por ejemplo, si el evento observado es $x = 3$, el software de vuelo sabe que la solución de actitud tiene una alta incertidumbre y podría decidir rechazar la medición o cambiar a un modo de navegación inercial degradada. La naturaleza discreta de X permite modelar su comportamiento utilizando una Función de Masa de Probabilidad (FMP), $p(x) = P(X = x)$, la cual asigna una probabilidad estrictamente positiva a cada uno de los 9 enteros posibles.

4.1.2. Ejemplo 2: Variable Aleatoria Continua en la Espectroscopia de Velocidad Radial

Principios de medición de precisión y espectroscopia de alta resolución (*Astronomical Measurement, Capítulo sobre Spectroscopy and Radial Velocity Measurements*).

En la búsqueda de exoplanetas mediante el método de velocidad radial, un espectrógrafo de alta estabilidad (como HARPS o ESPRESSO) mide el desplazamiento Doppler de las líneas de absorción en el espectro de una estrella anfitriona. El instrumento descompone la luz y calcula el centroide de una línea espectral específica (por ejemplo, la línea H-alfa del Hidrógeno) para determinar la velocidad de la estrella a lo largo de la línea de visión.

Definimos el experimento como: *Medir la velocidad de la estrella en un instante (época) dado*. El espacio muestral S consiste en todos los posibles desplazamientos físicos del centroide de la línea espectral en el detector CCD, los cuales están sujetos a ruido de fotones, ruido térmico del instrumento y 'jitter' astrofísico de la propia estrella.

Definimos la variable aleatoria continua Y como:

Y = la velocidad radial exacta medida de la estrella (en metros por segundo, m/s).

A diferencia del ejemplo anterior, el conjunto de posibles valores para Y no es numerable. La velocidad puede tomar cualquier valor dentro de un intervalo físico razonable, por ejemplo:

$$D_Y = [-5000,000 \dots, 5000,000 \dots] \subset \mathbb{R}$$

Dado que Y puede asumir infinitos valores no numerables dentro de un intervalo (incluyendo números irracionales), la probabilidad de que la medición sea un valor exacto y específico (por ejemplo, $Y = 12,3456789 \dots$ m/s) es estrictamente cero: $P(Y = c) = 0$ para cualquier constante c (Devore, Capítulo 4, Sección 4.1).

Por lo tanto, no podemos asignar probabilidades a puntos individuales mediante una función de masa. En su lugar, las probabilidades se asignan a *intervalos* de valores (por ejemplo, la probabilidad de que la velocidad radial esté entre $-10,5$ y $-10,0$ m/s). Esto requiere el uso de una Función de Densidad de Probabilidad (FDP), $f(y)$, donde la probabilidad se calcula mediante integración:

$$P(a \leq Y \leq b) = \int_a^b f(y) dy$$

4.2. Funciones de densidad de probabilidad

A diferencia de las variables discretas, donde podemos asignar probabilidades positivas a puntos exactos mediante una función de masa, en el caso continuo la probabilidad de que la variable asuma un valor exacto y específico es estrictamente cero: $P(X = c) = 0$ (Devore, Capítulo 4, Sección 4.1).

Para modelar estas variables, utilizamos la **Función de Densidad de Probabilidad (FDP)**, denotada como $f(x)$. Una función $f(x)$ es una FDP legítima si y solo si satisface rigurosamente las siguientes tres condiciones (Devore, Sección 4.1):

1. $f(x) \geq 0$ para todo x (la densidad de probabilidad no puede ser negativa).
2. $\int_{-\infty}^{\infty} f(x) dx = 1$ (la probabilidad total en todo el espacio muestral continuo es la certeza absoluta).
3. $P(a \leq X \leq b) = \int_a^b f(x) dx$ (la probabilidad de que X caiga en un intervalo específico es el área bajo la curva de densidad entre a y b).

La FDP no nos da la probabilidad en un punto, sino la 'densidad' de probabilidad.

4.2.1. Ejemplo 1: Tiempo de Permanencia de un Cometa en el Sistema Solar Interior

Practical Astronomy with your Calculator (Duffett-Smith y Zwart, Sección 61 y 62).

Cuando un cometa de período largo entra al sistema solar interior, su velocidad varía drásticamente debido a la conservación del momento angular (es mucho más rápido en el perihelio que en el afelio). Definamos la variable aleatoria continua X como el *tiempo normalizado* que el cometa pasa dentro de la región de los planetas terrestres (digamos, $r < 3$ UA) durante un paso orbital, relativo a su tiempo máximo teórico.

Supongamos que, debido a la distribución de velocidades orbitales, la FDP de esta fracción de tiempo X está modelada por una función cuadrática en el intervalo $[0, 1]$:

$$f(x) = \begin{cases} kx(1-x) & \text{para } 0 < x < 1 \\ 0 & \text{en otro caso} \end{cases}$$

a) Determinación de la constante de normalización k : Para que $f(x)$ sea una FDP legítima, el área total bajo la curva debe ser 1 (Devore, Sección 4.1).

$$\int_{-\infty}^{\infty} f(x) dx = \int_0^1 k(x - x^2) dx = k \left[\frac{x^2}{2} - \frac{x^3}{3} \right]_0^1 = k \left(\frac{1}{2} - \frac{1}{3} \right) = k \left(\frac{1}{6} \right) = 1$$

Por lo tanto, la constante es $k = 6$. La FDP completa es $f(x) = 6x(1-x)$ para $0 < x < 1$.

b) Probabilidad de una permanencia prolongada: Nos interesa calcular la probabilidad de que el cometa pase más del 50 % de su tiempo máximo en el sistema interior, es decir, $P(X > 0,5)$.

$$P(X > 0,5) = \int_{0,5}^1 6(x - x^2) dx = 6 \left[\frac{x^2}{2} - \frac{x^3}{3} \right]_{0,5}^1$$

$$= 6 \left[\left(\frac{1}{2} - \frac{1}{3} \right) - \left(\frac{0,25}{2} - \frac{0,125}{3} \right) \right] = 6 \left[\frac{1}{6} - \left(\frac{1}{8} - \frac{1}{24} \right) \right] = 6 \left[\frac{1}{6} - \frac{2}{24} \right] = 6 \left[\frac{1}{6} - \frac{1}{12} \right] = 6 \left(\frac{1}{12} \right) = 0,5$$

c) Obtención de la Función de Distribución Acumulativa (FDA): La FDA, $F(x)$, es fundamental para calcular percentiles y generar variables aleatorias para simulaciones de Monte Carlo (Devore, Sección 4.2). Para $0 \leq x \leq 1$:

$$F(x) = \int_{-\infty}^x f(t) dt = \int_0^x 6(t - t^2) dt = 6 \left[\frac{t^2}{2} - \frac{t^3}{3} \right]_0^x = 3x^2 - 2x^3$$

La FDA completa se define por tramos: $F(x) = 0$ si $x < 0$; $F(x) = 3x^2 - 2x^3$ si $0 \leq x \leq 1$; y $F(x) = 1$ si $x > 1$.

d) Cálculo del Valor Esperado (Media): El tiempo normalizado esperado que un cometa de esta población pasa en el sistema interior es:

$$\begin{aligned} E[X] &= \int_{-\infty}^{\infty} x f(x) dx = \int_0^1 x[6x(1-x)] dx = 6 \int_0^1 (x^2 - x^3) dx \\ &= 6 \left[\frac{x^3}{3} - \frac{x^4}{4} \right]_0^1 = 6 \left(\frac{1}{3} - \frac{1}{4} \right) = 6 \left(\frac{1}{12} \right) = 0,5 \end{aligned}$$

4.2.2. Ejemplo 2: Error de Apuntamiento de la Antena de Alta Ganancia en una Sonda

Modern Spacecraft Guidance, Navigation, and Control (Capítulo sobre *Communication Subsystems and Link Budgets*).

Definamos la variable aleatoria continua X como la magnitud del error de apuntamiento de la antena de alta ganancia (HGA) de una sonda en la deep space, medido en arcosegundos. Debido a los micro-vibraciones de las ruedas de reacción y los límites físicos del sensor estelar, el error está acotado entre 0 y 5 arcosegundos. La FDP del error está modelada por:

$$f(x) = \begin{cases} k(25 - x^2) & \text{para } 0 \leq x \leq 5 \\ 0 & \text{en otro caso} \end{cases}$$

Este modelo refleja que los errores pequeños son mucho más probables (mayor densidad) que los errores grandes que se acercan al límite mecánico de 5 arcosegundos. Analicemos las propiedades de esta distribución:

a) Determinación de la constante k : Aplicamos la condición de normalización (Devore, Sección 4.1):

$$\int_0^5 k(25 - x^2) dx = k \left[25x - \frac{x^3}{3} \right]_0^5 = k \left(125 - \frac{125}{3} \right) = k \left(\frac{250}{3} \right) = 1$$

Despejando, obtenemos $k = \frac{3}{250} = 0,012$.

b) Probabilidad de Pérdida de Enlace (Loss of Signal): El presupuesto de enlace de la misión dicta que si el error de apuntamiento supera los 3 arcosegundos, la ganancia de la antena

cae por debajo del umbral requerido, provocando una pérdida temporal de datos (Loss of Signal, LoS). Calculamos $P(X > 3)$:

$$\begin{aligned} P(X > 3) &= \int_3^5 \frac{3}{250}(25 - x^2) dx = \frac{3}{250} \left[25x - \frac{x^3}{3} \right]_3^5 \\ &= \frac{3}{250} \left[\left(125 - \frac{125}{3} \right) - \left(75 - \frac{27}{3} \right) \right] = \frac{3}{250} \left[\frac{250}{3} - (75 - 9) \right] \\ &= \frac{3}{250} \left[\frac{250}{3} - 66 \right] = 1 - \frac{198}{250} = 1 - 0,792 = 0,208 \end{aligned}$$

Existe un 20.8 % de probabilidad de que, en un instante aleatorio, el error de apuntamiento sea lo suficientemente grande como para degradar o perder el enlace de telemetry.

c) Cálculo del Error de Apuntamiento Esperado (Media): El valor esperado nos indica el sesgo o error promedio del sistema (Devore, Sección 4.2):

$$\begin{aligned} E[X] &= \int_0^5 x \left[\frac{3}{250}(25 - x^2) \right] dx = \frac{3}{250} \int_0^5 (25x - x^3) dx \\ &= \frac{3}{250} \left[\frac{25x^2}{2} - \frac{x^4}{4} \right]_0^5 = \frac{3}{250} \left[\frac{625}{2} - \frac{625}{4} \right] = \frac{3}{250} \left[\frac{625}{4} \right] = \frac{1875}{1000} = 1,875 \text{ arcosegundos.} \end{aligned}$$

El error promedio del sistema es de 1.875 arcosegundos.

d) Probabilidad de operar dentro de la tolerancia de alta precisión: Supongamos que ciertos modos de observación científica (como la espectroscopía de alta resolución con una rendija estrecha) requieren que el error de apuntamiento esté a menos de 1 arcosegundo de distancia del error promedio (es decir, en el intervalo $[E[X] - 1, E[X] + 1] = [0,875, 2,875]$). Calculamos esta probabilidad:

$$\begin{aligned} P(0,875 \leq X \leq 2,875) &= \int_{0,875}^{2,875} \frac{3}{250}(25 - x^2) dx = \frac{3}{250} \left[25x - \frac{x^3}{3} \right]_{0,875}^{2,875} \\ P &= \frac{3}{250} \left(\frac{98233 - 33257}{1536} \right) = \frac{3}{250} \left(\frac{64976}{1536} \right) = \frac{3}{250} \left(\frac{4061}{96} \right) = \frac{4061}{8000} = 0,507625 \end{aligned}$$

Existe aproximadamente un 50.76 % de probabilidad de que el error de apuntamiento caiga dentro de esta ventana de alta precisión de ± 1 arcosegundo alrededor de la media.

4.3. Función de distribución acumulativa

La función de distribución acumulativa $F(x)$ de una variable aleatoria continua X se define para cualquier número real x como la probabilidad de que X tome un valor menor o igual a x (Devore, Capítulo 4, Sección 4.2):

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt$$

Primero, es una función monótona no decreciente. Segundo, sus límites asintóticos son $\lim_{x \rightarrow -\infty} F(x) = 0$ y $\lim_{x \rightarrow \infty} F(x) = 1$. Tercero, la probabilidad de que la variable caiga en un intervalo específico $(a, b]$ se calcula de manera directa y elegante sin necesidad de reintegrar la FDP:

$$P(a < X \leq b) = F(b) - F(a)$$

Además, la FDA es la vía principal para definir y calcular percentiles, cuartiles y medianas. Si X es continua y $F(x)$ es estrictamente creciente, la derivada de la FDA nos devuelve la FDP: $f(x) = \frac{d}{dx}F(x)$ (Devore, Sección 4.2).

4.3.1. Ejemplo 1: Perfil de Densidad de Polvo en un Disco Protoplanetario

(*Planetary Geology*, Capítulo sobre *Protoplanetary Disks and Planetesimal Formation*; *Astronomical Measurement*, Sección sobre *Radiative Transfer*).

Considere un disco protoplanetario alrededor de una estrella joven. Definimos la variable aleatoria continua X como la distancia radial normalizada (adimensional) de un grano de polvo respecto al radio exterior del disco, de modo que $X \in (0, 1)$. Debido a los procesos de arrastre aerodinámico y la dinámica orbital, la densidad de probabilidad de encontrar un grano de polvo de un tamaño específico a una distancia x está modelada por la siguiente FDP:

$$f(x) = \begin{cases} 4x^3 & \text{para } 0 < x < 1 \\ 0 & \text{en otro caso} \end{cases}$$

Esta función indica que la probabilidad de encontrar polvo aumenta drásticamente hacia las regiones exteriores del disco modelado.

a) Obtención de la Función de Distribución Acumulativa: Para $0 \leq x \leq 1$, integramos la FDP desde el límite inferior del soporte hasta x :

$$F(x) = \int_0^x 4t^3 dt = [t^4]_0^x = x^4$$

La FDA completa se define por tramos: $F(x) = 0$ si $x \leq 0$; $F(x) = x^4$ si $0 < x < 1$; y $F(x) = 1$ si $x \geq 1$.

b) Probabilidad de localización en la 'línea de hielo': En la ciencia planetaria, la 'línea de hielo' es la distancia a la cual los compuestos volátiles como el agua se condensan en grano de hielo, un paso crítico para la formación de núcleos de gigantes gaseosos. Supongamos que esta región corresponde al intervalo normalizado $0,4 < X \leq 0,6$. Usando la propiedad de la FDA (Devore, Sección 4.2):

$$P(0,4 < X \leq 0,6) = F(0,6) - F(0,4) = (0,6)^4 - (0,4)^4 = 0,1296 - 0,0256 = 0,1040$$

Existe un 10.4 % de probabilidad de que un grano de polvo seleccionado al azar se encuentre en esta región crítica de condensación.

c) **Cálculo de la Mediana Radial:** La mediana m es el valor que divide la distribución de probabilidad en dos mitades iguales, es decir, el radio que encierra el 50 % de la masa de polvo total. Resolvemos $F(m) = 0,5$:

$$m^4 = 0,5 \implies m = (0,5)^{1/4} \approx 0,8409$$

La mediana radial es aproximadamente 0.84. Aunque el disco llega hasta $x = 1$, la mitad de los granos de polvo están concentrados en el 84 % exterior del disco, confirmando la tendencia de acumulación de materia hacia las regiones frías y lejanas.

d) **Determinación del Percentil 90:** Para calibrar un instrumento de observación que solo puede resolver estructuras más allá de cierto radio, necesitamos el percentil 90 (P_{90}). Resolvemos $F(x) = 0,90$:

$$x^4 = 0,90 \implies x = (0,90)^{0,25} \approx 0,9740$$

El 90 % de los granos de polvo se encuentran a una distancia normalizada menor o igual a 0.974.

4.3.2. Ejemplo 2: Error Radial en el Elipse de Aterrizaje de un Rover

Análisis de desempeño de navegación y los márgenes de error en las misiones a Marte (*Modern Spacecraft Guidance, Navigation, and Control*, Capítulo sobre *Entry, Descent, and Landing Systems*).

Cuando un rover es lanzado hacia la superficie marciana, el punto de impacto real rara vez coincide con el punto de referencia (target). Definimos la variable aleatoria continua X como el error radial de aterrizaje, es decir, la distancia euclidiana (en kilómetros) desde el centro del elipse de aterrizaje designado hasta el punto de impacto real.

Debido a que los errores en los ejes ortogonales (Norte y Este) suelen modelarse como variables normales independientes con media cero y misma varianza, la distancia radial resultante X sigue una **Distribución de Rayleigh** (mencionada en Devore, Ejercicios de la Sección 4.4). La FDP del error radial es:

$$f(x) = \begin{cases} \frac{x}{\sigma^2} e^{-x^2/(2\sigma^2)} & \text{para } x \geq 0 \\ 0 & \text{en otro caso} \end{cases}$$

donde σ es el parámetro de escala que representa la dispersión característica del sistema de navegación. Desarrollaremos las propiedades de esta distribución utilizando su FDA.

a) **Derivación de la FDA del Error Radial:** Para $x \geq 0$, calculamos la integral de la FDP. Utilizamos la sustitución $u = \frac{t^2}{2\sigma^2}$, de donde $du = \frac{t}{\sigma^2} dt$:

$$F(x) = \int_0^x \frac{t}{\sigma^2} e^{-t^2/(2\sigma^2)} dt = \int_0^{x^2/(2\sigma^2)} e^{-u} du$$

$$F(x) = [-e^{-u}]_0^{x^2/(2\sigma^2)} = 1 - e^{-x^2/(2\sigma^2)}$$

b) **Cálculo del CEP (Circular Error Probable):** En la literatura de GNC, el CEP es la métrica estándar de precisión. Se define como el radio del círculo centrado en el target que contiene el 50 %

de las probabilidades de impacto. Es, por definición, la mediana de la distribución radial. Igualamos la FDA a 0.5:

$$1 - e^{-m^2/(2\sigma^2)} = 0,5 \implies e^{-m^2/(2\sigma^2)} = 0,5$$

Aplicando el logaritmo natural:

$$-\frac{m^2}{2\sigma^2} = \ln(0,5) \implies m^2 = -2\sigma^2 \ln(0,5) = 2\sigma^2 \ln(2)$$

$$m = \sigma\sqrt{2\ln 2} \approx 1,1774\sigma$$

El CEP es aproximadamente $1,18\sigma$. Si el requisito de la misión dicta que el CEP no debe exceder los 5 km, el ingeniero de navegación sabe que debe diseñar el sistema para que $\sigma \leq 5/1,1774 \approx 4,24$ km.

c) Probabilidad de caer fuera de la zona de seguridad de 3σ : Las zonas de seguridad para evitar terrenos peligrosos (como cráteres o pendientes pronunciadas) suelen definirse como un radio de 3σ desde el centro. La probabilidad de que el rover aterrice fuera de esta zona segura es el complemento de la FDA evaluada en 3σ :

$$P(X > 3\sigma) = 1 - F(3\sigma) = 1 - \left(1 - e^{-(3\sigma)^2/(2\sigma^2)}\right) = e^{-9/2} = e^{-4,5} \approx 0,0111$$

Existe un 1.11 % de probabilidad de que el rover aterrice fuera de la zona de seguridad de 3σ . En misiones de miles de millones de dólares, este número se evalúa rigurosamente contra la topografía del sitio de aterrizaje.

d) Probabilidad condicional de dispersión extrema: Supongamos que los sensores de a bordo detectan anomalías en el viento durante el descenso, y se sabe con certeza que el rover ha aterrizado a más de 1σ del centro (es decir, ya está fuera de la zona de error nominal). Nos interesa calcular la probabilidad condicional de que el error sea aún mayor, superando los 2σ .

Usando la definición de probabilidad condicional (Devore, Capítulo 2) y la función de supervivencia $S(x) = 1 - F(x)$:

$$P(X > 2\sigma \mid X > \sigma) = \frac{P(X > 2\sigma \cap X > \sigma)}{P(X > \sigma)} = \frac{P(X > 2\sigma)}{P(X > \sigma)}$$

Evaluando los complementos de la FDA:

$$P(X > 2\sigma) = 1 - F(2\sigma) = e^{-4/2} = e^{-2}$$

$$P(X > \sigma) = 1 - F(\sigma) = e^{-1/2} = e^{-0,5}$$

Sustituyendo:

$$P(X > 2\sigma \mid X > \sigma) = \frac{e^{-2}}{e^{-0,5}} = e^{-1,5} \approx 0,2231$$

Dado que el rover ya ha caído fuera de la zona de 1σ , existe un 22.31 % de probabilidad de que su error radial supere los 2σ . Este tipo de razonamiento condicional, facilitado por la estructura de la FDA, permite a los algoritmos de a bordo tomar decisiones en tiempo real sobre si desplegar paracaídas de respaldo o activar propulsores de desvío de último minuto.

4.4. Valor esperado

Frecuentemente, necesitamos resumir la distribución de una variable aleatoria mediante un único valor que represente su centro de gravedad o tendencia central. El valor esperado de una variable aleatoria X , denotado como $E(X)$ o μ , es la media ponderada de sus posibles valores, donde los pesos son las probabilidades de ocurrencia (Devore, Capítulo 3, Sección 3.3 para variables discretas; Capítulo 4, Sección 4.2 para variables continuas).

Para una variable aleatoria discreta con función de masa de probabilidad $p(x)$, el valor esperado se define como:

$$E(X) = \sum_{x \in D} x \cdot p(x)$$

Para una variable aleatoria continua con función de densidad de probabilidad $f(x)$, la suma se reemplaza por una integral:

$$E(X) = \int_{-\infty}^{\infty} x \cdot f(x) dx$$

Si $g(X)$ es cualquier función matemática de la variable aleatoria X , el valor esperado de $g(X)$ se calcula aplicando la misma estructura de ponderación (Devore, Sección 3.3 y Sección 4.2):

$$E[g(X)] = \sum_{x \in D} g(x) \cdot p(x) \quad \text{o} \quad E[g(X)] = \int_{-\infty}^{\infty} g(x) \cdot f(x) dx$$

4.5. Varianza

Mientras que el valor esperado nos indica dónde está centrada la distribución, la varianza cuantifica la dispersión o variabilidad de los valores alrededor de dicha media. La varianza de una variable aleatoria X , denotada como $V(X)$ o σ^2 , se define como el valor esperado de la desviación al cuadrado con respecto a la media μ (Devore, Capítulo 3, Sección 3.3; Capítulo 4, Sección 4.2):

$$V(X) = E[(X - \mu)^2]$$

Aplicando la definición de valor esperado para una función de una variable aleatoria, las fórmulas operativas son:

$$V(X) = \sum_{x \in D} (x - \mu)^2 \cdot p(x) \quad \text{o} \quad V(X) = \int_{-\infty}^{\infty} (x - \mu)^2 \cdot f(x) dx$$

La desviación estándar, $\sigma_X = \sqrt{V(X)}$, se expresa en las mismas unidades que la variable original, lo que la hace más interpretable físicamente.

Para el cálculo práctico, la teoría proporciona una fórmula abreviada que evita integrar o sumar términos cuadráticos complejos. Expandiendo el binomio al cuadrado y utilizando las propiedades de linealidad del valor esperado, se demuestra que (Devore, Sección 3.3):

$$V(X) = E(X^2) - [E(X)]^2$$

4.5.1. Ejemplo 1: Demostración de la Fórmula Abreviada de la Varianza

Partimos de la definición fundamental de la varianza como el valor esperado de la desviación al cuadrado:

$$V(X) = E[(X - \mu)^2]$$

Expandimos el término cuadrático dentro de la esperanza matemática:

$$V(X) = E[X^2 - 2\mu X + \mu^2]$$

Aplicamos la propiedad de linealidad del valor esperado, la cual establece que la esperanza de una suma es la suma de las esperanzas, y que las constantes pueden factorizarse fuera del operador E :

$$V(X) = E(X^2) - E(2\mu X) + E(\mu^2)$$

$$V(X) = E(X^2) - 2\mu E(X) + E(\mu^2)$$

Dado que μ es una constante (el valor esperado de X), sabemos que $E(X) = \mu$. Además, el valor esperado de una constante es la constante misma, por lo que $E(\mu^2) = \mu^2$. Sustituimos estos valores en la ecuación:

$$V(X) = E(X^2) - 2\mu(\mu) + \mu^2$$

$$V(X) = E(X^2) - 2\mu^2 + \mu^2$$

Simplificando los términos algebraicos, obtenemos el resultado deseado:

$$V(X) = E(X^2) - \mu^2$$

Y dado que $\mu = E(X)$, reescribimos la expresión final como:

$$V(X) = E(X^2) - [E(X)]^2$$

4.5.2. Ejemplo 2: Propagación de Error en el Sistema de Magnitudes Fotométricas

En la astronomía observacional, la relación entre el flujo físico medido por un detector y la magnitud aparente reportada en los catálogos es altamente no lineal. Inspirados en los principios de fotometría y propagación de errores (*Astronomical Measurement*, Capítulo sobre *Photometry and Magnitudes*), analizaremos un problema complejo de transformación de variables aleatorias continuas.

La magnitud aparente m de una fuente astrofísica se define en función de su flujo medido f mediante la ecuación:

$$m = -2,5 \log_{10}(f) + C$$

donde C es el punto cero fotométrico (una constante instrumental).

Supongamos que, debido a las características de ruido de un detector en el límite de sensibilidad o a la distribución estadística de una población de fuentes débiles, el flujo f sigue una distribución exponencial con parámetro de tasa $\lambda > 0$. La función de densidad de probabilidad del flujo es:

$$g(f) = \lambda e^{-\lambda f}, \quad \text{para } f > 0$$

Nuestro objetivo es calcular el valor esperado $E(m)$ y la varianza $V(m)$ de la magnitud fotométrica.

Paso 1: Reformulación de la variable aleatoria Para facilitar el cálculo integral, convertimos el logaritmo en base 10 a logaritmo natural utilizando la identidad $\log_{10}(f) = \frac{\ln(f)}{\ln(10)}$. Definimos la constante de escala $k = \frac{2.5}{\ln(10)} \approx 1,0857$. La magnitud se reescribe como:

$$m = -k \ln(f) + C$$

Paso 2: Cálculo del Valor Esperado $E(m)$ Aplicamos la definición de valor esperado para una función de una variable aleatoria continua (Devore, Sección 4.2):

$$E(m) = \int_0^\infty [-k \ln(f) + C] \lambda e^{-\lambda f} df$$

Realizamos un cambio de variable: sea $x = \lambda f$, de donde $df = \frac{dx}{\lambda}$ y $\ln(f) = \ln(x/\lambda) = \ln(x) - \ln(\lambda)$. La integral se transforma en:

$$E(m) = \int_0^\infty [-k(\ln(x) - \ln(\lambda)) + C] e^{-x} dx$$

$$E(m) = \int_0^\infty [-k \ln(x) + k \ln(\lambda) + C] e^{-x} dx$$

Separamos la integral en tres términos. Para resolverla, invocamos las derivadas de la función Gamma $\Gamma(z) = \int_0^\infty x^{z-1} e^{-x} dx$ evaluadas en $z = 1$. Sabemos que $\int_0^\infty e^{-x} dx = 1$ y que la primera derivada $\Gamma'(1) = \int_0^\infty \ln(x) e^{-x} dx = -\gamma$, donde $\gamma \approx 0,5772$ es la constante de Euler-Mascheroni. Sustituyendo estos resultados:

$$E(m) = -k(-\gamma) + (k \ln(\lambda) + C)(1)$$

$$E(m) = k(\gamma + \ln(\lambda)) + C$$

Paso 3: Cálculo de la Varianza $V(m)$ Calcular $V(m)$ mediante $E(m^2) - [E(m)]^2$ sería algebraicamente tedioso. Es mucho más elegante utilizar la definición $V(m) = E[(m - E(m))^2]$. Primero, evaluamos la desviación de la magnitud respecto a su media:

$$m - E(m) = [-k \ln(x) + k \ln(\lambda) + C] - [k\gamma + k \ln(\lambda) + C]$$

$$m - E(m) = -k(\ln(x) + \gamma)$$

Ahora, calculamos el valor esperado del cuadrado de esta desviación:

$$V(m) = \int_0^\infty [-k(\ln(x) + \gamma)]^2 e^{-x} dx = k^2 \int_0^\infty (\ln(x) + \gamma)^2 e^{-x} dx$$

Expandimos el binomio al cuadrado dentro de la integral:

$$V(m) = k^2 \left[\int_0^\infty (\ln(x))^2 e^{-x} dx + 2\gamma \int_0^\infty \ln(x) e^{-x} dx + \gamma^2 \int_0^\infty e^{-x} dx \right]$$

Para la primera integral, requerimos la segunda derivada de la función Gamma en $z = 1$, la cual es un resultado conocido en cálculo avanzado: $\Gamma''(1) = \int_0^\infty (\ln(x))^2 e^{-x} dx = \gamma^2 + \frac{\pi^2}{6}$. Sustituyendo las tres integrales conocidas:

$$V(m) = k^2 \left[\left(\gamma^2 + \frac{\pi^2}{6} \right) + 2\gamma(-\gamma) + \gamma^2(1) \right]$$

Al simplificar los términos dentro del corchete, observamos una cancelación exacta de las constantes de Euler-Mascheroni:

$$\gamma^2 + \frac{\pi^2}{6} - 2\gamma^2 + \gamma^2 = \frac{\pi^2}{6}$$

Por lo tanto, la varianza de la magnitud fotométrica es:

$$V(m) = k^2 \frac{\pi^2}{6}$$

Sustituyendo el valor de la constante $k = \frac{2,5}{\ln(10)}$, obtenemos el resultado final:

$$V(m) = \left(\frac{2,5}{\ln(10)} \right)^2 \frac{\pi^2}{6} \approx 1,939$$

Conclusión: La varianza de la magnitud $V(m)$ depende exclusivamente de constantes matemáticas puras (π y el factor de escala logarítmico $2,5/\ln(10)$). Es completamente independiente del parámetro de escala del flujo λ y del punto cero instrumental C . Esto demuestra que, bajo un modelo de flujo exponencial, la dispersión estadística en el sistema de magnitudes está intrínsecamente acotada por la geometría de la transformación logarítmica, un hecho crucial para calibrar los límites de detección y las incertidumbres sistemáticas en sondeos astronómicos de gran profundidad.

Clase 5

5.1. Distribución de probabilidad binomial

En el modelado de fenómenos astronómicos y aeroespaciales, frecuentemente nos enfrentamos a experimentos que consisten en una secuencia de observaciones o ensayos repetidos, donde cada uno solo puede resultar en dos categorías mutuamente excluyentes: éxito o fracaso. Un experimento binomial satisface rigurosamente las siguientes cuatro condiciones (Devore, Capítulo 3, Sección 3.4):

1. El experimento consta de un número fijo n de ensayos.
2. Cada ensayo puede dar por resultado uno de dos posibles resultados: éxito (E) o fracaso (F).
3. La probabilidad de éxito, denotada por p , es constante de un ensayo a otro.
4. Los ensayos son independientes entre sí.

Si definimos la variable aleatoria discreta X como el número total de éxitos observados en los n ensayos, decimos que X sigue una distribución binomial con parámetros n y p , denotado como $X \sim \text{Bin}(n, p)$. La función de masa de probabilidad (FMP) se deriva combinando la probabilidad de cualquier secuencia específica de éxitos y fracasos con el número de formas en que dicha secuencia puede ocurrir (combinaciones). La FMP está dada por:

$$b(x; n, p) = \binom{n}{x} p^x (1-p)^{n-x} \quad \text{para } x = 0, 1, 2, \dots, n$$

Las características fundamentales de esta distribución, que resumen su tendencia central y dispersión, son su valor esperado y su varianza (Devore, Sección 3.4):

$$E(X) = np$$

$$V(X) = np(1-p)$$

5.1.1. Ejemplo 1: Demostración de la Moda de la Distribución Binomial

Para encontrar el valor de x que maximiza $b(x; n, p)$, analizamos la razón entre probabilidades consecutivas. Esto nos indica cuándo la función está creciendo y cuándo empieza a decrecer. Calculamos la razón $R(x)$:

$$R(x) = \frac{b(x; n, p)}{b(x-1; n, p)} = \frac{\frac{n!}{x!(n-x)!} p^x (1-p)^{n-x}}{\frac{n!}{(x-1)!(n-x+1)!} p^{x-1} (1-p)^{n-x+1}}$$

Al simplificar los factoriales y las potencias de p y $(1-p)$, obtenemos:

$$R(x) = \frac{(x-1)!(n-x+1)!}{x!(n-x)!} \cdot \frac{p}{1-p} = \frac{n-x+1}{x} \cdot \frac{p}{1-p}$$

La probabilidad $b(x; n, p)$ es mayor o igual que $b(x - 1; n, p)$ siempre y cuando $R(x) \geq 1$. Establezcamos la desigualdad:

$$\frac{n - x + 1}{x} \cdot \frac{p}{1 - p} \geq 1$$

Multiplicamos ambos lados por $x(1 - p)$ (dado que $x > 0$ y $0 < p < 1$, el denominador es positivo y la desigualdad se mantiene):

$$(n - x + 1)p \geq x(1 - p)$$

$$np - xp + p \geq x - xp$$

Sumamos xp a ambos lados y reagrupamos los términos con x :

$$np + p \geq x$$

$$x \leq (n + 1)p$$

Este resultado nos indica que la función de masa de probabilidad $b(x; n, p)$ es estrictamente creciente para todos los valores de x que satisfacen $x \leq (n + 1)p$, y es estrictamente decreciente para $x > (n + 1)p$. Por lo tanto, el valor máximo se alcanza en el mayor entero que cumple la condición de crecimiento, el cual es exactamente la parte entera de $(n + 1)p$.

$$\text{Moda} = \lfloor (n + 1)p \rfloor$$

5.1.2. Ejemplo 2: Demostración del k -ésimo momento factorial de la distribución binomial

Sea $X \sim \text{Bin}(n, p)$ una variable aleatoria binomial. Definimos el factorial descendente de orden k como $X^{(k)} = X(X - 1)(X - 2) \cdots (X - k + 1)$, con la convención de que $X^{(k)} = 0$ si $X < k$.

Para calcular $E[X^{(k)}]$, aplicamos la definición del valor esperado de una función de una variable aleatoria discreta (Devore, Capítulo 3, Sección 3.3):

$$E[X^{(k)}] = \sum_{x=0}^n x^{(k)} \cdot P(X = x)$$

Sustituimos la función de masa de probabilidad binomial $P(X = x) = \binom{n}{x} p^x (1 - p)^{n-x}$ y la expresión explícita del factorial descendente $x^{(k)} = \frac{x!}{(x-k)!}$:

$$E[X^{(k)}] = \sum_{x=0}^n \frac{x!}{(x-k)!} \binom{n}{x} p^x (1 - p)^{n-x}$$

Dado que $\frac{x!}{(x-k)!} = 0$ para todo $x < k$, los términos desde $x = 0$ hasta $x = k - 1$ son nulos. Por lo tanto, podemos ajustar el límite inferior de la sumatoria a $x = k$:

$$E[X^{(k)}] = \sum_{x=k}^n \frac{x!}{(x-k)!} \frac{n!}{x!(n-x)!} p^x (1-p)^{n-x}$$

Cancelamos $x!$ en el numerador y denominador del coeficiente combinatorio:

$$E[X^{(k)}] = \sum_{x=k}^n \frac{n!}{(x-k)!(n-x)!} p^x (1-p)^{n-x}$$

El objetivo analítico es factorizar la sumatoria para que adopte la forma de una expansión binomial completa. Para ello, multiplicamos y dividimos por $(n-k)!$ dentro de la sumatoria:

$$E[X^{(k)}] = \frac{n!}{(n-k)!} \sum_{x=k}^n \frac{(n-k)!}{(x-k)!(n-x)!} p^x (1-p)^{n-x}$$

Reconocemos que el término fraccionario es exactamente el coeficiente binomial $\binom{n-k}{x-k}$. Además, extraemos el factor constante $\frac{n!}{(n-k)!} = n^{(k)}$ fuera de la sumatoria:

$$E[X^{(k)}] = n^{(k)} \sum_{x=k}^n \binom{n-k}{x-k} p^x (1-p)^{n-x}$$

Realizamos un cambio de índice para simplificar la sumatoria. Sea $y = x - k$. Entonces $x = y + k$. Los límites de la sumatoria se transforman de la siguiente manera: cuando $x = k$, $y = 0$; cuando $x = n$, $y = n - k$. Sustituimos en la expresión:

$$E[X^{(k)}] = n^{(k)} \sum_{y=0}^{n-k} \binom{n-k}{y} p^{y+k} (1-p)^{n-(y+k)}$$

Separamos las potencias de p y reagrupamos los exponentes de $(1-p)$:

$$E[X^{(k)}] = n^{(k)} p^k \sum_{y=0}^{n-k} \binom{n-k}{y} p^y (1-p)^{(n-k)-y}$$

La sumatoria restante es exactamente la expansión del Teorema del Binomio para el exponente $m = n - k$:

$$\sum_{y=0}^{n-k} \binom{n-k}{y} p^y (1-p)^{(n-k)-y} = (p + (1-p))^{n-k} = 1^{n-k} = 1$$

Al sustituir este resultado unitario en la expresión anterior, obtenemos directamente el teorema demostrado:

$$E[X^{(k)}] = n^{(k)}p^k = \frac{n!}{(n-k)!}p^k$$

5.1.3. Ejemplo 3: Momentos de Orden Superior en la Integración de Señales de Radar Planetario

En la astronomía de radar (como las observaciones realizadas por la Red del Espacio Profundo o el Goldstone Solar System Radar), se envían secuencias de pulsos electromagnéticos hacia un asteroide. Debido a la topografía irregular y la rotación del cuerpo, la coherencia de fase de la señal reflejada puede variar.

Modelaremos un escenario simplificado pero físicamente motivado: se transmiten n pulsos. Cada pulso tiene una probabilidad p de regresar con la fase coherente necesaria para la integración constructiva. Sea $X \sim \text{Bin}(n, p)$ el número de pulsos coherentes recibidos. Debido a las no linealidades en el receptor de correlación y a la física de la dispersión, la potencia de la señal integrada Y es proporcional al cuadrado del número de pulsos coherentes, es decir, $Y = cX^2$, donde c es una constante instrumental.

Para caracterizar la estabilidad del radiómetro y calcular el índice de centelleo (scintillation index), necesitamos determinar el valor esperado $E(Y)$ y, de manera crucial, la varianza $V(Y)$. Calcular $V(Y)$ requiere hallar el cuarto momento ordinario de la distribución binomial, $E(X^4)$.

Paso 1: Cálculo de $E(Y)$ Sabemos que $E(X) = np$ y $V(X) = np(1-p)$. Utilizando la relación $V(X) = E(X^2) - [E(X)]^2$, despejamos el segundo momento:

$$E(X^2) = V(X) + [E(X)]^2 = np(1-p) + n^2p^2$$

Por lo tanto, el valor esperado de la potencia es:

$$E(Y) = cE(X^2) = c[np(1-p) + n^2p^2]$$

Paso 2: Estrategia para el cuarto momento usando Factoriales Descendentes Calcular $E(X^4)$ directamente sumando $x^4b(x; n, p)$ es algebraicamente tedioso. Es mucho más elegante utilizar los momentos factoriales. Definimos el factorial descendente como $X^{(k)} = X(X-1) \cdots (X-k+1)$. Para una variable binomial, el valor esperado de su factorial descendente es notablemente simple (Devore, Sección 3.3 y ejercicios de la Sección 3.4):

$$E[X^{(k)}] = n^{(k)}p^k = \frac{n!}{(n-k)!}p^k$$

Debemos expresar la potencia ordinaria X^4 en términos de factoriales descendentes. Mediante expansión algebraica (o usando los números de Stirling de segunda especie), obtenemos:

$$X^2 = X^{(2)} + X^{(1)}$$

$$X^3 = X^{(3)} + 3X^{(2)} + X^{(1)}$$

$$X^4 = X^{(4)} + 6X^{(3)} + 7X^{(2)} + X^{(1)}$$

Paso 3: Cálculo de $E(X^4)$ Aplicamos la linealidad del valor esperado y la fórmula del momento factorial:

$$E(X^4) = E[X(X-1)(X-2)(X-3)] + 6E[X(X-1)(X-2)] + 7E[X(X-1)(X-2)] + E[X(X-1)]$$

$$E(X^4) = n(n-1)(n-2)(n-3)p^4 + 6n(n-1)(n-2)p^3 + 7n(n-1)p^2 + np$$

Para facilitar el cálculo de la varianza, expandimos esta expresión agrupando por potencias de n :

$$E(X^4) = n^4 p^4 + 6n^3 p^3(1-p) + n^2 p^2(1-p)(11p-7) + np(1-p)(1-6p+6p^2)$$

Paso 4: Cálculo de la Varianza $V(Y)$ La varianza de la potencia integrada es $V(Y) = c^2 V(X^2) = c^2 [E(X^4) - (E(X^2))^2]$. Primero, elevamos al cuadrado el segundo momento que obtuvimos en el Paso 1:

$$(E(X^2))^2 = [n^2 p^2 + np(1-p)]^2 = n^4 p^4 + 2n^3 p^3(1-p) + n^2 p^2(1-p)^2$$

Ahora restamos $(E(X^2))^2$ de $E(X^4)$. Observamos que los términos de orden n^4 se cancelan exactamente. Para los términos de orden n^3 :

$$6n^3 p^3(1-p) - 2n^3 p^3(1-p) = 4n^3 p^3(1-p)$$

Para los términos de orden n^2 , factorizamos $n^2 p^2(1-p)$:

$$n^2 p^2(1-p)[(11p-7) - (1-p)] = n^2 p^2(1-p)[12p-8] = 4n^2 p^2(1-p)(3p-2)$$

El término de orden n permanece intacto ya que no hay términos cuadráticos cruzados que lo afecten en $(E(X^2))^2$:

$$np(1-p)(1-6p+6p^2)$$

Sumando todo y factorizando el término común $np(1-p)$, obtenemos la expresión final para la varianza de X^2 :

$$V(X^2) = np(1-p) [4n^2 p^2 + 4np(3p-2) + (1-6p+6p^2)]$$

Finalmente, la varianza de la potencia de la señal de radar es:

$$V(Y) = c^2 np(1-p) [4n^2 p^2 + 4np(3p-2) + (1-6p+6p^2)]$$

Conclusión: La expresión entre corchetes revela cómo la varianza de la señal integrada escala con n^2 para un número grande de pulsos, dominada por el término $4n^2 p^2$. En el diseño de sistemas de radar planetario (inspirado en los principios de *Astronomical Measurement* y procesamiento de señales), conocer esta varianza exacta permite a los ingenieros dimensionar los tiempos de integración necesarios para que la relación señal-ruido de la potencia (que depende de $V(Y)$) supere los umbrales de detección de características superficiales en asteroides, evitando así sobreestimar la calidad de la imagen si se asumiera erróneamente una distribución gaussiana para X^2 .

5.1.4. Ejemplo 4: Interferometría de Línea de Base Larga con Enjambre de Nanosatélites

Principios de síntesis de apertura y diseño de arreglos distribuidos (*Astronomical Measurement, Capítulo sobre Interferometry and Aperture Synthesis*).

Una agencia espacial despliega una constelación de $n = 10$ nanosatélites idénticos en órbita lunar para formar un interferómetro de radio de línea de base larga. El objetivo científico es resolver la estructura fina de las emisiones de máseres en regiones de formación estelar. Para que el arreglo funcione y se pueda sintetizar una imagen, cada par de nanosatélites que logre establecer un enlace óptico de fase coherente genera una línea base interferométrica independiente.

El proceso de despliegue y establecimiento de enlaces es estocástico. Definimos la variable aleatoria X como el número de nanosatélites que logran establecer el enlace con éxito. Dado que cada satélite opera de manera independiente y tiene la misma probabilidad p de éxito, X sigue una distribución binomial:

$$X \sim \text{Bin}(10, p)$$

La métrica de rendimiento científico de la misión, denotada como Y , es el número total de líneas base interferométricas únicas que se pueden formar con los X satélites operativos. Combinatorialmente, esto corresponde a elegir 2 satélites de los X disponibles:

$$Y = \binom{X}{2} = \frac{X(X-1)}{2}$$

a) Expresión de Y mediante factoriales descendentes Para facilitar el cálculo de los momentos de Y , reescribimos la variable en términos del factorial descendente de orden 2, definido como $X^{(2)} = X(X-1)$:

$$Y = \frac{1}{2}X^{(2)}$$

b) Cálculo del número esperado de líneas base Aplicamos la propiedad de linealidad del valor esperado y el teorema del k -ésimo momento factorial de la distribución binomial (Devore, Capítulo 3, Sección 3.3 y Sección 3.4), el cual establece que $E[X^{(k)}] = n^{(k)}p^k$. Para $k = 2$ y $n = 10$:

$$E(Y) = \frac{1}{2}E[X^{(2)}] = \frac{1}{2}n^{(2)}p^2 = \frac{1}{2}(10 \times 9)p^2 = 45p^2$$

El rendimiento científico esperado escala cuadráticamente con la probabilidad de éxito individual de los nanosatélites.

c) Cálculo de la varianza del rendimiento científico Determinar la varianza de Y requiere calcular $V(Y) = V\left(\frac{1}{2}X^{(2)}\right) = \frac{1}{4}V(X^{(2)})$. Para hallar $V(X^{(2)})$, necesitamos el segundo momento de $X^{(2)}$, es decir, $E[(X^{(2)})^2]$. En lugar de expandir tediosamente las potencias ordinarias X^4 , utilizamos la propiedad de que el producto de factoriales descendentes puede expresarse como una combinación lineal de factoriales descendentes de mayor orden. Específicamente, desarrollamos $[X(X-1)]^2 = X^2(X-1)^2$. Reescribiendo $X^2 = X^{(2)} + X^{(1)}$ y $(X-1)^2 = (X-1)(X-2) + (X-1) = X_{desplazado}^{(2)} + X_{desplazado}^{(1)}$, o más directamente, expandiendo y convirtiendo a factoriales descendentes:

$$[X(X-1)]^2 = X^4 - 2X^3 + X^2$$

Sustituyendo las potencias ordinarias por sus equivalentes en factoriales descendentes ($X^2 = X^{(2)} + X^{(1)}$, $X^3 = X^{(3)} + 3X^{(2)} + X^{(1)}$, $X^4 = X^{(4)} + 6X^{(3)} + 7X^{(2)} + X^{(1)}$):

$$[X(X-1)]^2 = X^{(4)} + 4X^{(3)} + 2X^{(2)}$$

Aplicando el valor esperado a cada término usando $E[X^{(k)}] = n^{(k)}p^k$:

$$E[(X^{(2)})^2] = n^{(4)}p^4 + 4n^{(3)}p^3 + 2n^{(2)}p^2$$

Para $n = 10$, los factoriales descendentes son $10^{(4)} = 5040$, $10^{(3)} = 720$, y $10^{(2)} = 90$. Sustituyendo:

$$E[(X^{(2)})^2] = 5040p^4 + 2880p^3 + 180p^2$$

Ahora, calculamos la varianza de $X^{(2)}$ restando el cuadrado de su media, $(E[X^{(2)}])^2 = (90p^2)^2 = 8100p^4$:

$$V(X^{(2)}) = (5040p^4 + 2880p^3 + 180p^2) - 8100p^4 = 180p^2 + 2880p^3 - 3060p^4$$

Finalmente, la varianza del número de líneas base es:

$$V(Y) = \frac{1}{4}V(X^{(2)}) = 45p^2 + 720p^3 - 765p^4$$

Esta expresión cuantifica exactamente cómo la incertidumbre en el despliegue de los satélites se amplifica no linealmente en la degradación de la calidad de la imagen interferométrica.

d) Requisito de la misión y probabilidad mínima de despliegue Los algoritmos de síntesis de apertura (*Astronomical Measurement*, Sección sobre *Image Reconstruction*) dictan que para lograr la relación señal-ruido requerida en el tiempo de integración asignado, el arreglo debe tener un valor esperado de al menos 30 líneas base independientes. Planteamos la desigualdad:

$$E(Y) \geq 30$$

$$45p^2 \geq 30$$

$$p^2 \geq \frac{30}{45} = \frac{2}{3}$$

$$p \geq \sqrt{\frac{2}{3}} \approx 0,8165$$

Conclusión Para garantizar el éxito científico de la misión, la ingeniería de los nanosatélites debe asegurar que la probabilidad de establecer el enlace óptico sea de al menos un 81.65 %.

Clase 6

6.1. Distribución de Poisson

En la modelación de fenómenos astronómicos, existe una clase fundamental de experimentos que no se basan en un número fijo de ensayos, sino en la ocurrencia de eventos a lo largo de un intervalo continuo de tiempo o de espacio. La distribución de Poisson es el modelo probabilístico por excelencia para el conteo de este tipo de eventos (Devore, Capítulo 3, Sección 3.6).

Sea $N(t)$ la variable aleatoria que representa el número de eventos ocurridos en el intervalo de tiempo $[0, t]$. Las condiciones estrictas que definen un proceso de Poisson homogéneo con tasa $\lambda > 0$ se expresan matemáticamente analizando un intervalo infinitesimal $(t, t + \Delta t]$, donde $\Delta t \rightarrow 0$:

1. Independencia de incrementos: Los eventos que ocurren en intervalos de tiempo disjuntos (no traslapantes) son estadísticamente independientes. Para cualesquiera $0 \leq t_1 < t_2 \leq t_3 < t_4$:

$$P\left(N(t_2) - N(t_1) = k_1 \cap N(t_4) - N(t_3) = k_2\right) = P\left(N(t_2) - N(t_1) = k_1\right) \cdot P\left(N(t_4) - N(t_3) = k_2\right)$$

2. Probabilidad de exactamente un evento (proporcional a Δt): La probabilidad de que ocurra exactamente un evento en el intervalo infinitesimal $(t, t + \Delta t]$ es proporcional a la duración del intervalo, donde λ es la constante de proporcionalidad (tasa de ocurrencia):

$$P\left(N(t + \Delta t) - N(t) = 1\right) = \lambda \Delta t + o(\Delta t)$$

donde $o(\Delta t)$ denota un término que tiende a cero más rápido que Δt cuando $\Delta t \rightarrow 0$ (es decir, $\lim_{\Delta t \rightarrow 0} \frac{o(\Delta t)}{\Delta t} = 0$).

3. Probabilidad de cero eventos: Dado que la suma de todas las probabilidades en el intervalo debe ser 1, la probabilidad de que no ocurra ningún evento es:

$$P\left(N(t + \Delta t) - N(t) = 0\right) = 1 - \lambda \Delta t + o(\Delta t)$$

4. Probabilidad de dos o más eventos (despreciable): La probabilidad de que ocurran dos o más eventos simultáneamente en el intervalo infinitesimal es despreciable, lo que significa que es de un orden de magnitud superior a Δt :

$$P\left(N(t + \Delta t) - N(t) \geq 2\right) = o(\Delta t)$$

$$\lim_{\Delta t \rightarrow 0} \frac{P\left(N(t + \Delta t) - N(t) \geq 2\right)}{\Delta t} = 0$$

Si definimos la variable aleatoria discreta X como el número de eventos que ocurren en un intervalo de longitud t , y λ representa la tasa promedio de ocurrencia por unidad de intervalo, la función de masa de probabilidad está dada por:

$$p(x; \lambda t) = \frac{e^{-\lambda t} (\lambda t)^x}{x!} \quad \text{para } x = 0, 1, 2, \dots$$

Las propiedades de esperanza y varianza son idénticas y coinciden con el parámetro de la distribución:

$$E(X) = V(X) = \lambda t$$

6.2. Distribuciones continuas

Mientras que las distribuciones discretas como la de Poisson modelan conteos enteros, la mayoría de las mediciones físicas en astronomía y navegación espacial (como el tiempo de llegada de un fotón, la posición angular de un astro, o el flujo de energía) son variables continuas. Una variable aleatoria continua X toma valores en un intervalo de la recta real, y su comportamiento se describe mediante una función de densidad de probabilidad (FDP) $f(x)$ (Devore, Capítulo 4, Sección 4.1).

Las propiedades fundamentales de $f(x)$ son:

$$f(x) \geq 0 \quad \text{para todo } x$$

$$\int_{-\infty}^{\infty} f(x) dx = 1$$

$$P(a \leq X \leq b) = \int_a^b f(x) dx$$

6.2.1. Ejemplo 1: Demostración de la Propiedad de Reproductividad en Procesos de Poisson

Teorema: Sean X y Y dos variables aleatorias independientes tales que $X \sim \text{Poisson}(\lambda_1)$ y $Y \sim \text{Poisson}(\lambda_2)$. Entonces, la variable aleatoria $Z = X + Y$ sigue una distribución de Poisson con parámetro $\lambda_1 + \lambda_2$.

Demostración: Dado que X y Y son variables aleatorias discretas e independientes, la función de masa de probabilidad de su suma Z se obtiene mediante la convolución de sus respectivas distribuciones (Devore, Capítulo 5, Sección sobre Distribuciones de probabilidad conjunta). Para un valor entero no negativo z , la probabilidad de que $Z = z$ es:

$$P(Z = z) = \sum_{x=0}^z P(X = x) \cdot P(Y = z - x)$$

Sustituimos la función de masa de probabilidad de Poisson para X y Y :

$$P(Z = z) = \sum_{x=0}^z \left(\frac{e^{-\lambda_1} \lambda_1^x}{x!} \right) \left(\frac{e^{-\lambda_2} \lambda_2^{z-x}}{(z-x)!} \right)$$

Extraemos las constantes exponenciales fuera de la sumatoria, ya que no dependen del índice de suma x :

$$P(Z = z) = e^{-(\lambda_1 + \lambda_2)} \sum_{x=0}^z \frac{\lambda_1^x \lambda_2^{z-x}}{x!(z-x)!}$$

Para reconocer una expansión binomial en la sumatoria, multiplicamos y dividimos la expresión por $z!$:

$$P(Z = z) = \frac{e^{-(\lambda_1 + \lambda_2)}}{z!} \sum_{x=0}^z \frac{z!}{x!(z-x)!} \lambda_1^x \lambda_2^{z-x}$$

El término fraccionario es exactamente el coeficiente binomial $\binom{z}{x}$. Reescribimos la sumatoria:

$$P(Z = z) = \frac{e^{-(\lambda_1 + \lambda_2)}}{z!} \sum_{x=0}^z \binom{z}{x} \lambda_1^x \lambda_2^{z-x}$$

Aplicamos el Teorema del Binomio de Newton, el cual establece que $\sum_{x=0}^z \binom{z}{x} a^x b^{z-x} = (a + b)^z$. En nuestro caso, $a = \lambda_1$ y $b = \lambda_2$:

$$\sum_{x=0}^z \binom{z}{x} \lambda_1^x \lambda_2^{z-x} = (\lambda_1 + \lambda_2)^z$$

Sustituimos este resultado de vuelta en la ecuación de $P(Z = z)$:

$$P(Z = z) = \frac{e^{-(\lambda_1 + \lambda_2)} (\lambda_1 + \lambda_2)^z}{z!}$$

Esta expresión final es exactamente la función de masa de probabilidad de una distribución de Poisson evaluada en z , con parámetro $\lambda = \lambda_1 + \lambda_2$. Por lo tanto, queda demostrado que $Z \sim \text{Poisson}(\lambda_1 + \lambda_2)$.

6.2.2. Ejemplo 2: Del Conteo de Fotones al Tiempo de Espera y la Función Gamma

Consideremos un escenario de instrumentación astronómica de alta energía, inspirado en los principios de detectores de rayos X y tiempos de llegada (*Astronomical Measurement*, Capítulo sobre *Detectors and Instruments*).

Un telescopio espacial observa una binaria de rayos X tenue. Los fotones llegan al detector siguiendo un proceso de Poisson con una tasa constante λ (fotones por segundo).

Paso 1: Derivación de la distribución continua del tiempo de llegada Sea X la variable aleatoria continua que representa el tiempo exacto (en segundos) transcurrido desde el inicio de la observación hasta la llegada del *primer* fotón. Para encontrar la función de distribución acumulativa (FDA) de X , notamos que el evento $\{X > x\}$ es equivalente a que *no llegue ningún fotón* en el intervalo de tiempo $[0, x]$.

Utilizando la distribución de Poisson con $t = x$ y evaluando en $x = 0$ eventos:

$$P(X > x) = P(N = 0) = \frac{e^{-\lambda x}(\lambda x)^0}{0!} = e^{-\lambda x}$$

Por lo tanto, la FDA de X es $F(x) = P(X \leq x) = 1 - P(X > x) = 1 - e^{-\lambda x}$. Derivando la FDA, obtenemos la función de densidad de probabilidad continua (la distribución Exponencial):

$$f(x) = \lambda e^{-\lambda x} \quad \text{para } x > 0$$

Paso 2: Un problema de valor esperado no trivial El sistema de rastreo del telescopio utiliza un algoritmo de bloqueo que introduce una penalización de ruido térmico en el procesador de señales. Esta penalización es inversamente proporcional a la raíz cuadrada del tiempo de llegada del primer fotón, modelada por la función $g(X) = \frac{1}{\sqrt{X}}$.

Para dimensionar los filtros de software, los ingenieros deben calcular el valor esperado de esta penalización, es decir, $E\left[\frac{1}{\sqrt{X}}\right]$. Este cálculo requiere evaluar una integral impropia que no tiene una solución elemental directa, pero que se resuelve elegantemente utilizando la función Gamma.

Aplicamos la definición de valor esperado para variables continuas (Devore, Sección 4.2):

$$E\left[\frac{1}{\sqrt{X}}\right] = \int_0^\infty \frac{1}{\sqrt{x}} \lambda e^{-\lambda x} dx$$

Para resolver esta integral, realizamos un cambio de variable. Sea $u = \lambda x$, de donde $x = \frac{u}{\lambda}$ y $dx = \frac{du}{\lambda}$. Sustituyendo en la integral:

$$E\left[\frac{1}{\sqrt{X}}\right] = \int_0^\infty \left(\frac{u}{\lambda}\right)^{-1/2} \lambda e^{-u} \frac{du}{\lambda}$$

Simplificando los términos algebraicos y las constantes:

$$E\left[\frac{1}{\sqrt{X}}\right] = \int_0^\infty \sqrt{\lambda} u^{-1/2} e^{-u} \frac{du}{\lambda} \cdot \lambda = \sqrt{\lambda} \int_0^\infty u^{-1/2} e^{-u} du$$

En este punto, reconocemos que la integral restante es exactamente la definición de la función Gamma, $\Gamma(z) = \int_0^\infty t^{z-1} e^{-t} dt$, evaluada en $z - 1 = -1/2$, lo que implica $z = 1/2$.

$$\int_0^\infty u^{-1/2} e^{-u} du = \Gamma\left(\frac{1}{2}\right)$$

$\Gamma(1/2) = \sqrt{\pi}$. Sustituyendo este valor, obtenemos el resultado final:

$$E\left[\frac{1}{\sqrt{X}}\right] = \sqrt{\pi\lambda}$$

Conclusión En el contexto de la ingeniería espacial, conocer que esta penalización esperada escala con $\sqrt{\lambda}$ permite a los diseñadores predecir cómo aumentará el ruido procesado si la fuente astrofísica se vuelve más brillante (mayor λ), asegurando que los umbrales de descarte de datos se ajusten dinámicamente según la física fundamental del detector.

6.3. Percentiles

En el estudio de las variables aleatorias continuas, a menudo no basta con conocer la probabilidad de que una variable caiga en un intervalo; es fundamental poder identificar valores específicos que actúen como umbrales o puntos de corte que dividan la distribución en proporciones conocidas. Para cualquier número p tal que $0 < p < 1$, el percentil $(100p)$ de una distribución continua con función de densidad $f(x)$ y función de distribución acumulativa $F(x)$ es el valor numérico x_p que satisface la siguiente condición (Devore, Capítulo 4, Sección 4.2):

$$F(x_p) = \int_{-\infty}^{x_p} f(x) dx = p$$

Geométricamente, x_p es el valor sobre el eje horizontal tal que el área bajo la curva de densidad a la izquierda de x_p es exactamente p . Esto significa que una fracción p de la población o de la distribución de probabilidad cae por debajo de x_p , y una fracción $1 - p$ cae por encima.

Algunos percentiles reciben nombres especiales debido a su utilidad para resumir la tendencia central y la dispersión de los datos. El percentil 50 ($p = 0,5$) se denomina *mediana* de la distribución, el cual divide el área bajo la curva en dos mitades iguales. Los percentiles 25 y 75 ($p = 0,25$ y $p = 0,75$) se conocen como el *primer* y *tercer cuartil*, respectivamente, y son ampliamente utilizados para definir el rango intercuartílico, una medida robusta de variabilidad.

6.4. Distribución normal

Sin duda, la distribución de probabilidad más importante y ubicua en toda la estadística y en las ciencias físicas es la distribución normal. Como se detalla en *Astronomical Measurement* (Apéndice sobre *Error Analysis and Probability Distributions*), la mayoría de los errores de medición instrumentales y el ruido térmico en los detectores astrofísicos siguen este modelo, gracias al Teorema del Límite Central.

Se dice que una variable aleatoria continua X tiene una distribución normal con parámetros de media μ (donde $-\infty < \mu < \infty$) y desviación estándar σ (donde $\sigma > 0$) si su función de densidad de probabilidad es (Devore, Capítulo 4, Sección 4.3):

$$f(x; \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} \quad \text{para } -\infty < x < \infty$$

La curva en forma de campana resultante es simétrica respecto a su media μ , y la dispersión está gobernada por σ . El cálculo de áreas bajo esta curva (es decir, probabilidades) requiere integrar una función que no tiene una antiderivada elemental. Para resolver esto, se utiliza la *distribución normal estándar*, que es el caso especial donde $\mu = 0$ y $\sigma = 1$. La variable aleatoria estándar se denota como Z , y su función de distribución acumulativa se denota tradicionalmente como $\Phi(z)$.

La herramienta fundamental para calcular probabilidades de cualquier variable normal $X \sim N(\mu, \sigma^2)$ es el proceso de *estandarización*. Si X es normal, entonces la variable estandarizada Z también es normal estándar:

$$Z = \frac{X - \mu}{\sigma}$$

Esto permite utilizar las tablas de la distribución normal estándar (como la Tabla A.3 en el apéndice de Devore) para encontrar percentiles y probabilidades de cualquier fenómeno físico modelado por esta distribución, desde la dispersión de velocidades en un cúmulo estelar hasta los errores de apuntamiento de una nave espacial.

6.4.1. Ejemplo 1: Percentiles en la distribución de concentración de isótopos en un núcleo de meteorito

Principios de datación y análisis de choque en meteoritos expuestos en *Planetary Geology* (Capítulo sobre *Shock Metamorphism and Isotope Geochemistry*).

Un laboratorio de geoquímica isotópica analiza el núcleo de una condrita carbonácea que sufrió un evento de impacto. Debido al gradiente de presión y temperatura generado por la onda de choque desde la costra de fusión hacia el interior, la concentración de un isótopo de corta vida (como el Al-26) no es uniforme, sino que aumenta a medida que se profundiza en la muestra.

Definimos la variable aleatoria continua X como la *profundidad fraccional normalizada* dentro del núcleo, donde $X \in (0, 1)$. Basado en el perfil de choque medido, la función de densidad de probabilidad de la concentración relativa del isótopo en función de la profundidad está modelada por:

$$f(x) = \begin{cases} 2x & \text{para } 0 < x < 1 \\ 0 & \text{en otro caso} \end{cases}$$

El equipo científico necesita determinar dos umbrales críticos para su protocolo de muestreo: la profundidad mediana (donde se alcanza la concentración isotópica promedio acumulada) y el percentil 90 (para descartar el 10 % superior de la muestra que podría estar excesivamente alterada por el calor del impacto).

Paso 1: Obtención de la Función de Distribución Acumulativa (FDA) Para $0 < x < 1$, la FDA $F(x)$ se calcula integrando la FDP desde el límite inferior del soporte hasta x :

$$F(x) = \int_0^x 2t \, dt = [t^2]_0^x = x^2$$

Paso 2: Cálculo de la Mediana (Percentil 50) La mediana m es el valor que satisface $F(m) = 0,5$. Planteamos la ecuación:

$$m^2 = 0,5 \implies m = \sqrt{0,5} \approx 0,7071$$

La profundidad mediana es aproximadamente 0.707. Esto indica que el 50 % de la probabilidad de concentración isotópica total se encuentra en el 70.7 % superior del núcleo, lo cual es consistente con una distribución que sesga la masa hacia las profundidades mayores.

Paso 3: Cálculo del Percentil 90 Para encontrar el percentil 90 ($x_{0,90}$), resolvemos la ecuación $F(x_{0,90}) = 0,90$:

$$x_{0,90}^2 = 0,90 \implies x_{0,90} = \sqrt{0,90} \approx 0,9487$$

El percentil 90 se encuentra en la profundidad fraccional 0.9487.

Conclusión Este resultado dicta que el 90 % de la distribución de concentración del isótopo ocurre en los primeros 94.87 % de la profundidad del núcleo. Los geoquímicos utilizarán este percentil para establecer el límite de corte físico al tallar la muestra, asegurando que el 10 % más profundo (que representa las colas de la distribución donde los efectos térmicos del impacto son no lineales y difíciles de modelar) sea descartado del análisis de datación principal.

6.4.2. Ejemplo 2: Distribución normal y percentiles en la navegación de una sonda interplanetaria

Presupuesto de combustible y maniobras de corrección de trayectoria (*Modern Spacecraft Guidance, Navigation, and Control*, Capítulo sobre *Trajectory Correction Maneuvers*).

Una sonda espacial en ruta a Marte debe ejecutar una Maniobra de Corrección de Trayectoria (TCM, por sus siglas en inglés). El sistema de propulsión está comandado para entregar un incremento de velocidad (ΔV) exacto de 15.0 m/s. Sin embargo, debido a las fluctuaciones en la presión de la cámara de combustión, la eficiencia del propulsor y el ruido en los sensores de navegación, el ΔV realmente entregado es una variable aleatoria continua X que sigue una distribución normal.

Los ingenieros de vuelo han caracterizado el sistema y determinan que $X \sim N(\mu = 15,0 \text{ m/s}, \sigma = 0,4 \text{ m/s})$.

El equipo de la misión debe resolver dos problemas críticos de diseño y operación:

Problema A: Probabilidad de exceder el límite de seguridad del tanque Por restricciones estructurales del chasis de la sonda, la válvula de regulación no puede soportar un ΔV instantáneo superior a 16.0 m/s sin riesgo de fatiga catastrófica. ¿Cuál es la probabilidad de que la maniobra exceda este límite?

Estandarizamos la variable X para convertir el problema en uno de distribución normal estándar:

$$P(X > 16,0) = P\left(Z > \frac{16,0 - 15,0}{0,4}\right) = P(Z > 2,5)$$

Utilizando la función de distribución acumulativa estándar $\Phi(z)$:

$$P(Z > 2,5) = 1 - \Phi(2,5)$$

Consultando la tabla de la normal estándar (Devore, Tabla A.3), sabemos que $\Phi(2,5) \approx 0,9938$. Por lo tanto:

$$P(X > 16,0) = 1 - 0,9938 = 0,0062$$

Existe un riesgo del 0.62 % de que la maniobra supere el límite estructural. En el contexto de *Modern Spacecraft GN&C*, este valor es lo suficientemente bajo como para ser aceptable, pero se monitorea de cerca.

Problema B: Dimensionamiento del tanque de contingencia usando percentiles Para garantizar que la sonda llegue a Marte incluso en el peor escenario de dispersión de combustible,

el tanque de reserva debe dimensionarse para contener el ΔV que solo es superado en el 1 % de los casos. Es decir, los ingenieros necesitan calcular el *percentil 99* de la distribución del ΔV .

Buscamos el valor $x_{0,99}$ tal que $P(X \leq x_{0,99}) = 0,99$. Primero, encontramos el percentil 99 de la distribución normal estándar, $z_{0,99}$, tal que $\Phi(z_{0,99}) = 0,99$. Buscando en la tabla inversa de la normal estándar, el valor que deja un área de 0.99 a su izquierda es aproximadamente:

$$z_{0,99} \approx 2,326$$

Ahora, desacoplamos la ecuación de estandarización $Z = \frac{X-\mu}{\sigma}$ para despejar X :

$$x_{0,99} = \mu + z_{0,99} \cdot \sigma$$

Sustituimos los parámetros de la misión:

$$x_{0,99} = 15,0 + (2,326)(0,4) = 15,0 + 0,9304 = 15,9304 \text{ m/s}$$

Conclusión: El percentil 99 del ΔV es de 15.93 m/s. Esto significa que el 99 % de las veces, la maniobra requerirá 15.93 m/s o menos. Los ingenieros de sistemas utilizarán este valor exacto para dimensionar la capacidad de reserva del tanque de hidracina. Este ejercicio demuestra cómo la teoría de la distribución normal y el cálculo de percentiles (Devore, Sección 4.3) se traducen directamente en márgenes de seguridad físicos y decisiones de diseño de hardware en la exploración del sistema solar.

6.4.3. Ejemplo 3: Control de Calidad Óptica y Razón de Strehl en Telescopios Espaciales

Criterios de calidad de imagen y la aproximación de Marechal para la razón de Strehl (*Astronomical Measurement*, Capítulo sobre *Image Quality and the Point Spread Function*).

En el diseño de telescopios espaciales, la precisión de la superficie del espejo primario dicta la capacidad del instrumento para resolver detalles finos. Sea X la variable aleatoria continua que representa el error de frente de onda RMS (Raíz del Cuadrado Medio), medido en nanómetros (nm). Debido a las fluctuaciones térmicas en órbita y a los errores de fabricación, este error sigue una distribución normal con una media de 12 nm y una desviación estándar de 4 nm. Es decir, $X \sim N(12, 4^2)$.

La calidad de la imagen se cuantifica mediante la razón de Strehl $\mathcal{S}$, que relaciona la intensidad pico real con la de un sistema óptico perfecto. Debido a un desplazamiento sistemático conocido en el enfoque nominal del instrumento, el modelo de degradación para este telescopio específico está dado por la siguiente función exponencial:

$$\mathcal{S} = \exp\left(-\frac{(X - 10)^2}{25}\right)$$

A continuación, resolvemos una secuencia de requerimientos de ingeniería para la misión:

a) Estandarización y probabilidad de cola (Límite de degradación severa) El protocolo de seguridad dicta que si el error de frente de onda supera los 20 nm, el telescopio debe entrar

en modo de recalibración automática. ¿Cuál es la probabilidad de que una observación aleatoria exceda este límite?

Estandarizamos la variable X restando la media y dividiendo por la desviación estándar para convertir el problema en uno de distribución normal estándar $Z \sim N(0, 1)$:

$$P(X > 20) = P\left(Z > \frac{20 - 12}{4}\right) = P(Z > 2)$$

Utilizando la función de distribución acumulativa estándar $\Phi(z)$:

$$P(Z > 2) = 1 - \Phi(2) \approx 1 - 0,9772 = 0,0228$$

Existe un 2.28 % de probabilidad de que el sistema requiera recalibración por superar el límite de 20 nm.

b) Cálculo de percentiles (Umbral de bloqueo de actuadores) Para prevenir daños mecánicos en los actuadores del espejo secundario, el sistema de control debe bloquear los ajustes cuando el error acumulado alcance el percentil 95 de la distribución esperada. Debemos encontrar el valor $x_{0,95}$ tal que $P(X \leq x_{0,95}) = 0,95$.

Primero, buscamos el percentil 95 de la normal estándar, $z_{0,95}$, tal que $\Phi(z_{0,95}) = 0,95$. Consultando las tablas normales, $z_{0,95} \approx 1,645$.

Despejamos X de la ecuación de estandarización $Z = \frac{X - \mu}{\sigma}$:

$$x_{0,95} = \mu + z_{0,95} \cdot \sigma = 12 + (1,645)(4) = 12 + 6,58 = 18,58 \text{ nm}$$

El sistema de control bloqueará los actuadores cuando el error alcance los 18.58 nm.

c) Probabilidad de un evento compuesto no lineal (Requerimiento científico) El objetivo científico principal de la misión es imagear los criovolcanes en la superficie de Europa. Para lograr el contraste necesario, los algoritmos de procesamiento de imagen exigen que la razón de Strehl sea estrictamente mayor que e^{-4} . ¿Cuál es la probabilidad de que un fotograma aleatorio cumpla con este requerimiento científico?

Planteamos la desigualdad basada en el modelo físico:

$$\mathcal{S} > e^{-4} \implies \exp\left(-\frac{(X - 10)^2}{25}\right) > e^{-4}$$

Dado que la función exponencial es estrictamente creciente, podemos igualar los exponentes preservando el sentido de la desigualdad:

$$-\frac{(X - 10)^2}{25} > -4$$

Multiplicamos por -25 (lo que invierte la desigualdad):

$$(X - 10)^2 < 100$$

Para resolver esta inecuación cuadrática, aplicamos la raíz cuadrada en ambos lados, lo que genera un valor absoluto:

$$|X - 10| < 10$$

Esto se descompone en una doble desigualdad lineal:

$$-10 < X - 10 < 10 \implies 0 < X < 20$$

El requerimiento científico se traduce matemáticamente en que el error de frente de onda debe estar estrictamente entre 0 y 20 nm. Ahora, estandarizamos ambos límites de este intervalo para calcular la probabilidad utilizando la normal estándar:

- Límite inferior: $Z_1 = \frac{0-12}{4} = -3$
- Límite superior: $Z_2 = \frac{20-12}{4} = 2$

La probabilidad de cumplir con el requerimiento es el área bajo la curva normal estándar entre estos dos valores:

$$P(0 < X < 20) = P(-3 < Z < 2) = \Phi(2) - \Phi(-3)$$

Para obtener una expresión matemática cerrada y manejable, aplicamos la propiedad de simetría de la distribución normal estándar, $\Phi(-z) = 1 - \Phi(z)$:

$$P(-3 < Z < 2) = \Phi(2) - (1 - \Phi(3)) = \Phi(2) + \Phi(3) - 1$$

Sustituyendo los valores de las tablas normales ($\Phi(2) \approx 0,9772$ y $\Phi(3) \approx 0,9987$):

$$P(0 < X < 20) \approx 0,9772 + 0,9987 - 1 = 0,9759$$

Conclusión: Existe un 97.59% de probabilidad de que el telescopio entregue imágenes con la calidad suficiente para el estudio de Europa.

Clase 7

7.1. Funciones de varias variables

En el estudio de múltiples variables aleatorias, es fundamental poder calcular el valor esperado de una función $h(X, Y)$ que depende de dos variables aleatorias X y Y . Este valor esperado se obtiene ponderando la función por la probabilidad conjunta de las variables (Devore, Capítulo 5, Sección 5.2).

Para variables aleatorias conjuntamente discretas con función de masa de probabilidad conjunta $p(x, y)$:

$$E[h(X, Y)] = \sum_x \sum_y h(x, y)p(x, y)$$

Para variables aleatorias conjuntamente continuas con función de densidad de probabilidad conjunta $f(x, y)$:

$$E[h(X, Y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} h(x, y)f(x, y) dx dy$$

Una propiedad fundamental derivada de esta definición es la linealidad del valor esperado. Si la función es una combinación lineal $h(X, Y) = aX + bY$, donde a y b son constantes, entonces:

$$E(aX + bY) = aE(X) + bE(Y) = a\mu_X + b\mu_Y$$

7.2. Distribuciones de probabilidad conjunta

El comportamiento simultáneo de dos variables aleatorias se describe mediante su distribución conjunta.

Para el caso discreto, la función de masa de probabilidad conjunta $p(x, y)$ especifica la probabilidad de que $X = x$ y $Y = y$ simultáneamente. Debe satisfacer rigurosamente (Devore, Capítulo 5, Sección 5.1):

$$p(x, y) \geq 0 \quad \text{para todo } (x, y)$$
$$\sum_x \sum_y p(x, y) = 1$$

Para el caso continuo, la función de densidad de probabilidad conjunta $f(x, y)$ define la probabilidad de que (X, Y) caiga en una región bidimensional A . Sus condiciones analíticas son (Devore, Sección 5.1):

$$f(x, y) \geq 0 \quad \text{para todo } (x, y)$$
$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$$
$$P((X, Y) \in A) = \iint_A f(x, y) dx dy$$

7.3. Distribuciones marginales

Las distribuciones marginales describen el comportamiento probabilístico de una sola variable (por ejemplo, X), ignorando o promediando los resultados de la otra variable (Y). Se obtienen directamente de la distribución conjunta (Devore, Capítulo 5, Sección 5.1).

Para variables discretas, la función de masa de probabilidad marginal de X se calcula sumando la probabilidad conjunta sobre todos los posibles valores de Y :

$$p_X(x) = \sum_y p(x, y)$$

Para variables continuas, la función de densidad de probabilidad marginal de X se obtiene integrando la densidad conjunta sobre todo el rango de Y :

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy$$

De manera simétrica, las distribuciones marginales para Y se definen como $p_Y(y) = \sum_x p(x, y)$ en el caso discreto, y $f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx$ en el caso continuo.

7.4. Combinación de variables aleatorias

Al combinar variables aleatorias, es crucial cuantificar no solo sus medias individuales, sino también cómo varían conjuntamente. La covarianza mide la relación lineal entre X y Y , y se define como el valor esperado del producto de sus desviaciones respecto a sus respectivas medias (Devore, Capítulo 5, Sección 5.2):

$$Cov(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] = E(XY) - \mu_X\mu_Y$$

El coeficiente de correlación ρ estandariza la covarianza para acotarla entre -1 y 1 :

$$\rho_{X,Y} = \frac{Cov(X, Y)}{\sigma_X\sigma_Y}$$

Para una combinación lineal de variables aleatorias $U = aX + bY$, la varianza de U depende de las varianzas individuales y de su covarianza. La expresión general es (Devore, Capítulo 5, Sección 5.5):

$$V(aX + bY) = a^2V(X) + b^2V(Y) + 2abCov(X, Y)$$

Si las variables aleatorias X y Y son estadísticamente independientes, su covarianza es nula ($Cov(X, Y) = 0$). En este escenario, la varianza de la combinación lineal se simplifica a la suma ponderada de las varianzas individuales:

$$V(aX + bY) = a^2V(X) + b^2V(Y)$$

7.4.1. Ejemplo 1: Abundancia Mineralógica en una Sección Delgada de Meteorito

Principios de petrología y análisis de secciones delgadas expuestos en *Planetary Geology* (Capítulo sobre *Mineralogy and Petrology of Meteorites*).

Un laboratorio de geoquímica isotópica analiza una sección delgada de una condrita ordinaria. El microscopio electrónico mide las fracciones normalizadas de dos minerales de silicato fundamentales: Olivino (variable aleatoria X) y Piroxeno (variable aleatoria Y). Debido a la presencia de matriz vítrea y otros minerales accesorios, la suma de las fracciones de Olivino y Piroxeno no puede exceder la unidad.

La función de densidad de probabilidad conjunta que modela la ocurrencia de estas abundancias en esta clase específica de meteoritos está dada por:

$$f(x, y) = \begin{cases} c(x + y) & \text{para } x > 0, y > 0, x + y < 1 \\ 0 & \text{en otro caso} \end{cases}$$

A continuación, resolvemos una secuencia de requerimientos para caracterizar completamente el sistema mineralógico:

a) Determinación de la constante de normalización c Para que $f(x, y)$ sea una FDP legítima, la integral doble sobre toda la región de soporte debe ser igual a 1 (Devore, Capítulo 5, Sección 5.1). La región es un triángulo en el primer cuadrante acotado por $x + y = 1$:

$$\int_0^1 \int_0^{1-x} c(x + y) dy dx = 1$$

Resolvemos la integral interna respecto a y :

$$\int_0^{1-x} (x + y) dy = \left[xy + \frac{y^2}{2} \right]_0^{1-x} = x(1-x) + \frac{(1-x)^2}{2}$$

Simplificando la expresión algebraica:

$$x - x^2 + \frac{1 - 2x + x^2}{2} = \frac{2x - 2x^2 + 1 - 2x + x^2}{2} = \frac{1 - x^2}{2}$$

Ahora integramos respecto a x :

$$c \int_0^1 \frac{1 - x^2}{2} dx = \frac{c}{2} \left[x - \frac{x^3}{3} \right]_0^1 = \frac{c}{2} \left(1 - \frac{1}{3} \right) = \frac{c}{2} \left(\frac{2}{3} \right) = \frac{c}{3}$$

Igualando a 1, obtenemos $c = 3$. La FDP conjunta es $f(x, y) = 3(x + y)$ en la región definida.

b) Obtención de la distribución marginal de X La distribución marginal de X describe la probabilidad de encontrar una cierta abundancia de Olivino, independientemente de la cantidad de Piroxeno. Se obtiene integrando la conjunta sobre todos los valores posibles de Y (Devore, Sección 5.1):

$$f_X(x) = \int_0^{1-x} 3(x + y) dy$$

Utilizando el resultado de la integral interna calculado en el paso anterior:

$$f_X(x) = 3 \left(\frac{1-x^2}{2} \right) = \frac{3}{2}(1-x^2) \quad \text{para } 0 < x < 1$$

c) Valor esperado de la fracción total de silicatos El índice de saturación de silicatos se define como la suma de las fracciones, $Z = X + Y$. Calculamos su valor esperado utilizando la definición para funciones de variables conjuntas (Devore, Sección 5.2):

$$E(X + Y) = \int_0^1 \int_0^{1-x} (x + y) \cdot 3(x + y) dy dx = 3 \int_0^1 \int_0^{1-x} (x + y)^2 dy dx$$

Resolvemos la integral interna haciendo el cambio mental $u = x + y$:

$$\int_0^{1-x} (x + y)^2 dy = \left[\frac{(x + y)^3}{3} \right]_{y=0}^{y=1-x} = \frac{1^3}{3} - \frac{x^3}{3} = \frac{1-x^3}{3}$$

Sustituimos en la integral externa:

$$E(X + Y) = 3 \int_0^1 \frac{1-x^3}{3} dx = \int_0^1 (1-x^3) dx = \left[x - \frac{x^4}{4} \right]_0^1 = 1 - \frac{1}{4} = \frac{3}{4}$$

El valor esperado de la fracción total de silicatos es 0.75.

d) Covarianza y Correlación entre Olivino y Piroxeno Para calcular la covarianza, necesitamos $E(X)$, $E(Y)$ y $E(XY)$. Por simetría de la función $f(x, y)$ respecto a X y Y , sabemos que $E(X) = E(Y)$.

$$E(X) = \int_0^1 x f_X(x) dx = \int_0^1 x \frac{3}{2}(1-x^2) dx = \frac{3}{2} \int_0^1 (x - x^3) dx = \frac{3}{2} \left[\frac{x^2}{2} - \frac{x^4}{4} \right]_0^1 = \frac{3}{2} \left(\frac{1}{4} \right) = \frac{3}{8}$$

Calculamos $E(X^2)$ para hallar la varianza de X :

$$E(X^2) = \int_0^1 x^2 \frac{3}{2}(1-x^2) dx = \frac{3}{2} \left[\frac{x^3}{3} - \frac{x^5}{5} \right]_0^1 = \frac{3}{2} \left(\frac{2}{15} \right) = \frac{1}{5}$$

$$V(X) = E(X^2) - [E(X)]^2 = \frac{1}{5} - \left(\frac{3}{8} \right)^2 = \frac{1}{5} - \frac{9}{64} = \frac{64-45}{320} = \frac{19}{320}$$

Por simetría, $V(Y) = 19/320$. Ahora calculamos $E(XY)$:

$$E(XY) = \int_0^1 \int_0^{1-x} xy \cdot 3(x + y) dy dx = 3 \int_0^1 \int_0^{1-x} (x^2y + xy^2) dy dx$$

Integral interna:

$$\left[\frac{x^2y^2}{2} + \frac{xy^3}{3} \right]_0^{1-x} = \frac{x^2(1-x)^2}{2} + \frac{x(1-x)^3}{3} = \frac{x(1-x)^2}{6} [3x + 2(1-x)] = \frac{x(1-x)^2(2+x)}{6}$$

Expandiendo el polinomio: $\frac{1}{6}(x - 2x^2 + x^3)(2 + x) = \frac{1}{6}(2x - 3x^2 + x^4)$. Integral externa:

$$E(XY) = 3 \int_0^1 \frac{1}{6}(2x - 3x^2 + x^4) dx = \frac{1}{2} \left[x^2 - x^3 + \frac{x^5}{5} \right]_0^1 = \frac{1}{2} \left(1 - 1 + \frac{1}{5} \right) = \frac{1}{10}$$

Finalmente, la covarianza y el coeficiente de correlación (Devore, Sección 5.2):

$$Cov(X, Y) = E(XY) - E(X)E(Y) = \frac{1}{10} - \left(\frac{3}{8}\right)\left(\frac{3}{8}\right) = \frac{32}{320} - \frac{45}{320} = -\frac{13}{320}$$

$$\rho_{X,Y} = \frac{Cov(X, Y)}{\sqrt{V(X)V(Y)}} = \frac{-13/320}{19/320} = -\frac{13}{19} \approx -0,684$$

La correlación negativa fuerte es físicamente consistente: al estar limitadas por $X + Y < 1$, una alta abundancia de Olivino restringe matemáticamente la cantidad máxima de Piroxeno que puede coexistir en la sección delgada.

e) Varianza de un índice petrográfico combinado El laboratorio define un Índice de Diferenciación Petrográfica como $W = 2X + 3Y$. Utilizando la regla de la varianza para combinaciones lineales (Devore, Sección 5.5):

$$V(W) = 2^2V(X) + 3^2V(Y) + 2(2)(3)Cov(X, Y)$$

$$V(W) = 4\left(\frac{19}{320}\right) + 9\left(\frac{19}{320}\right) + 12\left(-\frac{13}{320}\right) = \frac{76 + 171 - 156}{320} = \frac{91}{320} \approx 0,284$$

Este resultado cuantifica rigurosamente cómo la incertidumbre en las mediciones minerales individuales y su correlación negativa se propagan en el índice compuesto, permitiendo a los geólogos planetarios establecer márgenes de confianza para la clasificación del meteorito.

7.4.2. Ejemplo 2: Detección Multi-banda de Tránsitos Exoplanetarios

En la astronomía observacional, la confirmación de exoplanetas requiere cruzar datos de diferentes instrumentos o bandas espectrales para descartar falsos positivos. Inspirados en los métodos de fotometría y validación estadística de *Astronomical Measurement* (Capítulo sobre *Transit Photometry and False Positive Probabilities*), modelaremos un escenario de detección discreta.

Un telescopio espacial analiza un campo estelar. Para una estrella objetivo específica, definimos las variables aleatorias discretas:

- X : Número de señales candidatas a tránsito detectadas en la banda visual.
- Y : Número de señales candidatas a tránsito detectadas en la banda infrarroja.

Basado en el rendimiento histórico del pipeline de reducción de datos, la función de masa de probabilidad conjunta $p(x, y)$ para $X \in \{0, 1, 2\}$ y $Y \in \{0, 1\}$ se resume en la siguiente tabla:

	$X = 0$	$X = 1$	$X = 2$
$Y = 0$	0,10	0,15	0,05
$Y = 1$	0,20	0,25	0,25

A continuación, desarrollamos los pasos para evaluar la estadística de detección del sistema:

a) Distribuciones marginales Las distribuciones marginales describen el comportamiento de cada banda por separado, sumando las probabilidades conjuntas (Devore, Sección 5.1): Para X :

$$p_X(0) = 0,10 + 0,20 = 0,30$$

$$p_X(1) = 0,15 + 0,25 = 0,40$$

$$p_X(2) = 0,05 + 0,25 = 0,30$$

Para Y :

$$p_Y(0) = 0,10 + 0,15 + 0,05 = 0,30$$

$$p_Y(1) = 0,20 + 0,25 + 0,25 = 0,70$$

b) Valores esperados y varianzas individuales Calculamos los momentos de primer y segundo orden para cada variable (Devore, Capítulo 3, Sección 3.3):

$$E(X) = 0(0,30) + 1(0,40) + 2(0,30) = 1,0$$

$$E(X^2) = 0^2(0,30) + 1^2(0,40) + 2^2(0,30) = 0,40 + 1,20 = 1,60$$

$$V(X) = E(X^2) - [E(X)]^2 = 1,60 - 1,0^2 = 0,60$$

$$E(Y) = 0(0,30) + 1(0,70) = 0,70$$

$$E(Y^2) = 0^2(0,30) + 1^2(0,70) = 0,70$$

$$V(Y) = E(Y^2) - [E(Y)]^2 = 0,70 - 0,70^2 = 0,70 - 0,49 = 0,21$$

c) Covarianza y Correlación Para evaluar si las detecciones en ambas bandas son independientes o están correlacionadas, calculamos $E(XY)$ sumando sobre todos los pares (x, y) donde la probabilidad es distinta de cero:

$$E(XY) = \sum_x \sum_y xy \cdot p(x, y)$$

Los únicos términos que no se anulan (donde $x \neq 0$ y $y \neq 0$) son:

$$E(XY) = (1)(1)(0,25) + (2)(1)(0,25) = 0,25 + 0,50 = 0,75$$

La covarianza es:

$$Cov(X, Y) = E(XY) - E(X)E(Y) = 0,75 - (1,0)(0,70) = 0,05$$

El coeficiente de correlación es:

$$\rho_{X,Y} = \frac{Cov(X, Y)}{\sqrt{V(X)V(Y)}} = \frac{0,05}{\sqrt{0,60 \times 0,21}} = \frac{0,05}{\sqrt{0,126}} \approx \frac{0,05}{0,355} \approx 0,141$$

La correlación positiva débil sugiere que, aunque las bandas son físicamente distintas, existen factores astrofísicos subyacentes (como la actividad estelar o el tamaño del planeta) que tienden a aumentar la tasa de detección en ambas bandas simultáneamente.

d) Varianza de un discriminante de validación Para separar los planetas reales de los binarios eclipsantes de fondo, el pipeline calcula un Puntaje Discriminante $Z = 3X - 2Y$. Las ponderaciones positivas para la banda visual y negativas para la infrarroja ayudan a filtrar ciertos tipos de falsos positivos. Necesitamos la varianza de este puntaje para calibrar los umbrales de alerta.

Aplicando la fórmula de la varianza para una combinación lineal (Devore, Sección 5.5):

$$V(Z) = V(3X - 2Y) = 3^2V(X) + (-2)^2V(Y) + 2(3)(-2)Cov(X, Y)$$

$$V(Z) = 9(0,60) + 4(0,21) - 12(0,05)$$

$$V(Z) = 5,40 + 0,84 - 0,60 = 5,64$$

La varianza del puntaje discriminante es 5.64. Conocer este valor exacto permite a los científicos de datos establecer los intervalos de confianza para el puntaje Z . Si la varianza hubiera sido calculada asumiendo erróneamente que X e Y eran independientes (ignorando el término de covarianza), el resultado habría sido 6,24, lo que llevaría a subestimar la precisión del discriminante y a un diseño ineficiente de los filtros de validación automática. Este ejercicio demuestra el poder de las distribuciones conjuntas para modelar sistemas de detección complejos en la astronomía moderna.

Clase 8

8.1. Valores esperados en varias variables

Para calcular el valor esperado de una función $h(X, Y)$ que depende de dos variables aleatorias conjuntas, se debe ponderar la función por la probabilidad de ocurrencia de cada par de valores. De acuerdo con el texto guía, la definición formal varía dependiendo de si las variables son discretas o continuas (Devore, Capítulo 5, Sección 5.2).

Para variables aleatorias conjuntamente discretas con función de masa de probabilidad conjunta $p(x, y)$:

$$E[h(X, Y)] = \sum_x \sum_y h(x, y)p(x, y)$$

Para variables aleatorias conjuntamente continuas con función de densidad de probabilidad conjunta $f(x, y)$:

$$E[h(X, Y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} h(x, y)f(x, y) dx dy$$

Una propiedad fundamental derivada de esta definición es la linealidad del valor esperado. Si la función es una combinación lineal $h(X, Y) = aX + bY$, donde a y b son constantes, entonces:

$$E(aX + bY) = aE(X) + bE(Y) = a\mu_X + b\mu_Y$$

8.2. Funciones de correlación

En el estudio de la dependencia entre variables, el coeficiente de correlación es la medida por excelencia para cuantificar la fuerza y dirección de una relación lineal. El coeficiente de correlación de la población, denotado como ρ , estandariza la covarianza dividiéndola por el producto de las desviaciones estándar de las variables, acotando el resultado en el intervalo $[-1, 1]$ (Devore, Capítulo 5, Sección 5.2):

$$\rho_{X,Y} = \frac{Cov(X, Y)}{\sigma_X \sigma_Y}$$

En la práctica observacional, la población es desconocida y se debe estimar a partir de una muestra de n pares de observaciones $(x_1, y_1), \dots, (x_n, y_n)$. El coeficiente de correlación muestral r actúa como la función de correlación empírica y se calcula mediante (Devore, Capítulo 12, Sección 12.5):

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

Un valor de r cercano a 1 o -1 indica una fuerte relación lineal, mientras que un valor cercano a 0 sugiere la ausencia de una relación lineal, aunque no descarta la existencia de dependencias no lineales.

8.3. Covarianza

La covarianza es la medida fundamental de la asociación lineal entre dos variables aleatorias. Se define como el valor esperado del producto de las desviaciones de cada variable respecto a su respectiva media (Devore, Capítulo 5, Sección 5.2):

$$Cov(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$$

Desarrollando esta expresión mediante la linealidad del valor esperado, se obtiene la fórmula de cálculo abreviada, la cual es computacionalmente más eficiente:

$$Cov(X, Y) = E(XY) - \mu_X \mu_Y$$

Si X y Y son variables aleatorias estadísticamente independientes, entonces $E(XY) = E(X)E(Y)$, lo que implica que $Cov(X, Y) = 0$. En este caso, se dice que las variables no están correlacionadas. Es importante destacar que una covarianza nula no implica necesariamente independencia, salvo en familias de distribuciones específicas como la normal bivalente.

8.4. Combinación de variables aleatorias

Al formar combinaciones lineales de variables aleatorias, como $U = aX + bY$, es crucial determinar su varianza para cuantificar la incertidumbre propagada. La varianza de una combinación lineal depende de las varianzas individuales y de la covarianza entre las variables. La expresión general es (Devore, Capítulo 5, Sección 5.5):

$$V(aX + bY) = a^2V(X) + b^2V(Y) + 2abCov(X, Y)$$

Esta fórmula demuestra que la varianza de la suma o resta de variables no es simplemente la suma de sus varianzas, a menos que exista una condición específica de independencia.

Si las variables aleatorias X y Y son independientes (o simplemente no correlacionadas), su covarianza es nula ($Cov(X, Y) = 0$). En este escenario, la varianza de la combinación lineal se simplifica a la suma ponderada de las varianzas individuales:

$$V(aX + bY) = a^2V(X) + b^2V(Y)$$

Este principio es la base matemática para la propagación de errores instrumentales y la evaluación de la incertidumbre en observaciones astronómicas compuestas, donde múltiples fuentes de ruido independiente se combinan para formar el error total de una medición (*Astronomical Measurement*, Apéndice A.6 y A.10).

8.4.1. Ejemplo 1: Propagación de Errores Correlacionados en Transformaciones de Observación Radar

En la determinación inicial de órbitas y el seguimiento satelital, los sensores ópticos o de radar proporcionan mediciones en el sistema topocéntrico (por ejemplo, Azimut, Elevación y Range).

Para integrar estas observaciones en un filtro de estimación orbital, deben transformarse al sistema geocéntrico inercial. Según los principios de transformaciones de observación (Vallado, Capítulo 4, Sección 4.4), esta transformación es no lineal, pero para el análisis de incertidumbre se linealiza mediante la matriz Jacobiana.

Consideremos una estación de seguimiento terrestre que observa un satélite en órbita baja (LEO). El vector de observaciones $\vec{y} = [\rho, Az, El]^T$ contiene errores aleatorios. Debido a efectos no modelados de refracción troposférica, los errores en el Range (X) y en la Elevación (Y) no son independientes, sino que presentan una covarianza distinta de cero.

Definimos las variables aleatorias con media nula (errores):

- X : Error en el Range (km), con $E[X] = 0$ y $V(X) = \sigma_X^2 = 0,04 \text{ km}^2$.
- Y : Error en la Elevación (rad), con $E[Y] = 0$ y $V(Y) = \sigma_Y^2 = 10^{-4} \text{ rad}^2$.
- La covarianza entre ambos errores, inducida por el gradiente de refracción, es $Cov(X, Y) = 0,001 \text{ km} \cdot \text{rad}$.

El error en la componente radial (hacia arriba, U) del vector de posición topocéntrica se aproxima mediante la combinación lineal de los errores de observación:

$$Z = \sin(El)X + \rho \cos(El)Y$$

Supongamos que en la época de la observación, el satélite se encuentra a un Range $\rho = 800 \text{ km}$ y una Elevación $El = 30^\circ$ ($\pi/6 \text{ rad}$). Los coeficientes de la combinación lineal son:

$$a = \sin(30^\circ) = 0,5$$

$$b = 800 \cos(30^\circ) = 800 \left(\frac{\sqrt{3}}{2} \right) = 400\sqrt{3} \approx 692,82 \text{ km}$$

Para dimensionar correctamente el ruido del proceso en un filtro de Kalman de determinación de órbita (Vallado, Capítulo 10), necesitamos la varianza exacta de Z . Aplicando la regla de la varianza para combinaciones lineales de variables aleatorias correlacionadas (Devore, Capítulo 5, Sección 5.5):

$$V(Z) = a^2V(X) + b^2V(Y) + 2abCov(X, Y)$$

Sustituyendo los valores numéricos:

$$V(Z) = (0,5)^2(0,04) + (400\sqrt{3})^2(10^{-4}) + 2(0,5)(400\sqrt{3})(0,001)$$

$$V(Z) = (0,25)(0,04) + (480000)(10^{-4}) + 0,4\sqrt{3}$$

$$V(Z) = 0,01 + 48 + 0,6928 = 48,7028 \text{ km}^2$$

La desviación estándar del error radial es $\sigma_Z = \sqrt{48,7028} \approx 6,98 \text{ km}$.

Si el ingeniero de dinámica de vuelo hubiera asumido erróneamente que los errores de Range y Elevación eran independientes ($Cov(X, Y) = 0$), la varianza calculada habría sido $48,01 \text{ km}^2$, subestimando la incertidumbre real. El término de covarianza ($0,6928 \text{ km}^2$) representa una contribución significativa que, al ser ignorada, degradaría la consistencia estadística del estimador orbital, generando elipses de error demasiado optimistas que no reflejan la física del medio de propagación de la señal.

8.4.2. Ejemplo 2: Incertidumbre Conjunta en Perturbaciones No Gravitacionales para Orbitografía de Precisión

En la orbitografía de precisión (POD) de satélites geoestacionarios o de navegación, las perturbaciones no gravitacionales, como el arrastre atmosférico (drag) y la presión de radiación solar (SRP), son las principales fuentes de error. Estas aceleraciones dependen de parámetros empíricos que el filtro de estimación ajusta en tiempo real.

Definimos dos variables aleatorias continuas que representan los factores de escala inciertos para estos modelos:

- X : Factor de escala de la densidad atmosférica local.
- Y : Factor de escala del coeficiente balístico efectivo (que agrupa área y coeficiente de arrastre).

Debido a que la actividad solar afecta simultáneamente la expansión de la atmósfera y las propiedades de degradación de los paneles solares del satélite, X e Y están estadísticamente correlacionados. Su función de densidad de probabilidad conjunta se modela como:

$$f(x, y) = \begin{cases} \frac{2}{3}(2x + y) & \text{para } 0 < x < 1, 0 < y < 1 \\ 0 & \text{en otro caso} \end{cases}$$

Para diseñar la matriz de covarianza del ruido de proceso, debemos extraer rigurosamente los momentos de esta distribución conjunta.

a) Distribuciones marginales y valores esperados La densidad marginal de X se obtiene integrando respecto a Y :

$$f_X(x) = \int_0^1 \frac{2}{3}(2x + y) dy = \frac{2}{3} \left[2xy + \frac{y^2}{2} \right]_0^1 = \frac{4x + 1}{3} \quad \text{para } 0 < x < 1$$

El valor esperado de X es:

$$E[X] = \int_0^1 x \left(\frac{4x + 1}{3} \right) dx = \frac{1}{3} \left[\frac{4x^3}{3} + \frac{x^2}{2} \right]_0^1 = \frac{1}{3} \left(\frac{4}{3} + \frac{1}{2} \right) = \frac{11}{18}$$

El segundo momento de X es:

$$E[X^2] = \int_0^1 x^2 \left(\frac{4x + 1}{3} \right) dx = \frac{1}{3} \left[x^4 + \frac{x^3}{3} \right]_0^1 = \frac{1}{3} \left(1 + \frac{1}{3} \right) = \frac{4}{9}$$

La varianza de X resulta en:

$$V(X) = E[X^2] - (E[X])^2 = \frac{4}{9} - \left(\frac{11}{18} \right)^2 = \frac{144 - 121}{324} = \frac{23}{324}$$

De manera similar, la densidad marginal de Y es:

$$f_Y(y) = \int_0^1 \frac{2}{3}(2x + y) dx = \frac{2}{3} [x^2 + xy]_0^1 = \frac{2}{3}(1 + y)$$

Los momentos para Y son:

$$E[Y] = \int_0^1 y \frac{2}{3}(1+y) dy = \frac{2}{3} \left[\frac{y^2}{2} + \frac{y^3}{3} \right]_0^1 = \frac{5}{9} = \frac{10}{18}$$

$$E[Y^2] = \int_0^1 y^2 \frac{2}{3}(1+y) dy = \frac{2}{3} \left[\frac{y^3}{3} + \frac{y^4}{4} \right]_0^1 = \frac{7}{18}$$

$$V(Y) = \frac{7}{18} - \left(\frac{5}{9} \right)^2 = \frac{63 - 50}{162} = \frac{13}{162} = \frac{26}{324}$$

b) Covarianza y Correlación El momento cruzado $E[XY]$ se calcula mediante la integral doble sobre la región de soporte:

$$E[XY] = \int_0^1 \int_0^1 xy \frac{2}{3}(2x+y) dy dx = \frac{2}{3} \int_0^1 \left(2x^2 \int_0^1 y dy + x \int_0^1 y^2 dy \right) dx$$

$$E[XY] = \frac{2}{3} \int_0^1 \left(x^2 + \frac{x}{3} \right) dx = \frac{2}{3} \left[\frac{x^3}{3} + \frac{x^2}{6} \right]_0^1 = \frac{2}{3} \left(\frac{1}{3} + \frac{1}{6} \right) = \frac{1}{3} = \frac{6}{18}$$

La covarianza entre los factores de perturbación es:

$$Cov(X, Y) = E[XY] - E[X]E[Y] = \frac{1}{3} - \left(\frac{11}{18} \right) \left(\frac{10}{18} \right) = \frac{108}{324} - \frac{110}{324} = -\frac{2}{324} = -\frac{1}{162}$$

El coeficiente de correlación es:

$$\rho_{X,Y} = \frac{Cov(X, Y)}{\sqrt{V(X)V(Y)}} = \frac{-2/324}{\sqrt{(23/324)(26/324)}} = \frac{-2}{\sqrt{598}} \approx -0,0817$$

Esta correlación negativa leve indica que, bajo este modelo, un sobreestimación empírica de la densidad atmosférica tiende a compensarse ligeramente con una subestimación del área efectiva de arrastre durante el proceso de ajuste del filtro.

c) Varianza de un estado combinado del filtro El vector de estado aumentado del filtro de estimación incluye una corrección combinada para el modelo dinámico, definida como $W = 4X - 3Y$. Para asignar la matriz de covarianza correcta, necesitamos $V(W)$. Aplicando la propiedad de combinación lineal:

$$V(W) = 4^2 V(X) + (-3)^2 V(Y) + 2(4)(-3)Cov(X, Y)$$

$$V(W) = 16 \left(\frac{23}{324} \right) + 9 \left(\frac{26}{324} \right) - 24 \left(-\frac{2}{324} \right)$$

$$V(W) = \frac{368 + 234 + 48}{324} = \frac{650}{324} = \frac{325}{162} \approx 2,006$$

Este resultado demuestra cómo la estructura de correlación subyacente entre las perturbaciones físicas (Devore, Capítulo 5) altera directamente la varianza del estado dinámico. En la práctica de la astrodinámica operativa (Vallado, Capítulo 8), ignorar el término de covarianza $-24(-2/324)$ habría resultado en una varianza de 1,851, subestimando la dispersión esperada y provocando que el filtro de navegación confiara excesivamente en su modelo dinámico, lo que eventualmente llevaría a la divergencia del estimador ante maniobras o cambios bruscos en el entorno espacial.

8.4.3. Ejemplo 3: Espectroscopia de Mezclas Minerales y el Índice de Diferenciación Redox

En la teledetección planetaria de alta resolución, como la realizada por espectrómetros orbitales (p. ej., CRISM en MRO o OMEGA en Mars Express), la superficie de un cuerpo se modela frecuentemente como una mezcla lineal de endmiembros mineralógicos. De acuerdo con los principios de desmezcla espectral y la interpretación de firmas de absorción (*Planetary Geology*, Capítulo sobre *Spectroscopy and Mineralogy*), la abundancia relativa de óxidos de hierro y el grado de polimerización de la sílice están físicamente acoplados durante los procesos de diferenciación magmática y alteración hidrotermal.

Para un depósito volcánico específico en la región de Tharsis, definimos las variables aleatorias continuas normalizadas:

- X : Fracción volumétrica efectiva de hematita espectralmente activa.
- Y : Índice de polimerización de la red silicatada (relacionado con la proporción de piroxeno sobre olivino).

Debido a las restricciones físico-químicas del sistema magmático, ambas variables están confinadas al intervalo unitario $[0, 1]$, pero su distribución conjunta no es uniforme. Los datos de calibración in situ y los modelos de transferencia radiativa sugieren que la función de densidad de probabilidad conjunta que describe esta población geológica es:

$$f(x, y) = c(1 + 2xy) \quad \text{para } 0 \leq x \leq 1, 0 \leq y \leq 1$$

y $f(x, y) = 0$ en otro caso. El término $2xy$ modela el acoplamiento positivo entre la cristalización de óxidos y la evolución del fundido silicatado.

A continuación, resolvemos una secuencia de requerimientos para cuantificar la incertidumbre mineralógica y validar un índice geoquímico compuesto.

a) Normalización y distribución marginal Para que $f(x, y)$ sea una FDP válida, la integral doble sobre el soporte debe ser unitaria (Devore, Capítulo 5, Sección 5.1):

$$\int_0^1 \int_0^1 c(1 + 2xy) dy dx = 1$$

Resolvemos la integral interna respecto a y :

$$\int_0^1 (1 + 2xy) dy = [y + xy^2]_0^1 = 1 + x$$

Integrando respecto a x :

$$c \int_0^1 (1 + x) dx = c \left[x + \frac{x^2}{2} \right]_0^1 = c \left(1 + \frac{1}{2} \right) = \frac{3c}{2}$$

Igualando a 1, obtenemos la constante de normalización $c = \frac{2}{3}$. La FDP conjunta es $f(x, y) = \frac{2}{3}(1 + 2xy)$.

La densidad marginal de X se obtiene integrando la conjunta sobre todo el rango de Y (Devore, Sección 5.1):

$$f_X(x) = \int_0^1 \frac{2}{3}(1 + 2xy) dy = \frac{2}{3}(1 + x) \quad \text{para } 0 \leq x \leq 1$$

Por simetría de la expresión original respecto a x y y , la marginal de Y es idéntica:

$$f_Y(y) = \frac{2}{3}(1+y) \quad \text{para } 0 \leq y \leq 1$$

b) Momentos de primer y segundo orden, y varianzas individuales Calculamos los valores esperados utilizando las marginales (Devore, Capítulo 5, Sección 5.2):

$$E[X] = \int_0^1 x \cdot \frac{2}{3}(1+x) dx = \frac{2}{3} \int_0^1 (x+x^2) dx = \frac{2}{3} \left[\frac{x^2}{2} + \frac{x^3}{3} \right]_0^1 = \frac{2}{3} \left(\frac{1}{2} + \frac{1}{3} \right) = \frac{5}{9}$$

$$E[Y] = \frac{5}{9} \quad (\text{por simetría})$$

Para las varianzas, necesitamos los segundos momentos:

$$E[X^2] = \int_0^1 x^2 \cdot \frac{2}{3}(1+x) dx = \frac{2}{3} \int_0^1 (x^2+x^3) dx = \frac{2}{3} \left[\frac{x^3}{3} + \frac{x^4}{4} \right]_0^1 = \frac{2}{3} \left(\frac{1}{3} + \frac{1}{4} \right) = \frac{7}{18}$$

$$V(X) = E[X^2] - (E[X])^2 = \frac{7}{18} - \left(\frac{5}{9} \right)^2 = \frac{7}{18} - \frac{25}{81} = \frac{63-50}{162} = \frac{13}{162}$$

$$V(Y) = \frac{13}{162} \quad (\text{por simetría})$$

c) Covarianza y coeficiente de correlación El momento cruzado $E[XY]$ se calcula mediante la integral doble sobre la región de soporte (Devore, Sección 5.2):

$$E[XY] = \int_0^1 \int_0^1 xy \cdot \frac{2}{3}(1+2xy) dy dx = \frac{2}{3} \int_0^1 x \left[\frac{y^2}{2} + \frac{2xy^3}{3} \right]_0^1 dx$$

$$E[XY] = \frac{2}{3} \int_0^1 x \left(\frac{1}{2} + \frac{2x}{3} \right) dx = \frac{2}{3} \int_0^1 \left(\frac{x}{2} + \frac{2x^2}{3} \right) dx$$

$$E[XY] = \frac{2}{3} \left[\frac{x^2}{4} + \frac{2x^3}{9} \right]_0^1 = \frac{2}{3} \left(\frac{1}{4} + \frac{2}{9} \right) = \frac{2}{3} \left(\frac{9+8}{36} \right) = \frac{17}{54}$$

La covarianza es:

$$Cov(X, Y) = E[XY] - E[X]E[Y] = \frac{17}{54} - \left(\frac{5}{9} \right) \left(\frac{5}{9} \right) = \frac{17}{54} - \frac{25}{81} = \frac{51-50}{162} = \frac{1}{162}$$

El coeficiente de correlación estandarizado (Devore, Sección 5.2) resulta:

$$\rho_{X,Y} = \frac{Cov(X, Y)}{\sqrt{V(X)V(Y)}} = \frac{1/162}{\sqrt{(13/162)(13/162)}} = \frac{1/162}{13/162} = \frac{1}{13} \approx 0,0769$$

Esta correlación positiva débil refleja físicamente que, aunque la hematita y la polimerización de sílice comparten tendencias magmáticas comunes, la variabilidad está dominada por procesos locales de alteración y mezcla física que desacoplan parcialmente sus abundancias a escala de píxel.

d) Varianza de un Índice Geoquímico Compuesto Para discriminar unidades geológicas en mapas orbitales, el equipo científico define un Índice de Diferenciación Redox Z , el cual pondera negativamente la sílice polimerizada para resaltar zonas ricas en óxidos férricos:

$$Z = 5X - 2Y$$

El valor esperado del índice se calcula por linealidad (Devore, Sección 5.2):

$$E[Z] = 5E[X] - 2E[Y] = 5\left(\frac{5}{9}\right) - 2\left(\frac{5}{9}\right) = \frac{25 - 10}{9} = \frac{15}{9} = \frac{5}{3} \approx 1,667$$

Para cuantificar la incertidumbre del índice, aplicamos rigurosamente la regla de varianza para combinaciones lineales de variables correlacionadas (Devore, Capítulo 5, Sección 5.5):

$$V(Z) = V(5X - 2Y) = 5^2V(X) + (-2)^2V(Y) + 2(5)(-2)Cov(X, Y)$$

$$\begin{aligned} V(Z) &= 25\left(\frac{13}{162}\right) + 4\left(\frac{13}{162}\right) - 20\left(\frac{1}{162}\right) \\ V(Z) &= \frac{325 + 52 - 20}{162} = \frac{357}{162} = \frac{119}{54} \approx 2,2037 \end{aligned}$$

La desviación estándar del índice es $\sigma_Z = \sqrt{119/54} \approx 1,484$.

Conclusión: El cálculo analítico revela que la varianza del índice geoquímico Z es significativamente mayor que la suma de las varianzas individuales escaladas. El término de covarianza $-20(1/162) \approx -0,123$ actúa como un factor de reducción de incertidumbre debido a la correlación positiva entre X y Y . Si un algoritmo de procesamiento de imágenes planetarias hubiera asumido erróneamente independencia ($Cov(X, Y) = 0$), la varianza calculada habría sido $377/162 \approx 2,327$, sobreestimando la dispersión real en un 5.6 %. Esta precisión estadística es crítica para calibrar los umbrales de clasificación en mapas de composición mineralógica (*Planetary Geology*, Sección sobre *Remote Sensing and Surface Composition*), permitiendo a los geólogos planetarios distinguir con confianza estadística entre unidades basálticas homogéneas y mezclas complejas alteradas por fluidos acuosos.

Clase 9

9.1. Muestras

En la inferencia estadística, el objetivo es extraer conclusiones sobre una población completa basándose en la observación de una parte de ella. Una muestra aleatoria de tamaño n se define como un conjunto de n variables aleatorias $X_1, X_2, \dots, X_n$ que son independientes e idénticamente distribuidas (i.i.d.), es decir, que comparten la misma función de densidad de probabilidad (o función de masa) $f(x)$ (Devore, Capítulo 5, Sección 5.3).

La independencia y la idéntica distribución implican que la función de densidad de probabilidad conjunta de la muestra completa es simplemente el producto de las densidades marginales:

$$f(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i)$$

9.2. Estadísticos

Un estadístico es cualquier función de las variables aleatorias de la muestra que no depende de parámetros desconocidos. Formalmente, si $X_1, X_2, \dots, X_n$ es una muestra aleatoria, un estadístico es una variable aleatoria T definida como $T = h(X_1, X_2, \dots, X_n)$ (Devore, Capítulo 5, Sección 5.3).

Los estadísticos más fundamentales para resumir la tendencia central y la dispersión de la muestra son la media muestral $\bar{X}$ y la varianza muestral S^2 :

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Mediante el uso de las propiedades de linealidad del valor esperado y la independencia de la muestra, podemos demostrar rigurosamente las propiedades de estos estadísticos. Asumiendo que la población tiene media $E(X_i) = \mu$ y varianza $V(X_i) = \sigma^2$:

Valor esperado de la media muestral:

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n}(n\mu) = \mu$$

Varianza de la media muestral: Dado que las X_i son independientes, la varianza de la suma es la suma de las varianzas:

$$V(\bar{X}) = V\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n V(X_i) = \frac{1}{n^2}(n\sigma^2) = \frac{\sigma^2}{n}$$

Valor esperado de la varianza muestral: Para demostrar que S^2 es un estimador insesgado de σ^2 , primero expandimos la suma de cuadrados utilizando la identidad algebraica $\sum (X_i - \bar{X})^2 = \sum X_i^2 - n\bar{X}^2$:

$$E(S^2) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - n\bar{X}^2\right) = \frac{1}{n-1} \left[\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2) \right]$$

Recordando que $E(Y^2) = V(Y) + [E(Y)]^2$, sustituimos $E(X_i^2) = \sigma^2 + \mu^2$ y $E(\bar{X}^2) = \frac{\sigma^2}{n} + \mu^2$:

$$E(S^2) = \frac{1}{n-1} \left[n(\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) \right] = \frac{1}{n-1} [n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2]$$

$$E(S^2) = \frac{1}{n-1} [(n-1)\sigma^2] = \sigma^2$$

Esta demostración formal justifica el uso del divisor $n-1$ (grados de libertad) en lugar de n para obtener un estimador insesgado de la varianza poblacional.

9.3. Distribución de estadísticos

La distribución de probabilidad de un estadístico T se denomina distribución de muestreo. Dado que $T = h(X_1, \dots, X_n)$ es en sí misma una variable aleatoria, posee su propia función de densidad o masa de probabilidad, la cual describe cómo varía el valor del estadístico a través de todas las muestras posibles de tamaño n (Devore, Capítulo 5, Sección 5.3).

La función de distribución acumulativa (FDA) de un estadístico continuo T se obtiene integrando la densidad conjunta de la muestra sobre la región donde $h(x_1, \dots, x_n) \leq t$:

$$F_T(t) = P(T \leq t) = \int \cdots \int_{h(x_1, \dots, x_n) \leq t} \prod_{i=1}^n f(x_i) dx_1 \cdots dx_n$$

1. Distribución de la media muestral:

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

Su densidad es $f_{\bar{X}}(x) = \frac{\sqrt{n}}{\sigma\sqrt{2\pi}} \exp\left(-\frac{n(x-\mu)^2}{2\sigma^2}\right)$.

2. Distribución de la varianza muestral: La variable estandarizada $(n-1)S^2/\sigma^2$ sigue una distribución Chi-cuadrada con $\nu = n-1$ grados de libertad:

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$$

3. Independencia de $\bar{X}$ y S^2 : Bajo la suposición de normalidad poblacional, el teorema de Basu garantiza que $\bar{X}$ y S^2 son estadísticos mutuamente independientes, una propiedad crucial para la construcción de pruebas de hipótesis como la t de Student.

9.4. Teorema central del límite

Cuando la población subyacente no es normal, las distribuciones de muestreo exactas pueden ser intratables. Sin embargo, el Teorema Central del Límite (TCL) proporciona una aproximación asintótica fundamental. El TCL establece que, para una muestra aleatoria de tamaño n extraída de cualquier población con media finita μ y varianza finita $\sigma^2 > 0$, la distribución de la media muestral estandarizada converge a la distribución normal estándar a medida que $n \rightarrow \infty$ (Devore, Capítulo 5, Sección 5.4).

Formalmente, si definimos la variable estandarizada Z_n como:

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} = \frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}}$$

Entonces, la convergencia en distribución se expresa mediante el límite de la función de distribución acumulativa:

$$\lim_{n \rightarrow \infty} P(Z_n \leq z) = \lim_{n \rightarrow \infty} \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = \Phi(z)$$

para todo $z \in \mathbb{R}$.

En la práctica astronómica y astrofísica, esto implica que para tamaños de muestra suficientemente grandes (típicamente $n \geq 30$), podemos aproximar la distribución de $\bar{X}$ como:

$$\bar{X}_n \stackrel{\text{aprox}}{\sim} N\left(\mu, \frac{\sigma^2}{n}\right)$$

De manera equivalente, para la suma total de las observaciones $T_n = \sum_{i=1}^n X_i$, el TCL dicta que:

$$T_n \stackrel{\text{aprox}}{\sim} N(n\mu, n\sigma^2)$$

Esta propiedad es la justificación teórica de por qué el ruido de disparo (*shot noise*) en los detectores CCD, que sigue una distribución de Poisson (discreta y asimétrica para tasas bajas), se modela como una distribución Gaussiana (continua y simétrica) cuando el número de fotones colectados es grande, permitiendo el uso de técnicas de mínimos cuadrados y máxima verosimilitud basadas en la normalidad.

9.5. Estimación puntual: Método de momentos

La estimación puntual busca calcular un valor único, basado en los datos de la muestra, que sirva como la mejor aproximación para un parámetro poblacional desconocido θ . El Método de Momentos es una técnica algorítmica para derivar estimadores que consiste en igualar los momentos muestrales con los momentos poblacionales correspondientes (Devore, Capítulo 6, Sección 6.2).

Sea $X_1, \dots, X_n$ una muestra aleatoria de una población con densidad $f(x; \theta_1, \dots, \theta_k)$, donde $\theta_1, \dots, \theta_k$ son k parámetros desconocidos.

El j -ésimo momento poblacional (no centrado) se define como una función de los parámetros:

$$\mu'_j = E(X^j) = \int_{-\infty}^{\infty} x^j f(x; \theta_1, \dots, \theta_k) dx = g_j(\theta_1, \dots, \theta_k)$$

El j -ésimo momento muestral se define puramente en términos de las observaciones:

$$M_j = \frac{1}{n} \sum_{i=1}^n X_i^j$$

El método establece el siguiente sistema de k ecuaciones simultáneas:

$$\mu'_1(\theta_1, \dots, \theta_k) = M_1$$

$$\mu'_2(\theta_1, \dots, \theta_k) = M_2$$

$$\vdots$$

$$\mu'_k(\theta_1, \dots, \theta_k) = M_k$$

Al resolver este sistema algebraico para $\theta_1, \dots, \theta_k$, se obtienen los estimadores de momentos $\hat{\theta}_1, \dots, \hat{\theta}_k$.

Ejemplo de formulación matemática: Estimación para una Distribución Gamma Supongamos que los tiempos de llegada de ciertos eventos astrofísicos siguen una distribución Gamma con parámetros de forma α y escala β . La densidad es $f(x; \alpha, \beta) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}$. Los primeros dos momentos poblacionales son:

$$\mu'_1 = E(X) = \alpha\beta$$

$$\mu'_2 = E(X^2) = V(X) + [E(X)]^2 = \alpha\beta^2 + (\alpha\beta)^2 = \alpha\beta^2(1 + \alpha)$$

Igualemos a los momentos muestrales $M_1 = \bar{X}$ y $M_2 = \frac{1}{n} \sum X_i^2$: 1) $\hat{\alpha}\hat{\beta} = \bar{X} \implies \hat{\beta} = \frac{\bar{X}}{\hat{\alpha}}$ 2) $\hat{\alpha}\hat{\beta}^2(1 + \hat{\alpha}) = M_2$

Sustituimos (1) en (2):

$$\hat{\alpha} \left(\frac{\bar{X}}{\hat{\alpha}} \right)^2 (1 + \hat{\alpha}) = M_2 \implies \frac{\bar{X}^2}{\hat{\alpha}} (1 + \hat{\alpha}) = M_2 \implies \bar{X}^2 \left(\frac{1}{\hat{\alpha}} + 1 \right) = M_2$$

Despejando $\hat{\alpha}$:

$$\frac{1}{\hat{\alpha}} + 1 = \frac{M_2}{\bar{X}^2} \implies \frac{1}{\hat{\alpha}} = \frac{M_2 - \bar{X}^2}{\bar{X}^2}$$

Notamos que $M_2 - \bar{X}^2 = \frac{1}{n} \sum X_i^2 - \bar{X}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$, la cual es la varianza muestral sesgada, denotada comúnmente como $\tilde{S}^2$. Por lo tanto, los estimadores de momentos cerrados son:

$$\hat{\alpha} = \frac{\bar{X}^2}{\tilde{S}^2}$$

$$\hat{\beta} = \frac{\tilde{S}^2}{\bar{X}}$$

Este procedimiento demuestra cómo el método de momentos traduce directamente las propiedades teóricas de la distribución (sus momentos) en fórmulas algebraicas explícitas aplicables a los datos observacionales, sin requerir la maximización de funciones de verosimilitud complejas.

9.5.1. Ejemplo 1: Acumulación de Errores de Navegación y el Significado del Teorema Central del Límite

Para visualizar el poder y el significado profundo del Teorema Central del Límite (TCL), es necesario alejarse de las distribuciones normales y observar qué ocurre cuando los errores individuales siguen una distribución exótica, con colas pesadas y una función de densidad compleja. En la astrodinámica operativa, los sensores de navegación a menudo enfrentan ambientes de ruido no gaussianos.

Consideremos un rastreador de estrellas (Star Tracker) en una sonda de espacio profundo. Debido a la dispersión de la luz zodiacal y a impactos microscópicos de polvo en los baffles ópticos, el error de medición angular X_i (en arcosegundos) no sigue una campana de Gauss, sino una distribución con colas pesadas modelada por la siguiente función de densidad de probabilidad:

$$f(x) = \frac{\sqrt{2}}{\pi} \frac{1}{1+x^4} \quad \text{para } -\infty < x < \infty$$

Esta es una distribución legítima. Para comprobarlo y extraer sus momentos, debemos evaluar integrales impropias no triviales.

Paso 1: Verificación de la densidad y cálculo de momentos La integral de normalización es un resultado clásico del análisis complejo (residuos):

$$\int_{-\infty}^{\infty} \frac{1}{1+x^4} dx = \frac{\pi}{\sqrt{2}}$$

Por lo tanto, $\int_{-\infty}^{\infty} f(x) dx = \frac{\sqrt{2}}{\pi} \cdot \frac{\pi}{\sqrt{2}} = 1$. Dado que $f(x)$ es una función par y x es impar, el valor esperado (la media) es estrictamente cero por simetría:

$$\mu = E(X) = \int_{-\infty}^{\infty} x f(x) dx = 0$$

Para la varianza, evaluamos el segundo momento:

$$\sigma^2 = E(X^2) = \int_{-\infty}^{\infty} x^2 \frac{\sqrt{2}}{\pi} \frac{1}{1+x^4} dx = \frac{\sqrt{2}}{\pi} \int_{-\infty}^{\infty} \frac{x^2}{1+x^4} dx$$

La integral $\int_{-\infty}^{\infty} \frac{x^2}{1+x^4} dx$ también converge a $\frac{\pi}{\sqrt{2}}$. Por lo tanto, la varianza es:

$$\sigma^2 = \frac{\sqrt{2}}{\pi} \cdot \frac{\pi}{\sqrt{2}} = 1$$

Tenemos una variable aleatoria con media $\mu = 0$ y varianza finita $\sigma^2 = 1$, pero cuya forma es radicalmente distinta a una normal (sus colas decaen como $1/x^4$, mucho más lento que la exponencial e^{-x^2} de una Gaussiana).

Paso 2: El problema de la medición individual (La pesadilla analítica) Supongamos que queremos calcular la probabilidad de que un solo error de medición supere los 0.15 arcosegundos. Debemos integrar la función exótica:

$$P(X_1 > 0.15) = \int_{0.15}^{\infty} \frac{\sqrt{2}}{\pi} \frac{1}{1+x^4} dx$$

La antiderivada de $\frac{1}{1+x^4}$ es notoriamente compleja, involucrando logaritmos y arcotangentes:

$$\int \frac{1}{1+x^4} dx = \frac{1}{4\sqrt{2}} \ln \left(\frac{x^2 + x\sqrt{2} + 1}{x^2 - x\sqrt{2} + 1} \right) + \frac{1}{2\sqrt{2}} \arctan \left(\frac{x\sqrt{2}}{1-x^2} \right)$$

Evaluar esta expresión entre 0,15 e ∞ es un proceso tedioso y propenso a errores numéricos debido a las asíntotas de la arcotangente. Además, debido a las colas pesadas, esta probabilidad es relativamente alta comparada con una distribución normal.

Paso 3: La magia del Teorema Central del Límite Ahora, el sistema de navegación no toma una sola medición, sino que promedia $n = 100$ observaciones independientes para suavizar el ruido. La variable de interés es la media muestral:

$$\bar{X}_{100} = \frac{1}{100} \sum_{i=1}^{100} X_i$$

Aquí es donde el TCL (Devore, Capítulo 5, Sección 5.4) revela su verdadero significado físico y matemático. El teorema establece que, sin importar cuán exótica, asimétrica o de colas pesadas sea la distribución original $f(x)$, siempre que la varianza sea finita, la distribución de la media muestral $\bar{X}_n$ converge a una distribución normal a medida que n crece.

Para $n = 100$, la aproximación es extraordinariamente precisa. La media de $\bar{X}_{100}$ es $\mu_{\bar{X}} = \mu = 0$, y su varianza es $\sigma_{\bar{X}}^2 = \sigma^2/n = 1/100 = 0,01$. Por lo tanto:

$$\bar{X}_{100} \approx N(0, 0,01)$$

Paso 4: Cálculo de la probabilidad acumulada Ahora, calcular la probabilidad de que el error promedio de las 100 mediciones supere los 0.15 arcosegundos se vuelve trivial. Ya no necesitamos la antiderivada exótica. Estandarizamos y usamos la función de distribución acumulativa estándar $\Phi(z)$:

$$P(\bar{X}_{100} > 0,15) = P\left(Z > \frac{0,15 - 0}{\sqrt{0,01}}\right) = P(Z > 1,5)$$

$$P(Z > 1,5) = 1 - \Phi(1,5) \approx 1 - 0,9332 = 0,0668$$

Significado y Conclusión Este ejemplo visualiza la esencia del Teorema Central del Límite. En el mundo físico, los errores instrumentales rara vez son puros y gaussianos; están contaminados por anomalías, colas pesadas y distribuciones complejas (como nuestra $f(x)$ con raíces cuárticas). Intentar modelar el error total sumando analíticamente estas distribuciones exóticas es computacional y matemáticamente inviable.

El TCL nos garantiza que el acto de promediar (o sumar) múltiples fuentes de error independientes actúa como un filtro matemático universal. Transforma el caos de distribuciones individuales irregulares en la perfecta, predecible y tabulada campana de Gauss. Esto permite a los ingenieros de astrodinámica utilizar las tablas normales estándar para calcular márgenes de error y probabilidades de fallo, confiando en que la naturaleza misma de la acumulación de variables aleatorias finitas dicta este comportamiento asintótico, independientemente de la física subyacente de cada sensor individual.

9.5.2. Ejemplo: Estimación de Parámetros de Albedo en Poblaciones de Asteroides mediante el Método de Momentos

Para expresar al máximo la metodología y comprender su alcance deductivo, aplicaremos el Método de Momentos a un problema real en la ciencia planetaria. Según los principios de estadística aplicada a la caracterización de superficies (*Planetary Geology*, Capítulo sobre *Surface Properties and Reflectance*), el albedo geométrico p_V de una población de asteroides es una variable estrictamente acotada en el intervalo $(0, 1)$.

Para modelar la distribución de albedos de una familia colisional específica (por ejemplo, la familia Flora, dominada por asteroides de tipo S), la distribución Beta es un modelo continuo excepcionalmente adecuado. La función de densidad de probabilidad para el albedo X está dada por:

$$f(x; \alpha, \beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1} \quad \text{para } 0 < x < 1$$

donde $\alpha > 0$ y $\beta > 0$ son los parámetros de forma que definen la asimetría y concentración de la población.

El objetivo es encontrar los estimadores de momento $\hat{\alpha}$ y $\hat{\beta}$ para una muestra aleatoria de n asteroides con albedos observados $X_1, X_2, \dots, X_n$. Dado que tenemos $m = 2$ parámetros desconocidos, el método (Devore, Capítulo 6, Sección 6.2) nos exige igualar los dos primeros momentos poblacionales con los dos primeros momentos muestrales.

Paso 1: Definición de los Momentos Poblacionales De la teoría de la distribución Beta, los primeros dos momentos crudos poblacionales son:

$$\begin{aligned} \mu'_1 &= E(X) = \frac{\alpha}{\alpha + \beta} \\ \mu'_2 &= E(X^2) = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)} \end{aligned}$$

Paso 2: Definición de los Momentos Muestrales Los momentos muestrales se calculan puramente a partir de los datos observados, sin asumir ninguna distribución subyacente:

$$\begin{aligned} M_1 &= \frac{1}{n} \sum_{i=1}^n X_i = \bar{X} \\ M_2 &= \frac{1}{n} \sum_{i=1}^n X_i^2 \end{aligned}$$

Paso 3: Planteamiento y Resolución del Sistema de Ecuaciones El núcleo del método consiste en resolver el sistema no lineal de dos ecuaciones con dos incógnitas: 1) $\frac{\alpha}{\alpha + \beta} = M_1$ 2) $\frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)} = M_2$

Para despejar los parámetros de manera elegante, definimos la suma de los parámetros como $S = \alpha + \beta$. De la ecuación (1), obtenemos inmediatamente $\alpha = M_1 S$. Dado que $\alpha + \beta = S$, podemos deducir que $\beta = S - \alpha = S(1 - M_1)$.

Sustituimos $\alpha = M_1 S$ y $\alpha + \beta = S$ en la ecuación (2):

$$\frac{(M_1 S)(M_1 S + 1)}{S(S + 1)} = M_2$$

Cancelamos S en el denominador y expandimos el numerador:

$$\frac{M_1^2 S + M_1}{S + 1} = M_2$$

$$M_1^2 S + M_1 = M_2 S + M_2$$

Agrupamos los términos que contienen S en un lado de la igualdad:

$$S(M_1^2 - M_2) = M_2 - M_1$$

Despejamos S :

$$S = \frac{M_2 - M_1}{M_1^2 - M_2} = \frac{M_1 - M_2}{M_2 - M_1^2}$$

Finalmente, sustituimos S en las expresiones para α y β para obtener los estimadores de momento cerrados:

$$\hat{\alpha} = M_1 \left(\frac{M_1 - M_2}{M_2 - M_1^2} \right)$$

$$\hat{\beta} = (1 - M_1) \left(\frac{M_1 - M_2}{M_2 - M_1^2} \right)$$

Paso 4: Interpretación Matemática y Física de los Estimadores El resultado anterior nos permite realizar un desglose profundo de las propiedades de estos estimadores:

1. **Relación con la Varianza Muestral:** El denominador $M_2 - M_1^2$ es exactamente la varianza muestral sesgada (el segundo momento central muestral), denotada comúnmente como $\tilde{S}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$. El numerador $M_1 - M_2$ puede reescribirse como $\bar{X} - \frac{1}{n} \sum X_i^2$. Dado que el albedo está estrictamente acotado entre 0 y 1, se cumple que $X_i > X_i^2$ para todo i . Por lo tanto, $M_1 > M_2$, lo que garantiza que el numerador es estrictamente positivo.

2. **Garantía del Espacio de Parámetros:** Una de las críticas frecuentes al Método de Momentos es que puede producir estimadores fuera del espacio de parámetros físico (por ejemplo, una varianza negativa). Sin embargo, para variables acotadas en $(0, 1)$ como el albedo, la estructura algebraica garantiza que $\tilde{S}^2 > 0$ y $M_1 - M_2 > 0$. En consecuencia, $\hat{\alpha} > 0$ y $\hat{\beta} > 0$ están matemáticamente asegurados para cualquier muestra válida. El método no fallará arrojando formas paramétricas imposibles.

3. **Significado Planetológico:** Los parámetros α y β dictan la naturaleza de la familia de asteroides. Si la muestra arroja un albedo promedio $\bar{X} = 0,25$ y una varianza $\tilde{S}^2 = 0,01$, los estimadores serían:

$$\hat{\alpha} = 0,25 \left(\frac{0,25 - (0,01 + 0,25^2)}{0,01} \right) = 0,25 \left(\frac{0,1875}{0,01} \right) = 4,6875$$

$$\hat{\beta} = (1 - 0,25)(18,75) = 14,0625$$

La relación $\hat{\alpha}/\hat{\beta} \approx 1/3$ indica que la distribución está fuertemente sesgada hacia valores oscuros. En el contexto de *Planetary Geology*, esto confirmaría que la familia está dominada por condritas carbonáceas (tipo C), con muy pocos miembros de alto albedo.

4. Ventaja Computacional frente a la Máxima Verosimilitud: Para la distribución Beta, obtener los estimadores de Máxima Verosimilitud (MLE) requiere igualar las derivadas de la log-verosimilitud a cero, lo que involucra la función Digamma $\psi(x) = \frac{d}{dx} \ln \Gamma(x)$. Esto no tiene solución algebraica cerrada y exige algoritmos numéricos iterativos (como Newton-Raphson). El Método de Momentos, en contraste, nos ha proporcionado una solución explícita, exacta y de costo computacional nulo, ideal para pipelines de reducción de datos en tiempo real donde se procesan miles de objetos transitorios diariamente.

Clase 10

10.1. Método de Mínimos Cuadrados

El método de mínimos cuadrados es el pilar fundamental de la estimación de parámetros y la ajuste de modelos en la ciencia de datos, la estadística y la astrodinámica. Su objetivo es encontrar la configuración de parámetros de un modelo matemático que minimice la discrepancia global entre los datos observados y los valores predichos por el modelo.

De acuerdo con el texto guía de estadística, el principio de mínimos cuadrados establece que un modelo proporciona un buen ajuste si las distancias verticales (desviaciones o residuos) de los puntos observados al modelo son pequeñas, y la medida de esta bondad de ajuste es la suma de los cuadrados de estas desviaciones (Devore, Capítulo 12). En el contexto de la determinación de órbitas y la navegación espacial, este método se utiliza para estimar el vector de estado de una nave o cuerpo celeste minimizando la diferencia entre las observaciones reales de los sensores y las observaciones computadas a partir de la dinámica orbital (Vallado, Capítulo 10).

10.1.1. Fundamento Matemático y Función de Costo

Sea un conjunto de N observaciones independientes $\vec{y} = [y_1, y_2, \dots, y_N]^T$ obtenidas en ciertos instantes o condiciones representadas por el vector $\vec{x}$. Supongamos que existe un modelo teórico $f(x_i, \vec{\theta})$ que depende de un vector de p parámetros desconocidos $\vec{\theta} = [\theta_1, \theta_2, \dots, \theta_p]^T$.

El residuo r_i para la i -ésima observación se define como la diferencia entre el valor medido y el valor predicho por el modelo:

$$r_i(\vec{\theta}) = y_i - f(x_i, \vec{\theta})$$

La función de costo (o función objetivo) $J(\vec{\theta})$, que representa el error cuadrático total, se construye sumando los cuadrados de todos los residuos:

$$J(\vec{\theta}) = \sum_{i=1}^N r_i^2 = \sum_{i=1}^N [y_i - f(x_i, \vec{\theta})]^2$$

La elección de elevar al cuadrado los residuos no es arbitraria; cumple tres funciones matemáticas cruciales: 1. Evita que los errores positivos y negativos se cancelen entre sí. 2. Penaliza fuertemente las desviaciones grandes, haciendo que el modelo sea sensible a los valores atípicos. 3. Transforma el problema de optimización en uno diferenciable y, para modelos lineales en sus parámetros, garantiza que la función de costo sea una forma cuadrática convexa, lo que asegura la existencia de un mínimo global único (Devore, Capítulo 12).

10.1.2. Formulación Matricial y Ecuaciones Normales

Cuando el modelo es lineal con respecto a los parámetros, es decir, $f(x_i, \vec{\theta}) = \theta_0 + \theta_1 x_{i1} + \dots + \theta_p x_{ip}$, el sistema puede expresarse elegantemente mediante álgebra lineal. Definimos la matriz de diseño H de tamaño $N \times (p + 1)$, donde cada fila contiene las variables independientes de la i -ésima observación:

$$H = \begin{bmatrix} 1 & x_{11} & \dots & x_{1p} \\ 1 & x_{21} & \dots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{N1} & \dots & x_{Np} \end{bmatrix}$$

El modelo completo se escribe como $\vec{y} = H\vec{\theta} + \vec{\epsilon}$, donde $\vec{\epsilon}$ es el vector de errores. La función de costo en notación matricial es:

$$J(\vec{\theta}) = (\vec{y} - H\vec{\theta})^T (\vec{y} - H\vec{\theta})$$

Para encontrar el estimador de mínimos cuadrados $\hat{\vec{\theta}}$, aplicamos el cálculo vectorial y igualamos el gradiente de J con respecto a $\vec{\theta}$ al vector cero:

$$\frac{\partial J}{\partial \vec{\theta}} = -2H^T(\vec{y} - H\vec{\theta}) = \vec{0}$$

Al reorganizar los términos, obtenemos el sistema de ecuaciones normales:

$$H^T H \hat{\vec{\theta}} = H^T \vec{y}$$

Si la matriz $H^T H$ es no singular (es decir, las columnas de H son linealmente independientes), la solución única que minimiza la suma de cuadrados es:

$$\hat{\vec{\theta}} = (H^T H)^{-1} H^T \vec{y}$$

10.1.3. Extensión a Sistemas No Lineales: Determinación de Órbitas

En la astrodinámica y la navegación de naves espaciales, la relación entre el vector de estado $\vec{X}$ (posición y velocidad) y las observaciones $\vec{y}$ (como rango, azimut y elevación) es altamente no lineal debido a las ecuaciones de movimiento orbital y la geometría esférica de las mediciones (Vallado, Capítulo 10). No podemos aplicar directamente la fórmula cerrada $(H^T H)^{-1} H^T \vec{y}$.

En su lugar, se utiliza un proceso iterativo de corrección diferencial (método de Gauss-Newton). Dado un estado nominal inicial $\vec{X}_{nom}$, linealizamos las observaciones computadas $\vec{y}_{comp} = f(\vec{X})$ mediante una serie de Taylor truncada de primer orden:

$$\vec{y}_{obs} - \vec{y}_{comp} \approx \frac{\partial f}{\partial \vec{X}} \Delta \vec{X} = H \Delta \vec{X}$$

Aquí, H es la matriz Jacobiana (o matriz de parciales), cuyos elementos son las derivadas parciales de cada observación con respecto a cada componente del vector de estado. El vector de residuos es $\Delta \vec{y} = \vec{y}_{obs} - \vec{y}_{comp}$.

Para mejorar la estimación, incorporamos una matriz de ponderación W , que generalmente es la inversa de la matriz de covarianza de los errores de observación ($W = R^{-1}$). Esto permite dar más confianza a los sensores más precisos. La corrección al estado $\Delta \vec{X}$ se calcula resolviendo el sistema normal ponderado:

$$\Delta \vec{X} = (H^T W H)^{-1} H^T W \Delta \vec{y}$$

El estado se actualiza iterativamente:

$$\vec{X}_{k+1} = \vec{X}_k + \Delta \vec{X}$$

Es imperativo destacar que, debido a la no linealidad de la dinámica orbital, la función de costo puede tener múltiples mínimos locales. Por lo tanto, el estado inicial nominal $\vec{X}_0$ debe estar suficientemente cerca del mínimo global para garantizar que el algoritmo converja correctamente y no diverja o converja a una solución física incorrecta (Vallado, Capítulo 10).

10.1.4. Verificación Computacional

Para consolidar la comprensión de la formulación matricial, se presenta un script breve en Python que resuelve las ecuaciones normales para un ajuste lineal simple, verificando la inversión de la matriz $H^T H$.

```
import numpy as np

# Datos observados (N=3)
# Modelo: y = theta_0 + theta_1 * x
H = np.array([[1, 1],
              [1, 2],
              [1, 3]])
y = np.array([2.1, 3.9, 6.2])

# Solucion de ecuaciones normales: theta = (H^T H)^-1 H^T y
H_T_H_inv = np.linalg.inv(H.T @ H)
theta_hat = H_T_H_inv @ H.T @ y

print(f"Intercepto (theta_0): {theta_hat[0]:.4f}")
print(f"Pendiente (theta_1): {theta_hat[1]:.4f}")
```

Este código demuestra la implementación directa de la derivación matemática $\hat{\theta} = (H^T H)^{-1} H^T \vec{y}$, proporcionando los parámetros que minimizan la suma de los cuadrados de los residuos para el conjunto de datos proporcionado.

10.2. Estimación de Máxima Verosimilitud

El método de máxima verosimilitud (MLE, por sus siglas en inglés) constituye uno de los pilares más robustos y elegantes de la inferencia estadística frecuentista. Según el texto guía, el principio fundamental de este método consiste en seleccionar aquellos valores de los parámetros desconocidos que maximicen la probabilidad conjunta de haber obtenido la muestra observada (Devore, Capítulo 6, Sección 6.2). En el contexto de la astrofísica observacional y la reducción de datos, como se detalla en *Astronomical Measurement* (Apéndice A.11), el objetivo de la inferencia estadística estándar es maximizar la probabilidad de los datos dado el modelo, cantidad que se denomina exactamente Verosimilitud o *Likelihood*.

Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria de una población cuya función de densidad (o masa) de probabilidad depende de un vector de m parámetros desconocidos $\vec{\theta} = [\theta_1, \theta_2, \dots, \theta_m]^T$. Dado que

las observaciones son independientes, la función de verosimilitud $L(\vec{\theta})$ se define como el producto de las probabilidades individuales, evaluada en los datos muestrales observados $x_1, \dots, x_n$:

$$L(\vec{\theta}) = \prod_{i=1}^n f(x_i; \vec{\theta})$$

Dado que maximizar un producto de n términos es computacional y algebraicamente tedioso, y para evitar problemas de subdesbordamiento numérico (underflow) cuando n es grande, se aplica el logaritmo natural. Como el logaritmo es una función monótona creciente, los valores de $\vec{\theta}$ que maximizan $L(\vec{\theta})$ también maximizan la función de log-verosimilitud $\ell(\vec{\theta})$:

$$\ell(\vec{\theta}) = \ln L(\vec{\theta}) = \sum_{i=1}^n \ln f(x_i; \vec{\theta})$$

Las estimaciones de máxima verosimilitud (EMV), denotadas como $\hat{\vec{\theta}}$, son aquellos valores que satisfacen el sistema de ecuaciones de primer orden (conocidas como ecuaciones de score), obtenidas al igualar el gradiente de la log-verosimilitud al vector cero:

$$\nabla_{\vec{\theta}} \ell(\vec{\theta}) = \vec{0} \implies \frac{\partial \ell(\vec{\theta})}{\partial \theta_j} = 0 \quad \text{para } j = 1, \dots, m$$

10.2.1. Equivalencia Formal con la Minimización de χ^2

En la práctica astronómica, es común modelar los errores instrumentales como variables aleatorias normales. *Astronomical Measurement* (Sección A.11) establece explícitamente que *se puede demostrar que minimizar χ^2 usualmente también maximiza la verosimilitud*. A continuación, se demuestra esta equivalencia fundamental para un modelo de datos general.

Supongamos que tenemos un conjunto de N observaciones y_i (por ejemplo, flujos fotométricos o posiciones astrométricas) que dependen de un modelo teórico $M_i(\vec{\theta})$ (por ejemplo, una curva de tránsito exoplanetario o una órbita kepleriana). Los residuos están dominados por ruido gaussiano independiente con media cero y varianzas conocidas σ_i^2 (derivadas, por ejemplo, del ruido de disparo o *shot noise*).

La función de densidad para cada observación es:

$$f(y_i; \vec{\theta}) = \frac{1}{\sqrt{2\pi}\sigma_i} \exp\left(-\frac{[y_i - M_i(\vec{\theta})]^2}{2\sigma_i^2}\right)$$

Construimos la log-verosimilitud:

$$\ell(\vec{\theta}) = \sum_{i=1}^N \left[-\ln(\sqrt{2\pi}\sigma_i) - \frac{[y_i - M_i(\vec{\theta})]^2}{2\sigma_i^2} \right]$$

Separamos los términos que no dependen de $\vec{\theta}$ y los agrupamos en una constante C :

$$\ell(\vec{\theta}) = C - \frac{1}{2} \sum_{i=1}^N \frac{[y_i - M_i(\vec{\theta})]^2}{\sigma_i^2}$$

Reconocemos que la sumatoria es exactamente la definición estadística de la chi-cuadrada (χ^2) para el modelo:

$$\chi^2(\vec{\theta}) = \sum_{i=1}^N \frac{[y_i - M_i(\vec{\theta})]^2}{\sigma_i^2}$$

Por lo tanto, la relación analítica directa es:

$$\ell(\vec{\theta}) = C - \frac{1}{2} \chi^2(\vec{\theta})$$

Dado que C es una constante independiente de los parámetros, maximizar $\ell(\vec{\theta})$ con respecto a $\vec{\theta}$ es matemáticamente idéntico a minimizar $\chi^2(\vec{\theta})$. Esta demostración justifica por qué los algoritmos de ajuste de curvas en astronomía (como el algoritmo de Levenberg-Marquardt mencionado en *Modern Spacecraft Guidance, Navigation, and Control*) buscan minimizar χ^2 ; están realizando implícitamente una estimación de máxima verosimilitud bajo la hipótesis de ruido gaussiano.

10.2.2. Propiedades Asintóticas y el Principio de Invarianza

El método de máxima verosimilitud goza de propiedades teóricas excepcionales cuando el tamaño de la muestra n es grande. De acuerdo con Devore (Proposición en Sección 6.2), bajo condiciones generales de regularidad, el EMV $\hat{\theta}$ es aproximadamente insesgado y su varianza es casi tan pequeña como la que puede ser lograda por cualquier estimador. En términos formales, el EMV es asintóticamente el estimador insesgado de varianza mínima (eficiente), alcanzando el límite inferior de Cramér-Rao.

Además, el método posee una propiedad algebraica sumamente útil para la inferencia de parámetros derivados, conocida como el **Principio de Invarianza** (Devore, Ejemplo 6.19).

PROPOSICIÓN: Sean $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$ los estimadores de máxima verosimilitud de los parámetros $\theta_1, \theta_2, \dots, \theta_m$. Entonces, el estimador de máxima verosimilitud de cualquier función $h(\theta_1, \theta_2, \dots, \theta_m)$ es simplemente la función evaluada en los EMV originales:

$$\widehat{h(\theta)} = h(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m)$$

Aplicación en Astrofísica: Supongamos que modelamos el espectro de una estrella para estimar la temperatura efectiva T y el radio estelar R . El método de máxima verosimilitud nos proporciona directamente los estimadores $\hat{T}$ y $\hat{R}$. Si el objetivo científico posterior es calcular la luminosidad bolométrica de la estrella, la cual es una función no lineal de los parámetros originales dada por la ley de Stefan-Boltzmann $L = 4\pi\sigma_{SB}R^2T^4$, no es necesario reconstruir la función de verosimilitud conjunta para L . Gracias al principio de invarianza, el EMV de la luminosidad es simplemente:

$$\hat{L} = 4\pi\sigma_{SB}\hat{R}^2\hat{T}^4$$

Esta propiedad evita la necesidad de realizar transformaciones de variables aleatorias complejas (como el uso de Jacobianos para encontrar la distribución de L) antes de estimar el parámetro, simplificando drásticamente los pipelines de reducción de datos en misiones espaciales donde se deben derivar cientos de parámetros físicos a partir de un conjunto común de observaciones crudas.

10.2.3. Ejemplo 1: Estimación de Trayectoria en Descenso Planetario

Para materializar la teoría del método de mínimos cuadrados y observar su potencia en un contexto de ingeniería aeroespacial, abordaremos un problema clásico de determinación de estado durante la fase de descenso de una sonda espacial. De acuerdo con los principios de navegación y estimación de estados (*Modern Spacecraft Guidance, Navigation, and Control*, Capítulo 10; *Fundamentals of Astrodynamics and Applications*, Vallado, Capítulo 10), el ordenador de a bordo (GNC) debe estimar la posición, velocidad y aceleración del vehículo utilizando una secuencia de mediciones de un altímetro de radar, las cuales están inevitablemente corruptas por ruido instrumental.

Formulación del Problema y Matriz de Diseño

Durante los últimos segundos del descenso, la trayectoria vertical $h(t)$ puede aproximarse localmente como un polinomio de segundo orden. Definimos el vector de parámetros desconocidos (el estado cinemático) como $\vec{\theta} = [\theta_0, \theta_1, \theta_2]^T$, donde:

- θ_0 : Altitud inicial (m).
- θ_1 : Velocidad vertical inicial (m/s).
- θ_2 : Mitad de la aceleración vertical constante (m/s²).

El modelo teórico para la i -ésima medición en el instante t_i es $f(t_i, \vec{\theta}) = \theta_0 + \theta_1 t_i + \theta_2 t_i^2$. El altímetro toma $N = 4$ mediciones en los instantes $t = [0, 1, 2, 3]$ segundos. El vector de observaciones reales $\vec{y}$, que incluye el ruido del sensor, es:

$$\vec{y} = \begin{bmatrix} 1002 \\ 946 \\ 879 \\ 807 \end{bmatrix} \text{ m}$$

Construimos la matriz de diseño H de tamaño 4×3 , donde cada fila evalúa las funciones base del modelo en el tiempo t_i :

$$H = \begin{bmatrix} 1 & t_1 & t_1^2 \\ 1 & t_2 & t_2^2 \\ 1 & t_3 & t_3^2 \\ 1 & t_4 & t_4^2 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 2 & 4 \\ 1 & 3 & 9 \end{bmatrix}$$

Resolución de las Ecuaciones Normales

El objetivo es encontrar el estimador $\hat{\vec{\theta}}$ que minimiza la función de costo $J(\vec{\theta}) = \sum_{i=1}^4 [y_i - f(t_i, \vec{\theta})]^2$. Utilizando la formulación matricial derivada previamente, la solución óptima satisface el sistema de ecuaciones normales:

$$H^T H \hat{\vec{\theta}} = H^T \vec{y}$$

Calculamos el producto $H^T H$:

$$H^T H = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 0 & 1 & 2 & 3 \\ 0 & 1 & 4 & 9 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 2 & 4 \\ 1 & 3 & 9 \end{bmatrix} = \begin{bmatrix} 4 & 6 & 14 \\ 6 & 14 & 36 \\ 14 & 36 & 98 \end{bmatrix}$$

Calculamos el vector del lado derecho $H^T \vec{y}$:

$$H^T \vec{y} = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 0 & 1 & 2 & 3 \\ 0 & 1 & 4 & 9 \end{bmatrix} \begin{bmatrix} 1002 \\ 946 \\ 879 \\ 807 \end{bmatrix} = \begin{bmatrix} 1002 + 946 + 879 + 807 \\ 0 + 946 + 1758 + 2421 \\ 0 + 946 + 3516 + 7263 \end{bmatrix} = \begin{bmatrix} 3634 \\ 5125 \\ 11725 \end{bmatrix}$$

Ahora debemos resolver el sistema lineal 3×3 :

$$\begin{bmatrix} 4 & 6 & 14 \\ 6 & 14 & 36 \\ 14 & 36 & 98 \end{bmatrix} \begin{bmatrix} \hat{\theta}_0 \\ \hat{\theta}_1 \\ \hat{\theta}_2 \end{bmatrix} = \begin{bmatrix} 3634 \\ 5125 \\ 11725 \end{bmatrix}$$

Mediante eliminación gaussiana o inversión matricial directa, obtenemos la solución única para el estimador de mínimos cuadrados:

$$\hat{\vec{\theta}} = (H^T H)^{-1} H^T \vec{y} = \begin{bmatrix} 1002,3 \\ -53,2 \\ -4,0 \end{bmatrix}$$

Análisis de Residuos y Función de Costo

Una vez obtenido $\hat{\vec{\theta}}$, el siguiente paso riguroso es evaluar la bondad del ajuste calculando el vector de residuos $\vec{r} = \vec{y} - H\hat{\vec{\theta}}$. Primero, calculamos las observaciones computadas (el modelo evaluado en los parámetros estimados):

$$H\hat{\vec{\theta}} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 2 & 4 \\ 1 & 3 & 9 \end{bmatrix} \begin{bmatrix} 1002,3 \\ -53,2 \\ -4,0 \end{bmatrix} = \begin{bmatrix} 1002,3 \\ 1002,3 - 53,2 - 4,0 \\ 1002,3 - 106,4 - 16,0 \\ 1002,3 - 159,6 - 36,0 \end{bmatrix} = \begin{bmatrix} 1002,3 \\ 945,1 \\ 879,9 \\ 806,7 \end{bmatrix}$$

Restamos esto de las observaciones reales para obtener los residuos:

$$\vec{r} = \begin{bmatrix} 1002 \\ 946 \\ 879 \\ 807 \end{bmatrix} - \begin{bmatrix} 1002,3 \\ 945,1 \\ 879,9 \\ 806,7 \end{bmatrix} = \begin{bmatrix} -0,3 \\ 0,9 \\ -0,9 \\ 0,3 \end{bmatrix} \text{ m}$$

Podemos verificar una propiedad fundamental del método: la suma de los residuos es estrictamente cero ($-0,3 + 0,9 - 0,9 + 0,3 = 0$), lo cual es una consecuencia directa de que el modelo incluye un término constante (la columna de unos en H).

Finalmente, evaluamos el valor mínimo de la función de costo $J(\hat{\vec{\theta}})$:

$$J(\hat{\vec{\theta}}) = \vec{r}^T \vec{r} = (-0,3)^2 + (0,9)^2 + (-0,9)^2 + (0,3)^2 = 0,09 + 0,81 + 0,81 + 0,09 = 1,80 \text{ m}^2$$

Interpretación en el Contexto de la Misión

El vector $\hat{\vec{\theta}} = [1002,3, -53,2, -4,0]^T$ proporciona al sistema de guía la estimación óptima del estado de la nave en $t = 0$.

- La altitud estimada es 1002,3 m.
- La velocidad de descenso es 53,2 m/s (el signo negativo indica dirección hacia la superficie).
- La aceleración vertical neta es $2 \times (-4,0) = -8,0 \text{ m/s}^2$. Dado que la gravedad marciana es aproximadamente $3,7 \text{ m/s}^2$ hacia abajo, una aceleración neta de $-8,0 \text{ m/s}^2$ indica que los propulsores de descenso están generando un empuje significativo para frenar la sonda.

El valor de la función de costo $J = 1,80 \text{ m}^2$ cuantifica la energía del ruido del altímetro. En un filtro de corrección diferencial (*Fundamentals of Astrodynamics and Applications*, Vallado, Sección 10.4), si este valor de J excediera ciertos umbrales estadísticos (basados en la varianza esperada del sensor), el sistema de navegación detectaría una posible falla instrumental o una dinámica no modelada (como una ráfaga de viento severa), activando protocolos de contingencia. Este ejemplo demuestra cómo la abstracción matricial de los mínimos cuadrados se traduce directamente en algoritmos de estimación de estado vitales para la supervivencia de una misión espacial.

10.2.4. Ejemplo: Estimación de la Pendiente de la Función Inicial de Masas en un Cúmulo Estelar

Para ilustrar el poder y la complejidad matemática del método de Máxima Verosimilitud (MLE) en un contexto astrofísico de alto nivel, abordaremos la estimación de los parámetros de la Función Inicial de Masas (IMF, por sus siglas en inglés). En el estudio de poblaciones estelares y evolución galáctica (*Astronomical Measurement*, Capítulo sobre *Stellar Populations and Luminosity Functions*), la IMF describe la distribución de masas de las estrellas en el momento de su formación.

Para un cúmulo estelar joven, la IMF de Salpeter se modela como una ley de potencias truncada, ya que las estrellas tienen límites físicos de masa (no pueden ser infinitamente masivas ni tener masa cero). Definimos la variable aleatoria continua M como la masa de una estrella individual, medida en masas solares ($M_\odot$). La función de densidad de probabilidad (FDP) para M , parametrizada por el índice espectral α , es:

$$f(m; \alpha) = \begin{cases} C(\alpha)m^{-\alpha} & \text{para } m_{min} \leq m \leq m_{max} \\ 0 & \text{en otro caso} \end{cases}$$

donde m_{min} y m_{max} son los límites físicos de masa del cúmulo (por ejemplo, $0,1M_\odot$ y $100M_\odot$), y $C(\alpha)$ es la constante de normalización.

Paso 1: Normalización de la Función de Densidad Para que $f(m; \alpha)$ sea una FDP legítima, su integral sobre el soporte debe ser la unidad (Devore, Capítulo 4, Sección 4.1):

$$\int_{m_{min}}^{m_{max}} C(\alpha) m^{-\alpha} dm = 1$$

Asumiendo $\alpha \neq 1$, resolvemos la integral:

$$C(\alpha) \left[\frac{m^{1-\alpha}}{1-\alpha} \right]_{m_{min}}^{m_{max}} = C(\alpha) \frac{m_{max}^{1-\alpha} - m_{min}^{1-\alpha}}{1-\alpha} = 1$$

Despejando la constante de normalización:

$$C(\alpha) = \frac{1-\alpha}{m_{max}^{1-\alpha} - m_{min}^{1-\alpha}}$$

Paso 2: Construcción de la Función de Verosimilitud Supongamos que, mediante espectroscopia de alta resolución y modelos de evolución estelar, hemos determinado las masas de una muestra aleatoria de N estrellas independientes en el cúmulo: $m_1, m_2, \dots, m_N$. Dado que las observaciones son independientes, la función de verosimilitud conjunta $L(\alpha)$ es el producto de las densidades individuales evaluadas en los datos observados (Devore, Capítulo 6, Sección 6.2):

$$L(\alpha) = \prod_{i=1}^N f(m_i; \alpha) = \prod_{i=1}^N (C(\alpha) m_i^{-\alpha}) = [C(\alpha)]^N \prod_{i=1}^N m_i^{-\alpha}$$

Paso 3: La Log-Verosimilitud Maximizar el producto directo es computacionalmente inestable y algebraicamente difícil. Aplicamos el logaritmo natural para obtener la log-verosimilitud $\ell(\alpha)$, la cual preserva los puntos de máximo por ser una función monótona creciente:

$$\ell(\alpha) = \ln L(\alpha) = N \ln[C(\alpha)] - \alpha \sum_{i=1}^N \ln m_i$$

Sustituyendo la expresión explícita de $C(\alpha)$:

$$\ell(\alpha) = N \ln(1-\alpha) - N \ln(m_{max}^{1-\alpha} - m_{min}^{1-\alpha}) - \alpha \sum_{i=1}^N \ln m_i$$

Paso 4: Maximización y la Ecuación de Puntuación (Score) Para encontrar el estimador de máxima verosimilitud $\hat{\alpha}$, derivamos $\ell(\alpha)$ con respecto a α e igualamos a cero. Este proceso requiere aplicar la regla de la cadena en el término logarítmico complejo. La derivada del primer término es $\frac{-N}{1-\alpha} = \frac{N}{\alpha-1}$. Para el segundo término, notamos que la derivada de $m^{1-\alpha}$ respecto a α es $-m^{1-\alpha} \ln m$. Por lo tanto:

$$\frac{d}{d\alpha} \ln(m_{max}^{1-\alpha} - m_{min}^{1-\alpha}) = \frac{-m_{max}^{1-\alpha} \ln m_{max} + m_{min}^{1-\alpha} \ln m_{min}}{m_{max}^{1-\alpha} - m_{min}^{1-\alpha}}$$

La derivada del tercer término es simplemente $-\sum_{i=1}^N \ln m_i$.

Ensamblando todo e igualando a cero, obtenemos la *ecuación de puntuación* o *score equation*:

$$\frac{N}{\alpha - 1} + N \frac{m_{max}^{1-\alpha} \ln m_{max} - m_{min}^{1-\alpha} \ln m_{min}}{m_{max}^{1-\alpha} - m_{min}^{1-\alpha}} - \sum_{i=1}^N \ln m_i = 0$$

Dividiendo toda la ecuación por N y reorganizando, llegamos a la forma final de la ecuación de verosimilitud:

$$\frac{1}{\alpha - 1} + \frac{m_{max}^{1-\alpha} \ln m_{max} - m_{min}^{1-\alpha} \ln m_{min}}{m_{max}^{1-\alpha} - m_{min}^{1-\alpha}} = \frac{1}{N} \sum_{i=1}^N \ln m_i$$

Paso 5: Interpretación Matemática y Resolución Numérica Esta ecuación es trascendental respecto a α . Al igual que ocurre con la estimación de máxima verosimilitud para la distribución de Weibull o Gamma (Devore, Capítulo 6, Sección 6.2), no existe una solución algebraica cerrada para $\hat{\alpha}$. El lado derecho de la ecuación es simplemente la media aritmética de los logaritmos de las masas observadas, un estadístico suficiente para este modelo. El lado izquierdo es una función no lineal compleja de α que depende de los límites físicos del cúmulo.

En la práctica astrofísica, esta ecuación se resuelve mediante algoritmos de búsqueda de raíces unidimensionales, como el método de Newton-Raphson o la secante, utilizando el valor clásico de Salpeter ($\alpha \approx 2,35$) como estimador inicial. La ventaja fundamental del MLE sobre el método de momentos en este escenario es que el estimador $\hat{\alpha}$ es asintóticamente eficiente (alcanza el límite inferior de Cramér-Rao) y es invariante ante reparametrizaciones, garantizando la mejor precisión estadística posible dada la muestra de estrellas.

Paso 6: Aplicación del Principio de Invarianza Supongamos que el objetivo científico final no es solo conocer la pendiente α , sino determinar la fracción de estrellas en el cúmulo que son candidatas a explotar como supernovas de colapso de núcleo, es decir, estrellas con masa $m > 8M_{\odot}$.

Definimos el parámetro de interés como la probabilidad teórica de que una estrella supere este umbral:

$$\theta = P(M > 8) = \int_8^{m_{max}} f(m; \alpha) dm = \frac{m_{max}^{1-\alpha} - 8^{1-\alpha}}{m_{max}^{1-\alpha} - m_{min}^{1-\alpha}}$$

Dado que θ es una función de α , es decir, $\theta = h(\alpha)$, no necesitamos derivar una nueva función de verosimilitud ni realizar transformaciones de variables aleatorias complejas. Gracias al **Principio de Invarianza** de los estimadores de máxima verosimilitud (Devore, Proposición en Sección 6.2), el estimador de máxima verosimilitud de θ es simplemente la función evaluada en el estimador de máxima verosimilitud de α :

$$\hat{\theta} = h(\hat{\alpha}) = \frac{m_{max}^{1-\hat{\alpha}} - 8^{1-\hat{\alpha}}}{m_{max}^{1-\hat{\alpha}} - m_{min}^{1-\hat{\alpha}}}$$

Este resultado demuestra la elegancia y utilidad del marco de máxima verosimilitud en la astrofísica moderna. Permite a los investigadores extraer el parámetro fundamental de la población ($\hat{\alpha}$) mediante optimización numérica de la log-verosimilitud, y luego propagar instantáneamente esa estimación a cualquier cantidad física derivada (como la fracción de supernovas, la masa total del cúmulo, o la tasa de formación de enanas blancas) simplemente sustituyendo $\hat{\alpha}$ en las ecuaciones teóricas correspondientes, preservando todas las propiedades de optimalidad estadística.

10.2.5. Ejemplo: Estimación de Máxima Verosimilitud en Funciones de Luminosidad con Umbral de Detección Desconocido

En la astrofísica de altas energías y los sondeos de gran campo, una de las tareas estadísticas más complejas y frecuentes es la caracterización de poblaciones transitorias (como Brotes de Rayos Gamma o Fractures de Radio Rápidos). La función de distribución de luminosidades de estas poblaciones a menudo sigue una ley de potencias. Sin embargo, debido a los límites de sensibilidad instrumental, el umbral mínimo de luminosidad L_{min} que la población puede tener (o que el instrumento puede detectar de manera fiable) no siempre se conoce a priori y debe ser inferido directamente de los datos.

Este problema es un ejemplo magistral de estimación de máxima verosimilitud donde el parámetro define el soporte de la distribución, lo que requiere un tratamiento matemático riguroso (Devore, Capítulo 6, Sección 6.2).

Definimos la variable aleatoria continua X como la luminosidad intrínseca de un evento. Supongamos que X sigue una distribución de Pareto (una ley de potencias truncada inferiormente), cuya función de densidad de probabilidad depende de dos parámetros desconocidos: el índice espectral $\alpha > 1$ y el umbral mínimo $x_m > 0$:

$$f(x; \alpha, x_m) = \begin{cases} \frac{\alpha-1}{x_m} \left(\frac{x}{x_m}\right)^{-\alpha} & \text{para } x \geq x_m \\ 0 & \text{para } x < x_m \end{cases}$$

Sea $x_1, x_2, \dots, x_n$ una muestra aleatoria de n eventos detectados. El objetivo es encontrar los estimadores de máxima verosimilitud (EMV) $\hat{\alpha}$ y $\hat{x}_m$.

Paso 1: Construcción de la Función de Verosimilitud con Soporte Variable La función de verosimilitud conjunta, dado que las observaciones son independientes, es el producto de las densidades individuales. Para manejar rigurosamente el soporte dependiente del parámetro, introducimos la función indicadora $\mathbb{I}(\cdot)$:

$$L(\alpha, x_m) = \prod_{i=1}^n \left[\frac{\alpha-1}{x_m} \left(\frac{x_i}{x_m}\right)^{-\alpha} \mathbb{I}(x_i \geq x_m) \right]$$

Para que la verosimilitud sea estrictamente positiva (es decir, para que el modelo sea compatible con los datos observados), debe cumplirse que $x_m \leq x_i$ para todo $i = 1, \dots, n$. Esto impone una restricción analítica dura: $x_m \leq \min(x_1, \dots, x_n)$. Denotemos al estadístico de orden mínimo como $x_{(1)} = \min(x_i)$.

Paso 2: La Log-Verosimilitud de Perfil Asumiendo que la restricción $x_m \leq x_{(1)}$ se satisface, la función indicadora es 1 y podemos aplicar el logaritmo natural para obtener la log-verosimilitud $\ell(\alpha, x_m)$:

$$\ell(\alpha, x_m) = n \ln(\alpha - 1) - n \ln(x_m) - \alpha \sum_{i=1}^n \ln\left(\frac{x_i}{x_m}\right)$$

Expandiendo el logaritmo de la razón:

$$\ell(\alpha, x_m) = n \ln(\alpha - 1) - n \ln(x_m) - \alpha \sum_{i=1}^n \ln(x_i) + n\alpha \ln(x_m)$$

Agrupando los términos que dependen de x_m :

$$\ell(\alpha, x_m) = n \ln(\alpha - 1) - \alpha \sum_{i=1}^n \ln(x_i) + n(\alpha - 1) \ln(x_m)$$

Paso 3: Maximización respecto al Umbral x_m Observamos analíticamente que, dado que $\alpha > 1$, el término $n(\alpha - 1) \ln(x_m)$ es una función estrictamente creciente de x_m . Para maximizar $\ell(\alpha, x_m)$, debemos hacer x_m tan grande como sea posible. Sin embargo, la restricción de soporte dicta que $x_m \leq x_{(1)}$.

Por lo tanto, el estimador de máxima verosimilitud para el umbral inferior es exactamente el valor mínimo observado en la muestra:

$$\hat{x}_m = x_{(1)}$$

Este resultado es fundamental en astronomía: la mejor estimación del límite de corte de la población es el evento más débil que hemos logrado detectar.

Paso 4: Maximización respecto al Índice Espectral α Sustituimos $\hat{x}_m = x_{(1)}$ en la log-verosimilitud para obtener la log-verosimilitud perfilada $\ell_p(\alpha)$:

$$\ell_p(\alpha) = n \ln(\alpha - 1) - \alpha \sum_{i=1}^n \ln(x_i) + n(\alpha - 1) \ln(x_{(1)})$$

Derivamos respecto a α e igualamos a cero para encontrar el punto crítico (la ecuación de score):

$$\frac{\partial \ell_p}{\partial \alpha} = \frac{n}{\alpha - 1} - \sum_{i=1}^n \ln(x_i) + n \ln(x_{(1)}) = 0$$

Reorganizando y factorizando n :

$$\frac{n}{\alpha - 1} = \sum_{i=1}^n \ln(x_i) - n \ln(x_{(1)}) = \sum_{i=1}^n [\ln(x_i) - \ln(x_{(1)})] = \sum_{i=1}^n \ln\left(\frac{x_i}{x_{(1)}}\right)$$

Despejando α , obtenemos el EMV cerrado para el índice espectral:

$$\hat{\alpha} = 1 + \frac{n}{\sum_{i=1}^n \ln\left(\frac{x_i}{x_{(1)}}\right)}$$

Paso 5: Información de Fisher y Varianza Asintótica Para cuantificar la incertidumbre de nuestra estimación, calculamos la segunda derivada de la log-verosimilitud perfilada respecto a α :

$$\frac{\partial^2 \ell_p}{\partial \alpha^2} = -\frac{n}{(\alpha - 1)^2}$$

La Información de Fisher esperada $I(\alpha)$ es el valor esperado del negativo de esta segunda derivada. Dado que la segunda derivada es determinista (no depende de las variables aleatorias X_i una vez perfilada), tenemos:

$$I(\alpha) = \frac{n}{(\alpha - 1)^2}$$

De acuerdo con las propiedades asintóticas del EMV (Devore, Proposición en Sección 6.2), la varianza asintótica de $\hat{\alpha}$ está dada por la inversa de la Información de Fisher (el límite inferior de Cramér-Rao):

$$V(\hat{\alpha}) \approx [I(\alpha)]^{-1} = \frac{(\alpha - 1)^2}{n}$$

Preguntas Clave y Análisis de la Teoría

Pregunta 1: Sobre las Condiciones de Regularidad y el Estadístico de Orden *¿Por qué la estimación de $\hat{x}_m = x_{(1)}$ no puede obtenerse simplemente igualando la derivada parcial $\frac{\partial \ell}{\partial x_m}$ a cero, y cómo se relaciona esto con las condiciones de regularidad mencionadas en la teoría de la estimación?*

Respuesta Analítica: Si intentamos derivar $\ell(\alpha, x_m)$ respecto a x_m directamente, obtenemos $\frac{\partial \ell}{\partial x_m} = \frac{n(\alpha-1)}{x_m}$. Dado que $\alpha > 1$ y $x_m > 0$, esta derivada es estrictamente positiva y nunca se anula. Esto ocurre porque el parámetro x_m define el límite del soporte de la distribución, violando la condición de regularidad estándar que exige que el soporte de $f(x; \theta)$ no dependa del parámetro θ (Devore, Sección 6.2). El máximo no se encuentra en un punto crítico del cálculo diferencial interior, sino en la frontera del espacio de parámetros permitidos por la función indicadora, lo que obliga a utilizar el estadístico de orden mínimo $x_{(1)}$ como solución de optimización con restricciones.

Pregunta 2: Aplicación del Principio de Invarianza *En astrofísica, rara vez nos interesa solo el índice α ; usualmente queremos conocer la luminosidad media de la población. Si el valor esperado teórico de la distribución es $E[X] = \frac{\alpha x_m}{\alpha-1}$, ¿cuál es el EMV de la luminosidad media y por qué no es necesario derivar una nueva función de verosimilitud?*

Respuesta Analítica: Gracias al **Principio de Invarianza** de los estimadores de máxima verosimilitud (Devore, Proposición 6.19), si $\hat{\alpha}$ y $\hat{x}_m$ son los EMV de los parámetros originales, el EMV de cualquier función $g(\alpha, x_m)$ es simplemente $g(\hat{\alpha}, \hat{x}_m)$. Por lo tanto, el estimador de la luminosidad media es:

$$\widehat{E[X]} = \frac{\hat{\alpha} \hat{x}_m}{\hat{\alpha} - 1} = \frac{\hat{\alpha} x_{(1)}}{\hat{\alpha} - 1}$$

Sustituyendo la expresión de $\hat{\alpha}$, notamos que $\hat{\alpha} - 1 = \frac{n}{\sum \ln(x_i/x_{(1)})}$. Esto simplifica enormemente la expresión a:

$$\widehat{E[X]} = x_{(1)} \left(1 + \frac{n}{\sum_{i=1}^n \ln \left(\frac{x_i}{x_{(1)}} \right)} \right)$$

Este resultado demuestra la potencia computacional del método: una vez resuelto el sistema de score, las propiedades de cualquier momento poblacional se obtienen por sustitución algebraica directa.

Pregunta 3: Comportamiento Asintótico y Límites Físicos *Analice la expresión de la varianza asintótica $V(\hat{\alpha}) \approx \frac{(\alpha-1)^2}{n}$. ¿Qué ocurre con la precisión del estimador cuando la población astrofísica es extremadamente "plana" (es decir, cuando $\alpha \rightarrow 1^+$), y qué implicaciones tiene esto para el diseño de sondeos telescópicos?*

Respuesta Analítica: Si el índice espectral α se acerca a 1 por la derecha ($\alpha \rightarrow 1^+$), el numerador de la varianza asintótica $(\alpha - 1)^2$ tiende a cero. Esto parecería indicar que la estimación se vuelve infinitamente precisa. Sin embargo, esto es una ilusión matemática que esconde una catástrofe física.

Cuando $\alpha \rightarrow 1^+$, la distribución de colas pesadas implica que la probabilidad de observar eventos de luminosidad extremadamente alta domina la muestra. El estadístico $\sum \ln(x_i/x_{(1)})$ en el denominador de $\hat{\alpha}$ crecerá descontroladamente debido a la presencia de valores atípicos (outliers) astrofísicos, haciendo que $\hat{\alpha}$ colapse hacia 1. Además, para $\alpha \leq 2$, la varianza teórica de la población $V(X)$ diverge, por lo que el Teorema Central del Límite y las aproximaciones asintóticas normales pierden su validez práctica.

Para el diseño de sondeos, esto dicta que si se sospecha que α es cercano a 1 (poblaciones dominadas por eventos ultra-luminosos pero raros), un tamaño de muestra n grande no garantiza la convergencia gaussiana del estimador. Se requerirá el uso de técnicas robustas o estimación bayesiana con previas informativas (Devore, Capítulo 6, ejercicios suplementarios) para regularizar la divergencia de la verosimilitud.

Clase 11

11.1. Límite de Cramer-Rao

En la teoría de la estimación estadística, no basta con encontrar un estimador insesgado; es imperativo determinar si existe un estimador óptimo, es decir, aquel que posea la menor dispersión posible alrededor del valor verdadero. El límite de Cramer-Rao establece una cota inferior fundamental para la varianza de cualquier estimador insesgado de un parámetro determinista. Este teorema define el límite absoluto de precisión que cualquier algoritmo o instrumento puede alcanzar, independientemente de la complejidad del procesamiento de datos.

De acuerdo con la teoría de la inferencia estadística (Devore, Capítulo 6, Sección de propiedades de los estimadores de máxima verosimilitud), la formalización matemática requiere definir primero la Información de Fisher.

Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria de una población con función de densidad (o masa) de probabilidad $f(x; \theta)$, donde θ es un parámetro desconocido. La función de log-verosimilitud de la muestra se define como:

$$\ell(\theta) = \sum_{i=1}^n \ln f(X_i; \theta)$$

La Información de Fisher contenida en la muestra completa, denotada como $I_n(\theta)$, mide la cantidad de información que los datos observados aportan sobre el parámetro θ . Se define mediante el valor esperado del cuadrado de la derivada primera de la log-verosimilitud (conocida como la función de puntuación o score):

$$I_n(\theta) = E \left[\left(\frac{\partial \ell(\theta)}{\partial \theta} \right)^2 \right]$$

Bajo condiciones regulares que permiten intercambiar la derivada y la integral, esta expresión es matemáticamente equivalente al negativo del valor esperado de la derivada segunda:

$$I_n(\theta) = -E \left[\frac{\partial^2 \ell(\theta)}{\partial \theta^2} \right]$$

Dado que las observaciones son independientes e idénticamente distribuidas, la información de Fisher de la muestra es simplemente n veces la información de una sola observación:

$$I_n(\theta) = nI_1(\theta) = nE \left[\left(\frac{\partial}{\partial \theta} \ln f(X; \theta) \right)^2 \right]$$

11.1.1. Enunciado del Teorema

Si $T = T(X_1, \dots, X_n)$ es cualquier estimador insesgado de θ , lo que significa que $E[T] = \theta$ para todo θ , entonces la varianza de T está acotada inferiormente por la inversa de la Información de Fisher:

$$V(T) \geq \frac{1}{I_n(\theta)}$$

Si el objetivo es estimar una función del parámetro, digamos $g(\theta)$, y T es un estimador insesgado de $g(\theta)$ (es decir, $E[T] = g(\theta)$), el límite se generaliza como:

$$V(T) \geq \frac{[g'(\theta)]^2}{I_n(\theta)}$$

Esta cota inferior se conoce como el Límite de Cramer-Rao. Un estimador insesgado que alcanza esta cota (es decir, cuya varianza es exactamente igual a $1/I_n(\theta)$) se denomina estimador eficiente de varianza mínima uniforme.

11.1.2. Eficiencia y Conexión con la Máxima Verosimilitud

La eficiencia relativa de un estimador insesgado T se define como la razón entre el límite de Cramer-Rao y la varianza real del estimador:

$$e(T) = \frac{1/I_n(\theta)}{V(T)}$$

Dado que $V(T) \geq 1/I_n(\theta)$, la eficiencia siempre satisface $0 < e(T) \leq 1$. Un valor de $e(T) = 1$ indica que el estimador es perfectamente eficiente.

En el contexto de la astronomía observacional y la astrofísica, como se detalla en *Astronomical Measurement* (Apéndice sobre estimación de parámetros y límites de error), los Estimadores de Máxima Verosimilitud (MLE) poseen una propiedad asintótica crucial: son asintóticamente eficientes. Esto significa que, a medida que el tamaño de la muestra n tiende a infinito, la distribución del MLE converge a una normal y su varianza converge exactamente al límite de Cramer-Rao. Por lo tanto, para sondeos astronómicos con millones de fotones detectados, el MLE proporciona la mejor estimación teóricamente posible.

11.1.3. Implicaciones en Astrodinámica y Navegación Espacial

En la determinación de órbitas y la navegación de naves espaciales (*Fundamentals of Astrodynamics and Applications*, Vallado, Capítulo 10), el estado de una nave (posición y velocidad) se estima a partir de observaciones de sensores (como rango, azimut y elevación) corruptas por ruido.

Si modelamos el vector de estado como $\vec{\theta}$ y las observaciones tienen una matriz de covarianza de ruido Σ , la Información de Fisher para un vector de parámetros se generaliza mediante la matriz de información de Fisher $\mathcal{I}(\vec{\theta})$. El límite de Cramer-Rao multivariante establece que la matriz de covarianza de cualquier estimador insesgado $\hat{\vec{\theta}}$ debe satisfacer la desigualdad matricial:

$$V(\hat{\vec{\theta}}) \geq \mathcal{I}(\vec{\theta})^{-1}$$

donde la desigualdad se interpreta en el sentido de que la diferencia $V(\hat{\vec{\theta}}) - \mathcal{I}(\vec{\theta})^{-1}$ es una matriz semidefinida positiva.

En la práctica, la matriz $\mathcal{I}(\vec{\theta})^{-1}$ es exactamente la matriz de covarianza que produce el filtro de mínimos cuadrados ponderados o el filtro de Kalman cuando el modelo es lineal y el ruido es gaussiano. Este resultado demuestra que los algoritmos de navegación espacial óptimos no solo minimizan la suma de cuadrados de los residuos, sino que también extraen la máxima información

posible de los sensores, alcanzando el límite de precisión física impuesto por el CRLB. Ningún software de navegación, por avanzado que sea, puede reducir la incertidumbre del estado de la nave por debajo de esta frontera matemática.

11.1.4. Ejemplo: Límite Fundamental de Precisión en Velocidades Radiales de Exoplanetas

En la astrofísica observacional moderna, la detección y caracterización de exoplanetas mediante el método de velocidades radiales (RV) representa un desafío estadístico de alta precisión. Como se detalla en *Astronomical Measurement* (Capítulo sobre *Radial Velocity Measurements and Precision Limits*), el objetivo es extraer la señal gravitacional minúscula de un planeta a partir de espectros estelares corruptos por ruido instrumental y actividad estelar intrínseca (jitter).

Para determinar la máxima precisión teóricamente alcanzable por cualquier algoritmo de ajuste (como MCMC o Mínimos Cuadrados), debemos calcular el Límite de Cramer-Rao (CRLB). Este ejemplo demuestra cómo la Matriz de Información de Fisher (FIM) se utiliza para desacoplar las incertidumbres de los parámetros orbitales en un modelo no lineal.

Paso 1: Formulación del Modelo de Observación Supongamos que disponemos de N observaciones espectroscópicas tomadas en instantes t_i . La velocidad radial medida y_i se modela como una señal kepleriana circular (excentricidad $e = 0$) sumada a un ruido gaussiano:

$$y_i = h(t_i, \vec{\theta}) + \epsilon_i$$

donde el modelo determinista es:

$$h(t_i, \vec{\theta}) = K \sin\left(\frac{2\pi}{P}t_i + \phi\right) + v_0$$

El vector de parámetros desconocidos a estimar es $\vec{\theta} = [K, \phi, v_0]^T$, donde K es la semi-amplitud orbital, ϕ es la fase orbital, y v_0 es la velocidad sistémica. Asumimos que el periodo P es conocido con alta precisión gracias a un periodograma preliminar. El término de error ϵ_i sigue una distribución normal con media cero y varianza $\sigma^2 = \sigma_{inst}^2 + \sigma_{jit}^2$, que agrupa la incertidumbre instrumental y el ruido astrofísico de la estrella.

Paso 2: Función de Log-Verosimilitud y Vector Score Dado que los errores son independientes e idénticamente distribuidos, la función de log-verosimilitud $\ell(\vec{\theta})$ para las N observaciones es (Devore, Capítulo 6):

$$\ell(\vec{\theta}) = -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^N \left[y_i - h(t_i, \vec{\theta}) \right]^2$$

Para construir la Matriz de Información de Fisher, primero calculamos las derivadas parciales del modelo h_i respecto a los parámetros. Definimos la fase instantánea $\psi_i = \frac{2\pi}{P}t_i + \phi$:

$$\frac{\partial h_i}{\partial K} = \sin \psi_i, \quad \frac{\partial h_i}{\partial \phi} = K \cos \psi_i, \quad \frac{\partial h_i}{\partial v_0} = 1$$

Paso 3: Construcción de la Matriz de Información de Fisher Para un modelo de regresión no lineal con ruido gaussiano aditivo, los elementos de la FIM $\mathcal{I}(\vec{\theta})$ se obtienen mediante el valor esperado del producto de las derivadas primeras (Devore, Sección de propiedades del MLE):

$$\mathcal{I}_{jk}(\vec{\theta}) = \frac{1}{\sigma^2} \sum_{i=1}^N \frac{\partial h_i}{\partial \theta_j} \frac{\partial h_i}{\partial \theta_k}$$

Sustituyendo las derivadas parciales, la matriz de 3×3 adopta la siguiente estructura formal:

$$\mathcal{I}(\vec{\theta}) = \frac{1}{\sigma^2} \sum_{i=1}^N \begin{bmatrix} \sin^2 \psi_i & K \sin \psi_i \cos \psi_i & \sin \psi_i \\ K \sin \psi_i \cos \psi_i & K^2 \cos^2 \psi_i & K \cos \psi_i \\ \sin \psi_i & K \cos \psi_i & 1 \end{bmatrix}$$

Paso 4: Aproximación Continua y Diagonalización Invertir esta matriz para un conjunto discreto y arbitrario de tiempos t_i es algebraicamente complejo. Sin embargo, en la práctica astronómica, las campañas de observación suelen cubrir múltiples órbitas con un muestreo relativamente uniforme. Podemos aplicar una aproximación continua donde la suma discreta converge a la integral temporal sobre un periodo completo P :

$$\frac{1}{N} \sum_{i=1}^N g(t_i) \approx \frac{1}{P} \int_0^P g(t) dt$$

Evaluamos las integrales trigonométricas fundamentales sobre el periodo P :

$$\begin{aligned} \frac{1}{P} \int_0^P \sin^2 \left(\frac{2\pi}{P} t + \phi \right) dt &= \frac{1}{2} \\ \frac{1}{P} \int_0^P \cos^2 \left(\frac{2\pi}{P} t + \phi \right) dt &= \frac{1}{2} \\ \frac{1}{P} \int_0^P \sin \left(\frac{2\pi}{P} t + \phi \right) \cos \left(\frac{2\pi}{P} t + \phi \right) dt &= 0 \\ \frac{1}{P} \int_0^P \sin(\dots) dt &= 0, \quad \frac{1}{P} \int_0^P \cos(\dots) dt = 0 \end{aligned}$$

Gracias a estas identidades ortogonales, los términos cruzados (fuera de la diagonal) se anulan rigurosamente. La Matriz de Información de Fisher promedio se simplifica a una matriz diagonal:

$$\mathcal{I}(\vec{\theta}) \approx \frac{N}{\sigma^2} \begin{bmatrix} 1/2 & 0 & 0 \\ 0 & K^2/2 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

Paso 5: Extracción del Límite de Cramer-Rao El Teorema de Cramer-Rao establece que la matriz de covarianza de cualquier estimador insesgado $\hat{\vec{\theta}}$ está acotada inferiormente por la inversa de la FIM: $V(\hat{\vec{\theta}}) \geq \mathcal{I}^{-1}(\vec{\theta})$. Al ser diagonal, la inversión es trivial:

$$\mathcal{I}^{-1}(\vec{\theta}) = \frac{\sigma^2}{N} \begin{bmatrix} 2 & 0 & 0 \\ 0 & \frac{2}{K^2} & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

De aquí extraemos las varianzas mínimas absolutas (los límites de Cramer-Rao) para cada parámetro:

$$\begin{aligned} V(\hat{K}) &\geq \frac{2\sigma^2}{N} \implies \sigma_{CRLB}(K) = \sqrt{\frac{2}{N}}\sigma \\ V(\hat{\phi}) &\geq \frac{2\sigma^2}{NK^2} \implies \sigma_{CRLB}(\phi) = \sqrt{\frac{2}{N}}\frac{\sigma}{K} \\ V(\hat{v}_0) &\geq \frac{\sigma^2}{N} \implies \sigma_{CRLB}(v_0) = \frac{\sigma}{\sqrt{N}} \end{aligned}$$

Interpretación Física y Conclusión Este resultado matemático revela verdades fundamentales sobre la arquitectura de los sondeos de exoplanetas (*Astronomical Measurement*, Sección sobre *Detection Limits*):

1. **Incertidumbre en la Masa (Semi-amplitud K):** La precisión con la que podemos medir la masa del planeta ($\propto K$) depende exclusivamente del ruido total σ y del número de épocas N . Curiosamente, no depende de la masa del planeta mismo. Un planeta supermasivo y un planeta terrestre alrededor de la misma estrella requerirán el mismo número de observaciones para alcanzar la misma precisión relativa en K , asumiendo que el ruido σ se mantiene constante.
2. **Incertidumbre en la Fase Orbital (ϕ):** La precisión en la fase (y por ende, en el tiempo de tránsito predicho T_0) es inversamente proporcional a la semi-amplitud K . Esto significa que para planetas de baja masa (señales de RV débiles), la incertidumbre en la fase se dispara.
3. **Diseño de Misiones:** Si un equipo científico desea predecir el tránsito de un exoplaneta recién descubierto por RV para observarlo con el telescopio espacial James Webb, el CRLB dicta exactamente cuántas noches de telescopio (N) y qué resolución espectral (σ) se necesitan para reducir $\sigma_{CRLB}(\phi)$ a un margen de minutos. Cualquier algoritmo de ajuste de curvas que reporte una incertidumbre menor a estos valores teóricos es matemáticamente imposible y probablemente sufre de sobreestimación (overfitting) o subestimación de las barras de error.

11.2. Introducción a los intervalos de confianza

En la práctica estadística y científica, rara vez tenemos el lujo de medir una población completa. Ya sea para determinar la distancia promedio a un cúmulo de galaxias o la vida útil media de un componente crítico de una nave espacial, debemos conformarnos con una muestra limitada de datos observados.

Tradicionalmente, podríamos calcular un único número a partir de esa muestra, conocido como estimación puntual, para representar el valor verdadero pero desconocido de la población. Sin embargo, una estimación puntual por sí sola es inherentemente incompleta: no nos dice nada sobre su propia precisión, dispersión o confiabilidad. Es análogo a proporcionar una coordenada de destino en el espacio sin indicar el margen de error del instrumento de navegación.

Para superar esta limitación, la estadística introduce el concepto de intervalo de confianza. En lugar de apostar por un solo valor numérico, proporcionamos un rango completo de valores factibles o plausibles para el parámetro desconocido. Este rango se construye mediante un procedimiento que garantiza que, si repitiéramos el proceso de muestreo y cálculo muchas veces, una proporción

especificada de estos intervalos (por ejemplo, el 95 por ciento) contendría el valor verdadero de la población.

Esta herramienta es fundamental en campos como la astronomía observacional y la ingeniería aeroespacial, donde el ruido instrumental, las perturbaciones ambientales y las limitaciones de los sensores son inevitables. Un intervalo de confianza no solo nos sugiere “cuál” podría ser el valor real, sino que cuantifica explícitamente “cuánta” incertidumbre estamos manejando, permitiendo tomar decisiones informadas y evaluar la solidez de nuestras conclusiones científicas.

Clase 12

12.1. Intervalos de confianza

En la inferencia estadística, una estimación puntual proporciona un único valor numérico como mejor aproximación de un parámetro poblacional desconocido θ . Sin embargo, debido a la variabilidad inherente del muestreo, esta estimación casi nunca coincide exactamente con el valor verdadero. Para cuantificar la precisión y la incertidumbre de la estimación, la teoría estadística introduce los intervalos de confianza. De acuerdo con el texto guía, un intervalo de confianza proporciona un rango de valores factibles para el parámetro, acompañado de un nivel de confianza que cuantifica la fiabilidad del procedimiento de generación del intervalo (Devore, Capítulo 7, Sección 7.1).

12.1.1. Formulación general y el método de la cantidad pivotal

La construcción rigurosa de un intervalo de confianza no se basa en adivinar límites, sino en el uso de una *cantidad pivotal* (o pivote). Una cantidad pivotal es una función de las observaciones muestrales y del parámetro desconocido cuya distribución de probabilidad es completamente conocida y no depende de ningún parámetro desconocido (Devore, Capítulo 7, Sección 7.1).

Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria y θ el parámetro de interés. Sea $Q = Q(X_1, \dots, X_n, \theta)$ una cantidad pivotal. Para un nivel de confianza deseado $1 - \alpha$ (donde $0 < \alpha < 1$), podemos encontrar constantes a y b tales que la probabilidad de que Q caiga entre estos valores sea exactamente $1 - \alpha$:

$$P(a \leq Q(X_1, \dots, X_n, \theta) \leq b) = 1 - \alpha$$

El paso matemático fundamental consiste en manipular algebraicamente las desigualdades dentro de la probabilidad para aislar el parámetro θ . Si la función Q es monótona respecto a θ , podemos invertir las desigualdades para obtener dos estadísticos, un límite inferior L y un límite superior U , que dependen únicamente de los datos muestrales:

$$P(L(X_1, \dots, X_n) \leq \theta \leq U(X_1, \dots, X_n)) = 1 - \alpha$$

La expresión $[L, U]$ constituye el intervalo de confianza del $100(1 - \alpha) \%$ para θ . En la gran mayoría de las aplicaciones prácticas, la distribución de Q es simétrica, y se elige a y b de manera que las colas de probabilidad sean iguales, es decir, $P(Q < a) = \alpha/2$ y $P(Q > b) = \alpha/2$.

12.1.2. Interpretación frecuentista

Es imperativo comprender la interpretación correcta del nivel de confianza, ya que es un error común malinterpretarlo como una probabilidad condicional sobre el parámetro (Devore, Sección 7.1).

Una vez que se extrae la muestra y se calculan los valores numéricos l y u , el intervalo $[l, u]$ es fijo. Dado que θ es una constante fija (aunque desconocida), la probabilidad de que θ esté en $[l, u]$ es estrictamente 1 o 0.

La afirmación “tenemos un 95 % de confianza” se refiere al procedimiento, no a un intervalo específico. Significa que si repetimos el proceso de extracción de muestras aleatorias de tamaño n un número infinito de veces, y calculamos un intervalo de confianza para cada muestra, aproximadamente el 95 % de todos esos intervalos generados contendrán el valor verdadero de θ . El nivel de confianza $1 - \alpha$ es la proporción a largo plazo de éxito del método de construcción.

12.1.3. Intervalos clásicos para una sola muestra

A partir del método pivotal, se derivan las fórmulas operativas para los escenarios más comunes en la modelación de datos físicos y astronómicos.

1. Intervalo para la media μ (Varianza poblacional σ^2 conocida o muestra grande): Si la población es normal con varianza conocida, o si el tamaño de muestra n es suficientemente grande para invocar el Teorema Central del Límite, la cantidad pivotal es la variable normal estándar:

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

Planteando $P(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) = 1 - \alpha$ y despejando μ , obtenemos el intervalo de confianza de muestra grande (Devore, Sección 7.2):

$$\bar{x} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

Si σ es desconocida y n es grande, se sustituye σ por la desviación estándar muestral s , y la aproximación sigue siendo válida por el Teorema Central del Límite y la Ley de los Grandes Números.

2. Intervalo para la media μ (Población normal, Varianza σ^2 desconocida, muestra pequeña): Cuando la población es estrictamente normal, la varianza es desconocida y n es pequeño, la cantidad pivotal adecuada sigue una distribución t de Student con $\nu = n - 1$ grados de libertad:

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

Al igualar $P(-t_{\alpha/2, n-1} \leq T \leq t_{\alpha/2, n-1}) = 1 - \alpha$ y despejar μ , el intervalo de confianza exacto es (Devore, Sección 7.2):

$$\bar{x} \pm t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}$$

Nótese que la incertidumbre adicional por estimar σ con S se paga con colas más pesadas en la distribución t , resultando en un valor crítico $t_{\alpha/2, n-1} > z_{\alpha/2}$, lo que ensancha el intervalo para mantener el nivel de cobertura nominal.

3. Intervalo para una proporción poblacional p : Para datos binarios, el estimador puntual es $\hat{p} = X/n$. Usando la aproximación normal a la binomial (válida cuando $np \geq 10$ y $n(1 - p) \geq 10$), la cantidad pivotal es:

$$Z = \frac{\hat{P} - p}{\sqrt{p(1 - p)/n}} \sim N(0, 1)$$

Dado que el error estándar $\sqrt{p(1-p)/n}$ depende del parámetro desconocido p , se estima mediante $\sqrt{\hat{p}(1-\hat{p})/n}$. El intervalo de confianza de muestra grande resultante es (Devore, Sección 7.2):

$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

12.1.4. Propiedades de precisión y determinación del tamaño de muestra

La utilidad de un intervalo de confianza depende de dos factores en competencia: la *confiabilidad* (el nivel de confianza $1 - \alpha$) y la *precisión* (el ancho del intervalo).

El ancho total W de un intervalo de la forma $\hat{\theta} \pm c \cdot \sigma_{\hat{\theta}}$ es:

$$W = 2 \cdot c \cdot \sigma_{\hat{\theta}}$$

De esta expresión matemática se desprenden tres propiedades fundamentales para el diseño de experimentos y sondeos:

1. **Efecto del nivel de confianza:** Aumentar $1 - \alpha$ (por ejemplo, pasar de 95 % a 99 %) incrementa el valor crítico c , ensanchando el intervalo. Se gana confiabilidad a costa de precisión.
2. **Efecto del tamaño de muestra:** Dado que el error estándar $\sigma_{\hat{\theta}}$ típicamente es inversamente proporcional a $\sqrt{n}$ (como en $\sigma/\sqrt{n}$), aumentar n reduce el ancho del intervalo. Esta es la única forma de aumentar simultáneamente la confiabilidad y la precisión.
3. **Cálculo inverso para el muestreo:** Si se exige un error máximo de estimación (margen de error) E , podemos despejar n de la ecuación $E = z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$ para determinar el tamaño de muestra mínimo requerido antes de iniciar la recolección de datos:

$$n = \left(\frac{z_{\alpha/2} \sigma}{E} \right)^2$$

En la planificación de misiones espaciales o campañas de observación astronómica, esta relación es vital. Permite a los ingenieros y científicos calcular exactamente cuántas mediciones independientes (cuántos fotones, cuántas épocas de observación, cuántos ciclos de telemetría) son necesarias para acotar un parámetro físico dentro de una tolerancia E con un riesgo α de fallar en el intento.

12.1.5. Ejemplo: Intervalo de Confianza para el Parámetro de una Distribución Uniforme

En muchas situaciones estadísticas, los intervalos de confianza no toman la forma simétrica clásica $\hat{\theta} \pm c \cdot \sigma_{\hat{\theta}}$. Para ilustrar la mecánica fundamental de las cantidades pivotes y la manipulación rigurosa de desigualdades (Devore, Capítulo 7, Sección 7.1), construiremos un intervalo para el límite superior de una distribución uniforme. Este ejercicio es esencial para comprender cómo la estructura matemática del estimador dicta la geometría del intervalo resultante.

Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria de una distribución uniforme en el intervalo $[0, \theta]$, donde $\theta > 0$ es un parámetro desconocido. La función de densidad es $f(x) = 1/\theta$ para $0 \leq x \leq \theta$.

Paso 1: Construcción de la Cantidad Pivotal El estadístico de orden máximo $Y = \max(X_i)$ es un estimador natural para θ . Para encontrar su distribución, primero determinamos su función de distribución acumulativa (FDA):

$$F_Y(y) = P(Y \leq y) = \prod_{i=1}^n P(X_i \leq y) = \left(\frac{y}{\theta}\right)^n \quad \text{para } 0 < y < \theta$$

El método general para obtener intervalos de confianza exige encontrar una variable aleatoria cuya distribución no dependa de ningún parámetro desconocido. Definimos la cantidad pivotal $U = Y/\theta$. La FDA de U es:

$$F_U(u) = P(U \leq u) = P\left(\frac{Y}{\theta} \leq u\right) = P(Y \leq u\theta) = \left(\frac{u\theta}{\theta}\right)^n = u^n \quad \text{para } 0 < u < 1$$

La función de densidad de U es $f_U(u) = nu^{n-1}$. Lo crucial aquí es que la distribución de U depende exclusivamente del tamaño de muestra n y es completamente independiente de θ . Por lo tanto, U es una cantidad pivotal legítima.

Paso 2: Planteamiento de la Probabilidad Para un nivel de confianza $1 - \alpha$, buscamos constantes a y b tales que $P(a \leq U \leq b) = 1 - \alpha$. Adoptando el criterio de colas iguales para distribuir el error α :

$$\begin{aligned} P(U < a) &= \frac{\alpha}{2} \implies a^n = \frac{\alpha}{2} \implies a = \left(\frac{\alpha}{2}\right)^{1/n} \\ P(U < b) &= 1 - \frac{\alpha}{2} \implies b^n = 1 - \frac{\alpha}{2} \implies b = \left(1 - \frac{\alpha}{2}\right)^{1/n} \end{aligned}$$

Sustituyendo $U = Y/\theta$, la proposición de probabilidad fundamental es:

$$P\left(\left(\frac{\alpha}{2}\right)^{1/n} \leq \frac{Y}{\theta} \leq \left(1 - \frac{\alpha}{2}\right)^{1/n}\right) = 1 - \alpha$$

Paso 3: Manipulación Algebraica para Aislar el Parámetro El paso matemático más importante consiste en despejar θ de las desigualdades. Dado que $\theta > 0$ y $Y > 0$, invertimos las fracciones. Recordemos que invertir los términos de una desigualdad invierte el sentido de la misma:

$$\frac{1}{\left(1 - \frac{\alpha}{2}\right)^{1/n}} \leq \frac{\theta}{Y} \leq \frac{1}{\left(\frac{\alpha}{2}\right)^{1/n}}$$

Multiplicamos toda la cadena de desigualdades por Y (que es estrictamente positivo, preservando el sentido):

$$P\left(\frac{Y}{\left(1 - \frac{\alpha}{2}\right)^{1/n}} \leq \theta \leq \frac{Y}{\left(\frac{\alpha}{2}\right)^{1/n}}\right) = 1 - \alpha$$

Esta es la fórmula general del intervalo de confianza. Los límites aleatorios son $L = Y/(1 - \alpha/2)^{1/n}$ y $U = Y/(\alpha/2)^{1/n}$.

Paso 4: Evaluación Numérica Supongamos que se extrae una muestra de tamaño $n = 15$ de un proceso industrial, y el valor máximo observado en la muestra es $y = 4,2$. Construimos un intervalo de confianza del 95 % ($\alpha = 0,05$).

Calculamos los límites sustituyendo los valores:

$$L = \frac{4,2}{(0,975)^{1/15}} \approx \frac{4,2}{0,99829} \approx 4,207$$

$$U = \frac{4,2}{(0,025)^{1/15}} \approx \frac{4,2}{0,79370} \approx 5,292$$

El intervalo de confianza del 95 % para θ es $[4,207, 5,292]$.

Interpretación Matemática Este resultado resalta propiedades estructurales que los intervalos simétricos clásicos ocultan. Primero, el intervalo no está centrado en el estimador puntual $Y = 4,2$; de hecho, el límite inferior está extremadamente cerca de Y , mientras que el superior se extiende mucho más hacia la derecha. Esta asimetría no es un defecto, sino una necesidad matemática: por la propia definición del soporte de la distribución uniforme, el parámetro θ nunca puede ser menor que el máximo valor observado Y .

Segundo, este ejercicio demuestra que el método de la cantidad pivotal (Devore, Sección 7.1) es una herramienta algebraica general. No requiere que la distribución del estimador sea normal ni simétrica, sino que se adapta perfectamente a la geometría real del espacio de parámetros, garantizando la cobertura de probabilidad exacta $1 - \alpha$ independientemente de la forma de la distribución subyacente.

12.1.6. Ejemplo: Determinación de la Distancia a un Cúmulo Globular mediante Variables RR Lyrae

En la astrofísica estelar, la calibración de la escala de distancias cósmicas es uno de los problemas fundamentales. Las estrellas variables RR Lyrae, que pulsan con periodos cortos y poseen una luminosidad intrínseca bien calibrada, se utilizan como “candelas estándar” para medir la distancia a cúmulos globulares y galaxias cercanas (*Astronomical Measurement*, Capítulo sobre *Standard Candles and the Distance Ladder*).

Supongamos que un equipo de astrónomos está caracterizando el cúmulo globular NGC 7492, ubicado en el halo galáctico. Utilizando fotometría de precisión con el telescopio espacial, han identificado $n = 12$ estrellas RR Lyrae confirmadas en el cúmulo. Tras corregir cada medición por la extinción interestelar (el enrojecimiento causado por el polvo en el plano galáctico), obtienen las siguientes magnitudes aparentes en la banda V:

$$\{14,02, 14,38, 13,95, 14,21, 14,10, 14,45, 13,88, 14,15, 14,29, 14,07, 14,33, 13,98\}$$

A partir de los modelos de evolución estelar y calibraciones con el satélite Gaia, se sabe que la magnitud absoluta intrínseca de las RR Lyrae es $M_V = 0,60$.

A continuación, resolvemos una secuencia de requerimientos científicos para determinar la distancia al cúmulo y evaluar la factibilidad de una campaña de observación posterior.

a) Estadísticos muestrales y verificación de supuestos Primero, calculamos la media y la desviación estándar muestral de las magnitudes aparentes observadas (Devore, Capítulo 1, Sección 1.3):

$$\bar{m} = \frac{1}{12} \sum_{i=1}^{12} m_i = \frac{169,81}{12} = 14,151$$

Para la desviación estándar muestral, calculamos la suma de cuadrados de las desviaciones:

$$\sum_{i=1}^{12} (m_i - \bar{m})^2 = 0,4287$$

$$s = \sqrt{\frac{\sum (m_i - \bar{m})^2}{n - 1}} = \sqrt{\frac{0,4287}{11}} = \sqrt{0,03897} = 0,1974$$

Antes de proceder, debemos verificar si la suposición de normalidad es razonable. Dado que $n = 12$ es pequeño, la validez del intervalo t depende de que la población de magnitudes aparentes sea aproximadamente normal. En la práctica astronómica, esto se justifica porque las fluctuaciones en la magnitud aparente de estrellas del mismo tipo en un cúmulo (debido a errores fotométricos, variaciones metalicidad- luminosidad y dispersión de profundidad a lo largo de la línea de visión) tienden a distribuirse simétricamente alrededor de la media. Un diagrama Q-Q normal de los datos muestra una alineación aceptable con la recta teórica.

b) Intervalo de confianza para la magnitud aparente media Dado que la varianza poblacional es desconocida y el tamaño de muestra es pequeño, utilizamos la distribución t de Student como cantidad pivotal (Devore, Capítulo 7, Sección 7.2):

$$T = \frac{\bar{M} - \mu_m}{S/\sqrt{n}} \sim t_{n-1}$$

Para un nivel de confianza del 95 % ($\alpha = 0,05$) con $\nu = n - 1 = 11$ grados de libertad, el valor crítico es $t_{0,025,11} = 2,201$.

El intervalo de confianza para la magnitud aparente media verdadera μ_m es:

$$\bar{m} \pm t_{0,025,11} \cdot \frac{s}{\sqrt{n}}$$

$$14,151 \pm 2,201 \cdot \frac{0,1974}{\sqrt{12}}$$

$$14,151 \pm 2,201 \cdot 0,0570 = 14,151 \pm 0,1254$$

Por lo tanto, el intervalo de confianza del 95 % para μ_m es:

$$[14,026, 14,276] \text{ mag}$$

c) Intervalo de confianza para el módulo de distancia El módulo de distancia μ es la diferencia entre la magnitud aparente media y la magnitud absoluta conocida. La relación es lineal:

$$\mu = \mu_m - M_V$$

Dado que $M_V = 0,60$ es una constante conocida, podemos transformar directamente los límites del intervalo. Esta es una aplicación directa de la propiedad de que si $[L, U]$ es un intervalo de confianza para μ_m , entonces $[L - c, U - c]$ es un intervalo de confianza con el mismo nivel para $\mu_m - c$:

$$\mu \in [14,026 - 0,60, 14,276 - 0,60] = [13,426, 13,676] \text{ mag}$$

El módulo de distancia estimado es $\hat{\mu} = 14,151 - 0,60 = 13,551 \text{ mag}$.

d) Intervalo de confianza para la distancia física (Transformación no lineal) Aquí es donde la teoría de intervalos de confianza revela su profundidad analítica. La distancia física d (en parsecs) se relaciona con el módulo de distancia mediante la función no lineal:

$$d = 10^{(\mu+5)/5}$$

A diferencia del paso anterior, esta transformación es no lineal y monótona creciente. Para construir el intervalo de confianza para d , no podemos simplemente aplicar la fórmula $\hat{d} \pm c \cdot \sigma_{\hat{d}}$. En su lugar, debemos aplicar la transformación a los límites del intervalo de μ directamente, preservando la cobertura de probabilidad.

Dado que $g(\mu) = 10^{(\mu+5)/5}$ es una función estrictamente creciente, la desigualdad $L \leq \mu \leq U$ se transforma en $g(L) \leq g(\mu) \leq g(U)$ sin cambiar el sentido de las desigualdades ni la probabilidad de cobertura:

$$P(13,426 \leq \mu \leq 13,676) = 0,95 \implies P(10^{(13,426+5)/5} \leq d \leq 10^{(13,676+5)/5}) = 0,95$$

Calculamos cada límite:

$$d_L = 10^{18,426/5} = 10^{3,6852} = 4844 \text{ pc} \approx 4,84 \text{ kpc}$$

$$d_U = 10^{18,676/5} = 10^{3,7352} = 5437 \text{ pc} \approx 5,44 \text{ kpc}$$

El intervalo de confianza del 95 % para la distancia física al cúmulo es:

$$d \in [4,84, 5,44] \text{ kpc}$$

La estimación puntual de la distancia es $\hat{d} = 10^{(13,551+5)/5} = 10^{3,7102} = 5131 \text{ pc} \approx 5,13 \text{ kpc}$.

Análisis de la asimetría: Observemos la geometría del intervalo resultante:

$$\hat{d} - d_L = 5,13 - 4,84 = 0,29 \text{ kpc}$$

$$d_U - \hat{d} = 5,44 - 5,13 = 0,31 \text{ kpc}$$

El intervalo *no es simétrico* alrededor de la estimación puntual. La cola superior es más ancha que la inferior. Esto no es un artefacto ni un error, sino una consecuencia matemática inevitable de aplicar una función convexa creciente (la exponencial en base 10) a un intervalo simétrico en el espacio del módulo de distancia. En el espacio logarítmico (magnitudes), la incertidumbre es aditiva y simétrica; en el espacio lineal (distancia física), la incertidumbre se amplifica asimétricamente

hacia distancias mayores. Este fenómeno es ubicuo en astronomía y explica por qué reportar incertidumbres de distancia como $\hat{d} \pm \Delta d$ puede ser engañoso.

e) Determinación del tamaño de muestra para una misión de seguimiento El equipo científico desea proponer tiempo de telescopio con el James Webb Space Telescope (JWST) para realizar espectroscopia de alta resolución de las RR Lyrae. Para que la propuesta sea aceptada, deben demostrar que pueden determinar la distancia al cúmulo con un margen de error en el módulo de distancia no mayor a $E = 0,05$ mag con un nivel de confianza del 95 %.

Utilizando la fórmula de determinación de tamaño de muestra (Devore, Sección 7.2), donde el error estándar es $\sigma/\sqrt{n}$, y dado que no conocemos σ poblacional, utilizamos $s = 0,1974$ como estimador preliminar:

$$n = \left(\frac{t_{\alpha/2} \cdot s}{E} \right)^2$$

Para una primera aproximación (dado que t depende de n , usamos $z_{0,025} = 1,96$ como valor inicial):

$$n \approx \left(\frac{1,96 \cdot 0,1974}{0,05} \right)^2 = \left(\frac{0,3869}{0,05} \right)^2 = (7,738)^2 = 59,88$$

Redondeando hacia arriba, se requieren al menos $n = 60$ estrellas RR Lyrae. Dado que el cúmulo NGC 7492 es relativamente pobre y solo contiene aproximadamente 15 RR Lyrae conocidas, este resultado tiene una implicación científica profunda: con la población disponible de variables en este cúmulo específico, es matemáticamente imposible alcanzar la precisión de 0.05 mag en el módulo de distancia utilizando únicamente el método de candelas estándar con un intervalo t clásico.

El equipo debe entonces considerar estrategias alternativas: combinar las RR Lyrae con otras candelas estándar (como la rama horizontal roja), utilizar isócronas de ajuste al diagrama color-magnitud completo del cúmulo, o recurrir a mediciones astrométricas de paralaje trigonométrico si la precisión de Gaia lo permite para estrellas a 5 kpc. Este ejercicio demuestra cómo el cálculo del intervalo de confianza y la determinación del tamaño de muestra no son solo operaciones algebraicas, sino herramientas que dictan directamente la viabilidad científica de misiones observacionales y la estrategia de investigación.

12.1.7. Ejemplo: Evaluación de Jitter de Apuntamiento en Telescopios Espaciales

En la ingeniería de sistemas espaciales, la estabilidad de la línea de visión de un telescopio orbital es crítica para la obtención de imágenes de alta resolución. Durante las campañas de prueba en vacío térmico, los sensores de guiño y cabeceo registran micro-vibraciones inducidas por los criocooladores y los ventiladores de refrigeración. Este fenómeno, conocido como jitter de apuntamiento, se modela según los principios de control de actitud y análisis de errores (*Modern Spacecraft Guidance, Navigation, and Control*, Capítulo sobre *Line-of-Sight Stability and Jitter Analysis*).

Supongamos que un equipo de ingenieros extrae una muestra de $n = 16$ mediciones de jitter (en arcosegundos) durante un ciclo de operación estable. Para construir un intervalo de confianza para la verdadera media poblacional del jitter μ , debemos recurrir a la distribución t de Student, dado que la varianza poblacional es desconocida y el tamaño de la muestra es pequeño.

Paso 1: Resumen Estadístico y Suposiciones De los 16 registros de telemetría, se calculan los siguientes estadísticos muestrales:

$$\bar{x} = 0,144 \text{ arcosegundos}$$

$$s = 0,023 \text{ arcosegundos}$$

Dado que el jitter es el resultado de la superposición de múltiples fuentes de ruido mecánico y térmico independientes, es razonable asumir que la población subyacente se distribuye aproximadamente de forma normal. Esta suposición es un requisito fundamental para la validez del intervalo t con muestras pequeñas (Devore, Capítulo 7, Sección 7.3).

Paso 2: Construcción de la Cantidad Pivotal La cantidad pivotal adecuada para la media μ cuando σ es desconocida es el estadístico T :

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

Bajo la suposición de normalidad, T sigue una distribución t de Student con $\nu = n - 1 = 15$ grados de libertad.

Paso 3: Determinación del Valor Crítico Para un nivel de confianza del 95 % ($\alpha = 0,05$), busquemos el valor crítico $t_{\alpha/2, \nu}$ que deja un área de 0.025 en cada cola de la distribución t_{15} . Consultando las tablas de la distribución t (Devore, Tabla A.4), obtenemos:

$$t_{0,025,15} = 2,131$$

Paso 4: Cálculo del Intervalo de Confianza La fórmula general para el intervalo de confianza de $100(1 - \alpha)$ % es:

$$\bar{x} \pm t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}$$

Sustituyendo los valores numéricos:

$$0,144 \pm 2,131 \left(\frac{0,023}{\sqrt{16}} \right)$$

$$0,144 \pm 2,131 (0,00575)$$

$$0,144 \pm 0,01225$$

El intervalo de confianza del 95 % para el jitter medio verdadero es:

$$[0,1317, 0,1562] \text{ arcosegundos}$$

Esto indica que, con un 95 % de confianza, el jitter promedio real del telescopio durante la fase térmica se encuentra entre 0.1317 y 0.1562 arcosegundos. Si el requisito de la misión dicta que el jitter no debe superar los 0.150 arcosegundos, este intervalo sugiere que el diseño podría estar al límite de la especificación, ya que el límite superior lo excede ligeramente.

Tarea de Implementación Computacional: Validación y Bootstrap

El enfoque matemático anterior asume ciegamente la normalidad de los datos. En la práctica astronómica y aeroespacial, los conjuntos de datos de telemetría a menudo contienen valores atípicos (outliers) debido a interferencias electromagnéticas o errores de cuantización del sensor. Si la población no es normal, el intervalo t puede tener una cobertura de confianza real muy distinta al 95 % nominal.

Su tarea es utilizar Python para validar la suposición de normalidad y calcular un intervalo de confianza alternativo que no dependa de dicha suposición, aplicando los conceptos de intervalos de confianza bootstrap (Devore, Capítulo 7, Sección 7.1 y Capítulo 6).

Instrucciones para el lector:

- Definición de Datos:** Utilice el siguiente conjunto de 16 mediciones reales de jitter (en arco-segundos) extraídas de la telemetría cruda: $0.121, 0.155, 0.132, 0.189, 0.141, 0.115, 0.162, 0.144, 0.210, 0.138, 0.149, 0.125, 0.171, 0.143, 0.136, 0.152$ (Nota: Observe que el valor 0.210 es sospechosamente alto comparado con el resto).
- Estadísticos Descriptivos:** Escriba un script que calcule la media muestral y la desviación estándar muestral de este arreglo utilizando la biblioteca *numpy*. Verifique si coinciden con los valores redondeados ($\bar{x} \approx 0,149$, $s \approx 0,026$) usados en un escenario hipotético, y recalculé el intervalo t del 95 % con estos datos exactos.
- Prueba de Normalidad:** Utilice la función *shapiro* de la biblioteca *scipy.stats* para realizar la prueba de normalidad de Shapiro-Wilk sobre los 16 datos. Con un nivel de significancia de $\alpha = 0,05$, ¿existe evidencia estadística suficiente para rechazar la hipótesis nula de que los datos provienen de una distribución normal? ¿Cómo afecta esto la validez del intervalo t calculado en el Paso 4?
- Intervalo de Confianza Bootstrap:** Dado que la presencia del valor atípico (0.210) podría estar violando la normalidad, implemente un método de remuestreo bootstrap para construir un intervalo de confianza del 95 % para la media sin asumir ninguna distribución subyacente.
 - Genere $B = 10,000$ muestras bootstrap extrayendo 16 valores con reemplazo del arreglo original de datos.
 - Calcule la media de cada una de las 10,000 muestras bootstrap.
 - Utilice el método del percentil (Devore, Sección 7.1) para encontrar el percentil 2.5 y el percentil 97.5 de la distribución de medias bootstrap. Estos valores constituirán su intervalo de confianza bootstrap.
- Análisis Comparativo:** Compare el ancho y la posición del intervalo t de Student con el intervalo bootstrap. ¿El valor atípico desplaza el intervalo t de manera desproporcionada? ¿El método bootstrap proporciona una estimación más robusta de la incertidumbre de la media en este escenario específico? Redacte una breve conclusión técnica sobre qué intervalo presentaría al comité de revisión de la misión.

Clase 13

13.1. Inferencia Estadística: Introducción

El estudio de la estadística se divide fundamentalmente en dos grandes ramas: la estadística descriptiva y la estadística inferencial. Mientras que la primera se ocupa de resumir y presentar la información contenida en un conjunto de datos mediante gráficos, tablas y medidas numéricas, la segunda tiene un objetivo mucho más ambicioso. De acuerdo con el texto guía, la inferencia estadística es el conjunto de métodos y procedimientos que permiten utilizar la información contenida en una muestra para sacar conclusiones o generalizaciones acerca de la población de la cual fue extraída (Devore, Capítulo 1, Sección 1.1; Capítulo 6, Introducción).

Para comprender este proceso, es imperativo establecer con rigor la distinción entre los conceptos fundamentales que lo componen:

- **Población:** Es la colección completa de todos los individuos, objetos o mediciones de interés en un estudio particular. Puede ser finita (como todas las estrellas de un cúmulo globular específico) o conceptualmente infinita (como todos los posibles resultados de un experimento de medición repetido indefinidamente).
- **Muestra:** Es un subconjunto de la población, seleccionado de tal manera que se espera que sea representativo de la totalidad. Debido a restricciones de tiempo, costo o viabilidad física, rara vez es posible observar la población completa.
- **Parámetro:** Es una característica numérica fija, aunque generalmente desconocida, que describe a la población completa. Se denota tradicionalmente con letras griegas (por ejemplo, la media poblacional μ , la varianza poblacional σ^2 o una proporción poblacional p).
- **Estadístico:** Es cualquier cantidad numérica calculada a partir de los datos de la muestra. Se denota con letras latinas (por ejemplo, la media muestral $\bar{x}$, la varianza muestral s^2 o la proporción muestral $\hat{p}$). Un estadístico es, en sí mismo, una variable aleatoria, ya que su valor fluctúa de una muestra a otra debido al azar del muestreo.

La relación entre probabilidad e inferencia es inversa. La teoría de la probabilidad es deductiva: asume que se conocen los parámetros de la población y se utiliza para predecir el comportamiento de las posibles muestras. La inferencia estadística es inductiva: se observan los datos de la muestra (el estadístico) y se utiliza esta información para deducir o estimar los parámetros desconocidos de la población.

El objetivo central de la inferencia estadística, que se desarrollará en los capítulos subsiguientes, se bifurca en dos direcciones principales (Devore, Capítulo 6, Introducción):

1. **Estimación:** Utilizar un estadístico muestral para aproximar el valor de un parámetro poblacional desconocido. Esto puede hacerse mediante una estimación puntual (un solo número) o una estimación por intervalos (un rango de valores plausibles).
2. **Prueba de Hipótesis:** Formular una afirmación o pretensión sobre el valor de un parámetro poblacional y utilizar los datos muestrales para decidir, con un cierto nivel de riesgo controlado, si la evidencia es suficiente para rechazar dicha afirmación.

En esta etapa introductoria, es crucial entender que cualquier conclusión inferencial está inherentemente sujeta a incertidumbre. La muestra es solo una ventana parcial a la población, y por lo tanto, los métodos inferenciales deben incorporar medidas de confiabilidad (como niveles de confianza o valores de significación) para cuantificar el margen de error de nuestras generalizaciones.

13.1.1. Ejemplo: Velocidad de Recesión en un Cúmulo de Galaxias

Para ilustrar la transición conceptual de la descripción a la inferencia, consideremos un escenario en astronomía extragaláctica. Supongamos que un equipo de astrofísicos desea determinar la velocidad media de recesión de las galaxias que pertenecen al cúmulo de Virgo, con el fin de refinar las estimaciones de la constante de Hubble en esa región del espacio.

- **La Población:** El conjunto de *todas* las galaxias que están gravitacionalmente ligadas al cúmulo de Virgo.
- **El Parámetro (μ):** La velocidad de recesión promedio verdadera de esta población completa. Este valor es una constante física fija, pero es desconocida para los investigadores, ya que es imposible medir el corrimiento al rojo de cada una de las miles de galaxias del cúmulo con la precisión requerida.
- **La Muestra:** Un conjunto de $n = 40$ galaxias seleccionadas aleatoriamente del cúmulo, para las cuales se obtienen espectros de alta resolución utilizando un telescopio de 8 metros.
- **El Estadístico ($\bar{x}$):** La velocidad de recesión promedio calculada a partir de las 40 galaxias observadas. Supongamos que este cálculo arroja $\bar{x} = 1150$ km/s.

La estadística descriptiva se limita a afirmar: “En nuestra muestra de 40 galaxias, la velocidad promedio fue de 1150 km/s, con una desviación estándar de 120 km/s”.

La inferencia estadística, en cambio, da el salto conceptual. El investigador utiliza el estadístico $\bar{x} = 1150$ km/s como base para hacer una afirmación sobre el parámetro μ . Sin embargo, debido a la variabilidad del muestreo, el investigador sabe que si hubiera seleccionado otras 40 galaxias, habría obtenido un promedio ligeramente distinto. Por lo tanto, la inferencia no se limita a decir “ μ es 1150 km/s”. En su lugar, el marco inferencial que se desarrollará permitirá al investigador afirmar, por ejemplo, que “tenemos un 95 % de confianza en que la verdadera velocidad media μ del cúmulo se encuentra entre 1110 km/s y 1190 km/s”, o plantear una prueba formal para evaluar la pretensión de que “ μ es mayor a 1100 km/s”.

Este ejemplo destaca que el estadístico es la herramienta observable, mientras que el parámetro es la verdad oculta que la inferencia intenta desvelar, siempre acompañada de una cuantificación rigurosa de la incertidumbre inherente al proceso.

Clase 14

14.1. Técnicas de prueba de hipótesis de una muestra Parte 1

La inferencia estadística no se limita únicamente a estimar parámetros mediante intervalos de confianza; con frecuencia, el objetivo científico o ingenieril es tomar una decisión binaria respecto a una pretensión o afirmación sobre el estado físico de un sistema. De acuerdo con el texto guía, una prueba de hipótesis es un procedimiento formal que utiliza datos muestrales para evaluar la validez de una afirmación sobre una población (Devore, Capítulo 8, Sección 8.1).

En el contexto de la astrodinámica y la astronomía, esto se traduce en validar si un nuevo algoritmo de navegación cumple con los requisitos de precisión, si la luminosidad promedio de una clase de estrellas cefeidas coincide con los modelos teóricos, o si la tasa de éxito de un sistema de adquisición de estrellas supera el umbral mínimo de la misión.

14.1.1. Lógica y estructura de una prueba de hipótesis

El procedimiento se fundamenta en la contradicción lógica. En lugar de intentar probar directamente que una afirmación es verdadera, la estadística asume que una afirmación base (la hipótesis nula) es cierta, y busca evidencia muestral tan contundente que haga imposible sostenerla.

- **Hipótesis Nula (H_0):** Es la afirmación inicial que se asume verdadera. Representa el estado de las cosas, el modelo teórico establecido o la especificación de diseño. Siempre tiene la forma de una igualdad, por ejemplo, $H_0 : \theta = \theta_0$.
- **Hipótesis Alternativa (H_a):** Es la afirmación que entrará en vigor si la evidencia muestral contradice fuertemente a H_0 . Puede ser bilateral ($H_a : \theta \neq \theta_0$) o unilateral ($H_a : \theta > \theta_0$ o $H_a : \theta < \theta_0$).
- **Estadístico de Prueba:** Es una variable aleatoria calculada a partir de los datos muestrales que sirve como base para la toma de decisiones. Su distribución de probabilidad bajo el supuesto de que H_0 es verdadera debe ser completamente conocida.
- **Región de Rechazo:** Es el conjunto de valores del estadístico de prueba que son tan extremos que conducen al rechazo de H_0 .

14.1.2. Errores de Tipo I y Tipo II

Dado que la decisión se basa en una muestra aleatoria y no en la población completa, existe la posibilidad inherente de cometer errores. La teoría de pruebas de hipótesis clasifica estos errores en dos categorías fundamentales (Devore, Sección 8.1):

1. **Error de Tipo I (α):** Ocurre cuando se rechaza la hipótesis nula H_0 siendo esta realmente verdadera. Es un ‘falso positivo’. En ingeniería aeroespacial, esto equivaldría a abortar una maniobra crítica porque los sensores indican una falla que en realidad no existe. La probabi-

lidad de cometer este error se denota como α y se le conoce como el *nivel de significación*.

$$\alpha = P(\text{Rechazar } H_0 \mid H_0 \text{ es verdadera})$$

2. **Error de Tipo II (β):** Ocurre cuando no se rechaza la hipótesis nula H_0 siendo esta realmente falsa. Es un ‘falso negativo’. En el contexto de la misión, esto equivaldría a continuar una maniobra a pesar de que el sistema está genuinamente degradado. La probabilidad de cometer este error se denota como β .

$$\beta = P(\text{No rechazar } H_0 \mid H_0 \text{ es falsa})$$

El diseño de cualquier prueba estadística busca minimizar α y β simultáneamente. Sin embargo, para un tamaño de muestra fijo n , reducir la probabilidad de un error incrementa inevitablemente la probabilidad del otro. La única forma de reducir ambos es aumentando el tamaño de la muestra.

14.1.3. Pruebas para la media poblacional (Varianza conocida: Prueba Z)

Supongamos que estamos evaluando el empuje promedio μ de un propulsor de hidracina. Sabemos por pruebas históricas extensas que la varianza del proceso de combustión es σ^2 (constante y conocida). Tomamos una muestra de n encendidos y calculamos la media muestral $\bar{X}$.

Si la población es normal, o si n es suficientemente grande para invocar el Teorema Central del Límite, el estadístico de prueba bajo $H_0 : \mu = \mu_0$ es la variable normal estándar:

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$$

Las regiones de rechazo para un nivel de significación α dependen de la forma de H_a :

- **Cola superior** ($H_a : \mu > \mu_0$): Rechazar H_0 si $Z \geq z_\alpha$.
- **Cola inferior** ($H_a : \mu < \mu_0$): Rechazar H_0 si $Z \leq -z_\alpha$.
- **Bilateral** ($H_a : \mu \neq \mu_0$): Rechazar H_0 si $Z \geq z_{\alpha/2}$ o $Z \leq -z_{\alpha/2}$.

Esta prueba es el estándar de oro cuando la incertidumbre del instrumento de medición (σ) ha sido caracterizada exhaustivamente en laboratorios de calibración en tierra.

14.1.4. Pruebas para la media poblacional (Varianza desconocida: Prueba t)

En la mayoría de los escenarios de astronomía observacional y operaciones espaciales, la varianza poblacional σ^2 es desconocida y debe ser estimada a partir de la propia muestra mediante la varianza muestral S^2 .

Al sustituir σ por S , el estadístico de prueba ya no sigue una distribución normal estándar, sino una distribución t de Student con $\nu = n - 1$ grados de libertad. Esta distribución tiene colas

más pesadas que la normal, lo que refleja la incertidumbre adicional introducida por estimar la dispersión poblacional. El estadístico de prueba es (Devore, Sección 8.2):

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$$

Las regiones de rechazo se construyen utilizando los valores críticos de la tabla t :

- **Cola superior:** Rechazar H_0 si $T \geq t_{\alpha, n-1}$.
- **Cola inferior:** Rechazar H_0 si $T \leq -t_{\alpha, n-1}$.
- **Bilateral:** Rechazar H_0 si $|T| \geq t_{\alpha/2, n-1}$.

Es imperativo notar que esta prueba asume que la población subyacente es aproximadamente normal. Si n es pequeño y la población es fuertemente asimétrica, la prueba t puede no ser válida, requiriendo métodos no paramétricos.

14.1.5. Pruebas para una proporción poblacional

En muchas misiones, el parámetro de interés no es una media continua, sino una proporción o probabilidad de éxito. Por ejemplo, la fracción p de imágenes astronómicas que cumplen con los criterios de calidad de enfoque (Strehl ratio $> 0,8$).

Si se toma una muestra de n imágenes y X es el número de éxitos, el estimador puntual es $\hat{P} = X/n$. Para tamaños de muestra grandes (donde $np_0 \geq 10$ y $n(1 - p_0) \geq 10$), la distribución binomial puede aproximarse mediante una normal. Para probar $H_0 : p = p_0$, el estadístico de prueba es (Devore, Sección 8.3):

$$Z = \frac{\hat{P} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$$

Las regiones de rechazo son idénticas a las de la prueba Z para la media descrita anteriormente. Esta técnica es vital para validar si un nuevo algoritmo de procesamiento de señales cumple con las tasas de detección requeridas por la agencia espacial.

14.1.6. El valor P como medida de evidencia

El enfoque clásico de regiones de rechazo tiene una limitación práctica: obliga a elegir un α arbitrario (como 0.05) antes de ver los datos. Para superar esto, la estadística moderna introduce el *valor P* (p-valor).

El valor P se define como la probabilidad de obtener un valor del estadístico de prueba tan extremo o más extremo que el observado, asumiendo que H_0 es verdadera (Devore, Sección 8.4). Matemáticamente, para una prueba de cola superior con estadístico Z :

$$\text{Valor P} = P(Z \geq z_{\text{obs}} \mid H_0 \text{ es verdadera})$$

Para una prueba bilateral:

$$\text{Valor P} = 2 \times P(Z \geq |z_{\text{obs}}|)$$

Regla de decisión universal: Rechazar H_0 si el Valor $P \leq \alpha$.

El valor P actúa como una medida continua de la fuerza de la evidencia en los datos contra H_0 . Un valor P de 0.001 indica que, si el modelo nulo fuera correcto, sería casi imposible observar los datos actuales. En la literatura astrofísica, reportar el valor P (junto con los intervalos de confianza) es preferible a simplemente declarar ‘significativo’ o ‘no significativo’, ya que proporciona el contexto completo de la inferencia.

14.1.7. Potencia de la prueba y determinación del tamaño de muestra

La *potencia* de una prueba estadística es la probabilidad de rechazar correctamente la hipótesis nula cuando esta es falsa. Es decir, es la capacidad del test para detectar una discrepancia real respecto al valor nominal μ_0 .

$$\text{Potencia} = 1 - \beta = P(\text{Rechazar } H_0 \mid H_0 \text{ es falsa})$$

La potencia no es un número fijo; depende de cuál sea el verdadero valor del parámetro μ . Si el verdadero valor está muy cerca de μ_0 , la potencia será baja (es difícil distinguir el ruido de la señal). Si el verdadero valor se aleja mucho de μ_0 , la potencia se acerca a 1.

Para una prueba Z de cola superior ($H_a : \mu > \mu_0$), si el verdadero valor es $\mu = \mu'$, la potencia se calcula como:

$$\text{Potencia}(\mu') = P\left(Z \geq z_\alpha - \frac{\mu' - \mu_0}{\sigma/\sqrt{n}}\right)$$

En la fase de diseño de una misión espacial (Conceptual Design), los ingenieros utilizan esta fórmula de manera inversa. Si se requiere que la prueba tenga una potencia de al menos $1 - \beta$ para detectar una desviación específica $\delta = \mu' - \mu_0$, se puede despejar n para determinar el número mínimo de experimentos o mediciones necesarias:

$$n = \left(\frac{\sigma(z_\alpha + z_\beta)}{\delta}\right)^2$$

Este cálculo es fundamental para optimizar los recursos. Por ejemplo, determina cuántas noches de telescopio se deben asignar para caracterizar la atmósfera de un exoplaneta con la certeza estadística requerida, o cuántos ciclos de prueba en cámara de vacío debe soportar un mecanismo de despliegue solar antes de certificar su confiabilidad. La estadística, por lo tanto, no es solo una herramienta de análisis posterior, sino el cimiento matemático de la planificación y el presupuesto de las misiones científicas.

14.1.8. Ejemplo: Manipulación Integral de las Herramientas de Prueba de Hipótesis

Para consolidar el dominio de las técnicas de prueba de hipótesis basadas en una sola muestra, es fundamental explorar cómo las diferentes herramientas matemáticas (regiones de rechazo, valores P , probabilidad de error de Tipo II y determinación del tamaño de muestra) interactúan entre sí dentro de un mismo escenario. A continuación, se presenta un ejercicio puramente estadístico que

permite manipular estas fórmulas de manera rigurosa, basándose en los procedimientos establecidos en el texto guía (Devore, Capítulo 8, Secciones 8.1, 8.2 y 8.4).

Contexto del problema: Un proceso químico industrial está diseñado para producir un compuesto con un rendimiento medio objetivo de $\mu_0 = 85$ gramos. Por estudios históricos extensos, se sabe que la desviación estándar del proceso es $\sigma = 4$ gramos. Se extrae una muestra aleatoria de $n = 16$ lotes para evaluar si el proceso ha sufrido una desviación en su media. Se establece un nivel de significación de $\alpha = 0,05$.

Paso 1: Formulación de Hipótesis y Región de Rechazo El equipo de control de calidad está preocupado específicamente por si el rendimiento medio ha *disminuido* por debajo del objetivo, lo que afectaría la rentabilidad. Por lo tanto, se plantea una prueba de cola inferior:

$$H_0 : \mu = 85$$

$$H_a : \mu < 85$$

El estadístico de prueba para una población normal con varianza conocida es (Devore, Sección 8.2):

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} = \frac{\bar{X} - 85}{4/\sqrt{16}} = \frac{\bar{X} - 85}{1} = \bar{X} - 85$$

Para una prueba de cola inferior con $\alpha = 0,05$, la región de rechazo en términos del estadístico estandarizado es $Z \leq -z_{0,05}$. Consultando la tabla normal estándar, $z_{0,05} = 1,645$, por lo que se rechaza H_0 si:

$$Z \leq -1,645$$

Para comprender esto en las unidades originales del proceso, despejamos $\bar{X}$:

$$\frac{\bar{X} - 85}{1} \leq -1,645 \implies \bar{X} \leq 85 - 1,645 = 83,355$$

La región de rechazo en términos de la media muestral es $\bar{X} \leq 83,355$.

Paso 2: Cálculo del Estadístico y el Valor P Supongamos que la muestra de 16 lotes arroja una media muestral de $\bar{x} = 82,8$ gramos. Calculamos el valor observado del estadístico de prueba:

$$z_{\text{obs}} = 82,8 - 85 = -2,2$$

Dado que $-2,2$ cae en la región de rechazo ($-2,2 \leq -1,645$), la decisión formal es rechazar H_0 .

Para cuantificar la fuerza de la evidencia, calculamos el valor P (Devore, Sección 8.4). Para una prueba de cola inferior, el valor P es la probabilidad de obtener un valor tan extremo o más extremo que el observado:

$$\text{Valor P} = P(Z \leq -2,2) = \Phi(-2,2)$$

Usando la tabla de distribución normal, $\Phi(-2,2) = 0,0139$. Como el valor P (0,0139) es menor que el nivel de significación α (0,05), se corrobora el rechazo de la hipótesis nula. Existe evidencia estadística sólida de que el rendimiento medio ha caído por debajo de 85 gramos.

Paso 3: Evaluación de la Probabilidad de Error de Tipo II (β) Rechazar H_0 conlleva el riesgo de un Error de Tipo I ($\alpha = 0,05$), pero no rechazarla cuando es falsa conlleva un Error

de Tipo II (β). Supongamos que la verdadera media del proceso en realidad ha caído a $\mu' = 83,5$ gramos. ¿Cuál es la probabilidad de que nuestra prueba falle en detectar esta caída y erróneamente no rechace H_0 ?

La fórmula para β en una prueba de cola inferior es (Devore, Sección 8.4):

$$\beta(\mu') = P(Z > -z_\alpha \mid \mu = \mu') = \Phi\left(-z_\alpha + \frac{\mu_0 - \mu'}{\sigma/\sqrt{n}}\right)$$

Sustituimos los valores ($\mu' = 83,5$, $\mu_0 = 85$, $\sigma/\sqrt{n} = 1$, $z_\alpha = 1,645$):

$$\beta(83,5) = \Phi\left(-1,645 + \frac{85 - 83,5}{1}\right) = \Phi(-1,645 + 1,5) = \Phi(-0,145)$$

Buscando en la tabla normal estándar (o interpolando entre $-0,14$ y $-0,15$):

$$\beta(83,5) \approx 0,4424$$

Esto significa que hay un 44.24 % de probabilidad de que el test no detecte que la media real es 83.5 gramos. La potencia de la prueba para este valor alternativo es $1 - \beta = 1 - 0,4424 = 0,5576$, lo cual es relativamente bajo.

Paso 4: Determinación del Tamaño de Muestra para una Potencia Específica Para mejorar la capacidad de detección del proceso, los ingenieros exigen que la prueba tenga una potencia de al menos 0,90 (es decir, $\beta \leq 0,10$) para detectar una caída de la media a $\mu' = 83,5$. ¿Cuántos lotes deben muestrear?

Utilizamos la fórmula de determinación del tamaño de muestra para una prueba de una cola (Devore, Sección 8.4):

$$n = \left(\frac{\sigma(z_\alpha + z_\beta)}{\mu_0 - \mu'}\right)^2$$

Para $\beta = 0,10$, el valor crítico es $z_{0,10} = 1,28$. Sustituimos los parámetros:

$$n = \left(\frac{4(1,645 + 1,28)}{85 - 83,5}\right)^2 = \left(\frac{4(2,925)}{1,5}\right)^2$$

$$n = \left(\frac{11,7}{1,5}\right)^2 = (7,8)^2 = 60,84$$

Dado que el tamaño de la muestra debe ser un número entero y debemos garantizar como mínimo la potencia requerida, siempre redondeamos hacia arriba:

$$n = 61$$

Conclusión del ejercicio: Este ejemplo demuestra la interconexión matemática de las herramientas de inferencia. La región de rechazo (Paso 1) dicta el umbral de decisión. El valor P (Paso 2) proporciona una medida continua de evidencia basada en ese mismo umbral estandarizado. La probabilidad de Error de Tipo II (Paso 3) evalúa la vulnerabilidad de la prueba ante una realidad alternativa específica, y el cálculo del tamaño de muestra (Paso 4) utiliza exactamente los mismos parámetros (z_α , z_β , σ , y la diferencia de medias) para diseñar un experimento que controle matemáticamente ambos tipos de errores simultáneamente.

14.1.9. Ejemplo: Prueba de Hipótesis sobre la Metalicidad de un Flujo Estelar Recién Descubierto

En la astrofísica galáctica moderna, la técnica de *arqueología galáctica* utiliza las abundancias químicas de las estrellas para rastrear la historia de ensamblaje de la Vía Láctea. Los flujos estelares (stellar streams) son los remanentes de cúmulos globulares o galaxias enanas que han sido destruidos por las fuerzas de marea galáctica. De acuerdo con los principios de espectroscopia de alta resolución y análisis de errores (*Astronomical Measurement*, Capítulo sobre *Spectroscopy and Chemical Abundances*), la determinación de la metalicidad $[Fe/H]$ de estas estrellas está sujeta a incertidumbres instrumentales y astrofísicas.

Supongamos que un equipo de astrónomos ha descubierto un nuevo flujo estelar en el halo galáctico, denominado “Stream-Alpha”. Los modelos cosmológicos de materia oscura fría (Λ CDM) predicen que este flujo debería provenir de una galaxia enana específica que fue acrecida hace 10 mil millones de años. Basado en las simulaciones de evolución química para ese progenitor enano, la metalicidad media teórica esperada para sus estrellas remanentes es de $\mu_0 = -1,50$ dex.

Para poner a prueba este modelo cosmológico, se obtienen espectros de alta resolución de $n = 25$ estrellas miembros del flujo utilizando un telescopio de 8 metros. El objetivo es determinar si la metalicidad media observada es consistente con la predicción teórica, o si los datos muestrales proporcionan evidencia estadística suficiente para rechazar el modelo de formación.

Paso 1: Formulación de Hipótesis Dado que una desviación significativa en *cualquier* dirección (ya sea que el flujo sea mucho más metálico o mucho más pobre en metales de lo previsto) invalidaría el modelo específico de evolución química del progenitor, planteamos una prueba bilateral (Devore, Capítulo 8, Sección 8.1):

$$H_0 : \mu = -1,50$$

$$H_a : \mu \neq -1,50$$

donde μ es la verdadera metalicidad media poblacional de las estrellas del Stream-Alpha.

Paso 2: Datos Muestrales y Suposiciones Del análisis de los 25 espectros, se obtienen los siguientes estadísticos muestrales:

- Tamaño de la muestra: $n = 25$
- Media muestral de metalicidad: $\bar{x} = -1,62$ dex
- Desviación estándar muestral: $s = 0,20$ dex

Dado que la varianza poblacional σ^2 es desconocida (una realidad ineludible en las observaciones astronómicas, donde el ruido instrumental y las variaciones atmosféricas contribuyen a la dispersión total), y asumiendo que las *erreurs* de medición espectroscópica se distribuyen aproximadamente de forma normal, el estadístico de prueba adecuado es la t de Student (Devore, Capítulo 8, Sección 8.2).

Paso 3: Cálculo del Estadístico de Prueba La fórmula para el estadístico t de una sola muestra es:

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$$

Sustituyendo los valores observados y el valor nulo propuesto por el modelo:

$$t_{\text{obs}} = \frac{-1,62 - (-1,50)}{0,20/\sqrt{25}} = \frac{-0,12}{0,20/5} = \frac{-0,12}{0,04} = -3,00$$

El valor observado del estadístico es $-3,00$. Esto indica que la media muestral está a 3 errores estándar por debajo de la media teórica predicha.

Paso 4: Región de Rechazo y Decisión Fijamos un nivel de significación de $\alpha = 0,05$. Para una prueba bilateral con $\nu = n - 1 = 24$ grados de libertad, buscamos los valores críticos en la tabla de la distribución t (Devore, Tabla A.4).

El valor crítico que deja un área de 0.025 en cada cola es:

$$t_{0,025,24} = 2,064$$

La región de rechazo para H_0 es:

$$T \leq -2,064 \quad \text{o} \quad T \geq 2,064$$

Dado que nuestro estadístico observado $t_{\text{obs}} = -3,00$ cae profundamente dentro de la región de rechazo inferior ($-3,00 < -2,064$), la decisión formal es **rechazar la hipótesis nula** H_0 .

Paso 5: Cálculo e Interpretación del Valor P Para cuantificar la fuerza de la evidencia contra el modelo cosmológico, calculamos el valor P (Devore, Capítulo 8, Sección 8.4). Para una prueba bilateral:

$$\text{Valor P} = 2 \times P(T_{24} \leq -3,00)$$

Consultando las tablas de la distribución t con 24 grados de libertad, sabemos que $t_{0,005,24} = 2,797$ y $t_{0,0025,24} = 3,091$. Dado que $2,797 < 3,00 < 3,091$, el área en una cola está estrictamente entre 0.0025 y 0.005. Por lo tanto:

$$0,005 < \text{Valor P} < 0,010$$

(El cálculo exacto por software arroja un valor $P \approx 0,0062$).

Dado que el valor P es mucho menor que nuestro nivel de significación $\alpha = 0,05$ (e incluso menor que un α más estricto de 0.01), la evidencia muestral en contra de H_0 es extremadamente fuerte.

Paso 6: Conclusión Astrofísica Desde la perspectiva de la inferencia estadística aplicada a la astronomía, los datos proporcionan evidencia estadísticamente sólida de que la metalicidad media del Stream-Alpha no es $-1,50$ dex.

Físicamente, esto tiene implicaciones profundas para los modelos de formación de galaxias. El hecho de que el flujo sea significativamente más pobre en metales ($\bar{x} = -1,62$) sugiere que la galaxia

enana progenitora tuvo una eficiencia de formación estelar menor a la asumida en las simulaciones de Λ CDM, o que el enriquecimiento químico por supernovas fue interrumpido prematuramente (posiblemente por una reionización temprana del medio intergaláctico). El modelo teórico original debe ser descartado o recalibrado para tener en cuenta estos nuevos límites observacionales. Este ejemplo demuestra cómo la prueba de hipótesis de una sola muestra actúa como el puente riguroso entre las predicciones teóricas abstractas y los datos observacionales ruidosos.

Clase 15

15.1. Técnicas de prueba de hipótesis de una muestra Parte 2