

1. Problema

Modelo de estrellas variables. Se adjunta el archivo `mw_cepheids.csv`, que contiene observaciones de un conjunto de estrellas Cefeidas. Para cada estrella se reportan su período de pulsación (en días), paralaje (en mas) y sus magnitudes en las bandas V e I. La relación período–luminosidad de las Cefeidas puede modelarse mediante la ecuación siguiente:

$$M_i = a + b \log_{10}(P_i) + \varepsilon_i,$$

donde M es la magnitud absoluta, P el período y los errores observacionales son independientes y siguen una distribución normal $\varepsilon_i \sim N(0, \sigma^2)$. Suponga que la desviación estándar de los errores es conocida e igual a $\sigma = 0,3$ mag.

Para los parámetros del modelo considere distribuciones a priori normales e independientes entre sí, ambas con $\mu = 0$ y $\sigma^2 = 10^2$.

1.1. Inspección inicial de los datos

Antes de comenzar con los incisos, se cargó el archivo de datos en Python y se revisaron sus primeras filas:

```
df = pd.read_csv('mw_cepheids.csv')
print(df.head())
```

El resultado obtenido fue:

	_RAJ2000	_DEJ2000	Per	plx	Vmag	Imag
	deg	deg	d	mas	mag	mag
0	-----	-----	-----	-----	-----	-----
1	-----	-----	-----	-----	-----	-----
2	916.456.086	+26.3292228	11.302	311	9.735	NaN
3	1.052.492.503	-87.089.917	8.014	383	10.100	8.708
4	1.007.812.989	+20.9391108	3.788	370	NaN	NaN

1.2. Parte A

- a) Lea el archivo `mw_cepheids.csv` y realice un gráfico de dispersión de la magnitud absoluta M en función de $\log_{10}(P)$. Describa brevemente la tendencia observada.

La magnitud absoluta M se relaciona con la magnitud aparente m y el paralaje ϖ (en arcosegundos) mediante la fórmula general del módulo de distancia [1]:

$$M = m + 5 \log_{10}(\varpi) + 5$$

Esta expresión se obtiene a partir de $m - M = 5 \log_{10}(d) - 5$, sustituyendo la distancia $d = 1/\varpi$ (con d en parsecs y ϖ en arcosegundos).

```
1 plx_arcsec = df['plx'].values / 1000                                # paralaje [
    arcsec]
2 x = np.log10(df['Per'].values)                                       # log10(P_i) [adim]
3 y = df['Vmag'].values + 5*np.log10(plx_arcsec) + 5                 # M_i [mag]
4 n = len(x)
5 sigma = 0.3                                                         # desv. est.
    conocida
```




Figura 1: Gráfico de dispersión de la magnitud absoluta en la banda V (M_V) en función del logaritmo del período ($\log_{10}(P)$) para la muestra seleccionada del dataset.

El gráfico de dispersión muestra una correlación negativa entre M_V y $\log_{10}(P)$: a medida que aumenta el período, la magnitud absoluta disminuye (las cefeidas se vuelven más luminosas), de acuerdo con la relación período–luminosidad descrita para estas estrellas variables [4, 6]. Se observa dispersión considerable, particularmente para períodos intermedios ($0,8 \lesssim \log_{10}(P) \lesssim 1,2$), donde M_V varía entre aproximadamente 11 y 15 mag.

- b) Escriba la función de verosimilitud para los parámetros a y b .

Como $y_i \mid M(a, b) \sim \mathcal{N}(a + bx_i, \sigma^2)$ de forma independiente para cada observación, la verosimilitud conjunta es $L(y \mid M(a, b)) = \prod_i f(y_i \mid M(a, b))$ [2]. Descartando la constante de normalización:

$$L(y \mid M(a, b)) \propto \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - a - bx_i)^2\right). \quad (1)$$

- c) Escriba la distribución posterior conjunta de a y b , ignorando constantes de normalización.

Por el teorema de Bayes, $P(M(a, b) \mid y) \propto L(y \mid M(a, b)) \cdot f(a, b)$, con prior $f(a, b) \propto \exp\left(-\frac{a^2+b^2}{200}\right)$ [3]:

$$P(M(a, b) \mid y) \propto \exp\left(-\frac{1}{2\sigma^2} \sum_i (y_i - a - bx_i)^2 - \frac{a^2 + b^2}{200}\right). \quad (2)$$

- d) Encuentre los valores de máxima probabilidad a posteriori (MAP) de a y b .

Se toma el logaritmo de (2) y se igualan a cero las derivadas parciales respecto de a y b . Las ecuaciones resultantes son **lineales** en $(\hat{a}, \hat{b})$ y forman el sistema $\mathbf{M}\vec{\theta} = \vec{Z}$:

$$\underbrace{\begin{bmatrix} n + \frac{\sigma^2}{100} & \sum_i x_i \\ \sum_i x_i & \sum_i x_i^2 + \frac{\sigma^2}{100} \end{bmatrix}}_{\mathbf{M}} \underbrace{\begin{bmatrix} \hat{a} \\ \hat{b} \end{bmatrix}}_{\vec{\theta}} = \underbrace{\begin{bmatrix} \sum_i y_i \\ \sum_i x_i y_i \end{bmatrix}}_{\vec{Z}}. \quad (3)$$

Los términos $\sigma^2/100$ en la diagonal provienen de derivar el término de la previa $-\frac{a^2+b^2}{200}$.

```

1 sum_x = x.sum();      sum_x2 = (x**2).sum()    # estadísticos
2 sum_y = y.sum();      sum_xy = (x*y).sum()
3
4 M_mat = np.array([[n + sigma**2/100, sum_x ],
5                   [sum_x,          sum_x2 + sigma**2/100]]) # matriz M
6 Z_vec = np.array([sum_y, sum_xy])              # vector Z
7
8 a_map, b_map = np.linalg.solve(M_mat, Z_vec)    # resuelve M theta = Z

```

La solución numérica obtenida para los estimadores MAP fue:

$$\hat{a} = 7,2506, \quad \hat{b} = 3,1462. \quad (4)$$

Es decir, el modelo ajustado con los valores de máxima probabilidad a posteriori queda

$$\widehat{M}_{\text{MAP}} = 7,2506 + 3,1462 \log_{10}(P). \quad (5)$$

- e) Demuestre que la distribución posterior conjunta de (a, b) es una normal bivariada y determine su media y matriz de covarianza.

Se expande el cuadrado en (2):

$$\sum_i (y_i - a - bx_i)^2 = na^2 + 2ab \sum_i x_i + b^2 \sum_i x_i^2 - 2a \sum_i y_i - 2b \sum_i x_i y_i + \underbrace{\sum_i y_i^2}_{\text{cte en } (a,b)}.$$

Sustituyendo en (2) y agrupando con el término de la previa, el exponente toma la forma cuadrática:

$$\ln P(M(a, b) | y) = -\frac{1}{2} (Aa^2 + 2Bab + Cb^2 - 2Da - 2Eb) + \text{cte}, \quad (6)$$

con coeficientes

$$A = \frac{n}{\sigma^2} + \frac{1}{100}, \quad B = \frac{\sum_i x_i}{\sigma^2}, \quad C = \frac{\sum_i x_i^2}{\sigma^2} + \frac{1}{100}, \quad (7)$$

$$D = \frac{\sum_i y_i}{\sigma^2}, \quad E = \frac{\sum_i x_i y_i}{\sigma^2}. \quad (8)$$

La expresión (6) es exactamente el núcleo de una distribución normal bivariada [2]. Por tanto:

$$(a, b) | y \sim \mathcal{N}_2((\hat{a}, \hat{b}), \Sigma), \quad (9)$$

donde $(\hat{a}, \hat{b})$ es la solución de (3) (media = moda para una normal), la **matriz de precisión** es

$$\Sigma^{-1} = \begin{bmatrix} A & B \\ B & C \end{bmatrix}, \quad \Sigma = \frac{1}{AC - B^2} \begin{bmatrix} C & -B \\ -B & A \end{bmatrix}. \quad (10)$$

```

1 A = n/sigma**2 + 1/100
2 B = sum_x/sigma**2
3 C = sum_x2/sigma**2 + 1/100
4
5 Prec = np.array([[A, B], [B, C]]) # matriz de precision
6 Sigma = np.linalg.inv(Prec)       # covarianza posterior

```

La solución numérica obtenida para estas matrices fue:

$$\Sigma^{-1} = \begin{bmatrix} 188,8989 & 165,8626 \\ 165,8626 & 155,9583 \end{bmatrix} \quad (11)$$

$$\Sigma = \begin{bmatrix} 0,0800 & -0,0851 \\ -0,0851 & 0,0969 \end{bmatrix} \quad (12)$$

Así, la posterior conjunta queda completamente determinada por la media MAP de (4) y la matriz de covarianza posterior de (12).

- f) Utilice el resultado anterior para generar 10^4 muestras aleatorias de la distribución posterior conjunta de (a, b) .

Se usa el resultado (9):

```
1 np.random.seed(42)
2 theta_s = np.random.multivariate_normal([a_map, b_map], Sigma, size=int(10e4))
3 a_s, b_s = theta_s[:, 0], theta_s[:, 1] # muestras marginales de a y b
```

- g) A partir de las muestras simuladas, estime un intervalo de credibilidad del 95 % para a y b .

Se obtienen como los percentiles 2.5 y 97.5 de las muestras:

```
1 ci_a = np.percentile(a_s, [2.5, 97.5]) # IC 95% para a
2 ci_b = np.percentile(b_s, [2.5, 97.5]) # IC 95% para b
```

Los intervalos de credibilidad del 95 % obtenidos fueron:

$$a \in [6,6925, 7,8155], \quad b \in [2,5270, 3,7607]. \quad (13)$$

- h) Utilice las muestras posteriores para estimar la distribución posterior de la magnitud absoluta de una Cefeida con período $P = 12$ días. Reporte la media posterior y un intervalo de credibilidad del 95 % para la magnitud absoluta predicha.

Para cada muestra $(\tilde{a}, \tilde{b})$ de la posterior se predice $\tilde{M} = \tilde{a} + \tilde{b} \log_{10}(12)$ la colección de $\tilde{M}$ aproxima la distribución posterior de la magnitud absoluta:

```
1 x_new = np.log10(12) # log10(P) para P = 12 dias
2 M_pred = a_s + b_s * x_new # distribucion predictiva
   posterior
3 mu_pred, ci_pred = M_pred.mean(), np.percentile(M_pred, [2.5, 97.5])
```

Para $P = 12$ días se tiene $x_{\text{new}} = \log_{10}(12) = 1,0792$. Las primeras muestras de la distribución predictiva posterior fueron 10,6616, 10,8020, 10,6148, 10,7918, 10,6640, usando un total de 10^4 muestras. La media predictiva posterior y el intervalo de credibilidad del 95 % fueron:

$$\mu_{\text{pred}} = 10,6468, \quad M_{\text{pred}} \in [10,4602, 10,8350]. \quad (14)$$

- i) Grafique la relación período–luminosidad utilizando la recta correspondiente a los valores MAP de los parámetros. Sobre el mismo gráfico, incluya una banda de credibilidad del 95 % obtenida a partir de las simulaciones de la distribución posterior.

Se evalúa cada muestra $(\tilde{a}, \tilde{b})$ en un grid de $\log_{10}(P)$ y se toman los percentiles 2.5 y 97.5 columna a columna:

```
1 x_grid = np.linspace(x.min(), x.max(), 300)
2 M_grid = a_s[:, None] + b_s[:, None]*x_grid # (10000, 300): curva por muestra
3 lo, hi = np.percentile(M_grid, [2.5, 97.5], axis=0)
```




Figura 2: Relación período–luminosidad ajustada con la recta MAP y banda de credibilidad posterior del 95 %.

- j) Compare los resultados obtenidos mediante el enfoque bayesiano con los que se obtendrían usando una regresión lineal clásica por mínimos cuadrados. Discuta semejanzas y diferencias entre ambos enfoques.

Para la regresión lineal clásica por mínimos cuadrados, también llamada OLS por sus siglas en inglés (*Ordinary Least Squares*), se usó [2]:

```
1 X_mat = np.column_stack([np.ones(n), x])
2 a_ols, b_ols = np.linalg.lstsq(X_mat, y, rcond=None)[0]
```

El resultado numérico fue:

$$\hat{a}_{\text{OLS}} = 7,2538, \quad \hat{b}_{\text{OLS}} = 3,1431 \quad (15)$$

Estos valores son muy cercanos a los estimadores MAP de (4), porque la prior normal usada es amplia y el término de regularización $\sigma^2/100 = 0,0009$ es pequeño. La diferencia principal es de interpretación: el enfoque bayesiano entrega una distribución posterior para (a, b) y permite construir intervalos de credibilidad, mientras que OLS (mínimos cuadrados ordinarios) entrega estimadores puntuales e intervalos de confianza frecuentistas. Además, con las muestras posteriores la incertidumbre se propaga de forma directa a nuevas predicciones.

1.3. Parte B

- a) Obtenga intervalos de confianza bootstrap del 95 % para los parámetros a y b . Compare estos resultados con los intervalos de credibilidad bayesianos.

```
1 B = 2000
2 a_boot, b_boot = [], []
3 for _ in range(B):
4     idx = np.random.choice(n, size=n, replace=True)
5     X_b = np.column_stack([np.ones(n), x[idx]])
6     y_b = y[idx]
7     theta_b = np.linalg.lstsq(X_b, y_b, rcond=None)[0]
8     a_boot.append(theta_b[0]); b_boot.append(theta_b[1])
9
10 ci_a_boot = np.percentile(a_boot, [2.5, 97.5])
11 ci_b_boot = np.percentile(b_boot, [2.5, 97.5])
```




Figura 3: Diagrama del algoritmo bootstrap no paramétrico: se remuestran los pares observados con reemplazo, se ajusta el modelo lineal en cada réplica, se almacenan los estimadores y se obtienen los intervalos de confianza mediante percentiles.

El resultado numérico para los intervalos bootstrap del 95 % fue:


$$a \in [-7,4550, 14,5516], \quad b \in [-3,1659, 17,4093]. \quad (16)$$

Estos intervalos son mucho más amplios que los intervalos de credibilidad bayesianos del inciso g), lo que indica mayor variabilidad bajo el remuestreo bootstrap de la muestra observada.

- b) Genere 10^4 conjuntos de datos sintéticos a partir del modelo posterior predictivo y compare la distribución de residuos simulados con la observada mediante una prueba de Kolmogorov-Smirnov.

```

1 # Residuos observados usando estimadores MAP
2 y_pred_map = a_map + b_map * x
3 res_obs = y - y_pred_map
4
5 # Residuos sintéticos (simulamos 10^4 conjuntos, tomamos uno representativo o
6 # aplanamos)
7 # Para la prueba K-S, aplanamos las simulaciones para tener una gran muestra
8 # de referencia
9 res_sim = np.random.normal(0, sigma, size=(10000, n)).flatten()
10
11 # Prueba de Kolmogorov-Smirnov de dos muestras
12 D_stat, p_value = stats.ks_2samp(res_obs, res_sim)
  
```



Validación posterior predictiva mediante comparación de residuos

Figura 4: Diagrama del algoritmo de validación posterior predictiva: se calculan los residuos observados con el modelo MAP, se generan residuos sintéticos bajo el supuesto normal con $\sigma = 0,3$ y se comparan ambas distribuciones mediante la prueba de Kolmogorov-Smirnov.

La comparación de distribuciones mediante la prueba de Kolmogorov-Smirnov se realizó como una prueba no paramétrica de dos muestras [5]. El resultado fue:

$$D = 0,7646, \quad p\text{-valor} = 6,70 \times 10^{-11}. \quad (17)$$

Como el p -valor es muy pequeño, se rechaza la hipótesis nula de que los residuos observados y los residuos simulados provienen de la misma distribución. Esto sugiere que el modelo lineal con errores normales de desviación estándar fija $\sigma = 0,3$ no reproduce completamente la distribución empírica de los residuos.

- c) Considere un modelo alternativo

$$M = a + b \log_{10}(P) + c[\log_{10}(P)]^2$$

Obtenga los valores MAP de los parámetros y compare el poder predictivo de este modelo con el modelo lineal utilizando remuestreo bootstrap.

```

1  # Estimadores MAP del modelo cuadrático
2  x2 = x**2
3  sum_x3 = (x**3).sum(); sum_x4 = (x**4).sum(); sum_x2y = (x2*y).sum()
4  M_quad = np.array([
5      [n + sigma**2/100, sum_x,          sum_x2],
6      [sum_x,          sum_x2 + sigma**2/100, sum_x3],
7      [sum_x2,          sum_x3,          sum_x4 + sigma**2/100]
8  ])
9  Z_quad = np.array([sum_y, sum_xy, sum_x2y])
10 a_q, b_q, c_q = np.linalg.solve(M_quad, Z_quad)
11
12 # Comparacion de poder predictivo Bootstrap (MSE)
13 mse_lin, mse_quad = [], []
14 for _ in range(B):
15     idx = np.random.choice(n, size=n, replace=True)
16     x_b, y_b = x[idx], y[idx]
17
18     # MSE Lineal
19     X_b_lin = np.column_stack([np.ones(n), x_b])
20     theta_lin = np.linalg.lstsq(X_b_lin, y_b, rcond=None)[0]
21     mse_lin.append(np.mean((y_b - X_b_lin @ theta_lin)**2))
22
23     # MSE Cuadrático
24     X_b_quad = np.column_stack([np.ones(n), x_b, x_b**2])
25     theta_quad = np.linalg.lstsq(X_b_quad, y_b, rcond=None)[0]
26     mse_quad.append(np.mean((y_b - X_b_quad @ theta_quad)**2))

```




Figura 5: Diagrama del algoritmo de comparación predictiva: el cálculo MAP del modelo cuadrático se realiza como estimación independiente, mientras que el remuestreo bootstrap toma pares observados, ajusta en paralelo los modelos lineal y cuadrático sobre cada réplica, guarda ambos MSEs y compara sus medianas al final.

Usando el mismo esquema de remuestreo bootstrap para comparar el error cuadrático medio de ambos modelos [5], las medianas obtenidas fueron:

$$\text{MSE}_{\text{lineal}} = 32,7084, \quad \text{MSE}_{\text{cuadrático}} = 30,1332. \quad (18)$$

El modelo cuadrático presenta una mediana de MSE menor, por lo que tiene mejor desempeño predictivo bajo este criterio.

Referencias

- [1] Astrónomo.org. Foro: Magnitud estelar. Foro en línea, 2024. Accedido: 15 de junio de 2026. URL: <https://www.astronomo.org/foro/index.php?topic=11137.0>.
- [2] Jay L. Devore. *Probabilidad y Estadística para Ingeniería y Ciencias*. Cengage Learning, México, 7ª edition, 2008. Traducido de: *Probability and Statistics for Engineering and the Sciences*, 7th ed., Brooks/Cole, 2008.

- [3] Eric D. Feigelson and G. Jogesh Babu. *Modern Statistical Methods for Astronomy: with R Applications*. Cambridge University Press, Cambridge, 2012. doi:10.1017/CB09780511779596.
- [4] NASA. Starchild: Cepheid variables. Sitio web. Accedido: 15 de junio de 2026. URL: <https://starchild.gsfc.nasa.gov/docs/StarChild/questions/cepheids.html>.
- [5] William H. Press, Saul A. Teukolsky, William T. Vetterling, and Brian P. Flannery. *Numerical Recipes in C: The Art of Scientific Computing*. Cambridge University Press, Cambridge, 2nd edition, 1992.
- [6] Wikipedia contributors. Period-luminosity relation — wikipedia, the free encyclopedia. Enciclopedia en línea, 2026. Accedido: 15 de junio de 2026. URL: https://en.wikipedia.org/wiki/Period-luminosity_relation.