



**UNIVERSIDAD
DE ANTIOQUIA**

1 8 0 3

Universidad de Antioquia

Facultad de Ciencias Exactas y Naturales

Instituto de Física

Curso: Astroestadística

Solución del problema práctico

Parcial 3 de Astroestadística

*Modelo estadístico bayesiano y comparación bootstrap
para la relación período–luminosidad de estrellas Cefeidas*

Autor: Daniel Soto Villada

Fecha: 15 de junio de 2026

1. Problema

Modelo de estrellas variables. Se adjunta el archivo `mw_cepheids.csv`, que contiene observaciones de un conjunto de estrellas Cefeidas. Para cada estrella se reportan su período de pulsación (en días), paralaje (en mas) y sus magnitudes en las bandas V e I. La relación período–luminosidad de las Cefeidas puede modelarse mediante la ecuación siguiente:

$$M_i = a + b \log_{10}(P_i) + \varepsilon_i,$$

donde M es la magnitud absoluta, P el período y los errores observacionales son independientes y siguen una distribución normal $\varepsilon_i \sim N(0, \sigma^2)$. Suponga que la desviación estándar de los errores es conocida e igual a $\sigma = 0,3$ mag.

Para los parámetros del modelo considere distribuciones a priori normales e independientes entre sí, ambas con $\mu = 0$ y $\sigma^2 = 10^2$.

1.1. Inspección inicial de los datos

Antes de comenzar con los incisos, se cargó el archivo de datos en Python y se revisaron sus primeras filas:

```
df = pd.read_csv('mw_cepheids.csv')
print(df.head())
```

El resultado obtenido fue:

	_RAJ2000	_DEJ2000	Per	plx	Vmag	Imag
	deg	deg	d	mas	mag	mag
0	-----	-----	-----	-----	-----	-----
1	-----	-----	-----	-----	-----	-----
2	916.456.086	+26.3292228	11.302	311	9.735	NaN
3	1.052.492.503	-87.089.917	8.014	383	10.100	8.708
4	1.007.812.989	+20.9391108	3.788	370	NaN	NaN

1.2. Parte A

- a) Lea el archivo `mw_cepheids.csv` y realice un gráfico de dispersión de la magnitud absoluta M en función de $\log_{10}(P)$. Describa brevemente la tendencia observada.

La magnitud absoluta M se relaciona con la magnitud aparente m y el paralaje ϖ (en arcosegundos) mediante la fórmula general del módulo de distancia [1]:

$$M = m + 5 \log_{10}(\varpi) + 5$$

Esta expresión se obtiene a partir de $m - M = 5 \log_{10}(d) - 5$, sustituyendo la distancia $d = 1/\varpi$ (con d en parsecs y ϖ en arcosegundos).

```
1 plx_arcsec = df['plx'].values / 1000                                # paralaje [
    arcsec]
2 x = np.log10(df['Per'].values)                                       # log10(P_i) [adim]
3 y = df['Vmag'].values + 5*np.log10(plx_arcsec) + 5                 # M_i [mag]
4 n = len(x)
5 sigma = 0.3                                                         # desv. est.
    conocida
```




Figura 1: Gráfico de dispersión de la magnitud absoluta en la banda V (M_V) en función del logaritmo del período ($\log_{10}(P)$) para la muestra seleccionada del dataset.

El gráfico de dispersión muestra una correlación negativa entre M_V y $\log_{10}(P)$: a medida que aumenta el período, la magnitud absoluta disminuye (las cefeidas se vuelven más luminosas), de acuerdo con la relación período–luminosidad descrita para estas estrellas variables [4, 7]. Se observa dispersión considerable, particularmente para períodos intermedios ($0.8 \lesssim \log_{10}(P) \lesssim 1.2$), donde M_V varía entre aproximadamente 11 y 15 mag.

- b) Escriba la función de verosimilitud para los parámetros a y b .

Como $y_i \mid M(a, b) \sim \mathcal{N}(a + bx_i, \sigma^2)$ de forma independiente para cada observación, la verosimilitud conjunta es $L(y \mid M(a, b)) = \prod_i f(y_i \mid M(a, b))$ [2]. Descartando la constante de normalización:

$$L(y \mid M(a, b)) \propto \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - a - bx_i)^2\right). \quad (1)$$

- c) Escriba la distribución posterior conjunta de a y b , ignorando constantes de normalización.

Por el teorema de Bayes, $P(M(a, b) \mid y) \propto L(y \mid M(a, b)) \cdot f(a, b)$, con prior $f(a, b) \propto \exp\left(-\frac{a^2+b^2}{200}\right)$ [3]:

$$P(M(a, b) \mid y) \propto \exp\left(-\frac{1}{2\sigma^2} \sum_i (y_i - a - bx_i)^2 - \frac{a^2 + b^2}{200}\right). \quad (2)$$

- d) Encuentre los valores de máxima probabilidad a posteriori (MAP) de a y b .

Se toma el logaritmo de (2) y se igualan a cero las derivadas parciales respecto de a y b . Las ecuaciones resultantes son **lineales** en $(\hat{a}, \hat{b})$ y forman el sistema $\mathbf{M}\vec{\theta} = \vec{Z}$:

$$\underbrace{\begin{bmatrix} n + \frac{\sigma^2}{100} & \sum_i x_i \\ \sum_i x_i & \sum_i x_i^2 + \frac{\sigma^2}{100} \end{bmatrix}}_{\mathbf{M}} \underbrace{\begin{bmatrix} \hat{a} \\ \hat{b} \end{bmatrix}}_{\vec{\theta}} = \underbrace{\begin{bmatrix} \sum_i y_i \\ \sum_i x_i y_i \end{bmatrix}}_{\vec{Z}}. \quad (3)$$

Los términos $\sigma^2/100$ en la diagonal provienen de derivar el término de la previa $-\frac{a^2+b^2}{200}$.

```

1 sum_x = x.sum();      sum_x2 = (x**2).sum()    # estadísticos
2 sum_y = y.sum();      sum_xy = (x*y).sum()
3
4 M_mat = np.array([[n + sigma**2/100, sum_x ],
5                   [sum_x,          sum_x2 + sigma**2/100]]) # matriz M
6 Z_vec = np.array([sum_y, sum_xy])              # vector Z
7
8 a_map, b_map = np.linalg.solve(M_mat, Z_vec)    # resuelve M theta = Z

```

La solución numérica obtenida para los estimadores MAP fue:

$$\hat{a} = 7,2506, \quad \hat{b} = 3,1462. \quad (4)$$

Es decir, el modelo ajustado con los valores de máxima probabilidad a posteriori queda

$$\widehat{M}_{\text{MAP}} = 7,2506 + 3,1462 \log_{10}(P). \quad (5)$$

- e) Demuestre que la distribución posterior conjunta de (a, b) es una normal bivariada y determine su media y matriz de covarianza.

Se expande el cuadrado en (2):

$$\sum_i (y_i - a - bx_i)^2 = na^2 + 2ab \sum_i x_i + b^2 \sum_i x_i^2 - 2a \sum_i y_i - 2b \sum_i x_i y_i + \underbrace{\sum_i y_i^2}_{\text{cte en } (a,b)}.$$

Sustituyendo en (2) y agrupando con el término de la previa, el exponente toma la forma cuadrática:

$$\ln P(M(a, b) | y) = -\frac{1}{2} (Aa^2 + 2Bab + Cb^2 - 2Da - 2Eb) + \text{cte}, \quad (6)$$

con coeficientes

$$A = \frac{n}{\sigma^2} + \frac{1}{100}, \quad B = \frac{\sum_i x_i}{\sigma^2}, \quad C = \frac{\sum_i x_i^2}{\sigma^2} + \frac{1}{100}, \quad (7)$$

$$D = \frac{\sum_i y_i}{\sigma^2}, \quad E = \frac{\sum_i x_i y_i}{\sigma^2}. \quad (8)$$

La expresión (6) es exactamente el núcleo de una distribución normal bivariada [2]. Por tanto:

$$(a, b) | y \sim \mathcal{N}_2((\hat{a}, \hat{b}), \Sigma), \quad (9)$$

donde $(\hat{a}, \hat{b})$ es la solución de (3) (media = moda para una normal), la **matriz de precisión** es

$$\Sigma^{-1} = \begin{bmatrix} A & B \\ B & C \end{bmatrix}, \quad \Sigma = \frac{1}{AC - B^2} \begin{bmatrix} C & -B \\ -B & A \end{bmatrix}. \quad (10)$$

```

1 A = n/sigma**2 + 1/100
2 B = sum_x/sigma**2
3 C = sum_x2/sigma**2 + 1/100
4
5 Prec = np.array([[A, B], [B, C]]) # matriz de precision
6 Sigma = np.linalg.inv(Prec)       # covarianza posterior

```

La solución numérica obtenida para estas matrices fue:

$$\Sigma^{-1} = \begin{bmatrix} 188,8989 & 165,8626 \\ 165,8626 & 155,9583 \end{bmatrix} \quad (11)$$

$$\Sigma = \begin{bmatrix} 0,0800 & -0,0851 \\ -0,0851 & 0,0969 \end{bmatrix} \quad (12)$$

Así, la posterior conjunta queda completamente determinada por la media MAP de (4) y la matriz de covarianza posterior de (12).

- f) Utilice el resultado anterior para generar 10^4 muestras aleatorias de la distribución posterior conjunta de (a, b) .

Se usa el resultado (9):

```
1 np.random.seed(42)
2 theta_s = np.random.multivariate_normal([a_map, b_map], Sigma, size=int(10e4))
3 a_s, b_s = theta_s[:, 0], theta_s[:, 1] # muestras marginales de a y b
```

- g) A partir de las muestras simuladas, estime un intervalo de credibilidad del 95 % para a y b .

Se obtienen como los percentiles 2.5 y 97.5 de las muestras:

```
1 ci_a = np.percentile(a_s, [2.5, 97.5]) # IC 95% para a
2 ci_b = np.percentile(b_s, [2.5, 97.5]) # IC 95% para b
```

Los intervalos de credibilidad del 95 % obtenidos fueron:

$$a \in [6,6925, 7,8155], \quad b \in [2,5270, 3,7607]. \quad (13)$$

- h) Utilice las muestras posteriores para estimar la distribución posterior de la magnitud absoluta de una Cefeida con período $P = 12$ días. Reporte la media posterior y un intervalo de credibilidad del 95 % para la magnitud absoluta predicha.

Para cada muestra $(\tilde{a}, \tilde{b})$ de la posterior se predice $\tilde{M} = \tilde{a} + \tilde{b} \log_{10}(12)$ la colección de $\tilde{M}$ aproxima la distribución posterior de la magnitud absoluta:

```
1 x_new = np.log10(12) # log10(P) para P = 12 dias
2 M_pred = a_s + b_s * x_new # distribucion predictiva
   posterior
3 mu_pred, ci_pred = M_pred.mean(), np.percentile(M_pred, [2.5, 97.5])
```

Para $P = 12$ días se tiene $x_{\text{new}} = \log_{10}(12) = 1,0792$. Las primeras muestras de la distribución predictiva posterior fueron 10,6616, 10,8020, 10,6148, 10,7918, 10,6640, usando un total de 10^4 muestras. La media predictiva posterior y el intervalo de credibilidad del 95 % fueron:

$$\mu_{\text{pred}} = 10,6468, \quad M_{\text{pred}} \in [10,4602, 10,8350]. \quad (14)$$

- i) Grafique la relación período–luminosidad utilizando la recta correspondiente a los valores MAP de los parámetros. Sobre el mismo gráfico, incluya una banda de credibilidad del 95 % obtenida a partir de las simulaciones de la distribución posterior.

Se evalúa cada muestra $(\tilde{a}, \tilde{b})$ en un grid de $\log_{10}(P)$ y se toman los percentiles 2.5 y 97.5 columna a columna:

```
1 x_grid = np.linspace(x.min(), x.max(), 300)
2 M_grid = a_s[:, None] + b_s[:, None]*x_grid # (10000, 300): curva por muestra
3 lo, hi = np.percentile(M_grid, [2.5, 97.5], axis=0)
```




Figura 2: Relación período–luminosidad ajustada con la recta MAP y banda de credibilidad posterior del 95 %.

- j) Compare los resultados obtenidos mediante el enfoque bayesiano con los que se obtendrían usando una regresión lineal clásica por mínimos cuadrados. Discuta semejanzas y diferencias entre ambos enfoques.

Para la regresión lineal clásica por mínimos cuadrados, también llamada OLS por sus siglas en inglés (*Ordinary Least Squares*), se usó [2]:

```
1 X_mat = np.column_stack([np.ones(n), x])
2 a_ols, b_ols = np.linalg.lstsq(X_mat, y, rcond=None)[0]
```

El resultado numérico fue:

$$\hat{a}_{\text{OLS}} = 7,2538, \quad \hat{b}_{\text{OLS}} = 3,1431 \quad (15)$$

Estos valores son muy cercanos a los estimadores MAP de (4), porque la prior normal usada es amplia y el término de regularización $\sigma^2/100 = 0,0009$ es pequeño. La diferencia principal es de interpretación: el enfoque bayesiano entrega una distribución posterior para (a, b) y permite construir intervalos de credibilidad, mientras que OLS (mínimos cuadrados ordinarios) entrega estimadores puntuales e intervalos de confianza frecuentistas. Además, con las muestras posteriores la incertidumbre se propaga de forma directa a nuevas predicciones.

1.3. Parte B

- a) Obtenga intervalos de confianza bootstrap del 95 % para los parámetros a y b . Compare estos resultados con los intervalos de credibilidad bayesianos.

```
1 B = 2000
2 a_boot, b_boot = [], []
3 for _ in range(B):
4     idx = np.random.choice(n, size=n, replace=True)
5     X_b = np.column_stack([np.ones(n), x[idx]])
6     y_b = y[idx]
7     theta_b = np.linalg.lstsq(X_b, y_b, rcond=None)[0]
8     a_boot.append(theta_b[0]); b_boot.append(theta_b[1])
9
10 ci_a_boot = np.percentile(a_boot, [2.5, 97.5])
11 ci_b_boot = np.percentile(b_boot, [2.5, 97.5])
```




Figura 3: Diagrama del algoritmo bootstrap no paramétrico: se remuestran los pares observados con reemplazo, se ajusta el modelo lineal en cada réplica, se almacenan los estimadores y se obtienen los intervalos de confianza mediante percentiles.

El resultado numérico para los intervalos bootstrap del 95 % fue:


$$a \in [-7,4550, 14,5516], \quad b \in [-3,1659, 17,4093]. \quad (16)$$

Estos intervalos son mucho más amplios que los intervalos de credibilidad bayesianos del inciso g), lo que indica mayor variabilidad bajo el remuestreo bootstrap de la muestra observada.

- b) Genere 10^4 conjuntos de datos sintéticos a partir del modelo posterior predictivo y compare la distribución de residuos simulados con la observada mediante una prueba de Kolmogorov-Smirnov.

```

1 # Residuos observados usando estimadores MAP
2 y_pred_map = a_map + b_map * x
3 res_obs = y - y_pred_map
4
5 # Residuos sintéticos (simulamos 10^4 conjuntos, tomamos uno representativo o
6   aplanamos)
7 # Para la prueba K-S, aplanamos las simulaciones para tener una gran muestra
8   de referencia
9 res_sim = np.random.normal(0, sigma, size=(10000, n)).flatten()
10
11 # Prueba de Kolmogorov-Smirnov de dos muestras
12 D_stat, p_value = stats.ks_2samp(res_obs, res_sim)
  
```



Validación posterior predictiva mediante comparación de residuos

Figura 4: Diagrama del algoritmo de validación posterior predictiva: se calculan los residuos observados con el modelo MAP, se generan residuos sintéticos bajo el supuesto normal con $\sigma = 0,3$ y se comparan ambas distribuciones mediante la prueba de Kolmogorov-Smirnov.

La comparación de distribuciones mediante la prueba de Kolmogorov-Smirnov se realizó como una prueba no paramétrica de dos muestras [5]. El resultado fue:

$$D = 0,7646, \quad p\text{-valor} = 6,70 \times 10^{-11}. \quad (17)$$

Como el p -valor es muy pequeño, se rechaza la hipótesis nula de que los residuos observados y los residuos simulados provienen de la misma distribución. Esto sugiere que el modelo lineal con errores normales de desviación estándar fija $\sigma = 0,3$ no reproduce completamente la distribución empírica de los residuos.

- c) Considere un modelo alternativo


$$M = a + b \log_{10}(P) + c[\log_{10}(P)]^2$$

Obtenga los valores MAP de los parámetros y compare el poder predictivo de este modelo con el modelo lineal utilizando remuestreo bootstrap.

```

1  # Estimadores MAP del modelo cuadrático
2  x2 = x**2
3  sum_x3 = (x**3).sum(); sum_x4 = (x**4).sum(); sum_x2y = (x2*y).sum()
4  M_quad = np.array([
5      [n + sigma**2/100, sum_x,          sum_x2],
6      [sum_x,          sum_x2 + sigma**2/100, sum_x3],
7      [sum_x2,          sum_x3,          sum_x4 + sigma**2/100]
8  ])
9  Z_quad = np.array([sum_y, sum_xy, sum_x2y])
10 a_q, b_q, c_q = np.linalg.solve(M_quad, Z_quad)
11
12 # Comparacion de poder predictivo Bootstrap (MSE)
13 mse_lin, mse_quad = [], []
14 for _ in range(B):
15     idx = np.random.choice(n, size=n, replace=True)
16     x_b, y_b = x[idx], y[idx]
17
18     # MSE Lineal
19     X_b_lin = np.column_stack([np.ones(n), x_b])
20     theta_lin = np.linalg.lstsq(X_b_lin, y_b, rcond=None)[0]
21     mse_lin.append(np.mean((y_b - X_b_lin @ theta_lin)**2))
22
23     # MSE Cuadrático
24     X_b_quad = np.column_stack([np.ones(n), x_b, x_b**2])
25     theta_quad = np.linalg.lstsq(X_b_quad, y_b, rcond=None)[0]
26     mse_quad.append(np.mean((y_b - X_b_quad @ theta_quad)**2))

```



Selección predictiva entre modelo lineal y cuadrático mediante remuestreo

Figura 5: Diagrama del algoritmo de comparación predictiva: el cálculo MAP del modelo cuadrático se realiza como estimación independiente, mientras que el remuestreo bootstrap toma pares observados, ajusta en paralelo los modelos lineal y cuadrático sobre cada réplica, guarda ambos MSEs y compara sus medianas al final.

Usando el mismo esquema de remuestreo bootstrap para comparar el error cuadrático medio de ambos modelos [5], las medianas obtenidas fueron:

$$\text{MSE}_{\text{lineal}} = 32,7084, \quad \text{MSE}_{\text{cuadrático}} = 30,1332. \quad (18)$$

El modelo cuadrático presenta una mediana de MSE menor, por lo que tiene mejor desempeño predictivo bajo este criterio.

Los cálculos completos implementados en Python, incluyendo la lectura de datos, los estimadores MAP, las simulaciones posteriores, el bootstrap y las pruebas de comparación, se encuentran disponibles en el cuaderno de Google Colab citado en la bibliografía; al hacer clic sobre la referencia se abre directamente el enlace correspondiente [6].

Referencias

- [1] Astrónomo.org. Foro: Magnitud estelar. Foro en línea, 2024. Accedido: 15 de junio de 2026. URL: <https://www.astronomo.org/foro/index.php?topic=11137.0>.
- [2] Jay L. Devore. *Probabilidad y Estadística para Ingeniería y Ciencias*. Cengage Learning, México, 7^a edition, 2008. Traducido de: Probability and Statistics for Engineering and the Sciences, 7th ed., Brooks/Cole, 2008.
- [3] Eric D. Feigelson and G. Jogesh Babu. *Modern Statistical Methods for Astronomy: with R Applications*. Cambridge University Press, Cambridge, 2012. doi:10.1017/CB09780511779596.
- [4] NASA. Starchild: Cepheid variables. Sitio web. Accedido: 15 de junio de 2026. URL: <https://starchild.gsfc.nasa.gov/docs/StarChild/questions/cepheids.html>.
- [5] William H. Press, Saul A. Teukolsky, William T. Vetterling, and Brian P. Flannery. *Numerical Recipes in C: The Art of Scientific Computing*. Cambridge University Press, Cambridge, 2nd edition, 1992.
- [6] Daniel Soto Villada. Parcial 3 solución: cálculos en python para astroestadística. Cuaderno de Google Colab, 2026. Cuaderno interactivo con los cálculos reproducibles en Python. Accedido: 15 de junio de 2026. URL: <https://colab.research.google.com/github/Daniel-534/Astroestadistica/blob/main/Evaluaciones/Parcial3Solucion.ipynb>.
- [7] Wikipedia contributors. Period-luminosity relation — wikipedia, the free encyclopedia. Enciclopedia en línea, 2026. Accedido: 15 de junio de 2026. URL: https://en.wikipedia.org/wiki/Period-luminosity_relation.