

Solución — Parte A

Se identifica la correspondencia entre las variables del modelo general (notas de clase) y las del problema:

$$y_i \equiv M_i \quad (\text{magnitud absoluta en banda } V),$$
$$x_i \equiv \log_{10}(P_i) \quad (\text{logaritmo del período en días}).$$

El parámetro de error $\sigma = 0,3$ mag es conocido; las distribuciones previas son $a, b \sim \mathcal{N}(0, 10^2)$ independientes, con $\sigma_a = \sigma_b = 10$.

Preparación de los datos

El archivo CSV de formato CDS (VizieR) contiene dos filas de encabezado (unidades y separadores de columnas) que quedan como texto. Convirtiendo cada columna relevante con `errors='coerce'`, esas filas se transforman en NaN y se eliminan junto con cualquier observación incompleta.

Nota. A pesar de la etiqueta `mas`, los valores de `plx` están almacenados en microsegundos de arco (μas). Se dividen por 10^3 para obtener el paralaje en mas antes de aplicar el módulo de distancia $\mu = 10 - 5 \log_{10}(\varpi[\text{mas}])$, lo que da $M_V = V + 5 \log_{10}(\varpi) - 10$.

```
1 import numpy as np, pandas as pd, matplotlib.pyplot as plt
2
3 df = pd.read_csv('mw_cepheids.csv')
4 for col in ['Per', 'plx', 'Vmag']:
5     df[col] = pd.to_numeric(df[col], errors='coerce') # texto -> NaN
6 df.dropna(subset=['Per', 'plx', 'Vmag'], inplace=True) # elimina NaN
7
8 plx_mas = df['plx'].values / 1000 # paralaje
9 x = np.log10(df['Per'].values) # log10(P_i)
10 y = df['Vmag'].values + 5*np.log10(plx_mas) - 10 # M_i [mag]
11 n = len(x)
12 sigma = 0.3 # desv.
    est. conocida
```

a) Gráfico de dispersión.

```
1 plt.figure()
2 plt.scatter(x, y, s=10, alpha=0.6)
3 plt.xlabel(r'$\log_{10}(P)$ [adim.]')
4 plt.ylabel(r'$M_V$ [mag]')
5 plt.gca().invert_yaxis() # magnitudes: escala invertida
6 plt.tight_layout(); plt.savefig('dispersion.pdf')
```

Tendencia observada: se aprecia una relación lineal negativa (Ley de Leavitt): a mayor período, menor magnitud absoluta (estrella más luminosa). La dispersión alrededor de la tendencia es pequeña, lo que justifica el modelo de regresión lineal propuesto.

b) Función de verosimilitud.

Como $y_i | M(a, b) \sim \mathcal{N}(a + bx_i, \sigma^2)$ de forma independiente para cada observación, la verosimilitud conjunta es $L(y | M(a, b)) = \prod_i f(y_i | M(a, b))$. Descartando la constante de normalización:

$$L(y | M(a, b)) \propto \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - a - bx_i)^2\right). \quad (1)$$

c) **Distribución posterior conjunta.**

Por el teorema de Bayes, $P(M(a, b) | y) \propto L(y | M(a, b)) \cdot f(a, b)$, con prior $f(a, b) \propto \exp(-\frac{a^2+b^2}{200})$:

$$P(M(a, b) | y) \propto \exp\left(-\frac{1}{2\sigma^2} \sum_i (y_i - a - bx_i)^2 - \frac{a^2 + b^2}{200}\right). \quad (2)$$

d) **Estimación MAP.**

Se toma el logaritmo de (2) y se igualan a cero las derivadas parciales respecto de a y b . Las ecuaciones resultantes son **lineales** en $(\hat{a}, \hat{b})$ y forman el sistema $\mathbf{M}\vec{\theta} = \vec{Z}$:

$$\underbrace{\begin{bmatrix} n + \frac{\sigma^2}{100} & \sum_i x_i \\ \sum_i x_i & \sum_i x_i^2 + \frac{\sigma^2}{100} \end{bmatrix}}_{\mathbf{M}} \underbrace{\begin{bmatrix} \hat{a} \\ \hat{b} \end{bmatrix}}_{\vec{\theta}} = \underbrace{\begin{bmatrix} \sum_i y_i \\ \sum_i x_i y_i \end{bmatrix}}_{\vec{Z}}. \quad (3)$$

Los términos $\sigma^2/100$ en la diagonal provienen de derivar el término de la previa $-\frac{a^2+b^2}{200}$ e incorporan regularización tipo *ridge* con parámetro efectivo $\lambda = \sigma^2/100 = 0,0009$.

```

1 sum_x = x.sum();      sum_x2 = (x**2).sum()    # estadísticos
   suficientes
2 sum_y = y.sum();      sum_xy = (x*y).sum()
3
4 M_mat = np.array([[n + sigma**2/100, sum_x ],
5                   [sum_x,          sum_x2 + sigma**2/100]]) #
   matriz M
6 Z_vec = np.array([sum_y, sum_xy])             #
   vector Z
7
8 a_map, b_map = np.linalg.solve(M_mat, Z_vec)  # resuelve M theta
   = Z

```

e) **La posterior es una normal bivariada.**

Se expande el cuadrado en (2):

$$\sum_i (y_i - a - bx_i)^2 = na^2 + 2ab \sum_i x_i + b^2 \sum_i x_i^2 - 2a \sum_i y_i - 2b \sum_i x_i y_i + \underbrace{\sum_i y_i^2}_{\text{cte en } (a,b)}.$$

Sustituyendo en (2) y agrupando con el término de la previa, el exponente toma la forma cuadrática:

$$\ln P(M(a, b) | y) = -\frac{1}{2}(Aa^2 + 2Bab + Cb^2 - 2Da - 2Eb) + \text{cte}, \quad (4)$$

con coeficientes

$$A = \frac{n}{\sigma^2} + \frac{1}{100}, \quad B = \frac{\sum_i x_i}{\sigma^2}, \quad C = \frac{\sum_i x_i^2}{\sigma^2} + \frac{1}{100}, \quad (5)$$

$$D = \frac{\sum_i y_i}{\sigma^2}, \quad E = \frac{\sum_i x_i y_i}{\sigma^2}. \quad (6)$$

La expresión (4) es exactamente el núcleo de una distribución normal bivariada (cf. notas de clase). Por tanto:

$$(a, b) | y \sim \mathcal{N}_2((\hat{a}, \hat{b}), \Sigma), \quad (7)$$

donde $(\hat{a}, \hat{b})$ es la solución de (3) (media = moda para una normal), la **matriz de precisión** es

$$\Sigma^{-1} = \begin{bmatrix} A & B \\ B & C \end{bmatrix}, \quad \Sigma = \frac{1}{AC - B^2} \begin{bmatrix} C & -B \\ -B & A \end{bmatrix}. \quad (8)$$

```

1 A = n/sigma**2 + 1/100
2 B = sum_x/sigma**2
3 C = sum_x2/sigma**2 + 1/100
4
5 Prec = np.array([[A, B], [B, C]]) # matriz de precision Sigma
   ^{-1}
6 Sigma = np.linalg.inv(Prec)      # covarianza posterior

```

f) Muestras de la distribución posterior.

Se usa directamente el resultado (7):

```

1 np.random.seed(42)
2 theta_s = np.random.multivariate_normal([a_map, b_map], Sigma,
   size=10_000)
3 a_s, b_s = theta_s[:, 0], theta_s[:, 1] # muestras marginales
   de a y b

```

g) Intervalos de credibilidad del 95 % para a y b .

Se obtienen como los percentiles 2.5 y 97.5 de las muestras:

```

1 ci_a = np.percentile(a_s, [2.5, 97.5]) # IC 95% para a
2 ci_b = np.percentile(b_s, [2.5, 97.5]) # IC 95% para b

```

h) Distribución posterior predictiva para $P = 12$ días.

Para cada muestra $(\tilde{a}, \tilde{b})$ de la posterior se predice $\tilde{M} = \tilde{a} + \tilde{b} \log_{10}(12)$; la colección de $\tilde{M}$ aproxima la distribución posterior de la magnitud absoluta:

```

1 x_new = np.log10(12) # log10(P) para P
   = 12 días
2 M_pred = a_s + b_s * x_new # distribucion
   predictiva posterior
3 mu_pred, ci_pred = M_pred.mean(), np.percentile(M_pred, [2.5,
   97.5])

```

i) Relación período–luminosidad con banda de credibilidad.

Se evalúa cada muestra $(\tilde{a}, \tilde{b})$ en una grilla de $\log_{10}(P)$ y se toman los percentiles 2.5 y 97.5 columna a columna:

```

1 x_grid = np.linspace(x.min(), x.max(), 300)
2 M_grid = a_s[:, None] + b_s[:, None]*x_grid # (10000, 300):
   curva por muestra
3 lo, hi = np.percentile(M_grid, [2.5, 97.5], axis=0)
4
5 plt.figure()
6 plt.scatter(x, y, s=10, alpha=0.5, label='Datos')
7 plt.plot(x_grid, a_map + b_map*x_grid, 'r-', lw=1.5, label='MAP')

```

```

8 plt.fill_between(x_grid, lo, hi, alpha=0.3, label='Banda 95\%')
9 plt.xlabel(r'$\log_{10}(P)$'); plt.ylabel(r'$M_V$ [mag]')
10 plt.gca().invert_yaxis(); plt.legend(); plt.tight_layout()
11 plt.savefig('pl_band.pdf')

```

j) Comparación con regresión por mínimos cuadrados (OLS).

Las ecuaciones normales de OLS son idénticas a (3) salvo por los términos de regularización diagonal:

$$\underbrace{\begin{bmatrix} n & \sum x_i \\ \sum x_i & \sum x_i^2 \end{bmatrix}}_{\mathbf{M}_{\text{OLS}}} \begin{bmatrix} \hat{a}_{\text{OLS}} \\ \hat{b}_{\text{OLS}} \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum x_i y_i \end{bmatrix}.$$

```

1 X_mat = np.column_stack([np.ones(n), x]) #
   disen0 [1 | x]
2 a_ols, b_ols = np.linalg.lstsq(X_mat, y, rcond=None)[0] #
   estimacion OLS

```

Semejanzas. Como $\sigma^2/100 = 0,0009 \ll n$, la perturbación diagonal es despreciable y los estimadores MAP y OLS son numéricamente casi idénticos.

Diferencias.

- El enfoque bayesiano produce la distribución posterior completa (7), por lo que cualquier probabilidad sobre (a, b) o sobre una predicción futura se calcula directamente como área bajo dicha densidad (intervalos de *credibilidad*).
- OLS produce intervalos de *confianza* frecuentistas: la interpretación es que, en repetidas muestras, el 95% de los intervalos construidos cubrirían el verdadero parámetro; (a, b) no es una variable aleatoria en ese marco.
- La incertidumbre en (a, b) se propaga de forma natural a cualquier cantidad de interés (inciso h) mediante las muestras posteriores, sin necesidad de aproximaciones adicionales como el método delta o remuestreo.