

Universidad de Antioquia

Facultad de Ciencias Exactas y Naturales

Instituto de Física

Astroestadística

Daniel Soto Villada

Estudiante del pregrado de astronomía

4 de julio de 2026

Índice general

1. Clase 1	1
1.1. Espacios Muestrales	1
1.1.1. Ejemplo 1: Clasificación Morfológica de Galaxias	1
1.1.2. Ejemplo 2: Espacio Muestral Infinito en el Seguimiento de Cometas	1
1.1.3. Extensión Analítica: Espacios Muestrales Continuos en Coordenadas Celestes	2
1.2. Eventos	3
1.2.1. Ejemplo 1: Clasificación Taxonómica de Asteroides	3
1.2.2. Ejemplo 2: Modelado Gravitacional en Operaciones de Proximidad	4
1.3. Probabilidad	5
1.4. Axiomas de probabilidad	6
1.4.1. Propiedades Fundamentales Derivadas de los Axiomas	6
1.4.2. Ejemplo 1: Demostración de la Probabilidad del Evento Nulo	7
1.4.3. Ejemplo 2: Clasificación de Señales en Astronomía de Ondas Gravitacionales	8
1.4.4. Ejemplo 3: Análisis de Modos de Falla en un Rover de Exploración	8
2. Clase 2	10
2.1. Probabilidad condicional	10
2.1.1. Ejemplo 1: Caracterización de Asteroides mediante Albedo Radar	10
2.1.2. Ejemplo 2: Regla de Multiplicación en Pipelines de Transitorios Astrofísicos	11
2.2. Independencia de eventos	12
2.2.1. Ejemplo 1: Confiabilidad de Subsistemas Críticos en una Sonda Interplanetaria	13
2.2.2. Ejemplo 2: Discriminación de Señales en la Red de Interferómetros de Ondas Gravitacionales	13
2.3. Teorema de Bayes	14
2.3.1. Ejemplo 1: Demostración del Teorema de Actualización Secuencial	15
2.3.2. Ejemplo 2: Clasificación Mineralógica mediante Espectroscopia de Reflexión	16
2.3.3. Ejemplo 3: Aislamiento de Fallas en el Sistema de Control de Actitud	17
2.3.4. Ejemplo 4: Clasificación Orbital de Cometas (Parabólico vs. Hiperbólico)	18
3. Clase 3	20
3.1. Conteos	20
3.1.1. Ejemplo 1: Configuración de Carga Útil en una Sonda Espacial	20
3.1.2. Ejemplo 2: Matriz de Observación Fotométrica en un Telescopio Robótico	21
3.2. Permutaciones	22
3.2.1. Ejemplo 1: Secuencia de Apuntamiento en un Telescopio Espacial	22
3.2.2. Ejemplo 2: Secuencia de Análisis en un Espectrómetro de Masas Planetario	23
3.3. Combinaciones	24
3.3.1. Ejemplo 1: Selección de Sitios de Aterrizaje en Ciencia Planetaria	24
3.3.2. Ejemplo 2: Configuración de Sub-arrays en Radio Interferometría	25

4. Clase 4	26
4.1. Variables aleatorias	26
4.2. Funciones de densidad de probabilidad	26
4.3. Densidad acumulativa de probabilidad	26
4.4. Valores esperados	26
4.5. Varianza	26
5. Clase 5	27
5.1. Funciones de distribución discreta: Binomial	27
6. Clase 6	28
6.1. Distribución de Poisson	28
6.2. Distribuciones continuas	28
6.3. Percentiles	28
6.4. Distribución normal	28
7. Clase 7	29
7.1. Funciones de varias variables	29
7.2. Distribuciones de probabilidad conjunta	29
7.3. Distribuciones marginales	29
7.4. Combinación de variables aleatorias	29
8. Clase 8	30
8.1. Valores esperados en varias variables	30
8.2. Funciones de correlación	30
8.3. Covarianza	30
8.4. Combinación de variables aleatorias	30
9. Clase 9	31
9.1. Teorema central del límite	31
9.2. Estadísticos	31
9.3. Distribución de estadísticos	31
9.4. Muestras	31
9.5. Estimación puntual: Método de momentos	31
10. Clase 10	32
10.1. Método de mínimos cuadrados	32
10.2. Maximum likelihood	32

Clase 1

1.1. Espacios Muestrales

El espacio muestral de un experimento denotado por S , es el conjunto de todos los posibles resultados de dicho experimento (Devore, Capítulo 2).

Cada resultado individual se denomina *evento simple*. Un *evento compuesto* es cualquier subconjunto del espacio muestral que contenga más de un resultado.

1.1.1. Ejemplo 1: Clasificación Morfológica de Galaxias

Un telescopio espacial apunta hacia un campo profundo del universo y detecta una galaxia previamente no catalogada. El experimento consiste en analizar su perfil de brillo superficial y asignarle una clase morfológica.

El resultado de esta observación debe caer en una de cuatro categorías macroscópicas mutuamente excluyentes:

- E : Galaxia Espiral.
- L : Galaxia Elíptica.
- I : Galaxia Irregular.
- D : Galaxia Lenticular (de disco, sin brazos espirales evidentes).

El espacio muestral S para este experimento es simplemente el conjunto:

$$S = \{E, L, I, D\}$$

1.1.2. Ejemplo 2: Espacio Muestral Infinito en el Seguimiento de Cometas

Los espacios muestrales infinitos son fundamentales cuando modelamos procesos de 'espera' o 'búsqueda' en astronomía. Para determinar la órbita de un cometa recién descubierto, un observatorio necesita obtener imágenes astrométricas de alta calidad (libres de nubes y con un *seeing* atmosférico adecuado) en múltiples noches.

Definamos el experimento como: *Intentar obtener una imagen usable del cometa noche tras noche hasta lograr el primer éxito*. Los resultados básicos para cada noche son:

- E : Noche despejada, imagen exitosa (Éxito).

- F : Noche nublada o con mal *seeing*, imagen descartada (Falla).

A diferencia del ejemplo anterior, aquí no fijamos un número finito de intentos de antemano. El experimento termina en el momento en que se obtiene el primer éxito. Por lo tanto, el espacio muestral S contiene un número infinito de resultados posibles:

$$S = \{E, FE, FFE, FFFE, FFFFE, \dots\}$$

Cada elemento de S representa una secuencia única de noches. Por ejemplo, el resultado $FFFE$ significa que el astrónomo sufrió tres noches consecutivas de mal clima antes de lograr captar el cometa en la cuarta noche.

Podemos construir eventos compuestos para analizar la eficiencia del observatorio. Sea C el evento *lograr la imagen exitosa en un número par de noches*. Analíticamente, este evento se expresa como:

$$C = \{FE, FFFE, FFFFFFE, \dots\}$$

O sea, $C = \{F^{2k-1}E \mid k = 1, 2, 3, \dots\}$.

Este tipo de espacio muestral infinito discreto es la base para modelar distribuciones de probabilidad como la Geométrica, la cual es sumamente útil en la astronomía observacional para calcular el tiempo esperado (o número de noches) que un telescopio debe invertir para caracterizar un objeto transitorio débil, como un cometa de órbita parabólica (Duffett-Smith y Zwart, Sección 62) o un evento de microlente gravitacional.

1.1.3. Extensión Analítica: Espacios Muestrales Continuos en Coordenadas Celestes

Aunque los ejemplos anteriores son discretos, es vital notar que la mayoría de las mediciones astronómicas generan espacios muestrales continuos. Por ejemplo, al calcular las coordenadas ecuatoriales (Ascensión Recta α y Declinación δ) de un planeta exterior como Júpiter (Duffett-Smith y Zwart, Sección 54), el resultado de una medición sujeta a error instrumental no es un punto exacto, sino un vector continuo.

Si definimos el experimento como *medir la posición aparente de un astro*, el espacio muestral es un subconjunto de $\mathbb{R}^2$:

$$S = \{(\alpha, \delta) \in \mathbb{R}^2 \mid 0 \leq \alpha < 24^h, -90^\circ \leq \delta \leq 90^\circ\}$$

En este escenario continuo, la probabilidad de obtener un resultado exacto (un evento simple) es estrictamente cero. Los eventos de interés (como que el planeta esté en una región específica de la eclíptica para estudiar sus perturbaciones orbitales) se definen como regiones o áreas dentro de este espacio muestral continuo, requiriendo el uso de funciones de densidad de probabilidad y cálculo integral para su evaluación.

1.2. Eventos

Un evento es cualquier recopilación o subconjunto de resultados contenidos en el espacio muestral S (Devore, Capítulo 2, Sección 2.1).

Si un evento consiste en exactamente un resultado, se denomina *evento simple*; si consiste en más de un resultado, se denomina *evento compuesto*. Dado que un evento es simplemente un conjunto, las operaciones y resultados de la teoría elemental de conjuntos se utilizan para estudiar las relaciones entre ellos. Las operaciones primarias incluyen:

- **Unión** ($A \cup B$): El evento que consiste en todos los resultados que están en A , en B , o en ambos.
- **Intersección** ($A \cap B$): El evento que consiste en todos los resultados que están tanto en A como en B .
- **Complemento** (A'): El conjunto de todos los resultados en S que no están en A .
- **Eventos mutuamente excluyentes (disjuntos)**: Dos eventos son mutuamente excluyentes si no tienen resultados en común (es decir, $A \cap B = \emptyset$).

La correcta formulación de eventos permite traducir preguntas físicas o astronómicas complejas a lenguaje matemático riguroso, sentando las bases para el cálculo de probabilidades y la inferencia estadística.

1.2.1. Ejemplo 1: Clasificación Taxonómica de Asteroides

Un sondeo astronómico detecta dos asteroides cercanos a la Tierra. Basado en sus espectros de reflexión, cada asteroide se clasifica en uno de tres complejos taxonómicos principales:

- C : Complejo-C (Carbonáceos).
- S : Complejo-S (Silicáceos).
- X : Complejo-X (Metálicos).

El experimento consiste en registrar la clasificación del par de asteroides. El espacio muestral S está compuesto por $3^2 = 9$ eventos simples, representados como pares ordenados:

$$S = \{CC, CS, CX, SC, SS, SX, XC, XS, XX\}$$

A partir de este espacio muestral, podemos definir eventos compuestos que representen escenarios de interés para la ciencia planetaria y la defensa planetaria:

Sea A el evento en el que *ambos asteroides pertenecen al mismo complejo taxonómico*:

$$A = \{CC, SS, XX\}$$

Sea B el evento en el que *al menos uno de los asteroides es de tipo S (silicáceo)*:

$$B = \{CS, SC, SS, SX, XS\}$$

Podemos analizar las operaciones entre estos eventos para extraer conclusiones analíticas:

- **Intersección** ($A \cap B$): El evento en que ambos son del mismo tipo *y* al menos uno es tipo S. Esto solo ocurre si ambos son silicáceos.

$$A \cap B = \{SS\}$$

- **Unión** ($A \cup B$): El evento en que ambos son del mismo tipo *o* al menos uno es tipo S.

$$A \cup B = \{CC, CS, SC, SS, SX, XS, XX\}$$

- **Complemento** (A'): El evento en que los asteroides *no* son del mismo tipo (población taxonómicamente diversa).

$$A' = \{CS, CX, SC, SX, XC, XS\}$$

Finalmente, para ilustrar la exclusión mutua (Devore, Sección 2.1), definamos el evento D como *exactamente un asteroide es de tipo X y el otro es de tipo C*:

$$D = \{CX, XC\}$$

Los eventos A y D son *mutuamente excluyentes* (o disjuntos), ya que es lógicamente imposible que ambos asteroides sean del mismo tipo (A) y que al mismo tiempo sean de tipos diferentes (D). Analíticamente, $A \cap D = \emptyset$.

1.2.2. Ejemplo 2: Modelado Gravitacional en Operaciones de Proximidad

Los espacios muestrales y sus eventos también son cruciales en la ingeniería aeroespacial y la navegación de naves autónomas (Capítulo 4, *Modern Spacecraft Guidance, Navigation, and Control*, sección Irregular solar system bodies").

Cuando una nave espacial (chaser) se aproxima a un asteroide, el campo gravitacional es altamente irregular. Los modelos de Armónicos Esféricos (SHE) son computacionalmente rápidos pero solo son válidos fuera de la 'esfera de Brillouin' (la región que engloba todo el cuerpo). Para operar dentro de esta esfera, el sistema de navegación debe cambiar a un modelo de Mascones o Poliedros, el cual es más preciso pero computacionalmente costoso.

Definamos el experimento como: *La nave ejecuta 3 pasadas de aproximación consecutivas. En cada pasada, el sistema de navegación a bordo selecciona el modelo gravitacional a utilizar para el filtro de navegación.* Los resultados básicos para cada pasada son:

- H : Se utiliza el modelo de Armónicos Esféricos (SHE).
- M : Se utiliza el modelo de Mascones.

El espacio muestral S está compuesto por $2^3 = 8$ eventos simples:

$$S = \{HHH, HHM, HMH, MHH, HMM, MHM, MMH, MMM\}$$

Definamos los siguientes eventos compuestos para evaluar la estrategia de navegación:

Sea A el evento en el que *el modelo SHE se utiliza exactamente en dos de las tres pasadas*:

$$A = \{HHM, HMH, MHH\}$$

Sea B el evento en el que *el modelo de Mascones se utiliza en la primera pasada* (lo que indicaría que la nave penetró la esfera de Brillouin de manera temprana o agresiva):

$$B = \{MHH, MHM, MMH, MMM\}$$

La intersección de estos eventos, $A \cap B$, representa el escenario donde la nave usó Mascones en la primera pasada, pero logró revertir al modelo SHE (más ligero computacionalmente) en las dos siguientes (probablemente porque la trayectoria de aproximación la alejó temporalmente de la esfera de Brillouin):

$$A \cap B = \{MHH\}$$

Por último, consideremos el evento C definido como *el modelo de Mascones nunca es utilizado en las tres pasadas* (la nave se mantuvo estrictamente fuera de la esfera de Brillouin):

$$C = \{HHH\}$$

Los eventos B y C son *mutuamente excluyentes*. Físicamente, la nave no puede haber utilizado el modelo de Mascones en la primera pasada (B) y al mismo tiempo no haberlo utilizado nunca (C). Por lo tanto, $B \cap C = \emptyset$. La modelación de estos eventos como subconjuntos del espacio muestral dota a los ingenieros de GNC de un marco analítico riguroso para cuantificar el riesgo de saturación del ordenador de a bordo (OBC). A través de esta representación, es posible estimar la probabilidad de que la exigencia computacional —derivada de la conmutación entre los distintos modelos de navegación— rebase los umbrales de seguridad del hardware durante las críticas fases de operaciones de proximidad, vinculando directamente esta métrica de riesgo con la geometría de la trayectoria relativa planificada.

1.3. Probabilidad

La probabilidad es la rama de las matemáticas que proporciona un marco riguroso para cuantificar la incertidumbre y el azar en cualquier situación donde pueden ocurrir diversos sucesos. En el contexto de la astronomía y la exploración espacial, la probabilidad es una herramienta fundamental para modelar desde la distribución de materia en el universo hasta la confiabilidad de los sistemas de navegación de una sonda interplanetaria.

La probabilidad asigna a cada evento A un número $P(A)$ que representa una medida precisa de la oportunidad de que A ocurra (Devore, Capítulo 2, Sección 2.2). En la práctica astronómica, esta asignación puede basarse en la interpretación frecuentista (por ejemplo, la tasa de ocurrencia de supernovas en un volumen dado, o la fracción de estrellas que poseen planetas) o en la interpretación geométrica/combinatoria (como la probabilidad de que un exoplaneta esté alineado con nuestra línea de visión).

1.4. Axiomas de probabilidad

Para garantizar que las asignaciones de probabilidad sean matemáticamente consistentes y respeten las nociones intuitivas de la frecuencia y la certeza, la teoría moderna se fundamenta en los Axiomas de Kolmogorov. Estos axiomas establecen las reglas inquebrantables que gobiernan la medida de probabilidad P sobre un espacio muestral S (Devore, Capítulo 2, Sección 2.2):

- **AXIOMA 1:** Para cualquier evento A , $P(A) \geq 0$. (La probabilidad no puede ser negativa).
- **AXIOMA 2:** $P(S) = 1$. (La probabilidad del espacio muestral completo, es decir, de que ocurra algún resultado, es la certeza absoluta).
- **AXIOMA 3:** Si $A_1, A_2, A_3, \dots$ es un conjunto (finito o infinito) de eventos mutuamente excluyentes (disjuntos), entonces la probabilidad de su unión es la suma de sus probabilidades individuales:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

A partir de estos tres axiomas, se pueden derivar rigurosamente todas las demás propiedades y teoremas de la probabilidad, como la probabilidad del complemento o la probabilidad de la unión de eventos no disjuntos.

1.4.1. Propiedades Fundamentales Derivadas de los Axiomas

A partir de los tres axiomas de Kolmogorov, se pueden demostrar rigurosamente las siguientes propiedades (Devore, Capítulo 2, Sección 2.2). Sea S el espacio muestral y $A, B, C \subseteq S$ eventos cualesquiera:

1. **Probabilidad del evento nulo:**

$$P(\emptyset) = 0$$

2. **Cota superior de la probabilidad:** Para todo evento A ,

$$P(A) \leq 1$$

3. **Regla del complemento:**

$$P(A') = 1 - P(A)$$

4. **Monotonicidad:** Si $A \subseteq B$, entonces

$$P(A) \leq P(B)$$

5. **Regla de adición para dos eventos:**

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

6. **Regla de adición para tres eventos (Principio de Inclusión-Exclusión):**

$$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) - P(B \cap C) + P(A \cap B \cap C)$$

7. **Desigualdad de Boole (cota de la unión):** Para cualesquiera eventos $A_1, A_2, \dots, A_n$,

$$P\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n P(A_i)$$

8. **Leyes de De Morgan aplicadas a la probabilidad:**

$$P((A \cup B)') = P(A' \cap B')$$

$$P((A \cap B)') = P(A' \cup B')$$

1.4.2. Ejemplo 1: Demostración de la Probabilidad del Evento Nulo

Consideremos una sucesión infinita de eventos donde cada evento es el conjunto vacío:

$$A_1 = \emptyset, \quad A_2 = \emptyset, \quad A_3 = \emptyset, \quad \dots$$

Primero, notamos que estos eventos son mutuamente excluyentes, ya que la intersección de cualquier par de ellos es el conjunto vacío ($A_i \cap A_j = \emptyset \cap \emptyset = \emptyset$).

Segundo, la unión de todos estos eventos es simplemente el conjunto vacío:

$$\bigcup_{i=1}^{\infty} A_i = \emptyset$$

Aplicando el **Axioma 3** (aditividad para eventos mutuamente excluyentes), tenemos:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

Sustituyendo la unión y los eventos individuales por $\emptyset$, la ecuación se convierte en:

$$P(\emptyset) = \sum_{i=1}^{\infty} P(\emptyset) = P(\emptyset) + P(\emptyset) + P(\emptyset) + \dots$$

Por el **Axioma 1**, sabemos que $P(\emptyset) \geq 0$, y por el **Axioma 2**, sabemos que cualquier probabilidad debe ser un número finito (acotado superiormente por 1). La única forma en que una suma infinita de un mismo valor no negativo converge a un número finito es si dicho valor es estrictamente cero. Si $P(\emptyset)$ fuera mayor que 0, la suma divergiría al infinito, violando la definición de probabilidad.

Por lo tanto, concluimos que:

$$P(\emptyset) = 0$$

1.4.3. Ejemplo 2: Clasificación de Señales en Astronomía de Ondas Gravitacionales

En el campo emergente de la astronomía de ondas gravitacionales, los interferómetros como LIGO y Virgo detectan continuamente candidatos a señales transitorias. Históricamente, tras años de ciclos de observación, la colaboración científica ha catalogado la naturaleza de estos eventos. Definamos el espacio muestral S para la clasificación de un nuevo candidato a señal como:

- A : Fusión de agujeros negros binarios (BBH).
- B : Fusión de estrellas de neutrones binarias (BNS).
- C : Artefacto instrumental o ruido sísmico (falso positivo).

Estos tres eventos son mutuamente excluyentes y exhaustivos. Basándonos en la frecuencia relativa histórica de los catálogos de eventos (como los catálogos GWTC de la colaboración LIGO-Virgo-KAGRA), podemos asignar las siguientes probabilidades a priori para un candidato genérico no validado:

$$P(A) = 0,78, \quad P(B) = 0,07, \quad P(C) = 0,15$$

Supongamos que el sistema de alerta temprana dispara una notificación para un nuevo evento candidato. Nos interesa calcular la probabilidad de que esta señal corresponda a una coalescencia binaria compacta genuina de origen astrofísico. Definamos este evento compuesto como $E = A \cup B$.

Dado que los eventos A y B son mutuamente excluyentes (un evento no puede ser simultáneamente una fusión de agujeros negros y de estrellas de neutrones), la probabilidad de su unión es simplemente la suma de sus probabilidades individuales:

$$P(E) = P(A) + P(B) = 0,78 + 0,07 = 0,85$$

Alternativamente, este mismo resultado puede obtenerse de manera más directa utilizando la regla del complemento. El evento de que la señal sea una coalescencia genuina (E) es exactamente el complemento del evento de que sea un artefacto instrumental (C). Por lo tanto:

$$P(E) = 1 - P(C) = 1 - 0,15 = 0,85$$

Estas asignaciones probabilísticas son críticas para los algoritmos de filtrado que procesan las alertas en tiempo real, priorizando aquellas candidatas con una probabilidad de ser astrofísicas ($P(E)$) lo suficientemente alta como para activar telescopios de seguimiento electromagnético en todo el mundo.

1.4.4. Ejemplo 3: Análisis de Modos de Falla en un Rover de Exploración

Los axiomas de probabilidad son la base para evaluar la confiabilidad de sistemas críticos en la ingeniería aeroespacial. Tomemos como referencia los análisis de modos de falla y efectos críticos (FMECA) utilizados en la operación de rovers en superficies planetarias (*Modern Spacecraft Guidance, Navigation, and Control*, y *Planetary Geology*).

Considere el mecanismo de perforación y muestreo de un rover marciano. Durante un ciclo operativo de 1 hora, el sistema puede experimentar uno de tres modos de falla críticos. Definimos los eventos mutuamente excluyentes (ya que el diagnóstico del sistema identifica la causa raíz primaria de manera única):

- A : Atasco mecánico del motor del taladro.
- B : Sobrecarga térmica en la electrónica de control.
- C : Pérdida de sincronización en el bus de comunicación.

Basado en datos históricos de pruebas en cámaras de vacío térmico, se han asignado las siguientes probabilidades para un ciclo operativo dado:

$$P(A) = 0,04, \quad P(B) = 0,03, \quad P(C) = 0,01$$

Sea F el evento compuesto definido como *que ocurra cualquier tipo de falla durante el ciclo*. Matemáticamente, F es la unión de los tres eventos:

$$F = A \cup B \cup C$$

Dado que A , B y C son mutuamente excluyentes, podemos aplicar directamente el **Axioma 3** para calcular la probabilidad de falla total del sistema:

$$P(F) = P(A) + P(B) + P(C) = 0,04 + 0,03 + 0,01 = 0,08$$

El evento de interés para la misión es que el rover complete el ciclo de perforación *sin fallas*, lo cual corresponde al evento complemento F' . Utilizando la propiedad derivada de los Axiomas 2 y 3 (donde $P(F) + P(F') = 1$), calculamos la probabilidad de éxito:

$$P(F') = 1 - P(F) = 1 - 0,08 = 0,92$$

Este cálculo indica que el rover tiene un 92 % de confiabilidad por ciclo. Los ingenieros de vuelo utilizan este valor para propagar la incertidumbre a través de la planificación de la misión, determinando cuántos ciclos redundantes deben programarse para asegurar que la probabilidad acumulada de obtener al menos una muestra geológica supere el umbral requerido para los objetivos científicos de la misión.

Clase 2

2.1. Probabilidad condicional

En la práctica astronómica y astrofísica, rara vez se evalúan los eventos de manera aislada. Frecuentemente, se dispone de información parcial o de observaciones preliminares que restringen el universo de posibilidades. La probabilidad condicional es la herramienta analítica que permite cuantificar cómo cambia la probabilidad de un evento cuando se tiene la certeza de que otro evento relacionado ya ha ocurrido.

Si A y B son dos eventos tales que $P(B) > 0$, la probabilidad condicional de A dado que B ha ocurrido se define como (Devore, Capítulo 2, Sección 2.4):

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Conceptualmente, esta definición refleja un cambio fundamental en el espacio muestral. El nuevo espacio muestral ya no es el conjunto original S , sino que se reduce exclusivamente al evento B (el evento condicionante). La probabilidad $P(A|B)$ mide la fracción de B que también pertenece a A .

A partir de esta definición, se deriva una de las herramientas más poderosas para el modelado de procesos observacionales secuenciales: la **regla de multiplicación**. Si reordenamos la ecuación anterior, obtenemos la probabilidad de la intersección de dos eventos:

$$P(A \cap B) = P(A|B) \cdot P(B)$$

Esta regla es esencial para calcular la probabilidad de que ocurran múltiples etapas en un proceso de observación o navegación, donde el éxito de una etapa depende condicionalmente del resultado de la etapa previa.

2.1.1. Ejemplo 1: Caracterización de Asteroides mediante Albedo Radar

Un radiotelescopio realiza un sondeo de 200 Asteroides Cercanos a la Tierra (NEAs) para estudiar su composición superficial.

Definimos los siguientes eventos para un asteroide seleccionado al azar de esta muestra:

- M : El asteroide es de tipo espectral M (metálico, compuesto principalmente de hierro y níquel).
- R : El asteroide presenta una alta reflectividad (albedo) en las observaciones de radar.

Tras procesar los datos del sondeo, se obtienen las siguientes frecuencias conjuntas:

- 40 asteroides son de tipo M: $P(M) = 40/200 = 0,20$.
- 60 asteroides tienen alta reflectividad radar: $P(R) = 60/200 = 0,30$.
- 30 asteroides son de tipo M *y* además tienen alta reflectividad radar: $P(M \cap R) = 30/200 = 0,15$.

Pregunta 1: Si el sistema de radar detecta que un asteroide tiene alta reflectividad (R), ¿cuál es la probabilidad de que sea metálico (M)?

$$P(M|R) = \frac{P(M \cap R)}{P(R)} = \frac{0,15}{0,30} = 0,50$$

Esto significa que, dado que el asteroide brilla intensamente en el radar, hay un 50 % de probabilidad de que su composición sea metálica. El espacio muestral se ha reducido a los 60 asteroides con alta reflectividad.

Pregunta 2: Si un asteroide ya ha sido clasificado espectroscópicamente como de tipo M (M), ¿cuál es la probabilidad de que presente alta reflectividad radar (R)?

$$P(R|M) = \frac{P(M \cap R)}{P(M)} = \frac{0,15}{0,20} = 0,75$$

Aquí, el espacio muestral se reduce a los 40 asteroides metálicos. La probabilidad es notablemente distinta (75 %). Este ejemplo resalta una de las advertencias más importantes en la inferencia estadística (Devore, Sección 2.4): la probabilidad de que un asteroide sea metálico dado su radar ($P(M|R)$) no es la misma que la probabilidad de que tenga alto radar dado que es metálico ($P(R|M)$).

2.1.2. Ejemplo 2: Regla de Multiplicación en Pipelines de Transitorios Astrofísicos

La regla de multiplicación es indispensable para modelar cadenas de eventos dependientes. En la astronomía de grandes sondeos temporales (como los realizados por el Observatorio Vera C. Rubin), los "pipelines" de reducción de datos deben filtrar miles de alertas nocturnas. Analicemos la detección de transitorios.

Definimos el experimento como el procesamiento de una alerta nocturna por parte del pipeline automatizado.

- V : El evento astrofísico subyacente es *verdadero* y genuino (ej. una kilonova o supernova real).
- V' : El evento es un *artefacto* instrumental o ruido cósmico (falso astrofísico).
- F : El pipeline de software etiqueta la alerta como 'Candidato de Alta Prioridad' (Flag).

Basado en el rendimiento histórico del telescopio y la naturaleza de los falsos positivos, sabemos que:

- La probabilidad a priori de que una alerta aleatoria sea un evento genuino es baja: $P(V) = 0,10$. Por lo tanto, $P(V') = 1 - 0,10 = 0,90$.

- Si el evento es genuino (V), el pipeline es muy eficiente detectándolo: $P(F|V) = 0,90$.
- Si el evento es un artefacto (V'), el pipeline aún puede ser engañado y etiquetarlo erróneamente como candidato (tasa de falsos positivos): $P(F|V') = 0,15$.

Escenario 1: Detección Exitosa (Verdadero Positivo) ¿Cuál es la probabilidad de que una alerta sea un evento genuino *y* que el pipeline la etiquete correctamente como candidato?

$$P(V \cap F) = P(F|V) \cdot P(V) = 0,90 \cdot 0,10 = 0,09$$

Esto indica que el 9 % de todas las alertas procesadas serán descubrimientos científicos reales y confirmados por el software.

Escenario 2: Falso Positivo ¿Cuál es la probabilidad de que una alerta sea un artefacto *y* que el pipeline la etiquete erróneamente como candidato?

$$P(V' \cap F) = P(F|V') \cdot P(V') = 0,15 \cdot 0,90 = 0,135$$

Esto revela que el 13.5 % de todas las alertas procesadas serán falsos positivos que consumirán tiempo valioso de seguimiento telescópico.

Este análisis condicional y multiplicativo permite a los arquitectos de misiones evaluar el 'costo' de falsas alarmas frente a la tasa de descubrimientos reales, justificando analíticamente la necesidad de introducir filtros secundarios (como la verificación de movimiento propio o el análisis de la forma del punto, PSF) antes de enviar alertas a la comunidad astronómica global.

2.2. Independencia de eventos

Dos eventos A y B se consideran independientes si la ocurrencia de uno de ellos no proporciona ninguna información sobre la ocurrencia del otro (Devore, Capítulo 2, Sección 2.5).

Analíticamente, esta noción se formaliza a través de la probabilidad condicional. Si A y B son independientes, entonces la probabilidad de A dado que B ha ocurrido es simplemente la probabilidad marginal de A :

$$P(A|B) = P(A)$$

Sustituyendo la definición de probabilidad condicional $P(A|B) = \frac{P(A \cap B)}{P(B)}$ en la ecuación anterior y reordenando, obtenemos la **regla de multiplicación para eventos independientes**, que es la definición operativa más utilizada en la práctica:

$$P(A \cap B) = P(A) \cdot P(B)$$

Es crucial destacar una distinción analítica fundamental (Devore, Sección 2.5): la independencia y la exclusión mutua son conceptos radicalmente distintos. Si dos eventos son mutuamente excluyentes ($A \cap B = \emptyset$), saber que A ocurrió garantiza que B no ocurrió ($P(B|A) = 0$), lo cual implica una dependencia extrema. Por el contrario, si son independientes, la ocurrencia de A no altera en absoluto la probabilidad de B .

2.2.1. Ejemplo 1: Confiabilidad de Subsistemas Críticos en una Sonda Interplanetaria

Modern Spacecraft Guidance, Navigation, and Control (Capítulo 4, "Fault Detection and Isolation").

Considere una sonda espacial que viaja hacia los planetas exteriores. Para mantener su actitud y orientación, la nave depende de dos subsistemas físicamente separados y eléctricamente aislados:

- A : El evento en el que el rastreador de estrellas principal (Star Tracker) sufre un bloqueo temporal por radiación cósmica.
- B : El evento en el que la unidad de medición inercial (IMU) experimenta una deriva térmica fuera de los límites de tolerancia.

Basado en los datos de pruebas en tierra y modelos de entorno espacial, se han estimado las siguientes probabilidades marginales para una ventana de misión de 30 días:

$$P(A) = 0,04$$

$$P(B) = 0,02$$

Dado que el rastreador de estrellas (óptico) y la IMU (mecánico-inercial) operan bajo principios físicos distintos y están blindados contra fallas en cascada, el modelo de confiabilidad asume que estos eventos son *mutuamente independientes*.

Podemos calcular la probabilidad de que la sonda experimente una pérdida total de referencia de actitud (el evento $A \cap B$, donde ambos sensores fallan simultáneamente) aplicando la regla de multiplicación para eventos independientes:

$$P(A \cap B) = P(A) \cdot P(B) = 0,04 \cdot 0,02 = 0,0008$$

Si hubiéramos asumido erróneamente que los eventos eran dependientes (por ejemplo, si una tormenta de radiación afectara a ambos por igual), la probabilidad de falla catastrófica sería mucho mayor. La independencia analítica permite a los ingenieros de vuelo demostrar que la probabilidad de pérdida de control (0,08 %) cumple con los estrictos requisitos de riesgo de la misión. Además, se puede verificar que $P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{0,0008}{0,02} = 0,04 = P(A)$, confirmando que la falla de la IMU no altera la probabilidad de fallo del rastreador de estrellas.

2.2.2. Ejemplo 2: Discriminación de Señales en la Red de Interferómetros de Ondas Gravitacionales

En la astronomía de multi-mensajeros y la astrofísica de altas energías, la independencia es la piedra angular para distinguir señales astrofísicas genuinas de ruido instrumental local. Tomemos como referencia los principios de detección de señales y análisis de ruido en redes de observatorios (*Astronomical Measurement*, Capítulo 6, "Signal-to-Noise and Detection").

Considere la red de interferómetros láser (como LIGO), compuesta por detectores separados geográficamente miles de kilómetros. Definimos los siguientes eventos para un intervalo de tiempo de 1 milisegundo:

- N_1 : El detector 1 (ej. Hanford) registra un transitorio de ruido sísmico/instrumental que supera el umbral de activación.
- N_2 : El detector 2 (ej. Livingston) registra un transitorio de ruido que supera el umbral.
- W : El paso de una onda gravitacional real proveniente de una fusión de agujeros negros.

Las fuentes de ruido local (microsismos, ruido térmico en los espejos, fluctuaciones láser) en el detector 1 son físicamente independientes de las del detector 2. Por lo tanto, los eventos de ruido N_1 y N_2 son *independientes*. Si la tasa de falsas alarmas (ruido superando el umbral) en cada detector es $P(N_1) = 10^{-3}$ y $P(N_2) = 10^{-3}$, la probabilidad de que *ambos* detectores registren un falso positivo simultáneamente por puro azar es:

$$P(N_1 \cap N_2) = P(N_1) \cdot P(N_2) = 10^{-3} \cdot 10^{-3} = 10^{-6}$$

Esta drástica reducción en la probabilidad de error (de 10^{-3} a 10^{-6}) es la base de la *coincidencia de red*.

Sin embargo, analicemos qué ocurre si el evento W (una onda gravitacional real) ocurre. Una onda gravitacional real afecta el espacio-tiempo local en ambos detectores casi simultáneamente. En este escenario, los eventos de 'detección de un umbral cruzado' en el detector 1 y el detector 2 **ya no son independientes**. La ocurrencia de la señal real condiciona fuertemente a ambos detectores:

$$P(\text{Umbral}_1 \cap \text{Umbral}_2 | W) \neq P(\text{Umbral}_1 | W) \cdot P(\text{Umbral}_2 | W)$$

De hecho, si W ocurre, la probabilidad de que ambos detectores se activen es cercana a 1 (dependiendo de la polarización y ubicación de la fuente), mientras que el producto de sus probabilidades marginales condicionadas a W no reflejaría esta correlación física. Este contraste analítico entre la independencia del ruido local ($N_1 \perp N_2$) y la dependencia inducida por una señal astrofísica común (W) es el mecanismo estadístico fundamental que permite a los astrónomos confirmar el descubrimiento de nuevos fenómenos cósmicos, filtrando el ruido instrumental aleatorio de las verdaderas perturbaciones del universo.

2.3. Teorema de Bayes

El Teorema de Bayes constituye la piedra angular del razonamiento estadístico inverso. Mientras que la probabilidad condicional tradicional nos permite calcular la probabilidad de una observación (efecto) dado un estado físico conocido (causa), el Teorema de Bayes invierte esta lógica: nos permite actualizar la probabilidad de una causa hipotética a la luz de una nueva evidencia observacional.

Si $A_1, A_2, \dots, A_k$ son eventos mutuamente excluyentes y exhaustivos (una partición del espacio muestral S), y B es cualquier evento con $P(B) > 0$, la probabilidad posterior de A_i dado B se calcula mediante (Devore, Capítulo 2, Sección 2.4):

$$P(A_i | B) = \frac{P(B | A_i) P(A_i)}{\sum_{j=1}^k P(B | A_j) P(A_j)}$$

En esta formulación analítica, $P(A_i)$ se denomina *probabilidad a priori*, representando nuestro conocimiento o creencia sobre el estado del sistema antes de realizar la observación B . El término $P(B|A_i)$ es la *verosimilitud* (likelihood), que cuantifica la probabilidad de observar la evidencia B asumiendo que la hipótesis A_i es verdadera. El denominador, calculado mediante la Ley de Probabilidad Total, actúa como una constante de normalización. El resultado, $P(A_i|B)$, es la *probabilidad a posteriori*.

En la astronomía moderna, este marco es fundamental. Como se discute en *Astronomical Measurement* (Apéndice A.12.1, *Prior and Posterior Probability Distributions*), el enfoque bayesiano permite a los astrofísicos combinar conocimientos teóricos previos (como modelos de formación planetaria) con datos observacionales ruidosos (como fotones detectados en un CCD) para refinar rigurosamente los parámetros del universo.

2.3.1. Ejemplo 1: Demostración del Teorema de Actualización Secuencial

En la astronomía observacional y la exploración espacial, los datos rara vez llegan en un solo lote; las observaciones son secuenciales. Un telescopio toma una imagen, luego otra, y cada nueva medición debería refinar nuestro conocimiento del sistema. El Teorema de Bayes posee una propiedad matemática profunda y elegante que justifica este proceso: la *Actualización Secuencial*.

A continuación, demostraremos un teorema fundamental que establece que actualizar una hipótesis H con un primer conjunto de datos D_1 y utilizar el resultado como la nueva probabilidad a priori para un segundo conjunto de datos D_2 , es matemáticamente idéntico a actualizar la hipótesis original con ambos conjuntos de datos $D_1 \cap D_2$ simultáneamente.

Teorema de Actualización Secuencial: Sean H una hipótesis, y D_1, D_2 dos conjuntos de datos observacionales. La probabilidad posterior de H dado ambos conjuntos de datos satisface:

$$P(H|D_1 \cap D_2) = \frac{P(D_2|H \cap D_1)P(H|D_1)}{P(D_2|D_1)}$$

Demostración: La probabilidad de H dado que han ocurrido tanto D_1 como D_2 es:

$$P(H|D_1 \cap D_2) = \frac{P(H \cap D_1 \cap D_2)}{P(D_1 \cap D_2)}$$

Para el numerador, aplicamos la regla de multiplicación para la intersección de tres eventos. Podemos expandir $P(H \cap D_1 \cap D_2)$ condicionando secuencialmente:

$$P(H \cap D_1 \cap D_2) = P(D_2|H \cap D_1) \cdot P(H \cap D_1)$$

A su vez, el término $P(H \cap D_1)$ puede expandirse nuevamente usando la regla de multiplicación:

$$P(H \cap D_1) = P(H|D_1) \cdot P(D_1)$$

Sustituyendo esto en la expresión del numerador, obtenemos:

$$P(H \cap D_1 \cap D_2) = P(D_2|H \cap D_1) \cdot P(H|D_1) \cdot P(D_1)$$

Para el denominador, aplicamos la regla de multiplicación para la intersección de D_1 y D_2 :

$$P(D_1 \cap D_2) = P(D_2|D_1) \cdot P(D_1)$$

Ahora, sustituimos el numerador y el denominador expandidos en la ecuación original de la probabilidad condicional:

$$P(H|D_1 \cap D_2) = \frac{P(D_2|H \cap D_1) \cdot P(H|D_1) \cdot P(D_1)}{P(D_2|D_1) \cdot P(D_1)}$$

Dado que $P(D_1) > 0$ (asumiendo que la primera observación es posible), podemos cancelar $P(D_1)$ en el numerador y el denominador, lo que nos deja con el resultado deseado:

$$P(H|D_1 \cap D_2) = \frac{P(D_2|H \cap D_1)P(H|D_1)}{P(D_2|D_1)}$$

Análisis del resultado: Esta demostración revela que el término $P(H|D_1)$ actúa exactamente como la *nueva probabilidad a priori* para el segundo paso, y $P(D_2|H \cap D_1)$ actúa como la *nueva verosimilitud*. Esto garantiza que el orden en que procesamos las observaciones astronómicas (por ejemplo, medir la posición de un asteroide noche tras noche) no altera el resultado final, siempre que se aplique rigurosamente el Teorema de Bayes.

2.3.2. Ejemplo 2: Clasificación Mineralógica mediante Espectroscopia de Reflexión

Para ilustrar la actualización bayesiana en la ciencia planetaria, nos inspiramos en los principios de identificación mineralógica a través de firmas espectrales (*Planetary Geology*, Capítulo sobre *Spectroscopy and Mineralogy*).

Un rover marciano utiliza su espectrómetro de infrarrojo cercano para analizar un afloramiento rocoso. Basado en el contexto geológico de la cuenca de impacto, el equipo científico establece las siguientes probabilidades a priori para la composición de la roca:

- A_1 : La roca es basáltica (rica en piroxeno). $P(A_1) = 0,20$.
- A_2 : La roca es una condrita carbonácea (rica en arcillas). $P(A_2) = 0,60$.
- A_3 : La roca es metálica (hierro-níquel). $P(A_3) = 0,20$.

El espectrómetro detecta una profunda banda de absorción centrada en $1 \mu\text{m}$, una firma característica de los enlaces Fe-O en el piroxeno. Definimos este evento observacional como B . Conociendo las calibraciones instrumentales y las propiedades físicas de los minerales, establecemos las verosimilitudes:

- $P(B|A_1) = 0,90$ (El basalto casi siempre muestra esta banda).
- $P(B|A_2) = 0,10$ (Las condritas raramente la presentan).
- $P(B|A_3) = 0,05$ (Los metales no tienen bandas de absorción silicatadas).

Nos interesa calcular la probabilidad a posteriori de que la roca sea basáltica dado que se detectó la banda de 1 μm , es decir, $P(A_1|B)$. Primero, calculamos la probabilidad total de observar la banda (el denominador):

$$P(B) = P(B|A_1)P(A_1) + P(B|A_2)P(A_2) + P(B|A_3)P(A_3)$$

$$P(B) = (0,90)(0,20) + (0,10)(0,60) + (0,05)(0,20) = 0,18 + 0,06 + 0,01 = 0,25$$

Aplicando ahora el Teorema de Bayes:

$$P(A_1|B) = \frac{P(B|A_1)P(A_1)}{P(B)} = \frac{0,18}{0,25} = 0,72$$

Analíticamente, este resultado es revelador. Aunque la creencia a priori de encontrar basalto en esa zona era baja (20 %), la fuerte evidencia espectral (una verosimilitud del 90 %) actualiza nuestra certeza a un 72 %. Este es el poder del razonamiento bayesiano (*Astronomical Measurement*, Sección A.12.2): los datos observacionales pueden dominar y corregir drásticamente las suposiciones iniciales derivadas de modelos geológicos contextuales.

2.3.3. Ejemplo 3: Aislamiento de Fallas en el Sistema de Control de Actitud

El Teorema de Bayes también es vital en la ingeniería de sistemas autónomos para la toma de decisiones en tiempo real. Tomemos como referencia los algoritmos de Detección y Aislamiento de Fallas (FDI) en naves espaciales (*Modern Spacecraft Guidance, Navigation, And Control*, Capítulo sobre *Fault Detection and Isolation*).

Durante una maniobra de giro, el ordenador de vuelo detecta un pico de torque anómalo en la rueda de reacción principal (Evento B). El sistema debe diagnosticar la causa raíz para seleccionar el modo de contingencia adecuado. Las causas hipotéticas mutuamente excluyentes son:

- A_1 : Ruido transitorio en el sensor de efecto Hall (falsa alarma). $P(A_1) = 0,70$.
- A_2 : Impacto de micrometeorito en el panel solar adyacente, generando una vibración estructural. $P(A_2) = 0,20$.
- A_3 : Falla mecánica real en los rodamientos de la rueda. $P(A_3) = 0,10$.

Para discriminar entre estas causas, el sistema cruza la información con un sensor independiente: el rastreador de estrellas secundario. Si hay una vibración estructural real (A_2) o una falla mecánica (A_3), el rastreador de estrellas debería detectar un "jitter" (temblor) de alta frecuencia en la línea de visión. Definimos este evento corroborativo como C . Las verosimilitudes de detectar el jitter en el rastreador de estrellas son:

- $P(C|A_1) = 0,05$ (El ruido del sensor de la rueda no afecta al rastreador de estrellas).
- $P(C|A_2) = 0,85$ (La vibración estructural se propaga y es claramente visible en el rastreador).
- $P(C|A_3) = 0,40$ (La falla mecánica genera algo de vibración, pero menos acoplada a la estructura general).

El sistema de FDI necesita calcular la probabilidad a posteriori de que se trate de un impacto de micrometeorito (A_2) dado que *ambos* sensores reportaron la anomalía. Asumiendo independencia condicional de los sensores dado el estado de la nave, el evento observacional combinado es la intersección del pico de torque (B) y el jitter óptico (C). Para simplificar el modelo bayesiano directo sobre la causa, actualizamos las probabilidades usando la nueva evidencia C sobre las creencias a priori de las causas.

La probabilidad total de observar el jitter C es:

$$P(C) = P(C|A_1)P(A_1) + P(C|A_2)P(A_2) + P(C|A_3)P(A_3)$$

$$P(C) = (0,05)(0,70) + (0,85)(0,20) + (0,40)(0,10) = 0,035 + 0,170 + 0,040 = 0,245$$

Aplicando el Teorema de Bayes para encontrar $P(A_2|C)$:

$$P(A_2|C) = \frac{P(C|A_2)P(A_2)}{P(C)} = \frac{0,170}{0,245} \approx 0,694$$

Antes de la observación del rastreador de estrellas, la hipótesis más probable era un simple error de sensor (70 %), lo que habría llevado al software a ignorar la alerta. Sin embargo, la evidencia cruzada (C) invierte la situación: la probabilidad de un impacto de micrometeorito salta al 69.4 %. Con esta probabilidad a posteriori, el algoritmo de *Modern Spacecraft GN&C* puede justificar matemáticamente la transición a un modo de control de actitud que filtre las frecuencias de resonancia estructurales, evitando así que el sistema de control entre en inestabilidad por realimentación positiva de la vibración.

2.3.4. Ejemplo 4: Clasificación Orbital de Cometas (Parabólico vs. Hiperbólico)

Practical Astronomy with your Calculator (Duffett-Smith y Zwart, Sección 61).

Cuando se descubre un nuevo cometa, determinar su excentricidad orbital (e) es crucial para entender su origen. Si $e = 1$, la órbita es parabólica (el cometa está gravitacionalmente ligado al sistema solar o en el límite de escape). Si $e > 1$, la órbita es hiperbólica, lo que indicaría un objeto interestelar (como 'Oumuamua o Borisov) que solo está de paso.

Sin embargo, las mediciones astrométricas (Ascensión Recta y Declinación) tienen errores inherentes. Definamos el evento M como: *la excentricidad medida es $\hat{e} \geq 1,0$* .

Tenemos dos hipótesis mutuamente excluyentes sobre la verdadera naturaleza del cometa:

- H_P : El cometa tiene una órbita verdaderamente parabólica ($e = 1$).
- H_H : El cometa tiene una órbita verdaderamente hiperbólica ($e > 1$).

Basado en el catálogo histórico de cometas, la inmensa mayoría de los cometas de período largo provienen de la nube de Oort y tienen órbitas parabólicas. Por lo tanto, establecemos las siguientes probabilidades a priori:

$$P(H_P) = 0,95$$

$$P(H_H) = 0,05$$

Conociendo la precisión típica de los telescopios terrestres y la propagación de errores en el cálculo de elementos orbitales (Duffett-Smith y Zwart, Sección 62), estimamos las siguientes verosimilitudes de obtener una medición $\hat{e} \geq 1,0$:

- $P(M|H_P) = 0,10$: Si el cometa es realmente parabólico, hay un 10 % de probabilidad de que el ruido observacional empuje la excentricidad medida a $\geq 1,0$ (falso positivo de hiperbolicidad).
- $P(M|H_H) = 0,90$: Si el cometa es realmente hiperbólico, hay un 90 % de probabilidad de que la medición lo refleje correctamente como $\geq 1,0$.

El pipeline de reducción de datos reporta que para el nuevo cometa C/202X, la excentricidad calculada es $\hat{e} = 1,03$. Es decir, el evento M ha ocurrido. Nos interesa calcular la probabilidad a posteriori de que sea un objeto interestelar, $P(H_H|M)$.

Primero, calculamos la probabilidad total de observar M (el denominador del Teorema de Bayes):

$$P(M) = P(M|H_P)P(H_P) + P(M|H_H)P(H_H)$$

$$P(M) = (0,10)(0,95) + (0,90)(0,05) = 0,095 + 0,045 = 0,140$$

Ahora, aplicamos el Teorema de Bayes para encontrar la probabilidad posterior:

$$P(H_H|M) = \frac{P(M|H_H)P(H_H)}{P(M)} = \frac{0,045}{0,140} \approx 0,3214$$

Conclusión: A pesar de que la medición directa sugiere una órbita hiperbólica ($\hat{e} = 1,03$), el Teorema de Bayes nos revela que la probabilidad real de que el cometa sea interestelar es de apenas un 32.14 %. La fuerte probabilidad a priori de que los cometas sean parabólicos (95 %), combinada con una tasa de falsos positivos del 10 % debido al error instrumental, hace que sea estadísticamente más probable (67.86 %) que el cometa sea en realidad parabólico y que la medición $\hat{e} \geq 1,0$ sea solo una fluctuación del ruido. Este ejemplo demuestra por qué en la astrometría moderna, nunca se debe confiar ciegamente en un parámetro orbital derivado sin un análisis bayesiano riguroso que contemple las tasas base y los errores de medición.

Clase 3

3.1. Conteos

En el desarrollo de la teoría de la probabilidad, antes de poder asignar valores numéricos a los eventos, es imperativo determinar el tamaño del espacio muestral, es decir, el número total de resultados posibles. Cuando los resultados de un experimento son numerosos, enumerarlos uno por uno se vuelve una tarea impracticable. Para resolver esto, la estadística se apoya en principios fundamentales de conteo.

El principio más elemental y poderoso es la **Regla del Producto** (Devore, Capítulo 2, Sección 2.3). Esta regla establece que si un proceso o experimento puede describirse como una sucesión de k etapas, donde la primera etapa tiene n_1 resultados posibles, la segunda tiene n_2 resultados (independientemente de lo que haya ocurrido en la primera), y así sucesivamente, entonces el número total de resultados en el espacio muestral S es el producto de las posibilidades de cada etapa:

$$N(S) = n_1 \times n_2 \times \cdots \times n_k$$

Complementariamente, la **Regla de la Suma** se utiliza cuando un evento puede descomponerse en categorías mutuamente excluyentes, sumando simplemente el número de resultados de cada categoría (Devore, Sección 2.3).

3.1.1. Ejemplo 1: Configuración de Carga Útil en una Sonda Espacial

Para ilustrar la Regla del Producto en un contexto de ingeniería espacial, nos inspiramos en la arquitectura modular de los subsistemas de naves no tripuladas (*Modern Spacecraft Guidance, Navigation, and Control*, Capítulo sobre *Spacecraft Subsystems and Payloads*).

Durante la fase de diseño preliminar de una misión a asteroides, el equipo de sistemas debe definir la configuración base del bus de la nave. El proceso de configuración se divide en tres etapas secuenciales e independientes, donde cada etapa representa la selección de un subsistema crítico:

- **Etap 1 (Propulsión):** Se debe elegir entre 3 tipos de sistemas de propulsión disponibles (Propulsión química bipropelente, Propulsión iónica de efecto Hall, Propulsión eléctrica de plasma).
- **Etap 2 (Navegación):** Se debe seleccionar el conjunto de sensores primarios entre 4 arquitecturas distintas (Solo rastreador de estrellas, Rastreador de estrellas + IMU, Navegación óptica relativa, Navegación por radio de espacio profundo).
- **Etap 3 (Comunicación):** Se debe elegir la banda de frecuencia para el enlace de telemetry entre 2 opciones (Banda X, Banda Ka).

El experimento consiste en definir una configuración única para la sonda. Aplicando la Regla del Producto (Devore, Sección 2.3), el número total de configuraciones posibles (el tamaño del espacio muestral S) es:

$$N(S) = 3 \times 4 \times 2 = 24$$

Desde una perspectiva analítica, este espacio muestral de 24 elementos define el universo de configuraciones que los ingenieros deben evaluar mediante simulaciones de Monte Carlo para garantizar que al menos una configuración satisfaga los requisitos de masa, potencia y ΔV de la misión. Si se quisiera calcular la probabilidad de seleccionar al azar una configuración que utilice propulsión iónica (asumiendo que todas las configuraciones son igualmente probables en un sorteo de diseño), el conteo preciso de $N(S)$ es el denominador indispensable para aplicar la definición clásica de probabilidad.

3.1.2. Ejemplo 2: Matriz de Observación Fotométrica en un Telescopio Robótico

En la astronomía observacional, la planificación de las tomas de datos implica la configuración de múltiples parámetros instrumentales. Tomemos como referencia los sistemas de adquisición de datos y la fotometría de precisión (*Practical Astronomy with your Calculator*, Sección sobre *Photometry and the UBVRI System*, y *Astronomical Measurement*, Capítulo sobre *Detectors and Instruments*).

Un telescopio robótico está programado para ejecutar una secuencia de observación de un cúmulo estelar. El pipeline de control del telescopio debe configurar el instrumento para cada exposición individual. La configuración de un "frame"(cuadro) de imagen se realiza en tres etapas secuenciales:

- **Etapla 1 (Filtro):** La rueda de filtros selecciona una banda espectral entre 5 opciones estándar del sistema Johnson-Cousins (U, B, V, R, I).
- **Etapla 2 (Tiempo de exposición):** El controlador de la cámara CCD establece el tiempo de integración entre 3 opciones predefinidas (Corto: 10s, Medio: 60s, Largo: 300s).
- **Etapla 3 (Modo de lectura):** Se elige la velocidad de lectura del CCD para equilibrar el ruido de lectura y el tiempo muerto entre 2 opciones (Modo Rápido, Modo Lento).

El experimento consiste en generar un tipo único de cuadro fotométrico. Utilizando la Regla del Producto, el número total de configuraciones de cuadro distintas que el telescopio puede producir es:

$$N(S) = 5 \times 3 \times 2 = 30$$

Este resultado analítico nos indica que el espacio muestral de posibles configuraciones de un solo cuadro está compuesto por 30 eventos simples. Por ejemplo, un resultado simple sería la tupla (V , Medio, Lento).

Si el telescopio toma una secuencia de 3 cuadros consecutivos para promediar y reducir el ruido cósmico, y cada cuadro se configura de manera independiente, la Regla del Producto se aplica

nuevamente a nivel de la secuencia. El número total de secuencias de 3 cuadros posibles sería $30 \times 30 \times 30 = 27,000$. Comprender la magnitud de estos espacios muestrales discretos es fundamental para los astrónomos al diseñar estrategias de observación (dithering) y para los estadísticos que modelan la probabilidad de que ciertos errores sistemáticos instrumentales (como el ruido de lectura en el modo rápido) se correlacionen con bandas espectrales específicas.

3.2. Permutaciones

En muchas situaciones experimentales, no solo nos interesa seleccionar un subconjunto de objetos o eventos de una población mayor, sino que el *orden* en el que estos elementos son seleccionados o dispuestos es fundamental para el resultado del experimento. Cuando el orden de los elementos importa, estamos tratando con permutaciones.

Una permutación es un subconjunto ordenado de tamaño k que se puede formar a partir de n individuos u objetos en un grupo (Devore, Capítulo 2, Sección 2.3). El número de permutaciones de tamaño k que se pueden formar con n objetos se denota como $P_{k,n}$.

Análiticamente, la fórmula para calcular el número de permutaciones se deriva directamente de la Regla del Producto. Para la primera posición hay n opciones, para la segunda hay $n - 1$ opciones (ya que un objeto ha sido utilizado y no hay reemplazo), y así sucesivamente hasta la k -ésima posición, donde quedan $n - k + 1$ opciones. Esto se expresa de manera compacta utilizando la notación factorial:

$$P_{k,n} = n(n-1)(n-2) \cdots (n-k+1) = \frac{n!}{(n-k)!}$$

La distinción analítica crucial entre permutaciones y combinaciones (que se verá en la siguiente sección) radica estrictamente en la relevancia del orden.

3.2.1. Ejemplo 1: Secuencia de Apuntamiento en un Telescopio Espacial

Para ilustrar la aplicación de las permutaciones en la planificación orbital, consideremos la programación de un telescopio espacial en órbita baja terrestre (LEO). El telescopio tiene una lista de 10 objetivos astrofísicos de alta prioridad (por ejemplo, exoplanetas específicos en tránsito). Sin embargo, debido a las estrictas restricciones de presupuesto térmico y a las ventanas de comunicación con la red de espacio profundo, el telescopio solo puede realizar observaciones consecutivas de 3 de estos 10 objetivos durante una órbita específica.

Definamos el experimento como: *Seleccionar y ordenar 3 objetivos de una lista de 10 para ser observados en secuencia.*

Es imperativo modelar esto como una permutación y no como una simple combinación. En la dinámica de naves espaciales (*Modern Spacecraft Guidance, Navigation, and Control*, Capítulo sobre *Attitude Control Systems*), el orden de apuntamiento (slew) altera drásticamente el perfil térmico de la nave. Observar el objetivo A, luego el B y finalmente el C requiere un gasto de

combustible y una disipación de calor completamente diferentes que observar C, luego B y luego A, debido a la inercia del telescopio y la exposición diferencial de sus radiadores al Sol.

Por lo tanto, calculamos el número total de secuencias de observación posibles (el tamaño del espacio muestral S) utilizando la fórmula de permutaciones con $n = 10$ y $k = 3$:

$$P_{3,10} = \frac{10!}{(10-3)!} = \frac{10!}{7!} = 10 \times 9 \times 8 = 720$$

Existen 720 secuencias ordenadas distintas. Si el planificador de la misión quisiera calcular la probabilidad de que una secuencia generada aleatoriamente cumpla con un perfil térmico específico (asumiendo que todas las permutaciones son igualmente probables en un sorteo ciego), el denominador de su modelo probabilístico sería rigurosamente 720. Ignorar el orden y usar combinaciones ($\binom{10}{3} = 120$) subestimaría el espacio muestral real y destruiría la validez física del modelo de probabilidad.

3.2.2. Ejemplo 2: Secuencia de Análisis en un Espectrómetro de Masas Planetario

En la ciencia planetaria, el análisis in situ de muestras geológicas requiere instrumentación de altísima precisión. Tomemos como referencia los procedimientos de los laboratorios de muestras en rovers marcianos, como el instrumento SAM (Sample Analysis at Mars) (*Planetary Geology*, Capítulo sobre *In Situ Instrumentation and Analytical Techniques*).

Un rover ha recolectado polvo y regolito de 7 ubicaciones geológicas distintas. El laboratorio a bordo debe procesar 4 de estas muestras en una secuencia de horneado dentro del espectrómetro de masas. Debido a la física del instrumento, el orden en que las muestras se introducen en la cámara de vacío es crítico: las muestras procesadas primero pueden dejar residuos de memoria" (gases adsorbidos en las paredes) que contaminan las lecturas de las muestras procesadas posteriormente.

Definimos el experimento como: *Seleccionar y ordenar 4 muestras geológicas de un total de 7 para la secuencia de análisis.*

Dado que la secuencia de horneado afecta los resultados científicos (la contaminación cruzada depende de qué muestra precede a cuál), el orden es una variable de estado fundamental. Aplicamos la fórmula de permutaciones (Devore, Sección 2.3) con $n = 7$ y $k = 4$:

$$P_{4,7} = \frac{7!}{(7-4)!} = \frac{7!}{3!} = 7 \times 6 \times 5 \times 4 = 840$$

El espacio muestral consta de 840 secuencias de análisis únicas. Desde una perspectiva de diseño de experimentos, el equipo científico debe evaluar estas 840 permutaciones para encontrar aquella que minimice el sesgo analítico (por ejemplo, colocando las muestras más 'prístinas' al final de la secuencia o intercalando muestras de limpieza). La modelación permutacional permite cuantificar la incertidumbre introducida por el orden de procesamiento y justificar analíticamente la secuencia óptima antes de comandar el instrumento en Marte.

3.3. Combinaciones

En muchas aplicaciones de la estadística y la probabilidad, el interés analítico no radica en el orden de los elementos seleccionados, sino únicamente en *cuáles* elementos conforman el subconjunto resultante. Cuando se seleccionan k objetos de un grupo de n objetos sin reemplazo y el orden de selección es irrelevante, el número de subconjuntos posibles se denomina combinaciones (Devore, Capítulo 2, Sección 2.3).

La fórmula para calcular el número de combinaciones de tamaño k que se pueden extraer de un conjunto de tamaño n se denota como $\binom{n}{k}$ y se expresa analíticamente mediante factoriales:

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

Es crucial establecer la distinción analítica entre permutaciones y combinaciones. Dado que cada combinación de k elementos puede ser ordenada internamente de $k!$ formas distintas, el número de combinaciones es siempre una fracción del número de permutaciones. La relación que las vincula es:

$$\binom{n}{k} = \frac{P_{k,n}}{k!}$$

3.3.1. Ejemplo 1: Selección de Sitios de Aterrizaje en Ciencia Planetaria

Para ilustrar el uso de combinaciones en la planificación de misiones, nos inspiramos en los criterios de selección de regiones de interés y sitios de aterrizaje discutidos en *Planetary Geology* (Capítulo sobre *Landing Site Selection and Geological Context*).

Durante la Fase 0/A de una misión de retorno de muestras marcianas, el equipo científico ha identificado un total de $n = 15$ sitios candidatos que poseen alto valor geológico (por ejemplo, lechos de antiguos lagos o depósitos de arcillas). Sin embargo, debido a las limitaciones estrictas de presupuesto, tiempo de computación y ventanas de lanzamiento, la ingeniería de sistemas solo puede realizar un estudio de factibilidad detallado para un subconjunto de exactamente $k = 4$ sitios.

Definimos el experimento como: *Seleccionar un grupo de 4 sitios de aterrizaje de los 15 candidatos disponibles.*

Dado que en esta etapa el objetivo es simplemente formar un *conjunto* de 4 sitios para ser evaluados en paralelo por los equipos de ingeniería, el orden en el que los sitios son nominados o extraídos de la lista original es completamente irrelevante. El resultado del experimento es la composición del grupo, no su secuencia. Por lo tanto, aplicamos la fórmula de combinaciones (Devore, Sección 2.3):

$$\binom{15}{4} = \frac{15!}{4!(15-4)!} = \frac{15!}{4! \cdot 11!} = \frac{15 \times 14 \times 13 \times 12}{4 \times 3 \times 2 \times 1} = \frac{32760}{24} = 1365$$

El espacio muestral S consta de 1365 configuraciones únicas de sitios.

Desde una perspectiva analítica, si hubiéramos cometido el error de modelar esto como una permutación (asumiendo que el orden de prioridad de los 4 sitios importa), habríamos calculado $P_{4,15} = 32760$ resultados. Esto habría sobreestimado el espacio muestral en un factor de $4! = 24$, introduciendo una asimetría inexistente en el problema físico y haciendo que cualquier cálculo de probabilidad clásica (como la probabilidad de que un sitio específico con una mineralogía particular sea incluido en el estudio) fuera matemáticamente erróneo. El uso correcto de combinaciones garantiza que la asignación de probabilidades a los eventos refleje fielmente la naturaleza del proceso de selección.

3.3.2. Ejemplo 2: Configuración de Sub-arrays en Radio Interferometría

En la astronomía observacional de altas resoluciones, la disposición geométrica de los telescopios define la calidad de la imagen final. Tomemos como referencia los principios de síntesis de apertura y diseño de arreglos en *Astronomical Measurement* (Capítulo sobre *Interferometry and Aperture Synthesis*).

Considere un observatorio de radio interferometría (análogo al VLA o ALMA) que cuenta con una configuración base de $n = 10$ antenas parabólicas distribuidas a lo largo de una pista en forma de "Y". Debido a una falla temporal en el sistema de criogenia de los receptores, 4 de las antenas han sido desconectadas de la red de correlación, dejando únicamente $k = 6$ antenas operativas para una campaña de observación crítica de un disco protoplanetario.

Definimos el experimento como: *Determinar la configuración del arreglo de observación seleccionando las 6 antenas que formarán la red activa.*

En la interferometría, la calidad de la imagen (el haz sintetizado y la cobertura del plano uv) depende exclusivamente de *cuáles* antenas están activas y de las distancias geométricas entre ellas (las líneas base). El orden temporal o la secuencia en la que el software de control 'activa' o 'selecciona' las antenas no altera en absoluto la respuesta física del interferómetro. Por lo tanto, el problema es estrictamente de combinaciones.

Calculamos el número total de configuraciones de sub-arrays posibles que el observatorio podría haber formado con 6 antenas de un total de 10:

$$\binom{10}{6} = \frac{10!}{6!(10-6)!} = \frac{10!}{6! \cdot 4!} = \frac{10 \times 9 \times 8 \times 7}{4 \times 3 \times 2 \times 1} = \frac{5040}{24} = 210$$

Existen 210 sub-arrays únicos posibles.

Este resultado es fundamental para los astrónomos que realizan simulaciones de rendimiento antes de la observación. Dado que cada una de las 210 combinaciones produce un patrón de interferencia (y por ende, artefactos de imagen o "sidelobes") ligeramente distinto, el equipo científico debe evaluar este espacio muestral de 210 elementos para determinar si la configuración específica de 6 antenas que quedó operativa es suficiente para cumplir con los requisitos de dinámica de contraste necesarios para detectar un exoplaneta en formación dentro del disco. Nuevamente, la correcta delimitación del espacio muestral mediante combinaciones (Devore, Sección 2.3) es el prerrequisito para cualquier inferencia estadística sobre la confiabilidad de los datos astronómicos obtenidos.

Clase 4

- 4.1. Variables aleatorias
- 4.2. Funciones de densidad de probabilidad
- 4.3. Densidad acumulativa de probabilidad
- 4.4. Valores esperados
- 4.5. Varianza

Clase 5

5.1. Funciones de distribución discreta: Binomial

Clase 6

6.1. Distribución de Poisson

6.2. Distribuciones continuas

6.3. Percentiles

6.4. Distribución normal

Clase 7

- 7.1. Funciones de varias variables
- 7.2. Distribuciones de probabilidad conjunta
- 7.3. Distribuciones marginales
- 7.4. Combinación de variables aleatorias

Clase 8

8.1. Valores esperados en varias variables

8.2. Funciones de correlación

8.3. Covarianza

8.4. Combinación de variables aleatorias

Clase 9

9.1. Teorema central del límite

9.2. Estadísticos

9.3. Distribución de estadísticos

9.4. Muestras

9.5. Estimación puntual: Método de momentos

Clase 10

10.1. Método de mínimos cuadrados

10.2. Maximum likelihood