

Universidad de Antioquia

Facultad de Ciencias Exactas y Naturales

Instituto de Física

# Astroestadística

Daniel Soto Villada

Estudiante del pregrado de astronomía

5 de julio de 2026

# Índice general

|                                                                                                             |           |
|-------------------------------------------------------------------------------------------------------------|-----------|
| <b>1. Clase 1</b>                                                                                           | <b>1</b>  |
| 1.1. Espacios Muestrales . . . . .                                                                          | 1         |
| 1.1.1. Ejemplo 1: Clasificación Morfológica de Galaxias . . . . .                                           | 1         |
| 1.1.2. Ejemplo 2: Espacio Muestral Infinito en el Seguimiento de Cometas . . . . .                          | 1         |
| 1.1.3. Extensión Analítica: Espacios Muestrales Continuos en Coordenadas Celestes . . . . .                 | 2         |
| 1.2. Eventos . . . . .                                                                                      | 3         |
| 1.2.1. Ejemplo 1: Clasificación Taxonómica de Asteroides . . . . .                                          | 3         |
| 1.2.2. Ejemplo 2: Modelado Gravitacional en Operaciones de Proximidad . . . . .                             | 4         |
| 1.3. Probabilidad . . . . .                                                                                 | 5         |
| 1.4. Axiomas de probabilidad . . . . .                                                                      | 6         |
| 1.4.1. Propiedades Fundamentales Derivadas de los Axiomas . . . . .                                         | 6         |
| 1.4.2. Ejemplo 1: Demostración de la Probabilidad del Evento Nulo . . . . .                                 | 7         |
| 1.4.3. Ejemplo 2: Clasificación de Señales en Astronomía de Ondas Gravitacionales . . . . .                 | 8         |
| 1.4.4. Ejemplo 3: Análisis de Modos de Falla en un Rover de Exploración . . . . .                           | 8         |
| <b>2. Clase 2</b>                                                                                           | <b>10</b> |
| 2.1. Probabilidad condicional . . . . .                                                                     | 10        |
| 2.1.1. Ejemplo 1: Caracterización de Asteroides mediante Albedo Radar . . . . .                             | 10        |
| 2.1.2. Ejemplo 2: Regla de Multiplicación en Pipelines de Transitorios Astrofísicos . . . . .               | 11        |
| 2.2. Independencia de eventos . . . . .                                                                     | 12        |
| 2.2.1. Ejemplo 1: Confiabilidad de Subsistemas Críticos en una Sonda Interplanetaria . . . . .              | 13        |
| 2.2.2. Ejemplo 2: Discriminación de Señales en la Red de Interferómetros de Ondas Gravitacionales . . . . . | 13        |
| 2.3. Teorema de Bayes . . . . .                                                                             | 14        |
| 2.3.1. Ejemplo 1: Demostración del Teorema de Actualización Secuencial . . . . .                            | 15        |
| 2.3.2. Ejemplo 2: Clasificación Mineralógica mediante Espectroscopia de Reflexión . . . . .                 | 16        |
| 2.3.3. Ejemplo 3: Aislamiento de Fallas en el Sistema de Control de Actitud . . . . .                       | 17        |
| 2.3.4. Ejemplo 4: Clasificación Orbital de Cometas (Parabólico vs. Hiperbólico) . . . . .                   | 18        |
| <b>3. Clase 3</b>                                                                                           | <b>20</b> |
| 3.1. Conteos . . . . .                                                                                      | 20        |
| 3.1.1. Ejemplo 1: Configuración de Carga Útil en una Sonda Espacial . . . . .                               | 20        |
| 3.1.2. Ejemplo 2: Matriz de Observación Fotométrica en un Telescopio Robótico . . . . .                     | 21        |
| 3.2. Permutaciones . . . . .                                                                                | 22        |
| 3.2.1. Ejemplo 1: Secuencia de Apuntamiento en un Telescopio Espacial . . . . .                             | 22        |
| 3.2.2. Ejemplo 2: Secuencia de Análisis en un Espectrómetro de Masas Planetario . . . . .                   | 23        |
| 3.3. Combinaciones . . . . .                                                                                | 24        |
| 3.3.1. Ejemplo 1: Selección de Sitios de Aterrizaje en Ciencia Planetaria . . . . .                         | 24        |
| 3.3.2. Ejemplo 2: Configuración de Sub-arrays en Radio Interferometría . . . . .                            | 25        |

|                                                                                                                   |           |
|-------------------------------------------------------------------------------------------------------------------|-----------|
| <b>4. Clase 4</b>                                                                                                 | <b>26</b> |
| 4.1. Variables aleatorias . . . . .                                                                               | 26        |
| 4.1.1. Ejemplo 1: Variable Aleatoria Discreta en la Adquisición de Estrellas Guía . . . . .                       | 26        |
| 4.1.2. Ejemplo 2: Variable Aleatoria Continua en la Espectroscopia de Velocidad Radial . . . . .                  | 27        |
| 4.2. Funciones de densidad de probabilidad . . . . .                                                              | 28        |
| 4.2.1. Ejemplo 1: Tiempo de Permanencia de un Cometa en el Sistema Solar Interior . . . . .                       | 28        |
| 4.2.2. Ejemplo 2: Error de Apuntamiento de la Antena de Alta Ganancia en una Sonda . . . . .                      | 29        |
| 4.3. Función de distribución acumulativa . . . . .                                                                | 30        |
| 4.3.1. Ejemplo 1: Perfil de Densidad de Polvo en un Disco Protoplanetario . . . . .                               | 31        |
| 4.3.2. Ejemplo 2: Error Radial en el Elipse de Aterrizaje de un Rover . . . . .                                   | 32        |
| 4.4. Valor esperado . . . . .                                                                                     | 34        |
| 4.5. Varianza . . . . .                                                                                           | 34        |
| 4.5.1. Ejemplo 1: Demostración de la Fórmula Abreviada de la Varianza . . . . .                                   | 35        |
| 4.5.2. Ejemplo 2: Propagación de Error en el Sistema de Magnitudes Fotométricas . . . . .                         | 35        |
| <b>5. Clase 5</b>                                                                                                 | <b>38</b> |
| 5.1. Distribución de probabilidad binomial . . . . .                                                              | 38        |
| 5.1.1. Ejemplo 1: Demostración de la Moda de la Distribución Binomial . . . . .                                   | 38        |
| 5.1.2. Ejemplo 2: Demostración del $k$ -ésimo momento factorial de la distribución binomial . . . . .             | 39        |
| 5.1.3. Ejemplo 3: Momentos de Orden Superior en la Integración de Señales de Radar Planetario . . . . .           | 41        |
| 5.1.4. Ejemplo 4: Interferometría de Línea de Base Larga con Enjambre de Nano-satélites . . . . .                 | 43        |
| <b>6. Clase 6</b>                                                                                                 | <b>45</b> |
| 6.1. Distribución de Poisson . . . . .                                                                            | 45        |
| 6.2. Distribuciones continuas . . . . .                                                                           | 46        |
| 6.2.1. Ejemplo 1: Demostración de la Propiedad de Reproductividad en Procesos de Poisson . . . . .                | 46        |
| 6.2.2. Ejemplo 2: Del Conteo de Fotones al Tiempo de Espera y la Función Gamma . . . . .                          | 47        |
| 6.3. Percentiles . . . . .                                                                                        | 49        |
| 6.4. Distribución normal . . . . .                                                                                | 49        |
| 6.4.1. Ejemplo 1: Percentiles en la distribución de concentración de isótopos en un núcleo de meteorito . . . . . | 50        |
| 6.4.2. Ejemplo 2: Distribución normal y percentiles en la navegación de una sonda interplanetaria . . . . .       | 51        |
| 6.4.3. Ejemplo 3: Control de Calidad Óptica y Razón de Strehl en Telescopios Espaciales . . . . .                 | 52        |
| <b>7. Clase 7</b>                                                                                                 | <b>56</b> |
| 7.1. Funciones de varias variables . . . . .                                                                      | 56        |
| 7.2. Distribuciones de probabilidad conjunta . . . . .                                                            | 56        |
| 7.3. Distribuciones marginales . . . . .                                                                          | 57        |
| 7.4. Combinación de variables aleatorias . . . . .                                                                | 57        |

|            |                                                                          |           |
|------------|--------------------------------------------------------------------------|-----------|
| 7.4.1.     | Ejemplo 1: Abundancia Mineralógica en una Sección Delgada de Meteorito . | 58        |
| 7.4.2.     | Ejemplo 2: Detección Multi-banda de Tránsitos Exoplanetarios . . . . .   | 60        |
| <b>8.</b>  | <b>Clase 8</b>                                                           | <b>63</b> |
| 8.1.       | Valores esperados en varias variables . . . . .                          | 63        |
| 8.2.       | Funciones de correlación . . . . .                                       | 63        |
| 8.3.       | Covarianza . . . . .                                                     | 63        |
| 8.4.       | Combinación de variables aleatorias . . . . .                            | 63        |
| <b>9.</b>  | <b>Clase 9</b>                                                           | <b>64</b> |
| 9.1.       | Teorema central del límite . . . . .                                     | 64        |
| 9.2.       | Estadísticos . . . . .                                                   | 64        |
| 9.3.       | Distribución de estadísticos . . . . .                                   | 64        |
| 9.4.       | Muestras . . . . .                                                       | 64        |
| 9.5.       | Estimación puntual: Método de momentos . . . . .                         | 64        |
| <b>10.</b> | <b>Clase 10</b>                                                          | <b>65</b> |
| 10.1.      | Método de mínimos cuadrados . . . . .                                    | 65        |
| 10.2.      | Maximum likelihood . . . . .                                             | 65        |

# Clase 1

## 1.1. Espacios Muestrales

El espacio muestral de un experimento denotado por  $S$ , es el conjunto de todos los posibles resultados de dicho experimento (Devore, Capítulo 2).

Cada resultado individual se denomina *evento simple*. Un *evento compuesto* es cualquier subconjunto del espacio muestral que contenga más de un resultado.

### 1.1.1. Ejemplo 1: Clasificación Morfológica de Galaxias

Un telescopio espacial apunta hacia un campo profundo del universo y detecta una galaxia previamente no catalogada. El experimento consiste en analizar su perfil de brillo superficial y asignarle una clase morfológica.

El resultado de esta observación debe caer en una de cuatro categorías macroscópicas mutuamente excluyentes:

- $E$ : Galaxia Espiral.
- $L$ : Galaxia Elíptica.
- $I$ : Galaxia Irregular.
- $D$ : Galaxia Lenticular (de disco, sin brazos espirales evidentes).

El espacio muestral  $S$  para este experimento es simplemente el conjunto:

$$S = \{E, L, I, D\}$$

### 1.1.2. Ejemplo 2: Espacio Muestral Infinito en el Seguimiento de Cometas

Los espacios muestrales infinitos son fundamentales cuando modelamos procesos de 'espera' o 'búsqueda' en astronomía. Para determinar la órbita de un cometa recién descubierto, un observatorio necesita obtener imágenes astrométricas de alta calidad (libres de nubes y con un *seeing* atmosférico adecuado) en múltiples noches.

Definamos el experimento como: *Intentar obtener una imagen usable del cometa noche tras noche hasta lograr el primer éxito*. Los resultados básicos para cada noche son:

- $E$ : Noche despejada, imagen exitosa (Éxito).

- $F$ : Noche nublada o con mal *seeing*, imagen descartada (Falla).

A diferencia del ejemplo anterior, aquí no fijamos un número finito de intentos de antemano. El experimento termina en el momento en que se obtiene el primer éxito. Por lo tanto, el espacio muestral  $S$  contiene un número infinito de resultados posibles:

$$S = \{E, FE, FFE, FFFE, FFFFE, \dots\}$$

Cada elemento de  $S$  representa una secuencia única de noches. Por ejemplo, el resultado  $FFFE$  significa que el astrónomo sufrió tres noches consecutivas de mal clima antes de lograr captar el cometa en la cuarta noche.

Podemos construir eventos compuestos para analizar la eficiencia del observatorio. Sea  $C$  el evento *lograr la imagen exitosa en un número par de noches*. Analíticamente, este evento se expresa como:

$$C = \{FE, FFFE, FFFFFFE, \dots\}$$

O sea,  $C = \{F^{2k-1}E \mid k = 1, 2, 3, \dots\}$ .

Este tipo de espacio muestral infinito discreto es la base para modelar distribuciones de probabilidad como la Geométrica, la cual es sumamente útil en la astronomía observacional para calcular el tiempo esperado (o número de noches) que un telescopio debe invertir para caracterizar un objeto transitorio débil, como un cometa de órbita parabólica (Duffett-Smith y Zwart, Sección 62) o un evento de microlente gravitacional.

### 1.1.3. Extensión Analítica: Espacios Muestrales Continuos en Coordenadas Celestes

Aunque los ejemplos anteriores son discretos, es vital notar que la mayoría de las mediciones astronómicas generan espacios muestrales continuos. Por ejemplo, al calcular las coordenadas ecuatoriales (Ascensión Recta  $\alpha$  y Declinación  $\delta$ ) de un planeta exterior como Júpiter (Duffett-Smith y Zwart, Sección 54), el resultado de una medición sujeta a error instrumental no es un punto exacto, sino un vector continuo.

Si definimos el experimento como *medir la posición aparente de un astro*, el espacio muestral es un subconjunto de  $\mathbb{R}^2$ :

$$S = \{(\alpha, \delta) \in \mathbb{R}^2 \mid 0 \leq \alpha < 24^h, -90^\circ \leq \delta \leq 90^\circ\}$$

En este escenario continuo, la probabilidad de obtener un resultado exacto (un evento simple) es estrictamente cero. Los eventos de interés (como que el planeta esté en una región específica de la eclíptica para estudiar sus perturbaciones orbitales) se definen como regiones o áreas dentro de este espacio muestral continuo, requiriendo el uso de funciones de densidad de probabilidad y cálculo integral para su evaluación.

## 1.2. Eventos

Un evento es cualquier recopilación o subconjunto de resultados contenidos en el espacio muestral  $S$  (Devore, Capítulo 2, Sección 2.1).

Si un evento consiste en exactamente un resultado, se denomina *evento simple*; si consiste en más de un resultado, se denomina *evento compuesto*. Dado que un evento es simplemente un conjunto, las operaciones y resultados de la teoría elemental de conjuntos se utilizan para estudiar las relaciones entre ellos. Las operaciones primarias incluyen:

- **Unión** ( $A \cup B$ ): El evento que consiste en todos los resultados que están en  $A$ , en  $B$ , o en ambos.
- **Intersección** ( $A \cap B$ ): El evento que consiste en todos los resultados que están tanto en  $A$  como en  $B$ .
- **Complemento** ( $A'$ ): El conjunto de todos los resultados en  $S$  que no están en  $A$ .
- **Eventos mutuamente excluyentes (disjuntos)**: Dos eventos son mutuamente excluyentes si no tienen resultados en común (es decir,  $A \cap B = \emptyset$ ).

La correcta formulación de eventos permite traducir preguntas físicas o astronómicas complejas a lenguaje matemático riguroso, sentando las bases para el cálculo de probabilidades y la inferencia estadística.

### 1.2.1. Ejemplo 1: Clasificación Taxonómica de Asteroides

Un sondeo astronómico detecta dos asteroides cercanos a la Tierra. Basado en sus espectros de reflexión, cada asteroide se clasifica en uno de tres complejos taxonómicos principales:

- $C$ : Complejo-C (Carbonáceos).
- $S$ : Complejo-S (Silicáceos).
- $X$ : Complejo-X (Metálicos).

El experimento consiste en registrar la clasificación del par de asteroides. El espacio muestral  $S$  está compuesto por  $3^2 = 9$  eventos simples, representados como pares ordenados:

$$S = \{CC, CS, CX, SC, SS, SX, XC, XS, XX\}$$

A partir de este espacio muestral, podemos definir eventos compuestos que representen escenarios de interés para la ciencia planetaria y la defensa planetaria:

Sea  $A$  el evento en el que *ambos asteroides pertenecen al mismo complejo taxonómico*:

$$A = \{CC, SS, XX\}$$

Sea  $B$  el evento en el que *al menos uno de los asteroides es de tipo  $S$  (silicáceo)*:

$$B = \{CS, SC, SS, SX, XS\}$$

Podemos analizar las operaciones entre estos eventos para extraer conclusiones analíticas:

- **Intersección** ( $A \cap B$ ): El evento en que ambos son del mismo tipo *y* al menos uno es tipo S. Esto solo ocurre si ambos son silicáceos.

$$A \cap B = \{SS\}$$

- **Unión** ( $A \cup B$ ): El evento en que ambos son del mismo tipo *o* al menos uno es tipo S.

$$A \cup B = \{CC, CS, SC, SS, SX, XS, XX\}$$

- **Complemento** ( $A'$ ): El evento en que los asteroides *no* son del mismo tipo (población taxonómicamente diversa).

$$A' = \{CS, CX, SC, SX, XC, XS\}$$

Finalmente, para ilustrar la exclusión mutua (Devore, Sección 2.1), definamos el evento  $D$  como *exactamente un asteroide es de tipo X y el otro es de tipo C*:

$$D = \{CX, XC\}$$

Los eventos  $A$  y  $D$  son *mutuamente excluyentes* (o disjuntos), ya que es lógicamente imposible que ambos asteroides sean del mismo tipo ( $A$ ) y que al mismo tiempo sean de tipos diferentes ( $D$ ). Analíticamente,  $A \cap D = \emptyset$ .

### 1.2.2. Ejemplo 2: Modelado Gravitacional en Operaciones de Proximidad

Los espacios muestrales y sus eventos también son cruciales en la ingeniería aeroespacial y la navegación de naves autónomas (Capítulo 4, *Modern Spacecraft Guidance, Navigation, and Control*, sección Irregular solar system bodies").

Cuando una nave espacial (chaser) se aproxima a un asteroide, el campo gravitacional es altamente irregular. Los modelos de Armónicos Esféricos (SHE) son computacionalmente rápidos pero solo son válidos fuera de la 'esfera de Brillouin' (la región que engloba todo el cuerpo). Para operar dentro de esta esfera, el sistema de navegación debe cambiar a un modelo de Mascones o Poliedros, el cual es más preciso pero computacionalmente costoso.

Definamos el experimento como: *La nave ejecuta 3 pasadas de aproximación consecutivas. En cada pasada, el sistema de navegación a bordo selecciona el modelo gravitacional a utilizar para el filtro de navegación.* Los resultados básicos para cada pasada son:

- $H$ : Se utiliza el modelo de Armónicos Esféricos (SHE).
- $M$ : Se utiliza el modelo de Mascones.

El espacio muestral  $S$  está compuesto por  $2^3 = 8$  eventos simples:

$$S = \{HHH, HHM, HMH, MHH, HMM, MHM, MMH, MMM\}$$



Definamos los siguientes eventos compuestos para evaluar la estrategia de navegación:

Sea  $A$  el evento en el que *el modelo SHE se utiliza exactamente en dos de las tres pasadas*:

$$A = \{HHM, HMH, MHH\}$$

Sea  $B$  el evento en el que *el modelo de Mascones se utiliza en la primera pasada* (lo que indicaría que la nave penetró la esfera de Brillouin de manera temprana o agresiva):

$$B = \{MHH, MHM, MMH, MMM\}$$

La intersección de estos eventos,  $A \cap B$ , representa el escenario donde la nave usó Mascones en la primera pasada, pero logró revertir al modelo SHE (más ligero computacionalmente) en las dos siguientes (probablemente porque la trayectoria de aproximación la alejó temporalmente de la esfera de Brillouin):

$$A \cap B = \{MHH\}$$

Por último, consideremos el evento  $C$  definido como *el modelo de Mascones nunca es utilizado en las tres pasadas* (la nave se mantuvo estrictamente fuera de la esfera de Brillouin):

$$C = \{HHH\}$$

Los eventos  $B$  y  $C$  son *mutuamente excluyentes*. Físicamente, la nave no puede haber utilizado el modelo de Mascones en la primera pasada ( $B$ ) y al mismo tiempo no haberlo utilizado nunca ( $C$ ). Por lo tanto,  $B \cap C = \emptyset$ . La modelación de estos eventos como subconjuntos del espacio muestral dota a los ingenieros de GNC de un marco analítico riguroso para cuantificar el riesgo de saturación del ordenador de a bordo (OBC). A través de esta representación, es posible estimar la probabilidad de que la exigencia computacional —derivada de la conmutación entre los distintos modelos de navegación— rebase los umbrales de seguridad del hardware durante las críticas fases de operaciones de proximidad, vinculando directamente esta métrica de riesgo con la geometría de la trayectoria relativa planificada.

### 1.3. Probabilidad

La probabilidad es la rama de las matemáticas que proporciona un marco riguroso para cuantificar la incertidumbre y el azar en cualquier situación donde pueden ocurrir diversos sucesos. En el contexto de la astronomía y la exploración espacial, la probabilidad es una herramienta fundamental para modelar desde la distribución de materia en el universo hasta la confiabilidad de los sistemas de navegación de una sonda interplanetaria.

La probabilidad asigna a cada evento  $A$  un número  $P(A)$  que representa una medida precisa de la oportunidad de que  $A$  ocurra (Devore, Capítulo 2, Sección 2.2). En la práctica astronómica, esta asignación puede basarse en la interpretación frecuentista (por ejemplo, la tasa de ocurrencia de supernovas en un volumen dado, o la fracción de estrellas que poseen planetas) o en la interpretación geométrica/combinatoria (como la probabilidad de que un exoplaneta esté alineado con nuestra línea de visión).

## 1.4. Axiomas de probabilidad

Para garantizar que las asignaciones de probabilidad sean matemáticamente consistentes y respeten las nociones intuitivas de la frecuencia y la certeza, la teoría moderna se fundamenta en los Axiomas de Kolmogorov. Estos axiomas establecen las reglas inquebrantables que gobiernan la medida de probabilidad  $P$  sobre un espacio muestral  $S$  (Devore, Capítulo 2, Sección 2.2):

- **AXIOMA 1:** Para cualquier evento  $A$ ,  $P(A) \geq 0$ . (La probabilidad no puede ser negativa).
- **AXIOMA 2:**  $P(S) = 1$ . (La probabilidad del espacio muestral completo, es decir, de que ocurra algún resultado, es la certeza absoluta).
- **AXIOMA 3:** Si  $A_1, A_2, A_3, \dots$  es un conjunto (finito o infinito) de eventos mutuamente excluyentes (disjuntos), entonces la probabilidad de su unión es la suma de sus probabilidades individuales:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

A partir de estos tres axiomas, se pueden derivar rigurosamente todas las demás propiedades y teoremas de la probabilidad, como la probabilidad del complemento o la probabilidad de la unión de eventos no disjuntos.

### 1.4.1. Propiedades Fundamentales Derivadas de los Axiomas

A partir de los tres axiomas de Kolmogorov, se pueden demostrar rigurosamente las siguientes propiedades (Devore, Capítulo 2, Sección 2.2). Sea  $S$  el espacio muestral y  $A, B, C \subseteq S$  eventos cualesquiera:

1. **Probabilidad del evento nulo:**

$$P(\emptyset) = 0$$

2. **Cota superior de la probabilidad:** Para todo evento  $A$ ,

$$P(A) \leq 1$$

3. **Regla del complemento:**

$$P(A') = 1 - P(A)$$

4. **Monotonicidad:** Si  $A \subseteq B$ , entonces

$$P(A) \leq P(B)$$

5. **Regla de adición para dos eventos:**

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

6. **Regla de adición para tres eventos (Principio de Inclusión-Exclusión):**

$$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) - P(B \cap C) + P(A \cap B \cap C)$$

7. **Desigualdad de Boole (cota de la unión):** Para cualesquiera eventos  $A_1, A_2, \dots, A_n$ ,

$$P\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n P(A_i)$$

8. **Leyes de De Morgan aplicadas a la probabilidad:**

$$P((A \cup B)') = P(A' \cap B')$$

$$P((A \cap B)') = P(A' \cup B')$$

### 1.4.2. Ejemplo 1: Demostración de la Probabilidad del Evento Nulo

Consideremos una sucesión infinita de eventos donde cada evento es el conjunto vacío:

$$A_1 = \emptyset, \quad A_2 = \emptyset, \quad A_3 = \emptyset, \quad \dots$$

Primero, notamos que estos eventos son mutuamente excluyentes, ya que la intersección de cualquier par de ellos es el conjunto vacío ( $A_i \cap A_j = \emptyset \cap \emptyset = \emptyset$ ).

Segundo, la unión de todos estos eventos es simplemente el conjunto vacío:

$$\bigcup_{i=1}^{\infty} A_i = \emptyset$$

Aplicando el **Axioma 3** (aditividad para eventos mutuamente excluyentes), tenemos:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

Sustituyendo la unión y los eventos individuales por  $\emptyset$ , la ecuación se convierte en:

$$P(\emptyset) = \sum_{i=1}^{\infty} P(\emptyset) = P(\emptyset) + P(\emptyset) + P(\emptyset) + \dots$$

Por el **Axioma 1**, sabemos que  $P(\emptyset) \geq 0$ , y por el **Axioma 2**, sabemos que cualquier probabilidad debe ser un número finito (acotado superiormente por 1). La única forma en que una suma infinita de un mismo valor no negativo converge a un número finito es si dicho valor es estrictamente cero. Si  $P(\emptyset)$  fuera mayor que 0, la suma divergiría al infinito, violando la definición de probabilidad.

Por lo tanto, concluimos que:

$$P(\emptyset) = 0$$

### 1.4.3. Ejemplo 2: Clasificación de Señales en Astronomía de Ondas Gravitacionales

En el campo emergente de la astronomía de ondas gravitacionales, los interferómetros como LIGO y Virgo detectan continuamente candidatos a señales transitorias. Históricamente, tras años de ciclos de observación, la colaboración científica ha catalogado la naturaleza de estos eventos. Definamos el espacio muestral  $S$  para la clasificación de un nuevo candidato a señal como:

- $A$ : Fusión de agujeros negros binarios (BBH).
- $B$ : Fusión de estrellas de neutrones binarias (BNS).
- $C$ : Artefacto instrumental o ruido sísmico (falso positivo).

Estos tres eventos son mutuamente excluyentes y exhaustivos. Basándonos en la frecuencia relativa histórica de los catálogos de eventos (como los catálogos GWTC de la colaboración LIGO-Virgo-KAGRA), podemos asignar las siguientes probabilidades a priori para un candidato genérico no validado:

$$P(A) = 0,78, \quad P(B) = 0,07, \quad P(C) = 0,15$$

Supongamos que el sistema de alerta temprana dispara una notificación para un nuevo evento candidato. Nos interesa calcular la probabilidad de que esta señal corresponda a una coalescencia binaria compacta genuina de origen astrofísico. Definamos este evento compuesto como  $E = A \cup B$ .

Dado que los eventos  $A$  y  $B$  son mutuamente excluyentes (un evento no puede ser simultáneamente una fusión de agujeros negros y de estrellas de neutrones), la probabilidad de su unión es simplemente la suma de sus probabilidades individuales:

$$P(E) = P(A) + P(B) = 0,78 + 0,07 = 0,85$$

Alternativamente, este mismo resultado puede obtenerse de manera más directa utilizando la regla del complemento. El evento de que la señal sea una coalescencia genuina ( $E$ ) es exactamente el complemento del evento de que sea un artefacto instrumental ( $C$ ). Por lo tanto:

$$P(E) = 1 - P(C) = 1 - 0,15 = 0,85$$

Estas asignaciones probabilísticas son críticas para los algoritmos de filtrado que procesan las alertas en tiempo real, priorizando aquellas candidatas con una probabilidad de ser astrofísicas ( $P(E)$ ) lo suficientemente alta como para activar telescopios de seguimiento electromagnético en todo el mundo.

### 1.4.4. Ejemplo 3: Análisis de Modos de Falla en un Rover de Exploración

Los axiomas de probabilidad son la base para evaluar la confiabilidad de sistemas críticos en la ingeniería aeroespacial. Tomemos como referencia los análisis de modos de falla y efectos críticos (FMECA) utilizados en la operación de rovers en superficies planetarias (*Modern Spacecraft Guidance, Navigation, and Control*, y *Planetary Geology*).

Considere el mecanismo de perforación y muestreo de un rover marciano. Durante un ciclo operativo de 1 hora, el sistema puede experimentar uno de tres modos de falla críticos. Definimos los eventos mutuamente excluyentes (ya que el diagnóstico del sistema identifica la causa raíz primaria de manera única):

- $A$ : Atasco mecánico del motor del taladro.
- $B$ : Sobrecarga térmica en la electrónica de control.
- $C$ : Pérdida de sincronización en el bus de comunicación.

Basado en datos históricos de pruebas en cámaras de vacío térmico, se han asignado las siguientes probabilidades para un ciclo operativo dado:

$$P(A) = 0,04, \quad P(B) = 0,03, \quad P(C) = 0,01$$

Sea  $F$  el evento compuesto definido como *que ocurra cualquier tipo de falla durante el ciclo*. Matemáticamente,  $F$  es la unión de los tres eventos:

$$F = A \cup B \cup C$$

Dado que  $A$ ,  $B$  y  $C$  son mutuamente excluyentes, podemos aplicar directamente el **Axioma 3** para calcular la probabilidad de falla total del sistema:

$$P(F) = P(A) + P(B) + P(C) = 0,04 + 0,03 + 0,01 = 0,08$$

El evento de interés para la misión es que el rover complete el ciclo de perforación *sin fallas*, lo cual corresponde al evento complemento  $F'$ . Utilizando la propiedad derivada de los Axiomas 2 y 3 (donde  $P(F) + P(F') = 1$ ), calculamos la probabilidad de éxito:

$$P(F') = 1 - P(F) = 1 - 0,08 = 0,92$$

Este cálculo indica que el rover tiene un 92 % de confiabilidad por ciclo. Los ingenieros de vuelo utilizan este valor para propagar la incertidumbre a través de la planificación de la misión, determinando cuántos ciclos redundantes deben programarse para asegurar que la probabilidad acumulada de obtener al menos una muestra geológica supere el umbral requerido para los objetivos científicos de la misión.

# Clase 2

## 2.1. Probabilidad condicional

En la práctica astronómica y astrofísica, rara vez se evalúan los eventos de manera aislada. Frecuentemente, se dispone de información parcial o de observaciones preliminares que restringen el universo de posibilidades. La probabilidad condicional es la herramienta analítica que permite cuantificar cómo cambia la probabilidad de un evento cuando se tiene la certeza de que otro evento relacionado ya ha ocurrido.

Si  $A$  y  $B$  son dos eventos tales que  $P(B) > 0$ , la probabilidad condicional de  $A$  dado que  $B$  ha ocurrido se define como (Devore, Capítulo 2, Sección 2.4):

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Conceptualmente, esta definición refleja un cambio fundamental en el espacio muestral. El nuevo espacio muestral ya no es el conjunto original  $S$ , sino que se reduce exclusivamente al evento  $B$  (el evento condicionante). La probabilidad  $P(A|B)$  mide la fracción de  $B$  que también pertenece a  $A$ .

A partir de esta definición, se deriva una de las herramientas más poderosas para el modelado de procesos observacionales secuenciales: la **regla de multiplicación**. Si reordenamos la ecuación anterior, obtenemos la probabilidad de la intersección de dos eventos:

$$P(A \cap B) = P(A|B) \cdot P(B)$$

Esta regla es esencial para calcular la probabilidad de que ocurran múltiples etapas en un proceso de observación o navegación, donde el éxito de una etapa depende condicionalmente del resultado de la etapa previa.

### 2.1.1. Ejemplo 1: Caracterización de Asteroides mediante Albedo Radar

Un radiotelescopio realiza un sondeo de 200 Asteroides Cercanos a la Tierra (NEAs) para estudiar su composición superficial.

Definimos los siguientes eventos para un asteroide seleccionado al azar de esta muestra:

- $M$ : El asteroide es de tipo espectral M (metálico, compuesto principalmente de hierro y níquel).
- $R$ : El asteroide presenta una alta reflectividad (albedo) en las observaciones de radar.

Tras procesar los datos del sondeo, se obtienen las siguientes frecuencias conjuntas:

- 40 asteroides son de tipo M:  $P(M) = 40/200 = 0,20$ .
- 60 asteroides tienen alta reflectividad radar:  $P(R) = 60/200 = 0,30$ .
- 30 asteroides son de tipo M *y* además tienen alta reflectividad radar:  $P(M \cap R) = 30/200 = 0,15$ .

**Pregunta 1:** Si el sistema de radar detecta que un asteroide tiene alta reflectividad ( $R$ ), ¿cuál es la probabilidad de que sea metálico ( $M$ )?

$$P(M|R) = \frac{P(M \cap R)}{P(R)} = \frac{0,15}{0,30} = 0,50$$

Esto significa que, dado que el asteroide brilla intensamente en el radar, hay un 50 % de probabilidad de que su composición sea metálica. El espacio muestral se ha reducido a los 60 asteroides con alta reflectividad.

**Pregunta 2:** Si un asteroide ya ha sido clasificado espectroscópicamente como de tipo M ( $M$ ), ¿cuál es la probabilidad de que presente alta reflectividad radar ( $R$ )?

$$P(R|M) = \frac{P(M \cap R)}{P(M)} = \frac{0,15}{0,20} = 0,75$$

Aquí, el espacio muestral se reduce a los 40 asteroides metálicos. La probabilidad es notablemente distinta (75 %). Este ejemplo resalta una de las advertencias más importantes en la inferencia estadística (Devore, Sección 2.4): la probabilidad de que un asteroide sea metálico dado su radar ( $P(M|R)$ ) no es la misma que la probabilidad de que tenga alto radar dado que es metálico ( $P(R|M)$ ).

### 2.1.2. Ejemplo 2: Regla de Multiplicación en Pipelines de Transitorios Astrofísicos

La regla de multiplicación es indispensable para modelar cadenas de eventos dependientes. En la astronomía de grandes sondeos temporales (como los realizados por el Observatorio Vera C. Rubin), los "pipelines" de reducción de datos deben filtrar miles de alertas nocturnas. Analicemos la detección de transitorios.

Definimos el experimento como el procesamiento de una alerta nocturna por parte del pipeline automatizado.

- $V$ : El evento astrofísico subyacente es *verdadero* y genuino (ej. una kilonova o supernova real).
- $V'$ : El evento es un *artefacto* instrumental o ruido cósmico (falso astrofísico).
- $F$ : El pipeline de software etiqueta la alerta como 'Candidato de Alta Prioridad' (Flag).

Basado en el rendimiento histórico del telescopio y la naturaleza de los falsos positivos, sabemos que:

- La probabilidad a priori de que una alerta aleatoria sea un evento genuino es baja:  $P(V) = 0,10$ . Por lo tanto,  $P(V') = 1 - 0,10 = 0,90$ .

- Si el evento es genuino ( $V$ ), el pipeline es muy eficiente detectándolo:  $P(F|V) = 0,90$ .
- Si el evento es un artefacto ( $V'$ ), el pipeline aún puede ser engañado y etiquetarlo erróneamente como candidato (tasa de falsos positivos):  $P(F|V') = 0,15$ .

**Escenario 1: Detección Exitosa (Verdadero Positivo)** ¿Cuál es la probabilidad de que una alerta sea un evento genuino *y* que el pipeline la etiquete correctamente como candidato?

$$P(V \cap F) = P(F|V) \cdot P(V) = 0,90 \cdot 0,10 = 0,09$$

Esto indica que el 9 % de todas las alertas procesadas serán descubrimientos científicos reales y confirmados por el software.

**Escenario 2: Falso Positivo** ¿Cuál es la probabilidad de que una alerta sea un artefacto *y* que el pipeline la etiquete erróneamente como candidato?

$$P(V' \cap F) = P(F|V') \cdot P(V') = 0,15 \cdot 0,90 = 0,135$$

Esto revela que el 13.5 % de todas las alertas procesadas serán falsos positivos que consumirán tiempo valioso de seguimiento telescópico.

Este análisis condicional y multiplicativo permite a los arquitectos de misiones evaluar el 'costo' de falsas alarmas frente a la tasa de descubrimientos reales, justificando analíticamente la necesidad de introducir filtros secundarios (como la verificación de movimiento propio o el análisis de la forma del punto, PSF) antes de enviar alertas a la comunidad astronómica global.

## 2.2. Independencia de eventos

Dos eventos  $A$  y  $B$  se consideran independientes si la ocurrencia de uno de ellos no proporciona ninguna información sobre la ocurrencia del otro (Devore, Capítulo 2, Sección 2.5).

Analíticamente, esta noción se formaliza a través de la probabilidad condicional. Si  $A$  y  $B$  son independientes, entonces la probabilidad de  $A$  dado que  $B$  ha ocurrido es simplemente la probabilidad marginal de  $A$ :

$$P(A|B) = P(A)$$

Sustituyendo la definición de probabilidad condicional  $P(A|B) = \frac{P(A \cap B)}{P(B)}$  en la ecuación anterior y reordenando, obtenemos la **regla de multiplicación para eventos independientes**, que es la definición operativa más utilizada en la práctica:

$$P(A \cap B) = P(A) \cdot P(B)$$

Es crucial destacar una distinción analítica fundamental (Devore, Sección 2.5): la independencia y la exclusión mutua son conceptos radicalmente distintos. Si dos eventos son mutuamente excluyentes ( $A \cap B = \emptyset$ ), saber que  $A$  ocurrió garantiza que  $B$  no ocurrió ( $P(B|A) = 0$ ), lo cual implica una dependencia extrema. Por el contrario, si son independientes, la ocurrencia de  $A$  no altera en absoluto la probabilidad de  $B$ .



### 2.2.1. Ejemplo 1: Confiabilidad de Subsistemas Críticos en una Sonda Interplanetaria

*Modern Spacecraft Guidance, Navigation, and Control* (Capítulo 4, "Fault Detection and Isolation").

Considere una sonda espacial que viaja hacia los planetas exteriores. Para mantener su actitud y orientación, la nave depende de dos subsistemas físicamente separados y eléctricamente aislados:

- $A$ : El evento en el que el rastreador de estrellas principal (Star Tracker) sufre un bloqueo temporal por radiación cósmica.
- $B$ : El evento en el que la unidad de medición inercial (IMU) experimenta una deriva térmica fuera de los límites de tolerancia.

Basado en los datos de pruebas en tierra y modelos de entorno espacial, se han estimado las siguientes probabilidades marginales para una ventana de misión de 30 días:

$$P(A) = 0,04$$

$$P(B) = 0,02$$

Dado que el rastreador de estrellas (óptico) y la IMU (mecánico-inercial) operan bajo principios físicos distintos y están blindados contra fallas en cascada, el modelo de confiabilidad asume que estos eventos son *mutuamente independientes*.

Podemos calcular la probabilidad de que la sonda experimente una pérdida total de referencia de actitud (el evento  $A \cap B$ , donde ambos sensores fallan simultáneamente) aplicando la regla de multiplicación para eventos independientes:

$$P(A \cap B) = P(A) \cdot P(B) = 0,04 \cdot 0,02 = 0,0008$$

Si hubiéramos asumido erróneamente que los eventos eran dependientes (por ejemplo, si una tormenta de radiación afectara a ambos por igual), la probabilidad de falla catastrófica sería mucho mayor. La independencia analítica permite a los ingenieros de vuelo demostrar que la probabilidad de pérdida de control (0,08 %) cumple con los estrictos requisitos de riesgo de la misión. Además, se puede verificar que  $P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{0,0008}{0,02} = 0,04 = P(A)$ , confirmando que la falla de la IMU no altera la probabilidad de fallo del rastreador de estrellas.

### 2.2.2. Ejemplo 2: Discriminación de Señales en la Red de Interferómetros de Ondas Gravitacionales

En la astronomía de multi-mensajeros y la astrofísica de altas energías, la independencia es la piedra angular para distinguir señales astrofísicas genuinas de ruido instrumental local. Tomemos como referencia los principios de detección de señales y análisis de ruido en redes de observatorios (*Astronomical Measurement*, Capítulo 6, "Signal-to-Noise and Detection").

Considere la red de interferómetros láser (como LIGO), compuesta por detectores separados geográficamente miles de kilómetros. Definimos los siguientes eventos para un intervalo de tiempo de 1 milisegundo:

- $N_1$ : El detector 1 (ej. Hanford) registra un transitorio de ruido sísmico/instrumental que supera el umbral de activación.
- $N_2$ : El detector 2 (ej. Livingston) registra un transitorio de ruido que supera el umbral.
- $W$ : El paso de una onda gravitacional real proveniente de una fusión de agujeros negros.

Las fuentes de ruido local (microsismos, ruido térmico en los espejos, fluctuaciones láser) en el detector 1 son físicamente independientes de las del detector 2. Por lo tanto, los eventos de ruido  $N_1$  y  $N_2$  son *independientes*. Si la tasa de falsas alarmas (ruido superando el umbral) en cada detector es  $P(N_1) = 10^{-3}$  y  $P(N_2) = 10^{-3}$ , la probabilidad de que *ambos* detectores registren un falso positivo simultáneamente por puro azar es:

$$P(N_1 \cap N_2) = P(N_1) \cdot P(N_2) = 10^{-3} \cdot 10^{-3} = 10^{-6}$$

Esta drástica reducción en la probabilidad de error (de  $10^{-3}$  a  $10^{-6}$ ) es la base de la *coincidencia de red*.

Sin embargo, analicemos qué ocurre si el evento  $W$  (una onda gravitacional real) ocurre. Una onda gravitacional real afecta el espacio-tiempo local en ambos detectores casi simultáneamente. En este escenario, los eventos de 'detección de un umbral cruzado' en el detector 1 y el detector 2 **ya no son independientes**. La ocurrencia de la señal real condiciona fuertemente a ambos detectores:

$$P(\text{Umbral}_1 \cap \text{Umbral}_2 | W) \neq P(\text{Umbral}_1 | W) \cdot P(\text{Umbral}_2 | W)$$

De hecho, si  $W$  ocurre, la probabilidad de que ambos detectores se activen es cercana a 1 (dependiendo de la polarización y ubicación de la fuente), mientras que el producto de sus probabilidades marginales condicionadas a  $W$  no reflejaría esta correlación física. Este contraste analítico entre la independencia del ruido local ( $N_1 \perp N_2$ ) y la dependencia inducida por una señal astrofísica común ( $W$ ) es el mecanismo estadístico fundamental que permite a los astrónomos confirmar el descubrimiento de nuevos fenómenos cósmicos, filtrando el ruido instrumental aleatorio de las verdaderas perturbaciones del universo.

## 2.3. Teorema de Bayes

El Teorema de Bayes constituye la piedra angular del razonamiento estadístico inverso. Mientras que la probabilidad condicional tradicional nos permite calcular la probabilidad de una observación (efecto) dado un estado físico conocido (causa), el Teorema de Bayes invierte esta lógica: nos permite actualizar la probabilidad de una causa hipotética a la luz de una nueva evidencia observacional.

Si  $A_1, A_2, \dots, A_k$  son eventos mutuamente excluyentes y exhaustivos (una partición del espacio muestral  $S$ ), y  $B$  es cualquier evento con  $P(B) > 0$ , la probabilidad posterior de  $A_i$  dado  $B$  se calcula mediante (Devore, Capítulo 2, Sección 2.4):

$$P(A_i | B) = \frac{P(B | A_i) P(A_i)}{\sum_{j=1}^k P(B | A_j) P(A_j)}$$

En esta formulación analítica,  $P(A_i)$  se denomina *probabilidad a priori*, representando nuestro conocimiento o creencia sobre el estado del sistema antes de realizar la observación  $B$ . El término  $P(B|A_i)$  es la *verosimilitud* (likelihood), que cuantifica la probabilidad de observar la evidencia  $B$  asumiendo que la hipótesis  $A_i$  es verdadera. El denominador, calculado mediante la Ley de Probabilidad Total, actúa como una constante de normalización. El resultado,  $P(A_i|B)$ , es la *probabilidad a posteriori*.

En la astronomía moderna, este marco es fundamental. Como se discute en *Astronomical Measurement* (Apéndice A.12.1, *Prior and Posterior Probability Distributions*), el enfoque bayesiano permite a los astrofísicos combinar conocimientos teóricos previos (como modelos de formación planetaria) con datos observacionales ruidosos (como fotones detectados en un CCD) para refinar rigurosamente los parámetros del universo.

### 2.3.1. Ejemplo 1: Demostración del Teorema de Actualización Secuencial

En la astronomía observacional y la exploración espacial, los datos rara vez llegan en un solo lote; las observaciones son secuenciales. Un telescopio toma una imagen, luego otra, y cada nueva medición debería refinar nuestro conocimiento del sistema. El Teorema de Bayes posee una propiedad matemática profunda y elegante que justifica este proceso: la *Actualización Secuencial*.

A continuación, demostraremos un teorema fundamental que establece que actualizar una hipótesis  $H$  con un primer conjunto de datos  $D_1$  y utilizar el resultado como la nueva probabilidad a priori para un segundo conjunto de datos  $D_2$ , es matemáticamente idéntico a actualizar la hipótesis original con ambos conjuntos de datos  $D_1 \cap D_2$  simultáneamente.

**Teorema de Actualización Secuencial:** Sean  $H$  una hipótesis, y  $D_1, D_2$  dos conjuntos de datos observacionales. La probabilidad posterior de  $H$  dado ambos conjuntos de datos satisface:

$$P(H|D_1 \cap D_2) = \frac{P(D_2|H \cap D_1)P(H|D_1)}{P(D_2|D_1)}$$

**Demostración:** La probabilidad de  $H$  dado que han ocurrido tanto  $D_1$  como  $D_2$  es:

$$P(H|D_1 \cap D_2) = \frac{P(H \cap D_1 \cap D_2)}{P(D_1 \cap D_2)}$$

Para el numerador, aplicamos la regla de multiplicación para la intersección de tres eventos. Podemos expandir  $P(H \cap D_1 \cap D_2)$  condicionando secuencialmente:

$$P(H \cap D_1 \cap D_2) = P(D_2|H \cap D_1) \cdot P(H \cap D_1)$$

A su vez, el término  $P(H \cap D_1)$  puede expandirse nuevamente usando la regla de multiplicación:

$$P(H \cap D_1) = P(H|D_1) \cdot P(D_1)$$

Sustituyendo esto en la expresión del numerador, obtenemos:

$$P(H \cap D_1 \cap D_2) = P(D_2|H \cap D_1) \cdot P(H|D_1) \cdot P(D_1)$$

Para el denominador, aplicamos la regla de multiplicación para la intersección de  $D_1$  y  $D_2$ :

$$P(D_1 \cap D_2) = P(D_2|D_1) \cdot P(D_1)$$

Ahora, sustituimos el numerador y el denominador expandidos en la ecuación original de la probabilidad condicional:

$$P(H|D_1 \cap D_2) = \frac{P(D_2|H \cap D_1) \cdot P(H|D_1) \cdot P(D_1)}{P(D_2|D_1) \cdot P(D_1)}$$

Dado que  $P(D_1) > 0$  (asumiendo que la primera observación es posible), podemos cancelar  $P(D_1)$  en el numerador y el denominador, lo que nos deja con el resultado deseado:

$$P(H|D_1 \cap D_2) = \frac{P(D_2|H \cap D_1)P(H|D_1)}{P(D_2|D_1)}$$

**Análisis del resultado:** Esta demostración revela que el término  $P(H|D_1)$  actúa exactamente como la *nueva probabilidad a priori* para el segundo paso, y  $P(D_2|H \cap D_1)$  actúa como la *nueva verosimilitud*. Esto garantiza que el orden en que procesamos las observaciones astronómicas (por ejemplo, medir la posición de un asteroide noche tras noche) no altera el resultado final, siempre que se aplique rigurosamente el Teorema de Bayes.

### 2.3.2. Ejemplo 2: Clasificación Mineralógica mediante Espectroscopia de Reflexión

Para ilustrar la actualización bayesiana en la ciencia planetaria, nos inspiramos en los principios de identificación mineralógica a través de firmas espectrales (*Planetary Geology*, Capítulo sobre *Spectroscopy and Mineralogy*).

Un rover marciano utiliza su espectrómetro de infrarrojo cercano para analizar un afloramiento rocoso. Basado en el contexto geológico de la cuenca de impacto, el equipo científico establece las siguientes probabilidades a priori para la composición de la roca:

- $A_1$ : La roca es basáltica (rica en piroxeno).  $P(A_1) = 0,20$ .
- $A_2$ : La roca es una condrita carbonácea (rica en arcillas).  $P(A_2) = 0,60$ .
- $A_3$ : La roca es metálica (hierro-níquel).  $P(A_3) = 0,20$ .

El espectrómetro detecta una profunda banda de absorción centrada en  $1 \mu\text{m}$ , una firma característica de los enlaces Fe-O en el piroxeno. Definimos este evento observacional como  $B$ . Conociendo las calibraciones instrumentales y las propiedades físicas de los minerales, establecemos las verosimilitudes:

- $P(B|A_1) = 0,90$  (El basalto casi siempre muestra esta banda).
- $P(B|A_2) = 0,10$  (Las condritas raramente la presentan).
- $P(B|A_3) = 0,05$  (Los metales no tienen bandas de absorción silicatadas).

Nos interesa calcular la probabilidad a posteriori de que la roca sea basáltica dado que se detectó la banda de 1  $\mu\text{m}$ , es decir,  $P(A_1|B)$ . Primero, calculamos la probabilidad total de observar la banda (el denominador):

$$P(B) = P(B|A_1)P(A_1) + P(B|A_2)P(A_2) + P(B|A_3)P(A_3)$$

$$P(B) = (0,90)(0,20) + (0,10)(0,60) + (0,05)(0,20) = 0,18 + 0,06 + 0,01 = 0,25$$

Aplicando ahora el Teorema de Bayes:

$$P(A_1|B) = \frac{P(B|A_1)P(A_1)}{P(B)} = \frac{0,18}{0,25} = 0,72$$

Analíticamente, este resultado es revelador. Aunque la creencia a priori de encontrar basalto en esa zona era baja (20 %), la fuerte evidencia espectral (una verosimilitud del 90 %) actualiza nuestra certeza a un 72 %. Este es el poder del razonamiento bayesiano (*Astronomical Measurement*, Sección A.12.2): los datos observacionales pueden dominar y corregir drásticamente las suposiciones iniciales derivadas de modelos geológicos contextuales.

### 2.3.3. Ejemplo 3: Aislamiento de Fallas en el Sistema de Control de Actitud

El Teorema de Bayes también es vital en la ingeniería de sistemas autónomos para la toma de decisiones en tiempo real. Tomemos como referencia los algoritmos de Detección y Aislamiento de Fallas (FDI) en naves espaciales (*Modern Spacecraft Guidance, Navigation, And Control*, Capítulo sobre *Fault Detection and Isolation*).

Durante una maniobra de giro, el ordenador de vuelo detecta un pico de torque anómalo en la rueda de reacción principal (Evento  $B$ ). El sistema debe diagnosticar la causa raíz para seleccionar el modo de contingencia adecuado. Las causas hipotéticas mutuamente excluyentes son:

- $A_1$ : Ruido transitorio en el sensor de efecto Hall (falsa alarma).  $P(A_1) = 0,70$ .
- $A_2$ : Impacto de micrometeorito en el panel solar adyacente, generando una vibración estructural.  $P(A_2) = 0,20$ .
- $A_3$ : Falla mecánica real en los rodamientos de la rueda.  $P(A_3) = 0,10$ .

Para discriminar entre estas causas, el sistema cruza la información con un sensor independiente: el rastreador de estrellas secundario. Si hay una vibración estructural real ( $A_2$ ) o una falla mecánica ( $A_3$ ), el rastreador de estrellas debería detectar un "jitter" (temblor) de alta frecuencia en la línea de visión. Definimos este evento corroborativo como  $C$ . Las verosimilitudes de detectar el jitter en el rastreador de estrellas son:

- $P(C|A_1) = 0,05$  (El ruido del sensor de la rueda no afecta al rastreador de estrellas).
- $P(C|A_2) = 0,85$  (La vibración estructural se propaga y es claramente visible en el rastreador).
- $P(C|A_3) = 0,40$  (La falla mecánica genera algo de vibración, pero menos acoplada a la estructura general).

El sistema de FDI necesita calcular la probabilidad a posteriori de que se trate de un impacto de micrometeorito ( $A_2$ ) dado que *ambos* sensores reportaron la anomalía. Asumiendo independencia condicional de los sensores dado el estado de la nave, el evento observacional combinado es la intersección del pico de torque ( $B$ ) y el jitter óptico ( $C$ ). Para simplificar el modelo bayesiano directo sobre la causa, actualizamos las probabilidades usando la nueva evidencia  $C$  sobre las creencias a priori de las causas.

La probabilidad total de observar el jitter  $C$  es:

$$P(C) = P(C|A_1)P(A_1) + P(C|A_2)P(A_2) + P(C|A_3)P(A_3)$$

$$P(C) = (0,05)(0,70) + (0,85)(0,20) + (0,40)(0,10) = 0,035 + 0,170 + 0,040 = 0,245$$

Aplicando el Teorema de Bayes para encontrar  $P(A_2|C)$ :

$$P(A_2|C) = \frac{P(C|A_2)P(A_2)}{P(C)} = \frac{0,170}{0,245} \approx 0,694$$

Antes de la observación del rastreador de estrellas, la hipótesis más probable era un simple error de sensor (70 %), lo que habría llevado al software a ignorar la alerta. Sin embargo, la evidencia cruzada ( $C$ ) invierte la situación: la probabilidad de un impacto de micrometeorito salta al 69.4 %. Con esta probabilidad a posteriori, el algoritmo de *Modern Spacecraft GN&C* puede justificar matemáticamente la transición a un modo de control de actitud que filtre las frecuencias de resonancia estructurales, evitando así que el sistema de control entre en inestabilidad por realimentación positiva de la vibración.

#### 2.3.4. Ejemplo 4: Clasificación Orbital de Cometas (Parabólico vs. Hiperbólico)

*Practical Astronomy with your Calculator* (Duffett-Smith y Zwart, Sección 61).

Cuando se descubre un nuevo cometa, determinar su excentricidad orbital ( $e$ ) es crucial para entender su origen. Si  $e = 1$ , la órbita es parabólica (el cometa está gravitacionalmente ligado al sistema solar o en el límite de escape). Si  $e > 1$ , la órbita es hiperbólica, lo que indicaría un objeto interestelar (como 'Oumuamua o Borisov) que solo está de paso.

Sin embargo, las mediciones astrométricas (Ascensión Recta y Declinación) tienen errores inherentes. Definamos el evento  $M$  como: *la excentricidad medida es  $\hat{e} \geq 1,0$* .

Tenemos dos hipótesis mutuamente excluyentes sobre la verdadera naturaleza del cometa:

- $H_P$ : El cometa tiene una órbita verdaderamente parabólica ( $e = 1$ ).
- $H_H$ : El cometa tiene una órbita verdaderamente hiperbólica ( $e > 1$ ).

Basado en el catálogo histórico de cometas, la inmensa mayoría de los cometas de período largo provienen de la nube de Oort y tienen órbitas parabólicas. Por lo tanto, establecemos las siguientes probabilidades a priori:

$$P(H_P) = 0,95$$

$$P(H_H) = 0,05$$

Conociendo la precisión típica de los telescopios terrestres y la propagación de errores en el cálculo de elementos orbitales (Duffett-Smith y Zwart, Sección 62), estimamos las siguientes verosimilitudes de obtener una medición  $\hat{e} \geq 1,0$ :

- $P(M|H_P) = 0,10$ : Si el cometa es realmente parabólico, hay un 10 % de probabilidad de que el ruido observacional empuje la excentricidad medida a  $\geq 1,0$  (falso positivo de hiperbolicidad).
- $P(M|H_H) = 0,90$ : Si el cometa es realmente hiperbólico, hay un 90 % de probabilidad de que la medición lo refleje correctamente como  $\geq 1,0$ .

El pipeline de reducción de datos reporta que para el nuevo cometa C/202X, la excentricidad calculada es  $\hat{e} = 1,03$ . Es decir, el evento  $M$  ha ocurrido. Nos interesa calcular la probabilidad a posteriori de que sea un objeto interestelar,  $P(H_H|M)$ .

Primero, calculamos la probabilidad total de observar  $M$  (el denominador del Teorema de Bayes):

$$P(M) = P(M|H_P)P(H_P) + P(M|H_H)P(H_H)$$

$$P(M) = (0,10)(0,95) + (0,90)(0,05) = 0,095 + 0,045 = 0,140$$

Ahora, aplicamos el Teorema de Bayes para encontrar la probabilidad posterior:

$$P(H_H|M) = \frac{P(M|H_H)P(H_H)}{P(M)} = \frac{0,045}{0,140} \approx 0,3214$$

**Conclusión:** A pesar de que la medición directa sugiere una órbita hiperbólica ( $\hat{e} = 1,03$ ), el Teorema de Bayes nos revela que la probabilidad real de que el cometa sea interestelar es de apenas un 32.14 %. La fuerte probabilidad a priori de que los cometas sean parabólicos (95 %), combinada con una tasa de falsos positivos del 10 % debido al error instrumental, hace que sea estadísticamente más probable (67.86 %) que el cometa sea en realidad parabólico y que la medición  $\hat{e} \geq 1,0$  sea solo una fluctuación del ruido. Este ejemplo demuestra por qué en la astrometría moderna, nunca se debe confiar ciegamente en un parámetro orbital derivado sin un análisis bayesiano riguroso que contemple las tasas base y los errores de medición.

# Clase 3

## 3.1. Conteos

En el desarrollo de la teoría de la probabilidad, antes de poder asignar valores numéricos a los eventos, es imperativo determinar el tamaño del espacio muestral, es decir, el número total de resultados posibles. Cuando los resultados de un experimento son numerosos, enumerarlos uno por uno se vuelve una tarea impracticable. Para resolver esto, la estadística se apoya en principios fundamentales de conteo.

El principio más elemental y poderoso es la **Regla del Producto** (Devore, Capítulo 2, Sección 2.3). Esta regla establece que si un proceso o experimento puede describirse como una sucesión de  $k$  etapas, donde la primera etapa tiene  $n_1$  resultados posibles, la segunda tiene  $n_2$  resultados (independientemente de lo que haya ocurrido en la primera), y así sucesivamente, entonces el número total de resultados en el espacio muestral  $S$  es el producto de las posibilidades de cada etapa:

$$N(S) = n_1 \times n_2 \times \cdots \times n_k$$

Complementariamente, la **Regla de la Suma** se utiliza cuando un evento puede descomponerse en categorías mutuamente excluyentes, sumando simplemente el número de resultados de cada categoría (Devore, Sección 2.3).

### 3.1.1. Ejemplo 1: Configuración de Carga Útil en una Sonda Espacial

Para ilustrar la Regla del Producto en un contexto de ingeniería espacial, nos inspiramos en la arquitectura modular de los subsistemas de naves no tripuladas (*Modern Spacecraft Guidance, Navigation, and Control*, Capítulo sobre *Spacecraft Subsystems and Payloads*).

Durante la fase de diseño preliminar de una misión a asteroides, el equipo de sistemas debe definir la configuración base del bus de la nave. El proceso de configuración se divide en tres etapas secuenciales e independientes, donde cada etapa representa la selección de un subsistema crítico:

- **Etap 1 (Propulsión):** Se debe elegir entre 3 tipos de sistemas de propulsión disponibles (Propulsión química bipropelente, Propulsión iónica de efecto Hall, Propulsión eléctrica de plasma).
- **Etap 2 (Navegación):** Se debe seleccionar el conjunto de sensores primarios entre 4 arquitecturas distintas (Solo rastreador de estrellas, Rastreador de estrellas + IMU, Navegación óptica relativa, Navegación por radio de espacio profundo).
- **Etap 3 (Comunicación):** Se debe elegir la banda de frecuencia para el enlace de telemetry entre 2 opciones (Banda X, Banda Ka).



El experimento consiste en definir una configuración única para la sonda. Aplicando la Regla del Producto (Devore, Sección 2.3), el número total de configuraciones posibles (el tamaño del espacio muestral  $S$ ) es:

$$N(S) = 3 \times 4 \times 2 = 24$$

Desde una perspectiva analítica, este espacio muestral de 24 elementos define el universo de configuraciones que los ingenieros deben evaluar mediante simulaciones de Monte Carlo para garantizar que al menos una configuración satisfaga los requisitos de masa, potencia y  $\Delta V$  de la misión. Si se quisiera calcular la probabilidad de seleccionar al azar una configuración que utilice propulsión iónica (asumiendo que todas las configuraciones son igualmente probables en un sorteo de diseño), el conteo preciso de  $N(S)$  es el denominador indispensable para aplicar la definición clásica de probabilidad.

### 3.1.2. Ejemplo 2: Matriz de Observación Fotométrica en un Telescopio Robótico

En la astronomía observacional, la planificación de las tomas de datos implica la configuración de múltiples parámetros instrumentales. Tomemos como referencia los sistemas de adquisición de datos y la fotometría de precisión (*Practical Astronomy with your Calculator*, Sección sobre *Photometry and the UBVRI System*, y *Astronomical Measurement*, Capítulo sobre *Detectors and Instruments*).

Un telescopio robótico está programado para ejecutar una secuencia de observación de un cúmulo estelar. El pipeline de control del telescopio debe configurar el instrumento para cada exposición individual. La configuración de un "frame"(cuadro) de imagen se realiza en tres etapas secuenciales:

- **Etapas 1 (Filtro):** La rueda de filtros selecciona una banda espectral entre 5 opciones estándar del sistema Johnson-Cousins ( $U, B, V, R, I$ ).
- **Etapas 2 (Tiempo de exposición):** El controlador de la cámara CCD establece el tiempo de integración entre 3 opciones predefinidas (Corto: 10s, Medio: 60s, Largo: 300s).
- **Etapas 3 (Modo de lectura):** Se elige la velocidad de lectura del CCD para equilibrar el ruido de lectura y el tiempo muerto entre 2 opciones (Modo Rápido, Modo Lento).

El experimento consiste en generar un tipo único de cuadro fotométrico. Utilizando la Regla del Producto, el número total de configuraciones de cuadro distintas que el telescopio puede producir es:

$$N(S) = 5 \times 3 \times 2 = 30$$

Este resultado analítico nos indica que el espacio muestral de posibles configuraciones de un solo cuadro está compuesto por 30 eventos simples. Por ejemplo, un resultado simple sería la tupla ( $V$ , Medio, Lento).

Si el telescopio toma una secuencia de 3 cuadros consecutivos para promediar y reducir el ruido cósmico, y cada cuadro se configura de manera independiente, la Regla del Producto se aplica

nuevamente a nivel de la secuencia. El número total de secuencias de 3 cuadros posibles sería  $30 \times 30 \times 30 = 27,000$ . Comprender la magnitud de estos espacios muestrales discretos es fundamental para los astrónomos al diseñar estrategias de observación (dithering) y para los estadísticos que modelan la probabilidad de que ciertos errores sistemáticos instrumentales (como el ruido de lectura en el modo rápido) se correlacionen con bandas espectrales específicas.

## 3.2. Permutaciones

En muchas situaciones experimentales, no solo nos interesa seleccionar un subconjunto de objetos o eventos de una población mayor, sino que el *orden* en el que estos elementos son seleccionados o dispuestos es fundamental para el resultado del experimento. Cuando el orden de los elementos importa, estamos tratando con permutaciones.

Una permutación es un subconjunto ordenado de tamaño  $k$  que se puede formar a partir de  $n$  individuos u objetos en un grupo (Devore, Capítulo 2, Sección 2.3). El número de permutaciones de tamaño  $k$  que se pueden formar con  $n$  objetos se denota como  $P_{k,n}$ .

Análiticamente, la fórmula para calcular el número de permutaciones se deriva directamente de la Regla del Producto. Para la primera posición hay  $n$  opciones, para la segunda hay  $n - 1$  opciones (ya que un objeto ha sido utilizado y no hay reemplazo), y así sucesivamente hasta la  $k$ -ésima posición, donde quedan  $n - k + 1$  opciones. Esto se expresa de manera compacta utilizando la notación factorial:

$$P_{k,n} = n(n-1)(n-2) \cdots (n-k+1) = \frac{n!}{(n-k)!}$$

La distinción analítica crucial entre permutaciones y combinaciones (que se verá en la siguiente sección) radica estrictamente en la relevancia del orden.

### 3.2.1. Ejemplo 1: Secuencia de Apuntamiento en un Telescopio Espacial

Para ilustrar la aplicación de las permutaciones en la planificación orbital, consideremos la programación de un telescopio espacial en órbita baja terrestre (LEO). El telescopio tiene una lista de 10 objetivos astrofísicos de alta prioridad (por ejemplo, exoplanetas específicos en tránsito). Sin embargo, debido a las estrictas restricciones de presupuesto térmico y a las ventanas de comunicación con la red de espacio profundo, el telescopio solo puede realizar observaciones consecutivas de 3 de estos 10 objetivos durante una órbita específica.

Definamos el experimento como: *Seleccionar y ordenar 3 objetivos de una lista de 10 para ser observados en secuencia.*

Es imperativo modelar esto como una permutación y no como una simple combinación. En la dinámica de naves espaciales (*Modern Spacecraft Guidance, Navigation, and Control*, Capítulo sobre *Attitude Control Systems*), el orden de apuntamiento (slew) altera drásticamente el perfil térmico de la nave. Observar el objetivo A, luego el B y finalmente el C requiere un gasto de

combustible y una disipación de calor completamente diferentes que observar C, luego B y luego A, debido a la inercia del telescopio y la exposición diferencial de sus radiadores al Sol.

Por lo tanto, calculamos el número total de secuencias de observación posibles (el tamaño del espacio muestral  $S$ ) utilizando la fórmula de permutaciones con  $n = 10$  y  $k = 3$ :

$$P_{3,10} = \frac{10!}{(10-3)!} = \frac{10!}{7!} = 10 \times 9 \times 8 = 720$$

Existen 720 secuencias ordenadas distintas. Si el planificador de la misión quisiera calcular la probabilidad de que una secuencia generada aleatoriamente cumpla con un perfil térmico específico (asumiendo que todas las permutaciones son igualmente probables en un sorteo ciego), el denominador de su modelo probabilístico sería rigurosamente 720. Ignorar el orden y usar combinaciones ( $\binom{10}{3} = 120$ ) subestimaría el espacio muestral real y destruiría la validez física del modelo de probabilidad.

### 3.2.2. Ejemplo 2: Secuencia de Análisis en un Espectrómetro de Masas Planetario

En la ciencia planetaria, el análisis in situ de muestras geológicas requiere instrumentación de altísima precisión. Tomemos como referencia los procedimientos de los laboratorios de muestras en rovers marcianos, como el instrumento SAM (Sample Analysis at Mars) (*Planetary Geology*, Capítulo sobre *In Situ Instrumentation and Analytical Techniques*).

Un rover ha recolectado polvo y regolito de 7 ubicaciones geológicas distintas. El laboratorio a bordo debe procesar 4 de estas muestras en una secuencia de horneado dentro del espectrómetro de masas. Debido a la física del instrumento, el orden en que las muestras se introducen en la cámara de vacío es crítico: las muestras procesadas primero pueden dejar residuos de memoria" (gases adsorbidos en las paredes) que contaminan las lecturas de las muestras procesadas posteriormente.

Definimos el experimento como: *Seleccionar y ordenar 4 muestras geológicas de un total de 7 para la secuencia de análisis.*

Dado que la secuencia de horneado afecta los resultados científicos (la contaminación cruzada depende de qué muestra precede a cuál), el orden es una variable de estado fundamental. Aplicamos la fórmula de permutaciones (Devore, Sección 2.3) con  $n = 7$  y  $k = 4$ :

$$P_{4,7} = \frac{7!}{(7-4)!} = \frac{7!}{3!} = 7 \times 6 \times 5 \times 4 = 840$$

El espacio muestral consta de 840 secuencias de análisis únicas. Desde una perspectiva de diseño de experimentos, el equipo científico debe evaluar estas 840 permutaciones para encontrar aquella que minimice el sesgo analítico (por ejemplo, colocando las muestras más 'prístinas' al final de la secuencia o intercalando muestras de limpieza). La modelación permutacional permite cuantificar la incertidumbre introducida por el orden de procesamiento y justificar analíticamente la secuencia óptima antes de comandar el instrumento en Marte.

### 3.3. Combinaciones

En muchas aplicaciones de la estadística y la probabilidad, el interés analítico no radica en el orden de los elementos seleccionados, sino únicamente en *cuáles* elementos conforman el subconjunto resultante. Cuando se seleccionan  $k$  objetos de un grupo de  $n$  objetos sin reemplazo y el orden de selección es irrelevante, el número de subconjuntos posibles se denomina combinaciones (Devore, Capítulo 2, Sección 2.3).

La fórmula para calcular el número de combinaciones de tamaño  $k$  que se pueden extraer de un conjunto de tamaño  $n$  se denota como  $\binom{n}{k}$  y se expresa analíticamente mediante factoriales:

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

Es crucial establecer la distinción analítica entre permutaciones y combinaciones. Dado que cada combinación de  $k$  elementos puede ser ordenada internamente de  $k!$  formas distintas, el número de combinaciones es siempre una fracción del número de permutaciones. La relación que las vincula es:

$$\binom{n}{k} = \frac{P_{k,n}}{k!}$$

#### 3.3.1. Ejemplo 1: Selección de Sitios de Aterrizaje en Ciencia Planetaria

Para ilustrar el uso de combinaciones en la planificación de misiones, nos inspiramos en los criterios de selección de regiones de interés y sitios de aterrizaje discutidos en *Planetary Geology* (Capítulo sobre *Landing Site Selection and Geological Context*).

Durante la Fase 0/A de una misión de retorno de muestras marcianas, el equipo científico ha identificado un total de  $n = 15$  sitios candidatos que poseen alto valor geológico (por ejemplo, lechos de antiguos lagos o depósitos de arcillas). Sin embargo, debido a las limitaciones estrictas de presupuesto, tiempo de computación y ventanas de lanzamiento, la ingeniería de sistemas solo puede realizar un estudio de factibilidad detallado para un subconjunto de exactamente  $k = 4$  sitios.

Definimos el experimento como: *Seleccionar un grupo de 4 sitios de aterrizaje de los 15 candidatos disponibles.*

Dado que en esta etapa el objetivo es simplemente formar un *conjunto* de 4 sitios para ser evaluados en paralelo por los equipos de ingeniería, el orden en el que los sitios son nominados o extraídos de la lista original es completamente irrelevante. El resultado del experimento es la composición del grupo, no su secuencia. Por lo tanto, aplicamos la fórmula de combinaciones (Devore, Sección 2.3):

$$\binom{15}{4} = \frac{15!}{4!(15-4)!} = \frac{15!}{4! \cdot 11!} = \frac{15 \times 14 \times 13 \times 12}{4 \times 3 \times 2 \times 1} = \frac{32760}{24} = 1365$$

El espacio muestral  $S$  consta de 1365 configuraciones únicas de sitios.

Desde una perspectiva analítica, si hubiéramos cometido el error de modelar esto como una permutación (asumiendo que el orden de prioridad de los 4 sitios importa), habríamos calculado  $P_{4,15} = 32760$  resultados. Esto habría sobreestimado el espacio muestral en un factor de  $4! = 24$ , introduciendo una asimetría inexistente en el problema físico y haciendo que cualquier cálculo de probabilidad clásica (como la probabilidad de que un sitio específico con una mineralogía particular sea incluido en el estudio) fuera matemáticamente erróneo. El uso correcto de combinaciones garantiza que la asignación de probabilidades a los eventos refleje fielmente la naturaleza del proceso de selección.

### 3.3.2. Ejemplo 2: Configuración de Sub-arrays en Radio Interferometría

En la astronomía observacional de altas resoluciones, la disposición geométrica de los telescopios define la calidad de la imagen final. Tomemos como referencia los principios de síntesis de apertura y diseño de arreglos en *Astronomical Measurement* (Capítulo sobre *Interferometry and Aperture Synthesis*).

Considere un observatorio de radio interferometría (análogo al VLA o ALMA) que cuenta con una configuración base de  $n = 10$  antenas parabólicas distribuidas a lo largo de una pista en forma de "Y". Debido a una falla temporal en el sistema de criogenia de los receptores, 4 de las antenas han sido desconectadas de la red de correlación, dejando únicamente  $k = 6$  antenas operativas para una campaña de observación crítica de un disco protoplanetario.

Definimos el experimento como: *Determinar la configuración del arreglo de observación seleccionando las 6 antenas que formarán la red activa.*

En la interferometría, la calidad de la imagen (el haz sintetizado y la cobertura del plano  $uv$ ) depende exclusivamente de *cuáles* antenas están activas y de las distancias geométricas entre ellas (las líneas base). El orden temporal o la secuencia en la que el software de control 'activa' o 'selecciona' las antenas no altera en absoluto la respuesta física del interferómetro. Por lo tanto, el problema es estrictamente de combinaciones.

Calculamos el número total de configuraciones de sub-arrays posibles que el observatorio podría haber formado con 6 antenas de un total de 10:

$$\binom{10}{6} = \frac{10!}{6!(10-6)!} = \frac{10!}{6! \cdot 4!} = \frac{10 \times 9 \times 8 \times 7}{4 \times 3 \times 2 \times 1} = \frac{5040}{24} = 210$$

Existen 210 sub-arrays únicos posibles.

Este resultado es fundamental para los astrónomos que realizan simulaciones de rendimiento antes de la observación. Dado que cada una de las 210 combinaciones produce un patrón de interferencia (y por ende, artefactos de imagen o "sidelobes") ligeramente distinto, el equipo científico debe evaluar este espacio muestral de 210 elementos para determinar si la configuración específica de 6 antenas que quedó operativa es suficiente para cumplir con los requisitos de dinámica de contraste necesarios para detectar un exoplaneta en formación dentro del disco. Nuevamente, la correcta delimitación del espacio muestral mediante combinaciones (Devore, Sección 2.3) es el prerrequisito para cualquier inferencia estadística sobre la confiabilidad de los datos astronómicos obtenidos.

# Clase 4

## 4.1. Variables aleatorias

Una variable aleatoria (v.a.) es una regla o función que asocia un valor numérico a cada resultado de un experimento cuyo espacio muestral es  $S$  (Devore, Capítulo 3, Sección 3.1).

Analíticamente, si denotamos un resultado individual del espacio muestral como  $\omega$ , una variable aleatoria  $X$  es una función que mapea el espacio muestral al conjunto de los números reales:

$$X : S \rightarrow \mathbb{R}$$

El valor observado de la variable aleatoria después de realizar el experimento se denomina valor realizado y se denota con la letra minúscula correspondiente (por ejemplo,  $x$ ). Las variables aleatorias se clasifican fundamentalmente en dos tipos:

- **Variables aleatorias discretas:** Sus posibles valores constituyen un conjunto finito o una secuencia infinita numerable (Devore, Sección 3.1).
- **Variables aleatorias continuas:** Sus posibles valores comprenden un intervalo continuo en la línea de los números reales, y la probabilidad de que asuman un valor exacto es estrictamente cero (Devore, Sección 3.1 y Capítulo 4).

### 4.1.1. Ejemplo 1: Variable Aleatoria Discreta en la Adquisición de Estrellas Guía

(*Modern Spacecraft Guidance, Navigation, and Control*, Capítulo sobre *Attitude Determination Systems*).

Un rastreador de estrellas (Star Tracker) a bordo de un satélite de observación terrestre toma una imagen del cielo nocturno para determinar la orientación de la nave. El catálogo interno del instrumento espera encontrar exactamente  $N = 8$  estrellas guía brillantes dentro de su campo de visión (FOV) para esa coordenada de apuntamiento específica. Sin embargo, debido a la presencia de ruido cósmico, luz parásita (stray light) o la magnitud límite del sensor, no todas las estrellas esperadas son necesariamente identificadas por el algoritmo de extracción de centroides.

Definimos el experimento como: *Ejecutar un ciclo de adquisición de actitud con el rastreador de estrellas*. El espacio muestral  $S$  está compuesto por todas las combinaciones posibles de estrellas identificadas y no identificadas (un total de  $2^8 = 256$  resultados cualitativos distintos, como "se identificaron las estrellas 1, 3, 5, 7, 8", etc.).

En lugar de trabajar con estos 256 resultados textuales, definimos la variable aleatoria discreta  $X$  como:

$X$  = el número de estrellas guía exitosamente identificadas por el rastreador.

El conjunto de posibles valores para  $X$  es finito y numerable:

$$D_X = \{0, 1, 2, 3, 4, 5, 6, 7, 8\}$$

Esta variable aleatoria transforma un problema de reconocimiento de patrones complejos en un escalar discreto. El sistema de control de actitud (ADCS) utiliza el valor realizado  $x$  para calcular un índice de confianza. Por ejemplo, si el evento observado es  $x = 3$ , el software de vuelo sabe que la solución de actitud tiene una alta incertidumbre y podría decidir rechazar la medición o cambiar a un modo de navegación inercial degradada. La naturaleza discreta de  $X$  permite modelar su comportamiento utilizando una Función de Masa de Probabilidad (FMP),  $p(x) = P(X = x)$ , la cual asigna una probabilidad estrictamente positiva a cada uno de los 9 enteros posibles.

#### 4.1.2. Ejemplo 2: Variable Aleatoria Continua en la Espectroscopia de Velocidad Radial

Principios de medición de precisión y espectroscopia de alta resolución (*Astronomical Measurement, Capítulo sobre Spectroscopy and Radial Velocity Measurements*).

En la búsqueda de exoplanetas mediante el método de velocidad radial, un espectrógrafo de alta estabilidad (como HARPS o ESPRESSO) mide el desplazamiento Doppler de las líneas de absorción en el espectro de una estrella anfitriona. El instrumento descompone la luz y calcula el centroide de una línea espectral específica (por ejemplo, la línea H-alfa del Hidrógeno) para determinar la velocidad de la estrella a lo largo de la línea de visión.

Definimos el experimento como: *Medir la velocidad de la estrella en un instante (época) dado*. El espacio muestral  $S$  consiste en todos los posibles desplazamientos físicos del centroide de la línea espectral en el detector CCD, los cuales están sujetos a ruido de fotones, ruido térmico del instrumento y 'jitter' astrofísico de la propia estrella.

Definimos la variable aleatoria continua  $Y$  como:

$Y$  = la velocidad radial exacta medida de la estrella (en metros por segundo, m/s).

A diferencia del ejemplo anterior, el conjunto de posibles valores para  $Y$  no es numerable. La velocidad puede tomar cualquier valor dentro de un intervalo físico razonable, por ejemplo:

$$D_Y = [-5000,000 \dots, 5000,000 \dots] \subset \mathbb{R}$$

Dado que  $Y$  puede asumir infinitos valores no numerables dentro de un intervalo (incluyendo números irracionales), la probabilidad de que la medición sea un valor exacto y específico (por ejemplo,  $Y = 12,3456789 \dots$  m/s) es estrictamente cero:  $P(Y = c) = 0$  para cualquier constante  $c$  (Devore, Capítulo 4, Sección 4.1).

Por lo tanto, no podemos asignar probabilidades a puntos individuales mediante una función de masa. En su lugar, las probabilidades se asignan a *intervalos* de valores (por ejemplo, la probabilidad de que la velocidad radial esté entre  $-10,5$  y  $-10,0$  m/s). Esto requiere el uso de una Función de Densidad de Probabilidad (FDP),  $f(y)$ , donde la probabilidad se calcula mediante integración:

$$P(a \leq Y \leq b) = \int_a^b f(y) dy$$

## 4.2. Funciones de densidad de probabilidad

A diferencia de las variables discretas, donde podemos asignar probabilidades positivas a puntos exactos mediante una función de masa, en el caso continuo la probabilidad de que la variable asuma un valor exacto y específico es estrictamente cero:  $P(X = c) = 0$  (Devore, Capítulo 4, Sección 4.1).

Para modelar estas variables, utilizamos la **Función de Densidad de Probabilidad (FDP)**, denotada como  $f(x)$ . De Una función  $f(x)$  es una FDP legítima si y solo si satisface rigurosamente las siguientes tres condiciones (Devore, Sección 4.1):

1.  $f(x) \geq 0$  para todo  $x$  (la densidad de probabilidad no puede ser negativa).
2.  $\int_{-\infty}^{\infty} f(x) dx = 1$  (la probabilidad total en todo el espacio muestral continuo es la certeza absoluta).
3.  $P(a \leq X \leq b) = \int_a^b f(x) dx$  (la probabilidad de que  $X$  caiga en un intervalo específico es el área bajo la curva de densidad entre  $a$  y  $b$ ).

La FDP no nos da la probabilidad en un punto, sino la 'densidad' de probabilidad.

### 4.2.1. Ejemplo 1: Tiempo de Permanencia de un Cometa en el Sistema Solar Interior

*Practical Astronomy with your Calculator* (Duffett-Smith y Zwart, Sección 61 y 62).

Cuando un cometa de período largo entra al sistema solar interior, su velocidad varía drásticamente debido a la conservación del momento angular (es mucho más rápido en el perihelio que en el afelio). Definamos la variable aleatoria continua  $X$  como el *tiempo normalizado* que el cometa pasa dentro de la región de los planetas terrestres (digamos,  $r < 3$  UA) durante un paso orbital, relativo a su tiempo máximo teórico.

Supongamos que, debido a la distribución de velocidades orbitales, la FDP de esta fracción de tiempo  $X$  está modelada por una función cuadrática en el intervalo  $[0, 1]$ :

$$f(x) = \begin{cases} kx(1-x) & \text{para } 0 < x < 1 \\ 0 & \text{en otro caso} \end{cases}$$

**a) Determinación de la constante de normalización  $k$ :** Para que  $f(x)$  sea una FDP legítima, el área total bajo la curva debe ser 1 (Devore, Sección 4.1).

$$\int_{-\infty}^{\infty} f(x) dx = \int_0^1 k(x - x^2) dx = k \left[ \frac{x^2}{2} - \frac{x^3}{3} \right]_0^1 = k \left( \frac{1}{2} - \frac{1}{3} \right) = k \left( \frac{1}{6} \right) = 1$$

Por lo tanto, la constante es  $k = 6$ . La FDP completa es  $f(x) = 6x(1-x)$  para  $0 < x < 1$ .

**b) Probabilidad de una permanencia prolongada:** Nos interesa calcular la probabilidad de que el cometa pase más del 50 % de su tiempo máximo en el sistema interior, es decir,  $P(X > 0,5)$ .

$$P(X > 0,5) = \int_{0,5}^1 6(x - x^2) dx = 6 \left[ \frac{x^2}{2} - \frac{x^3}{3} \right]_{0,5}^1$$



$$= 6 \left[ \left( \frac{1}{2} - \frac{1}{3} \right) - \left( \frac{0,25}{2} - \frac{0,125}{3} \right) \right] = 6 \left[ \frac{1}{6} - \left( \frac{1}{8} - \frac{1}{24} \right) \right] = 6 \left[ \frac{1}{6} - \frac{2}{24} \right] = 6 \left[ \frac{1}{6} - \frac{1}{12} \right] = 6 \left( \frac{1}{12} \right) = 0,5$$

**c) Obtención de la Función de Distribución Acumulativa (FDA):** La FDA,  $F(x)$ , es fundamental para calcular percentiles y generar variables aleatorias para simulaciones de Monte Carlo (Devore, Sección 4.2). Para  $0 \leq x \leq 1$ :

$$F(x) = \int_{-\infty}^x f(t) dt = \int_0^x 6(t - t^2) dt = 6 \left[ \frac{t^2}{2} - \frac{t^3}{3} \right]_0^x = 3x^2 - 2x^3$$

La FDA completa se define por tramos:  $F(x) = 0$  si  $x < 0$ ;  $F(x) = 3x^2 - 2x^3$  si  $0 \leq x \leq 1$ ; y  $F(x) = 1$  si  $x > 1$ .

**d) Cálculo del Valor Esperado (Media):** El tiempo normalizado esperado que un cometa de esta población pasa en el sistema interior es:

$$\begin{aligned} E[X] &= \int_{-\infty}^{\infty} x f(x) dx = \int_0^1 x[6x(1-x)] dx = 6 \int_0^1 (x^2 - x^3) dx \\ &= 6 \left[ \frac{x^3}{3} - \frac{x^4}{4} \right]_0^1 = 6 \left( \frac{1}{3} - \frac{1}{4} \right) = 6 \left( \frac{1}{12} \right) = 0,5 \end{aligned}$$

#### 4.2.2. Ejemplo 2: Error de Apuntamiento de la Antena de Alta Ganancia en una Sonda

*Modern Spacecraft Guidance, Navigation, and Control* (Capítulo sobre *Communication Subsystems and Link Budgets*).

Definamos la variable aleatoria continua  $X$  como la magnitud del error de apuntamiento de la antena de alta ganancia (HGA) de una sonda en la deep space, medido en arcosegundos. Debido a los micro-vibraciones de las ruedas de reacción y los límites físicos del sensor estelar, el error está acotado entre 0 y 5 arcosegundos. La FDP del error está modelada por:

$$f(x) = \begin{cases} k(25 - x^2) & \text{para } 0 \leq x \leq 5 \\ 0 & \text{en otro caso} \end{cases}$$

Este modelo refleja que los errores pequeños son mucho más probables (mayor densidad) que los errores grandes que se acercan al límite mecánico de 5 arcosegundos. Analicemos las propiedades de esta distribución:

**a) Determinación de la constante  $k$ :** Aplicamos la condición de normalización (Devore, Sección 4.1):

$$\int_0^5 k(25 - x^2) dx = k \left[ 25x - \frac{x^3}{3} \right]_0^5 = k \left( 125 - \frac{125}{3} \right) = k \left( \frac{250}{3} \right) = 1$$

Despejando, obtenemos  $k = \frac{3}{250} = 0,012$ .

**b) Probabilidad de Pérdida de Enlace (Loss of Signal):** El presupuesto de enlace de la misión dicta que si el error de apuntamiento supera los 3 arcosegundos, la ganancia de la antena

cae por debajo del umbral requerido, provocando una pérdida temporal de datos (Loss of Signal, LoS). Calculamos  $P(X > 3)$ :

$$\begin{aligned} P(X > 3) &= \int_3^5 \frac{3}{250} (25 - x^2) dx = \frac{3}{250} \left[ 25x - \frac{x^3}{3} \right]_3^5 \\ &= \frac{3}{250} \left[ \left( 125 - \frac{125}{3} \right) - \left( 75 - \frac{27}{3} \right) \right] = \frac{3}{250} \left[ \frac{250}{3} - (75 - 9) \right] \\ &= \frac{3}{250} \left[ \frac{250}{3} - 66 \right] = 1 - \frac{198}{250} = 1 - 0,792 = 0,208 \end{aligned}$$

Existe un 20.8 % de probabilidad de que, en un instante aleatorio, el error de apuntamiento sea lo suficientemente grande como para degradar o perder el enlace de telemetry.

**c) Cálculo del Error de Apuntamiento Esperado (Media):** El valor esperado nos indica el sesgo o error promedio del sistema (Devore, Sección 4.2):

$$\begin{aligned} E[X] &= \int_0^5 x \left[ \frac{3}{250} (25 - x^2) \right] dx = \frac{3}{250} \int_0^5 (25x - x^3) dx \\ &= \frac{3}{250} \left[ \frac{25x^2}{2} - \frac{x^4}{4} \right]_0^5 = \frac{3}{250} \left[ \frac{625}{2} - \frac{625}{4} \right] = \frac{3}{250} \left[ \frac{625}{4} \right] = \frac{1875}{1000} = 1,875 \text{ arcosegundos.} \end{aligned}$$

El error promedio del sistema es de 1.875 arcosegundos.

**d) Probabilidad de operar dentro de la tolerancia de alta precisión:** Supongamos que ciertos modos de observación científica (como la espectroscopía de alta resolución con una rendija estrecha) requieren que el error de apuntamiento esté a menos de 1 arcosegundo de distancia del error promedio (es decir, en el intervalo  $[E[X] - 1, E[X] + 1] = [0,875, 2,875]$ ). Calculamos esta probabilidad:

$$\begin{aligned} P(0,875 \leq X \leq 2,875) &= \int_{0,875}^{2,875} \frac{3}{250} (25 - x^2) dx = \frac{3}{250} \left[ 25x - \frac{x^3}{3} \right]_{0,875}^{2,875} \\ P &= \frac{3}{250} \left( \frac{98233 - 33257}{1536} \right) = \frac{3}{250} \left( \frac{64976}{1536} \right) = \frac{3}{250} \left( \frac{4061}{96} \right) = \frac{4061}{8000} = 0,507625 \end{aligned}$$

Existe aproximadamente un 50.76 % de probabilidad de que el error de apuntamiento caiga dentro de esta ventana de alta precisión de  $\pm 1$  arcosegundo alrededor de la media.

### 4.3. Función de distribución acumulativa

La función de distribución acumulativa  $F(x)$  de una variable aleatoria continua  $X$  se define para cualquier número real  $x$  como la probabilidad de que  $X$  tome un valor menor o igual a  $x$  (Devore, Capítulo 4, Sección 4.2):

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt$$

Primero, es una función monótona no decreciente. Segundo, sus límites asintóticos son  $\lim_{x \rightarrow -\infty} F(x) = 0$  y  $\lim_{x \rightarrow \infty} F(x) = 1$ . Tercero, la probabilidad de que la variable caiga en un intervalo específico  $(a, b]$  se calcula de manera directa y elegante sin necesidad de reintegrar la FDP:

$$P(a < X \leq b) = F(b) - F(a)$$

Además, la FDA es la vía principal para definir y calcular percentiles, cuartiles y medianas. Si  $X$  es continua y  $F(x)$  es estrictamente creciente, la derivada de la FDA nos devuelve la FDP:  $f(x) = \frac{d}{dx} F(x)$  (Devore, Sección 4.2).

### 4.3.1. Ejemplo 1: Perfil de Densidad de Polvo en un Disco Protoplanetario

(*Planetary Geology*, Capítulo sobre *Protoplanetary Disks and Planetesimal Formation*; *Astronomical Measurement*, Sección sobre *Radiative Transfer*).

Considere un disco protoplanetario alrededor de una estrella joven. Definimos la variable aleatoria continua  $X$  como la distancia radial normalizada (adimensional) de un grano de polvo respecto al radio exterior del disco, de modo que  $X \in (0, 1)$ . Debido a los procesos de arrastre aerodinámico y la dinámica orbital, la densidad de probabilidad de encontrar un grano de polvo de un tamaño específico a una distancia  $x$  está modelada por la siguiente FDP:

$$f(x) = \begin{cases} 4x^3 & \text{para } 0 < x < 1 \\ 0 & \text{en otro caso} \end{cases}$$

Esta función indica que la probabilidad de encontrar polvo aumenta drásticamente hacia las regiones exteriores del disco modelado.

**a) Obtención de la Función de Distribución Acumulativa:** Para  $0 \leq x \leq 1$ , integramos la FDP desde el límite inferior del soporte hasta  $x$ :

$$F(x) = \int_0^x 4t^3 dt = [t^4]_0^x = x^4$$

La FDA completa se define por tramos:  $F(x) = 0$  si  $x \leq 0$ ;  $F(x) = x^4$  si  $0 < x < 1$ ; y  $F(x) = 1$  si  $x \geq 1$ .

**b) Probabilidad de localización en la 'línea de hielo':** En la ciencia planetaria, la 'línea de hielo' es la distancia a la cual los compuestos volátiles como el agua se condensan en grano de hielo, un paso crítico para la formación de núcleos de gigantes gaseosos. Supongamos que esta región corresponde al intervalo normalizado  $0,4 < X \leq 0,6$ . Usando la propiedad de la FDA (Devore, Sección 4.2):

$$P(0,4 < X \leq 0,6) = F(0,6) - F(0,4) = (0,6)^4 - (0,4)^4 = 0,1296 - 0,0256 = 0,1040$$

Existe un 10.4 % de probabilidad de que un grano de polvo seleccionado al azar se encuentre en esta región crítica de condensación.

c) **Cálculo de la Mediana Radial:** La mediana  $m$  es el valor que divide la distribución de probabilidad en dos mitades iguales, es decir, el radio que encierra el 50 % de la masa de polvo total. Resolvemos  $F(m) = 0,5$ :

$$m^4 = 0,5 \implies m = (0,5)^{1/4} \approx 0,8409$$

La mediana radial es aproximadamente 0.84. Aunque el disco llega hasta  $x = 1$ , la mitad de los granos de polvo están concentrados en el 84 % exterior del disco, confirmando la tendencia de acumulación de materia hacia las regiones frías y lejanas.

d) **Determinación del Percentil 90:** Para calibrar un instrumento de observación que solo puede resolver estructuras más allá de cierto radio, necesitamos el percentil 90 ( $P_{90}$ ). Resolvemos  $F(x) = 0,90$ :

$$x^4 = 0,90 \implies x = (0,90)^{0,25} \approx 0,9740$$

El 90 % de los granos de polvo se encuentran a una distancia normalizada menor o igual a 0.974.

### 4.3.2. Ejemplo 2: Error Radial en el Elipse de Aterrizaje de un Rover

Análisis de desempeño de navegación y los márgenes de error en las misiones a Marte (*Modern Spacecraft Guidance, Navigation, and Control*, Capítulo sobre *Entry, Descent, and Landing Systems*).

Cuando un rover es lanzado hacia la superficie marciana, el punto de impacto real rara vez coincide con el punto de referencia (target). Definimos la variable aleatoria continua  $X$  como el error radial de aterrizaje, es decir, la distancia euclidiana (en kilómetros) desde el centro del elipse de aterrizaje designado hasta el punto de impacto real.

Debido a que los errores en los ejes ortogonales (Norte y Este) suelen modelarse como variables normales independientes con media cero y misma varianza, la distancia radial resultante  $X$  sigue una **Distribución de Rayleigh** (mencionada en Devore, Ejercicios de la Sección 4.4). La FDP del error radial es:

$$f(x) = \begin{cases} \frac{x}{\sigma^2} e^{-x^2/(2\sigma^2)} & \text{para } x \geq 0 \\ 0 & \text{en otro caso} \end{cases}$$

donde  $\sigma$  es el parámetro de escala que representa la dispersión característica del sistema de navegación. Desarrollaremos las propiedades de esta distribución utilizando su FDA.

a) **Derivación de la FDA del Error Radial:** Para  $x \geq 0$ , calculamos la integral de la FDP. Utilizamos la sustitución  $u = \frac{t^2}{2\sigma^2}$ , de donde  $du = \frac{t}{\sigma^2} dt$ :

$$F(x) = \int_0^x \frac{t}{\sigma^2} e^{-t^2/(2\sigma^2)} dt = \int_0^{x^2/(2\sigma^2)} e^{-u} du$$

$$F(x) = [-e^{-u}]_0^{x^2/(2\sigma^2)} = 1 - e^{-x^2/(2\sigma^2)}$$

b) **Cálculo del CEP (Circular Error Probable):** En la literatura de GNC, el CEP es la métrica estándar de precisión. Se define como el radio del círculo centrado en el target que contiene el 50 %

de las probabilidades de impacto. Es, por definición, la mediana de la distribución radial. Igualamos la FDA a 0.5:

$$1 - e^{-m^2/(2\sigma^2)} = 0,5 \implies e^{-m^2/(2\sigma^2)} = 0,5$$

Aplicando el logaritmo natural:

$$-\frac{m^2}{2\sigma^2} = \ln(0,5) \implies m^2 = -2\sigma^2 \ln(0,5) = 2\sigma^2 \ln(2)$$

$$m = \sigma\sqrt{2 \ln 2} \approx 1,1774\sigma$$

El CEP es aproximadamente  $1,18\sigma$ . Si el requisito de la misión dicta que el CEP no debe exceder los 5 km, el ingeniero de navegación sabe que debe diseñar el sistema para que  $\sigma \leq 5/1,1774 \approx 4,24$  km.

**c) Probabilidad de caer fuera de la zona de seguridad de  $3\sigma$ :** Las zonas de seguridad para evitar terrenos peligrosos (como cráteres o pendientes pronunciadas) suelen definirse como un radio de  $3\sigma$  desde el centro. La probabilidad de que el rover aterrice fuera de esta zona segura es el complemento de la FDA evaluada en  $3\sigma$ :

$$P(X > 3\sigma) = 1 - F(3\sigma) = 1 - \left(1 - e^{-(3\sigma)^2/(2\sigma^2)}\right) = e^{-9/2} = e^{-4,5} \approx 0,0111$$

Existe un 1.11 % de probabilidad de que el rover aterrice fuera de la zona de seguridad de  $3\sigma$ . En misiones de miles de millones de dólares, este número se evalúa rigurosamente contra la topografía del sitio de aterrizaje.

**d) Probabilidad condicional de dispersión extrema:** Supongamos que los sensores de a bordo detectan anomalías en el viento durante el descenso, y se sabe con certeza que el rover ha aterrizado a más de  $1\sigma$  del centro (es decir, ya está fuera de la zona de error nominal). Nos interesa calcular la probabilidad condicional de que el error sea aún mayor, superando los  $2\sigma$ .

Usando la definición de probabilidad condicional (Devore, Capítulo 2) y la función de supervivencia  $S(x) = 1 - F(x)$ :

$$P(X > 2\sigma \mid X > \sigma) = \frac{P(X > 2\sigma \cap X > \sigma)}{P(X > \sigma)} = \frac{P(X > 2\sigma)}{P(X > \sigma)}$$

Evaluando los complementos de la FDA:

$$P(X > 2\sigma) = 1 - F(2\sigma) = e^{-4/2} = e^{-2}$$

$$P(X > \sigma) = 1 - F(\sigma) = e^{-1/2} = e^{-0,5}$$

Sustituyendo:

$$P(X > 2\sigma \mid X > \sigma) = \frac{e^{-2}}{e^{-0,5}} = e^{-1,5} \approx 0,2231$$

Dado que el rover ya ha caído fuera de la zona de  $1\sigma$ , existe un 22.31 % de probabilidad de que su error radial supere los  $2\sigma$ . Este tipo de razonamiento condicional, facilitado por la estructura de la FDA, permite a los algoritmos de a bordo tomar decisiones en tiempo real sobre si desplegar paracaídas de respaldo o activar propulsores de desvío de último minuto.

## 4.4. Valor esperado

Frecuentemente, necesitamos resumir la distribución de una variable aleatoria mediante un único valor que represente su centro de gravedad o tendencia central. El valor esperado de una variable aleatoria  $X$ , denotado como  $E(X)$  o  $\mu$ , es la media ponderada de sus posibles valores, donde los pesos son las probabilidades de ocurrencia (Devore, Capítulo 3, Sección 3.3 para variables discretas; Capítulo 4, Sección 4.2 para variables continuas).

Para una variable aleatoria discreta con función de masa de probabilidad  $p(x)$ , el valor esperado se define como:

$$E(X) = \sum_{x \in D} x \cdot p(x)$$

Para una variable aleatoria continua con función de densidad de probabilidad  $f(x)$ , la suma se reemplaza por una integral:

$$E(X) = \int_{-\infty}^{\infty} x \cdot f(x) dx$$

Si  $g(X)$  es cualquier función matemática de la variable aleatoria  $X$ , el valor esperado de  $g(X)$  se calcula aplicando la misma estructura de ponderación (Devore, Sección 3.3 y Sección 4.2):

$$E[g(X)] = \sum_{x \in D} g(x) \cdot p(x) \quad \text{o} \quad E[g(X)] = \int_{-\infty}^{\infty} g(x) \cdot f(x) dx$$

## 4.5. Varianza

Mientras que el valor esperado nos indica dónde está centrada la distribución, la varianza cuantifica la dispersión o variabilidad de los valores alrededor de dicha media. La varianza de una variable aleatoria  $X$ , denotada como  $V(X)$  o  $\sigma^2$ , se define como el valor esperado de la desviación al cuadrado con respecto a la media  $\mu$  (Devore, Capítulo 3, Sección 3.3; Capítulo 4, Sección 4.2):

$$V(X) = E[(X - \mu)^2]$$

Aplicando la definición de valor esperado para una función de una variable aleatoria, las fórmulas operativas son:

$$V(X) = \sum_{x \in D} (x - \mu)^2 \cdot p(x) \quad \text{o} \quad V(X) = \int_{-\infty}^{\infty} (x - \mu)^2 \cdot f(x) dx$$

La desviación estándar,  $\sigma_X = \sqrt{V(X)}$ , se expresa en las mismas unidades que la variable original, lo que la hace más interpretable físicamente.

Para el cálculo práctico, la teoría proporciona una fórmula abreviada que evita integrar o sumar términos cuadráticos complejos. Expandiendo el binomio al cuadrado y utilizando las propiedades de linealidad del valor esperado, se demuestra que (Devore, Sección 3.3):

$$V(X) = E(X^2) - [E(X)]^2$$

### 4.5.1. Ejemplo 1: Demostración de la Fórmula Abreviada de la Varianza

Partimos de la definición fundamental de la varianza como el valor esperado de la desviación al cuadrado:

$$V(X) = E[(X - \mu)^2]$$

Expandimos el término cuadrático dentro de la esperanza matemática:

$$V(X) = E[X^2 - 2\mu X + \mu^2]$$

Aplicamos la propiedad de linealidad del valor esperado, la cual establece que la esperanza de una suma es la suma de las esperanzas, y que las constantes pueden factorizarse fuera del operador  $E$ :

$$V(X) = E(X^2) - E(2\mu X) + E(\mu^2)$$

$$V(X) = E(X^2) - 2\mu E(X) + E(\mu^2)$$

Dado que  $\mu$  es una constante (el valor esperado de  $X$ ), sabemos que  $E(X) = \mu$ . Además, el valor esperado de una constante es la constante misma, por lo que  $E(\mu^2) = \mu^2$ . Sustituimos estos valores en la ecuación:

$$V(X) = E(X^2) - 2\mu(\mu) + \mu^2$$

$$V(X) = E(X^2) - 2\mu^2 + \mu^2$$

Simplificando los términos algebraicos, obtenemos el resultado deseado:

$$V(X) = E(X^2) - \mu^2$$

Y dado que  $\mu = E(X)$ , reescribimos la expresión final como:

$$V(X) = E(X^2) - [E(X)]^2$$

### 4.5.2. Ejemplo 2: Propagación de Error en el Sistema de Magnitudes Fotométricas

En la astronomía observacional, la relación entre el flujo físico medido por un detector y la magnitud aparente reportada en los catálogos es altamente no lineal. Inspirados en los principios de fotometría y propagación de errores (*Astronomical Measurement*, Capítulo sobre *Photometry and Magnitudes*), analizaremos un problema complejo de transformación de variables aleatorias continuas.

La magnitud aparente  $m$  de una fuente astrofísica se define en función de su flujo medido  $f$  mediante la ecuación:

$$m = -2,5 \log_{10}(f) + C$$

donde  $C$  es el punto cero fotométrico (una constante instrumental).

Supongamos que, debido a las características de ruido de un detector en el límite de sensibilidad o a la distribución estadística de una población de fuentes débiles, el flujo  $f$  sigue una distribución exponencial con parámetro de tasa  $\lambda > 0$ . La función de densidad de probabilidad del flujo es:

$$g(f) = \lambda e^{-\lambda f}, \quad \text{para } f > 0$$

Nuestro objetivo es calcular el valor esperado  $E(m)$  y la varianza  $V(m)$  de la magnitud fotométrica.

**Paso 1: Reformulación de la variable aleatoria** Para facilitar el cálculo integral, convertimos el logaritmo en base 10 a logaritmo natural utilizando la identidad  $\log_{10}(f) = \frac{\ln(f)}{\ln(10)}$ . Definimos la constante de escala  $k = \frac{2.5}{\ln(10)} \approx 1,0857$ . La magnitud se reescribe como:

$$m = -k \ln(f) + C$$

**Paso 2: Cálculo del Valor Esperado**  $E(m)$  Aplicamos la definición de valor esperado para una función de una variable aleatoria continua (Devore, Sección 4.2):

$$E(m) = \int_0^{\infty} [-k \ln(f) + C] \lambda e^{-\lambda f} df$$

Realizamos un cambio de variable: sea  $x = \lambda f$ , de donde  $df = \frac{dx}{\lambda}$  y  $\ln(f) = \ln(x/\lambda) = \ln(x) - \ln(\lambda)$ . La integral se transforma en:

$$\begin{aligned} E(m) &= \int_0^{\infty} [-k(\ln(x) - \ln(\lambda)) + C] e^{-x} dx \\ E(m) &= \int_0^{\infty} [-k \ln(x) + k \ln(\lambda) + C] e^{-x} dx \end{aligned}$$

Separamos la integral en tres términos. Para resolverla, invocamos las derivadas de la función Gamma  $\Gamma(z) = \int_0^{\infty} x^{z-1} e^{-x} dx$  evaluadas en  $z = 1$ . Sabemos que  $\int_0^{\infty} e^{-x} dx = 1$  y que la primera derivada  $\Gamma'(1) = \int_0^{\infty} \ln(x) e^{-x} dx = -\gamma$ , donde  $\gamma \approx 0,5772$  es la constante de Euler-Mascheroni. Sustituyendo estos resultados:

$$E(m) = -k(-\gamma) + (k \ln(\lambda) + C)(1)$$

$$E(m) = k(\gamma + \ln(\lambda)) + C$$

**Paso 3: Cálculo de la Varianza**  $V(m)$  Calcular  $V(m)$  mediante  $E(m^2) - [E(m)]^2$  sería algebraicamente tedioso. Es mucho más elegante utilizar la definición  $V(m) = E[(m - E(m))^2]$ . Primero, evaluamos la desviación de la magnitud respecto a su media:

$$\begin{aligned} m - E(m) &= [-k \ln(x) + k \ln(\lambda) + C] - [k\gamma + k \ln(\lambda) + C] \\ m - E(m) &= -k(\ln(x) + \gamma) \end{aligned}$$

Ahora, calculamos el valor esperado del cuadrado de esta desviación:

$$V(m) = \int_0^{\infty} [-k(\ln(x) + \gamma)]^2 e^{-x} dx = k^2 \int_0^{\infty} (\ln(x) + \gamma)^2 e^{-x} dx$$



Expandimos el binomio al cuadrado dentro de la integral:

$$V(m) = k^2 \left[ \int_0^\infty (\ln(x))^2 e^{-x} dx + 2\gamma \int_0^\infty \ln(x) e^{-x} dx + \gamma^2 \int_0^\infty e^{-x} dx \right]$$

Para la primera integral, requerimos la segunda derivada de la función Gamma en  $z = 1$ , la cual es un resultado conocido en cálculo avanzado:  $\Gamma''(1) = \int_0^\infty (\ln(x))^2 e^{-x} dx = \gamma^2 + \frac{\pi^2}{6}$ . Sustituyendo las tres integrales conocidas:

$$V(m) = k^2 \left[ \left( \gamma^2 + \frac{\pi^2}{6} \right) + 2\gamma(-\gamma) + \gamma^2(1) \right]$$

Al simplificar los términos dentro del corchete, observamos una cancelación exacta de las constantes de Euler-Mascheroni:

$$\gamma^2 + \frac{\pi^2}{6} - 2\gamma^2 + \gamma^2 = \frac{\pi^2}{6}$$

Por lo tanto, la varianza de la magnitud fotométrica es:

$$V(m) = k^2 \frac{\pi^2}{6}$$

Sustituyendo el valor de la constante  $k = \frac{2,5}{\ln(10)}$ , obtenemos el resultado final:

$$V(m) = \left( \frac{2,5}{\ln(10)} \right)^2 \frac{\pi^2}{6} \approx 1,939$$

**Conclusión:** La varianza de la magnitud  $V(m)$  depende exclusivamente de constantes matemáticas puras ( $\pi$  y el factor de escala logarítmico  $2,5/\ln(10)$ ). Es completamente independiente del parámetro de escala del flujo  $\lambda$  y del punto cero instrumental  $C$ . Esto demuestra que, bajo un modelo de flujo exponencial, la dispersión estadística en el sistema de magnitudes está intrínsecamente acotada por la geometría de la transformación logarítmica, un hecho crucial para calibrar los límites de detección y las incertidumbres sistemáticas en sondeos astronómicos de gran profundidad.

# Clase 5

## 5.1. Distribución de probabilidad binomial

En el modelado de fenómenos astronómicos y aeroespaciales, frecuentemente nos enfrentamos a experimentos que consisten en una secuencia de observaciones o ensayos repetidos, donde cada uno solo puede resultar en dos categorías mutuamente excluyentes: éxito o fracaso. Un experimento binomial satisface rigurosamente las siguientes cuatro condiciones (Devore, Capítulo 3, Sección 3.4):

1. El experimento consta de un número fijo  $n$  de ensayos.
2. Cada ensayo puede dar por resultado uno de dos posibles resultados: éxito (E) o fracaso (F).
3. La probabilidad de éxito, denotada por  $p$ , es constante de un ensayo a otro.
4. Los ensayos son independientes entre sí.

Si definimos la variable aleatoria discreta  $X$  como el número total de éxitos observados en los  $n$  ensayos, decimos que  $X$  sigue una distribución binomial con parámetros  $n$  y  $p$ , denotado como  $X \sim \text{Bin}(n, p)$ . La función de masa de probabilidad (FMP) se deriva combinando la probabilidad de cualquier secuencia específica de éxitos y fracasos con el número de formas en que dicha secuencia puede ocurrir (combinaciones). La FMP está dada por:

$$b(x; n, p) = \binom{n}{x} p^x (1-p)^{n-x} \quad \text{para } x = 0, 1, 2, \dots, n$$

Las características fundamentales de esta distribución, que resumen su tendencia central y dispersión, son su valor esperado y su varianza (Devore, Sección 3.4):

$$E(X) = np$$

$$V(X) = np(1-p)$$

### 5.1.1. Ejemplo 1: Demostración de la Moda de la Distribución Binomial

Para encontrar el valor de  $x$  que maximiza  $b(x; n, p)$ , analizamos la razón entre probabilidades consecutivas. Esto nos indica cuándo la función está creciendo y cuándo empieza a decrecer. Calculamos la razón  $R(x)$ :

$$R(x) = \frac{b(x; n, p)}{b(x-1; n, p)} = \frac{\frac{n!}{x!(n-x)!} p^x (1-p)^{n-x}}{\frac{n!}{(x-1)!(n-x+1)!} p^{x-1} (1-p)^{n-x+1}}$$

Al simplificar los factoriales y las potencias de  $p$  y  $(1 - p)$ , obtenemos:

$$R(x) = \frac{(x-1)!(n-x+1)!}{x!(n-x)!} \cdot \frac{p}{1-p} = \frac{n-x+1}{x} \cdot \frac{p}{1-p}$$

La probabilidad  $b(x; n, p)$  es mayor o igual que  $b(x-1; n, p)$  siempre y cuando  $R(x) \geq 1$ . Establezcamos la desigualdad:

$$\frac{n-x+1}{x} \cdot \frac{p}{1-p} \geq 1$$

Multiplicamos ambos lados por  $x(1-p)$  (dado que  $x > 0$  y  $0 < p < 1$ , el denominador es positivo y la desigualdad se mantiene):

$$\begin{aligned}(n-x+1)p &\geq x(1-p) \\ np - xp + p &\geq x - xp\end{aligned}$$

Sumamos  $xp$  a ambos lados y reagrupamos los términos con  $x$ :

$$\begin{aligned}np + p &\geq x \\ x &\leq (n+1)p\end{aligned}$$

Este resultado nos indica que la función de masa de probabilidad  $b(x; n, p)$  es estrictamente creciente para todos los valores de  $x$  que satisfacen  $x \leq (n+1)p$ , y es estrictamente decreciente para  $x > (n+1)p$ . Por lo tanto, el valor máximo se alcanza en el mayor entero que cumple la condición de crecimiento, el cual es exactamente la parte entera de  $(n+1)p$ .

$$\text{Moda} = \lfloor (n+1)p \rfloor$$

### 5.1.2. Ejemplo 2: Demostración del $k$ -ésimo momento factorial de la distribución binomial

Sea  $X \sim \text{Bin}(n, p)$  una variable aleatoria binomial. Definimos el factorial descendente de orden  $k$  como  $X^{(k)} = X(X-1)(X-2)\cdots(X-k+1)$ , con la convención de que  $X^{(k)} = 0$  si  $X < k$ .

Para calcular  $E[X^{(k)}]$ , aplicamos la definición del valor esperado de una función de una variable aleatoria discreta (Devore, Capítulo 3, Sección 3.3):

$$E[X^{(k)}] = \sum_{x=0}^n x^{(k)} \cdot P(X=x)$$

Sustituimos la función de masa de probabilidad binomial  $P(X=x) = \binom{n}{x} p^x (1-p)^{n-x}$  y la expresión explícita del factorial descendente  $x^{(k)} = \frac{x!}{(x-k)!}$ :

$$E[X^{(k)}] = \sum_{x=0}^n \frac{x!}{(x-k)!} \binom{n}{x} p^x (1-p)^{n-x}$$

Dado que  $\frac{x!}{(x-k)!} = 0$  para todo  $x < k$ , los términos desde  $x = 0$  hasta  $x = k - 1$  son nulos. Por lo tanto, podemos ajustar el límite inferior de la sumatoria a  $x = k$ :

$$E[X^{(k)}] = \sum_{x=k}^n \frac{x!}{(x-k)!} \frac{n!}{x!(n-x)!} p^x (1-p)^{n-x}$$

Cancelamos  $x!$  en el numerador y denominador del coeficiente combinatorio:

$$E[X^{(k)}] = \sum_{x=k}^n \frac{n!}{(x-k)!(n-x)!} p^x (1-p)^{n-x}$$

El objetivo analítico es factorizar la sumatoria para que adopte la forma de una expansión binomial completa. Para ello, multiplicamos y dividimos por  $(n-k)!$  dentro de la sumatoria:

$$E[X^{(k)}] = \frac{n!}{(n-k)!} \sum_{x=k}^n \frac{(n-k)!}{(x-k)!(n-x)!} p^x (1-p)^{n-x}$$

Reconocemos que el término fraccionario es exactamente el coeficiente binomial  $\binom{n-k}{x-k}$ . Además, extraemos el factor constante  $\frac{n!}{(n-k)!} = n^{(k)}$  fuera de la sumatoria:

$$E[X^{(k)}] = n^{(k)} \sum_{x=k}^n \binom{n-k}{x-k} p^x (1-p)^{n-x}$$

Realizamos un cambio de índice para simplificar la sumatoria. Sea  $y = x - k$ . Entonces  $x = y + k$ . Los límites de la sumatoria se transforman de la siguiente manera: cuando  $x = k$ ,  $y = 0$ ; cuando  $x = n$ ,  $y = n - k$ . Sustituimos en la expresión:

$$E[X^{(k)}] = n^{(k)} \sum_{y=0}^{n-k} \binom{n-k}{y} p^{y+k} (1-p)^{n-(y+k)}$$

Separamos las potencias de  $p$  y reagrupamos los exponentes de  $(1-p)$ :

$$E[X^{(k)}] = n^{(k)} p^k \sum_{y=0}^{n-k} \binom{n-k}{y} p^y (1-p)^{(n-k)-y}$$

La sumatoria restante es exactamente la expansión del Teorema del Binomio para el exponente  $m = n - k$ :

$$\sum_{y=0}^{n-k} \binom{n-k}{y} p^y (1-p)^{(n-k)-y} = (p + (1-p))^{n-k} = 1^{n-k} = 1$$

Al sustituir este resultado unitario en la expresión anterior, obtenemos directamente el teorema demostrado:

$$E[X^{(k)}] = n^{(k)} p^k = \frac{n!}{(n-k)!} p^k$$

### 5.1.3. Ejemplo 3: Momentos de Orden Superior en la Integración de Señales de Radar Planetario

En la astronomía de radar (como las observaciones realizadas por la Red del Espacio Profundo o el Goldstone Solar System Radar), se envían secuencias de pulsos electromagnéticos hacia un asteroide. Debido a la topografía irregular y la rotación del cuerpo, la coherencia de fase de la señal reflejada puede variar.

Modelaremos un escenario simplificado pero físicamente motivado: se transmiten  $n$  pulsos. Cada pulso tiene una probabilidad  $p$  de regresar con la fase coherente necesaria para la integración constructiva. Sea  $X \sim \text{Bin}(n, p)$  el número de pulsos coherentes recibidos. Debido a las no linealidades en el receptor de correlación y a la física de la dispersión, la potencia de la señal integrada  $Y$  es proporcional al cuadrado del número de pulsos coherentes, es decir,  $Y = cX^2$ , donde  $c$  es una constante instrumental.

Para caracterizar la estabilidad del radiómetro y calcular el índice de centelleo (scintillation index), necesitamos determinar el valor esperado  $E(Y)$  y, de manera crucial, la varianza  $V(Y)$ . Calcular  $V(Y)$  requiere hallar el cuarto momento ordinario de la distribución binomial,  $E(X^4)$ .

**Paso 1: Cálculo de  $E(Y)$**  Sabemos que  $E(X) = np$  y  $V(X) = np(1-p)$ . Utilizando la relación  $V(X) = E(X^2) - [E(X)]^2$ , despejamos el segundo momento:

$$E(X^2) = V(X) + [E(X)]^2 = np(1-p) + n^2 p^2$$

Por lo tanto, el valor esperado de la potencia es:

$$E(Y) = cE(X^2) = c[np(1-p) + n^2 p^2]$$

**Paso 2: Estrategia para el cuarto momento usando Factoriales Descendentes** Calcular  $E(X^4)$  directamente sumando  $x^4 b(x; n, p)$  es algebraicamente tedioso. Es mucho más elegante utilizar los momentos factoriales. Definimos el factorial descendente como  $X^{(k)} = X(X-1) \cdots (X-k+1)$ . Para una variable binomial, el valor esperado de su factorial descendente es notablemente simple (Devore, Sección 3.3 y ejercicios de la Sección 3.4):

$$E[X^{(k)}] = n^{(k)} p^k = \frac{n!}{(n-k)!} p^k$$

Debemos expresar la potencia ordinaria  $X^4$  en términos de factoriales descendentes. Mediante expansión algebraica (o usando los números de Stirling de segunda especie), obtenemos:

$$\begin{aligned} X^2 &= X^{(2)} + X^{(1)} \\ X^3 &= X^{(3)} + 3X^{(2)} + X^{(1)} \\ X^4 &= X^{(4)} + 6X^{(3)} + 7X^{(2)} + X^{(1)} \end{aligned}$$

**Paso 3: Cálculo de  $E(X^4)$**  Aplicamos la linealidad del valor esperado y la fórmula del momento factorial:

$$\begin{aligned} E(X^4) &= E[X^{(4)}] + 6E[X^{(3)}] + 7E[X^{(2)}] + E[X^{(1)}] \\ E(X^4) &= n(n-1)(n-2)(n-3)p^4 + 6n(n-1)(n-2)p^3 + 7n(n-1)p^2 + np \end{aligned}$$

Para facilitar el cálculo de la varianza, expandimos esta expresión agrupando por potencias de  $n$ :

$$E(X^4) = n^4 p^4 + 6n^3 p^3(1-p) + n^2 p^2(1-p)(11p-7) + np(1-p)(1-6p+6p^2)$$

**Paso 4: Cálculo de la Varianza  $V(Y)$**  La varianza de la potencia integrada es  $V(Y) = c^2 V(X^2) = c^2 [E(X^4) - (E(X^2))^2]$ . Primero, elevamos al cuadrado el segundo momento que obtuvimos en el Paso 1:

$$(E(X^2))^2 = [n^2 p^2 + np(1-p)]^2 = n^4 p^4 + 2n^3 p^3(1-p) + n^2 p^2(1-p)^2$$

Ahora restamos  $(E(X^2))^2$  de  $E(X^4)$ . Observamos que los términos de orden  $n^4$  se cancelan exactamente. Para los términos de orden  $n^3$ :

$$6n^3 p^3(1-p) - 2n^3 p^3(1-p) = 4n^3 p^3(1-p)$$

Para los términos de orden  $n^2$ , factorizamos  $n^2 p^2(1-p)$ :

$$n^2 p^2(1-p)[(11p-7) - (1-p)] = n^2 p^2(1-p)[12p-8] = 4n^2 p^2(1-p)(3p-2)$$

El término de orden  $n$  permanece intacto ya que no hay términos cuadráticos cruzados que lo afecten en  $(E(X^2))^2$ :

$$np(1-p)(1-6p+6p^2)$$

Sumando todo y factorizando el término común  $np(1-p)$ , obtenemos la expresión final para la varianza de  $X^2$ :

$$V(X^2) = np(1-p) [4n^2 p^2 + 4np(3p-2) + (1-6p+6p^2)]$$

Finalmente, la varianza de la potencia de la señal de radar es:

$$V(Y) = c^2 np(1-p) [4n^2 p^2 + 4np(3p-2) + (1-6p+6p^2)]$$

**Conclusión:** La expresión entre corchetes revela cómo la varianza de la señal integrada escala con  $n^2$  para un número grande de pulsos, dominada por el término  $4n^2 p^2$ . En el diseño de sistemas de radar planetario (inspirado en los principios de *Astronomical Measurement* y procesamiento de señales), conocer esta varianza exacta permite a los ingenieros dimensionar los tiempos de integración necesarios para que la relación señal-ruido de la potencia (que depende de  $V(Y)$ ) supere los umbrales de detección de características superficiales en asteroides, evitando así sobreestimar la calidad de la imagen si se asumiera erróneamente una distribución gaussiana para  $X^2$ .

#### 5.1.4. Ejemplo 4: Interferometría de Línea de Base Larga con Enjambre de Nanosatélites

Principios de síntesis de apertura y diseño de arreglos distribuidos (*Astronomical Measurement*, Capítulo sobre *Interferometry and Aperture Synthesis*).

Una agencia espacial despliega una constelación de  $n = 10$  nanosatélites idénticos en órbita lunar para formar un interferómetro de radio de línea de base larga. El objetivo científico es resolver la estructura fina de las emisiones de máseres en regiones de formación estelar. Para que el arreglo funcione y se pueda sintetizar una imagen, cada par de nanosatélites que logre establecer un enlace óptico de fase coherente genera una línea base interferométrica independiente.

El proceso de despliegue y establecimiento de enlaces es estocástico. Definimos la variable aleatoria  $X$  como el número de nanosatélites que logran establecer el enlace con éxito. Dado que cada satélite opera de manera independiente y tiene la misma probabilidad  $p$  de éxito,  $X$  sigue una distribución binomial:

$$X \sim \text{Bin}(10, p)$$

La métrica de rendimiento científico de la misión, denotada como  $Y$ , es el número total de líneas base interferométricas únicas que se pueden formar con los  $X$  satélites operativos. Combinatorialmente, esto corresponde a elegir 2 satélites de los  $X$  disponibles:

$$Y = \binom{X}{2} = \frac{X(X-1)}{2}$$

**a) Expresión de  $Y$  mediante factoriales descendentes** Para facilitar el cálculo de los momentos de  $Y$ , reescribimos la variable en términos del factorial descendente de orden 2, definido como  $X^{(2)} = X(X-1)$ :

$$Y = \frac{1}{2}X^{(2)}$$

**b) Cálculo del número esperado de líneas base** Aplicamos la propiedad de linealidad del valor esperado y el teorema del  $k$ -ésimo momento factorial de la distribución binomial (Devore, Capítulo 3, Sección 3.3 y Sección 3.4), el cual establece que  $E[X^{(k)}] = n^{(k)}p^k$ . Para  $k = 2$  y  $n = 10$ :

$$E(Y) = \frac{1}{2}E[X^{(2)}] = \frac{1}{2}n^{(2)}p^2 = \frac{1}{2}(10 \times 9)p^2 = 45p^2$$

El rendimiento científico esperado escala cuadráticamente con la probabilidad de éxito individual de los nanosatélites.

**c) Cálculo de la varianza del rendimiento científico** Determinar la varianza de  $Y$  requiere calcular  $V(Y) = V\left(\frac{1}{2}X^{(2)}\right) = \frac{1}{4}V(X^{(2)})$ . Para hallar  $V(X^{(2)})$ , necesitamos el segundo momento de  $X^{(2)}$ , es decir,  $E[(X^{(2)})^2]$ . En lugar de expandir tediosamente las potencias ordinarias  $X^4$ , utilizamos la propiedad de que el producto de factoriales descendentes puede expresarse como una combinación lineal de factoriales descendentes de mayor orden. Específicamente, desarrollamos  $[X(X-1)]^2 = X^2(X-1)^2$ . Reescribiendo  $X^2 = X^{(2)} + X^{(1)}$  y  $(X-1)^2 = (X-1)(X-2) + (X-1) = X_{desplazado}^{(2)} + X_{desplazado}^{(1)}$ , o más directamente, expandiendo y convirtiendo a factoriales descendentes:

$$[X(X-1)]^2 = X^4 - 2X^3 + X^2$$

Sustituyendo las potencias ordinarias por sus equivalentes en factoriales descendentes ( $X^2 = X^{(2)} + X^{(1)}$ ,  $X^3 = X^{(3)} + 3X^{(2)} + X^{(1)}$ ,  $X^4 = X^{(4)} + 6X^{(3)} + 7X^{(2)} + X^{(1)}$ ):

$$[X(X-1)]^2 = X^{(4)} + 4X^{(3)} + 2X^{(2)}$$

Aplicando el valor esperado a cada término usando  $E[X^{(k)}] = n^{(k)}p^k$ :

$$E[(X^{(2)})^2] = n^{(4)}p^4 + 4n^{(3)}p^3 + 2n^{(2)}p^2$$

Para  $n = 10$ , los factoriales descendentes son  $10^{(4)} = 5040$ ,  $10^{(3)} = 720$ , y  $10^{(2)} = 90$ . Sustituyendo:

$$E[(X^{(2)})^2] = 5040p^4 + 2880p^3 + 180p^2$$

Ahora, calculamos la varianza de  $X^{(2)}$  restando el cuadrado de su media,  $(E[X^{(2)}])^2 = (90p^2)^2 = 8100p^4$ :

$$V(X^{(2)}) = (5040p^4 + 2880p^3 + 180p^2) - 8100p^4 = 180p^2 + 2880p^3 - 3060p^4$$

Finalmente, la varianza del número de líneas base es:

$$V(Y) = \frac{1}{4}V(X^{(2)}) = 45p^2 + 720p^3 - 765p^4$$

Esta expresión cuantifica exactamente cómo la incertidumbre en el despliegue de los satélites se amplifica no linealmente en la degradación de la calidad de la imagen interferométrica.

**d) Requisito de la misión y probabilidad mínima de despliegue** Los algoritmos de síntesis de apertura (*Astronomical Measurement*, Sección sobre *Image Reconstruction*) dictan que para lograr la relación señal-ruido requerida en el tiempo de integración asignado, el arreglo debe tener un valor esperado de al menos 30 líneas base independientes. Planteamos la desigualdad:

$$E(Y) \geq 30$$

$$45p^2 \geq 30$$

$$p^2 \geq \frac{30}{45} = \frac{2}{3}$$

$$p \geq \sqrt{\frac{2}{3}} \approx 0,8165$$

**Conclusión** Para garantizar el éxito científico de la misión, la ingeniería de los nanosatélites debe asegurar que la probabilidad de establecer el enlace óptico sea de al menos un 81.65 %.



# Clase 6

## 6.1. Distribución de Poisson

En la modelación de fenómenos astronómicos, existe una clase fundamental de experimentos que no se basan en un número fijo de ensayos, sino en la ocurrencia de eventos a lo largo de un intervalo continuo de tiempo o de espacio. La distribución de Poisson es el modelo probabilístico por excelencia para el conteo de este tipo de eventos (Devore, Capítulo 3, Sección 3.6).

Sea  $N(t)$  la variable aleatoria que representa el número de eventos ocurridos en el intervalo de tiempo  $[0, t]$ . Las condiciones estrictas que definen un proceso de Poisson homogéneo con tasa  $\lambda > 0$  se expresan matemáticamente analizando un intervalo infinitesimal  $(t, t + \Delta t]$ , donde  $\Delta t \rightarrow 0$ :

**1. Independencia de incrementos:** Los eventos que ocurren en intervalos de tiempo disjuntos (no traslapantes) son estadísticamente independientes. Para cualesquiera  $0 \leq t_1 < t_2 \leq t_3 < t_4$ :

$$P\left(N(t_2) - N(t_1) = k_1 \cap N(t_4) - N(t_3) = k_2\right) = P\left(N(t_2) - N(t_1) = k_1\right) \cdot P\left(N(t_4) - N(t_3) = k_2\right)$$

**2. Probabilidad de exactamente un evento (proporcional a  $\Delta t$ ):** La probabilidad de que ocurra exactamente un evento en el intervalo infinitesimal  $(t, t + \Delta t]$  es proporcional a la duración del intervalo, donde  $\lambda$  es la constante de proporcionalidad (tasa de ocurrencia):

$$P\left(N(t + \Delta t) - N(t) = 1\right) = \lambda \Delta t + o(\Delta t)$$

donde  $o(\Delta t)$  denota un término que tiende a cero más rápido que  $\Delta t$  cuando  $\Delta t \rightarrow 0$  (es decir,  $\lim_{\Delta t \rightarrow 0} \frac{o(\Delta t)}{\Delta t} = 0$ ).

**3. Probabilidad de cero eventos:** Dado que la suma de todas las probabilidades en el intervalo debe ser 1, la probabilidad de que no ocurra ningún evento es:

$$P\left(N(t + \Delta t) - N(t) = 0\right) = 1 - \lambda \Delta t + o(\Delta t)$$

**4. Probabilidad de dos o más eventos (despreciable):** La probabilidad de que ocurran dos o más eventos simultáneamente en el intervalo infinitesimal es despreciable, lo que significa que es de un orden de magnitud superior a  $\Delta t$ :

$$P\left(N(t + \Delta t) - N(t) \geq 2\right) = o(\Delta t)$$

$$\lim_{\Delta t \rightarrow 0} \frac{P\left(N(t + \Delta t) - N(t) \geq 2\right)}{\Delta t} = 0$$

Si definimos la variable aleatoria discreta  $X$  como el número de eventos que ocurren en un intervalo de longitud  $t$ , y  $\lambda$  representa la tasa promedio de ocurrencia por unidad de intervalo, la función de masa de probabilidad está dada por:

$$p(x; \lambda t) = \frac{e^{-\lambda t} (\lambda t)^x}{x!} \quad \text{para } x = 0, 1, 2, \dots$$

Las propiedades de esperanza y varianza son idénticas y coinciden con el parámetro de la distribución:

$$E(X) = V(X) = \lambda t$$

## 6.2. Distribuciones continuas

Mientras que las distribuciones discretas como la de Poisson modelan conteos enteros, la mayoría de las mediciones físicas en astronomía y navegación espacial (como el tiempo de llegada de un fotón, la posición angular de un astro, o el flujo de energía) son variables continuas. Una variable aleatoria continua  $X$  toma valores en un intervalo de la recta real, y su comportamiento se describe mediante una función de densidad de probabilidad (FDP)  $f(x)$  (Devore, Capítulo 4, Sección 4.1).

Las propiedades fundamentales de  $f(x)$  son:

$$f(x) \geq 0 \quad \text{para todo } x$$

$$\int_{-\infty}^{\infty} f(x) dx = 1$$

$$P(a \leq X \leq b) = \int_a^b f(x) dx$$

### 6.2.1. Ejemplo 1: Demostración de la Propiedad de Reproductividad en Procesos de Poisson

**Teorema:** Sean  $X$  y  $Y$  dos variables aleatorias independientes tales que  $X \sim \text{Poisson}(\lambda_1)$  y  $Y \sim \text{Poisson}(\lambda_2)$ . Entonces, la variable aleatoria  $Z = X + Y$  sigue una distribución de Poisson con parámetro  $\lambda_1 + \lambda_2$ .

**Demostración:** Dado que  $X$  y  $Y$  son variables aleatorias discretas e independientes, la función de masa de probabilidad de su suma  $Z$  se obtiene mediante la convolución de sus respectivas distribuciones (Devore, Capítulo 5, Sección sobre Distribuciones de probabilidad conjunta). Para un valor entero no negativo  $z$ , la probabilidad de que  $Z = z$  es:

$$P(Z = z) = \sum_{x=0}^z P(X = x) \cdot P(Y = z - x)$$

Sustituimos la función de masa de probabilidad de Poisson para  $X$  y  $Y$ :

$$P(Z = z) = \sum_{x=0}^z \left( \frac{e^{-\lambda_1} \lambda_1^x}{x!} \right) \left( \frac{e^{-\lambda_2} \lambda_2^{z-x}}{(z-x)!} \right)$$

Extraemos las constantes exponenciales fuera de la sumatoria, ya que no dependen del índice de suma  $x$ :

$$P(Z = z) = e^{-(\lambda_1 + \lambda_2)} \sum_{x=0}^z \frac{\lambda_1^x \lambda_2^{z-x}}{x!(z-x)!}$$

Para reconocer una expansión binomial en la sumatoria, multiplicamos y dividimos la expresión por  $z!$ :

$$P(Z = z) = \frac{e^{-(\lambda_1 + \lambda_2)}}{z!} \sum_{x=0}^z \frac{z!}{x!(z-x)!} \lambda_1^x \lambda_2^{z-x}$$

El término fraccionario es exactamente el coeficiente binomial  $\binom{z}{x}$ . Reescribimos la sumatoria:

$$P(Z = z) = \frac{e^{-(\lambda_1 + \lambda_2)}}{z!} \sum_{x=0}^z \binom{z}{x} \lambda_1^x \lambda_2^{z-x}$$

Aplicamos el Teorema del Binomio de Newton, el cual establece que  $\sum_{x=0}^z \binom{z}{x} a^x b^{z-x} = (a + b)^z$ . En nuestro caso,  $a = \lambda_1$  y  $b = \lambda_2$ :

$$\sum_{x=0}^z \binom{z}{x} \lambda_1^x \lambda_2^{z-x} = (\lambda_1 + \lambda_2)^z$$

Sustituimos este resultado de vuelta en la ecuación de  $P(Z = z)$ :

$$P(Z = z) = \frac{e^{-(\lambda_1 + \lambda_2)} (\lambda_1 + \lambda_2)^z}{z!}$$

Esta expresión final es exactamente la función de masa de probabilidad de una distribución de Poisson evaluada en  $z$ , con parámetro  $\lambda = \lambda_1 + \lambda_2$ . Por lo tanto, queda demostrado que  $Z \sim \text{Poisson}(\lambda_1 + \lambda_2)$ .

### 6.2.2. Ejemplo 2: Del Conteo de Fotones al Tiempo de Espera y la Función Gamma

Consideremos un escenario de instrumentación astronómica de alta energía, inspirado en los principios de detectores de rayos X y tiempos de llegada (*Astronomical Measurement*, Capítulo sobre *Detectors and Instruments*).

Un telescopio espacial observa una binaria de rayos X tenue. Los fotones llegan al detector siguiendo un proceso de Poisson con una tasa constante  $\lambda$  (fotones por segundo).

**Paso 1: Derivación de la distribución continua del tiempo de llegada** Sea  $X$  la variable aleatoria continua que representa el tiempo exacto (en segundos) transcurrido desde el inicio de la observación hasta la llegada del *primer* fotón. Para encontrar la función de distribución acumulativa (FDA) de  $X$ , notamos que el evento  $\{X > x\}$  es equivalente a que *no llegue ningún fotón* en el intervalo de tiempo  $[0, x]$ .

Utilizando la distribución de Poisson con  $t = x$  y evaluando en  $x = 0$  eventos:

$$P(X > x) = P(N = 0) = \frac{e^{-\lambda x} (\lambda x)^0}{0!} = e^{-\lambda x}$$

Por lo tanto, la FDA de  $X$  es  $F(x) = P(X \leq x) = 1 - P(X > x) = 1 - e^{-\lambda x}$ . Derivando la FDA, obtenemos la función de densidad de probabilidad continua (la distribución Exponencial):

$$f(x) = \lambda e^{-\lambda x} \quad \text{para } x > 0$$

**Paso 2: Un problema de valor esperado no trivial** El sistema de rastreo del telescopio utiliza un algoritmo de bloqueo que introduce una penalización de ruido térmico en el procesador de señales. Esta penalización es inversamente proporcional a la raíz cuadrada del tiempo de llegada del primer fotón, modelada por la función  $g(X) = \frac{1}{\sqrt{X}}$ .

Para dimensionar los filtros de software, los ingenieros deben calcular el valor esperado de esta penalización, es decir,  $E\left[\frac{1}{\sqrt{X}}\right]$ . Este cálculo requiere evaluar una integral impropia que no tiene una solución elemental directa, pero que se resuelve elegantemente utilizando la función Gamma.

Aplicamos la definición de valor esperado para variables continuas (Devore, Sección 4.2):

$$E\left[\frac{1}{\sqrt{X}}\right] = \int_0^\infty \frac{1}{\sqrt{x}} \lambda e^{-\lambda x} dx$$

Para resolver esta integral, realizamos un cambio de variable. Sea  $u = \lambda x$ , de donde  $x = \frac{u}{\lambda}$  y  $dx = \frac{du}{\lambda}$ . Sustituyendo en la integral:

$$E\left[\frac{1}{\sqrt{X}}\right] = \int_0^\infty \left(\frac{u}{\lambda}\right)^{-1/2} \lambda e^{-u} \frac{du}{\lambda}$$

Simplificando los términos algebraicos y las constantes:

$$E\left[\frac{1}{\sqrt{X}}\right] = \int_0^\infty \sqrt{\lambda} u^{-1/2} e^{-u} \frac{du}{\lambda} \cdot \lambda = \sqrt{\lambda} \int_0^\infty u^{-1/2} e^{-u} du$$

En este punto, reconocemos que la integral restante es exactamente la definición de la función Gamma,  $\Gamma(z) = \int_0^\infty t^{z-1} e^{-t} dt$ , evaluada en  $z - 1 = -1/2$ , lo que implica  $z = 1/2$ .

$$\int_0^\infty u^{-1/2} e^{-u} du = \Gamma\left(\frac{1}{2}\right)$$

$\Gamma(1/2) = \sqrt{\pi}$ . Sustituyendo este valor, obtenemos el resultado final:

$$E \left[ \frac{1}{\sqrt{X}} \right] = \sqrt{\pi\lambda}$$

**Conclusión** En el contexto de la ingeniería espacial, conocer que esta penalización esperada escala con  $\sqrt{\lambda}$  permite a los diseñadores predecir cómo aumentará el ruido procesado si la fuente astrofísica se vuelve más brillante (mayor  $\lambda$ ), asegurando que los umbrales de descarte de datos se ajusten dinámicamente según la física fundamental del detector.

## 6.3. Percentiles

En el estudio de las variables aleatorias continuas, a menudo no basta con conocer la probabilidad de que una variable caiga en un intervalo; es fundamental poder identificar valores específicos que actúen como umbrales o puntos de corte que dividan la distribución en proporciones conocidas. Para cualquier número  $p$  tal que  $0 < p < 1$ , el percentil  $(100p)$  de una distribución continua con función de densidad  $f(x)$  y función de distribución acumulativa  $F(x)$  es el valor numérico  $x_p$  que satisface la siguiente condición (Devore, Capítulo 4, Sección 4.2):

$$F(x_p) = \int_{-\infty}^{x_p} f(x) dx = p$$

Geométricamente,  $x_p$  es el valor sobre el eje horizontal tal que el área bajo la curva de densidad a la izquierda de  $x_p$  es exactamente  $p$ . Esto significa que una fracción  $p$  de la población o de la distribución de probabilidad cae por debajo de  $x_p$ , y una fracción  $1 - p$  cae por encima.

Algunos percentiles reciben nombres especiales debido a su utilidad para resumir la tendencia central y la dispersión de los datos. El percentil 50 ( $p = 0,5$ ) se denomina *mediana* de la distribución, el cual divide el área bajo la curva en dos mitades iguales. Los percentiles 25 y 75 ( $p = 0,25$  y  $p = 0,75$ ) se conocen como el *primer* y *tercer cuartil*, respectivamente, y son ampliamente utilizados para definir el rango intercuartílico, una medida robusta de variabilidad.

## 6.4. Distribución normal

Sin duda, la distribución de probabilidad más importante y ubicua en toda la estadística y en las ciencias físicas es la distribución normal. Como se detalla en *Astronomical Measurement* (Apéndice sobre *Error Analysis and Probability Distributions*), la mayoría de los errores de medición instrumentales y el ruido térmico en los detectores astrofísicos siguen este modelo, gracias al Teorema del Límite Central.

Se dice que una variable aleatoria continua  $X$  tiene una distribución normal con parámetros de media  $\mu$  (donde  $-\infty < \mu < \infty$ ) y desviación estándar  $\sigma$  (donde  $\sigma > 0$ ) si su función de densidad de probabilidad es (Devore, Capítulo 4, Sección 4.3):

$$f(x; \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} \quad \text{para } -\infty < x < \infty$$

La curva en forma de campana resultante es simétrica respecto a su media  $\mu$ , y la dispersión está gobernada por  $\sigma$ . El cálculo de áreas bajo esta curva (es decir, probabilidades) requiere integrar una función que no tiene una antiderivada elemental. Para resolver esto, se utiliza la *distribución normal estándar*, que es el caso especial donde  $\mu = 0$  y  $\sigma = 1$ . La variable aleatoria estándar se denota como  $Z$ , y su función de distribución acumulativa se denota tradicionalmente como  $\Phi(z)$ .

La herramienta fundamental para calcular probabilidades de cualquier variable normal  $X \sim N(\mu, \sigma^2)$  es el proceso de *estandarización*. Si  $X$  es normal, entonces la variable estandarizada  $Z$  también es normal estándar:

$$Z = \frac{X - \mu}{\sigma}$$

Esto permite utilizar las tablas de la distribución normal estándar (como la Tabla A.3 en el apéndice de Devore) para encontrar percentiles y probabilidades de cualquier fenómeno físico modelado por esta distribución, desde la dispersión de velocidades en un cúmulo estelar hasta los errores de apuntamiento de una nave espacial.

#### 6.4.1. Ejemplo 1: Percentiles en la distribución de concentración de isótopos en un núcleo de meteorito

Principios de datación y análisis de choque en meteoritos expuestos en *Planetary Geology* (Capítulo sobre *Shock Metamorphism and Isotope Geochemistry*).

Un laboratorio de geoquímica isotópica analiza el núcleo de una condrita carbonácea que sufrió un evento de impacto. Debido al gradiente de presión y temperatura generado por la onda de choque desde la costra de fusión hacia el interior, la concentración de un isótopo de corta vida (como el Al-26) no es uniforme, sino que aumenta a medida que se profundiza en la muestra.

Definimos la variable aleatoria continua  $X$  como la *profundidad fraccional normalizada* dentro del núcleo, donde  $X \in (0, 1)$ . Basado en el perfil de choque medido, la función de densidad de probabilidad de la concentración relativa del isótopo en función de la profundidad está modelada por:

$$f(x) = \begin{cases} 2x & \text{para } 0 < x < 1 \\ 0 & \text{en otro caso} \end{cases}$$

El equipo científico necesita determinar dos umbrales críticos para su protocolo de muestreo: la profundidad mediana (donde se alcanza la concentración isotópica promedio acumulada) y el percentil 90 (para descartar el 10 % superior de la muestra que podría estar excesivamente alterada por el calor del impacto).

**Paso 1: Obtención de la Función de Distribución Acumulativa (FDA)** Para  $0 < x < 1$ , la FDA  $F(x)$  se calcula integrando la FDP desde el límite inferior del soporte hasta  $x$ :

$$F(x) = \int_0^x 2t \, dt = [t^2]_0^x = x^2$$

**Paso 2: Cálculo de la Mediana (Percentil 50)** La mediana  $m$  es el valor que satisface  $F(m) = 0,5$ . Planteamos la ecuación:

$$m^2 = 0,5 \implies m = \sqrt{0,5} \approx 0,7071$$

La profundidad mediana es aproximadamente 0.707. Esto indica que el 50 % de la probabilidad de concentración isotópica total se encuentra en el 70.7 % superior del núcleo, lo cual es consistente con una distribución que sesga la masa hacia las profundidades mayores.

**Paso 3: Cálculo del Percentil 90** Para encontrar el percentil 90 ( $x_{0,90}$ ), resolvemos la ecuación  $F(x_{0,90}) = 0,90$ :

$$x_{0,90}^2 = 0,90 \implies x_{0,90} = \sqrt{0,90} \approx 0,9487$$

El percentil 90 se encuentra en la profundidad fraccional 0.9487.

**Conclusión** Este resultado dicta que el 90 % de la distribución de concentración del isótopo ocurre en los primeros 94.87 % de la profundidad del núcleo. Los geoquímicos utilizarán este percentil para establecer el límite de corte físico al tallar la muestra, asegurando que el 10 % más profundo (que representa las colas de la distribución donde los efectos térmicos del impacto son no lineales y difíciles de modelar) sea descartado del análisis de datación principal.

## 6.4.2. Ejemplo 2: Distribución normal y percentiles en la navegación de una sonda interplanetaria

Presupuesto de combustible y maniobras de corrección de trayectoria (*Modern Spacecraft Guidance, Navigation, and Control*, Capítulo sobre *Trajectory Correction Maneuvers*).

Una sonda espacial en ruta a Marte debe ejecutar una Maniobra de Corrección de Trayectoria (TCM, por sus siglas en inglés). El sistema de propulsión está comandado para entregar un incremento de velocidad ( $\Delta V$ ) exacto de 15.0 m/s. Sin embargo, debido a las fluctuaciones en la presión de la cámara de combustión, la eficiencia del propulsor y el ruido en los sensores de navegación, el  $\Delta V$  realmente entregado es una variable aleatoria continua  $X$  que sigue una distribución normal.

Los ingenieros de vuelo han caracterizado el sistema y determinan que  $X \sim N(\mu = 15,0 \text{ m/s}, \sigma = 0,4 \text{ m/s})$ .

El equipo de la misión debe resolver dos problemas críticos de diseño y operación:

**Problema A: Probabilidad de exceder el límite de seguridad del tanque** Por restricciones estructurales del chasis de la sonda, la válvula de regulación no puede soportar un  $\Delta V$  instantáneo superior a 16.0 m/s sin riesgo de fatiga catastrófica. ¿Cuál es la probabilidad de que la maniobra exceda este límite?

Estandarizamos la variable  $X$  para convertir el problema en uno de distribución normal estándar:

$$P(X > 16,0) = P\left(Z > \frac{16,0 - 15,0}{0,4}\right) = P(Z > 2,5)$$

Utilizando la función de distribución acumulativa estándar  $\Phi(z)$ :

$$P(Z > 2,5) = 1 - \Phi(2,5)$$

Consultando la tabla de la normal estándar (Devore, Tabla A.3), sabemos que  $\Phi(2,5) \approx 0,9938$ . Por lo tanto:

$$P(X > 16,0) = 1 - 0,9938 = 0,0062$$

Existe un riesgo del 0.62% de que la maniobra supere el límite estructural. En el contexto de *Modern Spacecraft GN&C*, este valor es lo suficientemente bajo como para ser aceptable, pero se monitorea de cerca.

**Problema B: Dimensionamiento del tanque de contingencia usando percentiles** Para garantizar que la sonda llegue a Marte incluso en el peor escenario de dispersión de combustible, el tanque de reserva debe dimensionarse para contener el  $\Delta V$  que solo es superado en el 1% de los casos. Es decir, los ingenieros necesitan calcular el *percentil 99* de la distribución del  $\Delta V$ .

Buscamos el valor  $x_{0,99}$  tal que  $P(X \leq x_{0,99}) = 0,99$ . Primero, encontramos el percentil 99 de la distribución normal estándar,  $z_{0,99}$ , tal que  $\Phi(z_{0,99}) = 0,99$ . Buscando en la tabla inversa de la normal estándar, el valor que deja un área de 0.99 a su izquierda es aproximadamente:

$$z_{0,99} \approx 2,326$$

Ahora, desacoplamos la ecuación de estandarización  $Z = \frac{X-\mu}{\sigma}$  para despejar  $X$ :

$$x_{0,99} = \mu + z_{0,99} \cdot \sigma$$

Sustituimos los parámetros de la misión:

$$x_{0,99} = 15,0 + (2,326)(0,4) = 15,0 + 0,9304 = 15,9304 \text{ m/s}$$

**Conclusión:** El percentil 99 del  $\Delta V$  es de 15.93 m/s. Esto significa que el 99% de las veces, la maniobra requerirá 15.93 m/s o menos. Los ingenieros de sistemas utilizarán este valor exacto para dimensionar la capacidad de reserva del tanque de hidracina. Este ejercicio demuestra cómo la teoría de la distribución normal y el cálculo de percentiles (Devore, Sección 4.3) se traducen directamente en márgenes de seguridad físicos y decisiones de diseño de hardware en la exploración del sistema solar.

### 6.4.3. Ejemplo 3: Control de Calidad Óptica y Razón de Strehl en Telescopios Espaciales

Criterios de calidad de imagen y la aproximación de Marechal para la razón de Strehl (*Astronomical Measurement*, Capítulo sobre *Image Quality and the Point Spread Function*).



En el diseño de telescopios espaciales, la precisión de la superficie del espejo primario dicta la capacidad del instrumento para resolver detalles finos. Sea  $X$  la variable aleatoria continua que representa el error de frente de onda RMS (Raíz del Cuadrado Medio), medido en nanómetros (nm). Debido a las fluctuaciones térmicas en órbita y a los errores de fabricación, este error sigue una distribución normal con una media de 12 nm y una desviación estándar de 4 nm. Es decir,  $X \sim N(12, 4^2)$ .

La calidad de la imagen se cuantifica mediante la razón de Strehl  $\mathcal{S}$ , que relaciona la intensidad pico real con la de un sistema óptico perfecto. Debido a un desplazamiento sistemático conocido en el enfoque nominal del instrumento, el modelo de degradación para este telescopio específico está dado por la siguiente función exponencial:

$$\mathcal{S} = \exp\left(-\frac{(X - 10)^2}{25}\right)$$

A continuación, resolvemos una secuencia de requerimientos de ingeniería para la misión:

**a) Estandarización y probabilidad de cola (Límite de degradación severa)** El protocolo de seguridad dicta que si el error de frente de onda supera los 20 nm, el telescopio debe entrar en modo de recalibración automática. ¿Cuál es la probabilidad de que una observación aleatoria exceda este límite?

Estandarizamos la variable  $X$  restando la media y dividiendo por la desviación estándar para convertir el problema en uno de distribución normal estándar  $Z \sim N(0, 1)$ :

$$P(X > 20) = P\left(Z > \frac{20 - 12}{4}\right) = P(Z > 2)$$

Utilizando la función de distribución acumulativa estándar  $\Phi(z)$ :

$$P(Z > 2) = 1 - \Phi(2) \approx 1 - 0,9772 = 0,0228$$

Existe un 2.28 % de probabilidad de que el sistema requiera recalibración por superar el límite de 20 nm.

**b) Cálculo de percentiles (Umbral de bloqueo de actuadores)** Para prevenir daños mecánicos en los actuadores del espejo secundario, el sistema de control debe bloquear los ajustes cuando el error acumulado alcance el percentil 95 de la distribución esperada. Debemos encontrar el valor  $x_{0,95}$  tal que  $P(X \leq x_{0,95}) = 0,95$ .

Primero, buscamos el percentil 95 de la normal estándar,  $z_{0,95}$ , tal que  $\Phi(z_{0,95}) = 0,95$ . Consultando las tablas normales,  $z_{0,95} \approx 1,645$ .

Despejamos  $X$  de la ecuación de estandarización  $Z = \frac{X - \mu}{\sigma}$ :

$$x_{0,95} = \mu + z_{0,95} \cdot \sigma = 12 + (1,645)(4) = 12 + 6,58 = 18,58 \text{ nm}$$

El sistema de control bloqueará los actuadores cuando el error alcance los 18.58 nm.

**c) Probabilidad de un evento compuesto no lineal (Requerimiento científico)** El objetivo científico principal de la misión es imagear los criovolcanes en la superficie de Europa. Para lograr el contraste necesario, los algoritmos de procesamiento de imagen exigen que la razón de Strehl sea estrictamente mayor que  $e^{-4}$ . ¿Cuál es la probabilidad de que un fotograma aleatorio cumpla con este requerimiento científico?

Planteamos la desigualdad basada en el modelo físico:

$$\mathcal{S} > e^{-4} \implies \exp\left(-\frac{(X-10)^2}{25}\right) > e^{-4}$$

Dado que la función exponencial es estrictamente creciente, podemos igualar los exponentes preservando el sentido de la desigualdad:

$$-\frac{(X-10)^2}{25} > -4$$

Multiplicamos por  $-25$  (lo que invierte la desigualdad):

$$(X-10)^2 < 100$$

Para resolver esta inecuación cuadrática, aplicamos la raíz cuadrada en ambos lados, lo que genera un valor absoluto:

$$|X-10| < 10$$

Esto se descompone en una doble desigualdad lineal:

$$-10 < X-10 < 10 \implies 0 < X < 20$$

El requerimiento científico se traduce matemáticamente en que el error de frente de onda debe estar estrictamente entre 0 y 20 nm. Ahora, estandarizamos ambos límites de este intervalo para calcular la probabilidad utilizando la normal estándar:

- Límite inferior:  $Z_1 = \frac{0-12}{4} = -3$
- Límite superior:  $Z_2 = \frac{20-12}{4} = 2$

La probabilidad de cumplir con el requerimiento es el área bajo la curva normal estándar entre estos dos valores:

$$P(0 < X < 20) = P(-3 < Z < 2) = \Phi(2) - \Phi(-3)$$

Para obtener una expresión matemática cerrada y manejable, aplicamos la propiedad de simetría de la distribución normal estándar,  $\Phi(-z) = 1 - \Phi(z)$ :

$$P(-3 < Z < 2) = \Phi(2) - (1 - \Phi(3)) = \Phi(2) + \Phi(3) - 1$$

Sustituyendo los valores de las tablas normales ( $\Phi(2) \approx 0,9772$  y  $\Phi(3) \approx 0,9987$ ):

$$P(0 < X < 20) \approx 0,9772 + 0,9987 - 1 = 0,9759$$

**Conclusión:** Existe un 97.59 % de probabilidad de que el telescopio entregue imágenes con la calidad suficiente para el estudio de Europa.

# Clase 7

## 7.1. Funciones de varias variables

En el estudio de múltiples variables aleatorias, es fundamental poder calcular el valor esperado de una función  $h(X, Y)$  que depende de dos variables aleatorias  $X$  y  $Y$ . Este valor esperado se obtiene ponderando la función por la probabilidad conjunta de las variables (Devore, Capítulo 5, Sección 5.2).

Para variables aleatorias conjuntamente discretas con función de masa de probabilidad conjunta  $p(x, y)$ :

$$E[h(X, Y)] = \sum_x \sum_y h(x, y)p(x, y)$$

Para variables aleatorias conjuntamente continuas con función de densidad de probabilidad conjunta  $f(x, y)$ :

$$E[h(X, Y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} h(x, y)f(x, y) dx dy$$

Una propiedad fundamental derivada de esta definición es la linealidad del valor esperado. Si la función es una combinación lineal  $h(X, Y) = aX + bY$ , donde  $a$  y  $b$  son constantes, entonces:

$$E(aX + bY) = aE(X) + bE(Y) = a\mu_X + b\mu_Y$$

## 7.2. Distribuciones de probabilidad conjunta

El comportamiento simultáneo de dos variables aleatorias se describe mediante su distribución conjunta.

Para el caso discreto, la función de masa de probabilidad conjunta  $p(x, y)$  especifica la probabilidad de que  $X = x$  y  $Y = y$  simultáneamente. Debe satisfacer rigurosamente (Devore, Capítulo 5, Sección 5.1):

$$p(x, y) \geq 0 \quad \text{para todo } (x, y)$$
$$\sum_x \sum_y p(x, y) = 1$$

Para el caso continuo, la función de densidad de probabilidad conjunta  $f(x, y)$  define la probabilidad de que  $(X, Y)$  caiga en una región bidimensional  $A$ . Sus condiciones analíticas son (Devore, Sección 5.1):

$$f(x, y) \geq 0 \quad \text{para todo } (x, y)$$

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$$

$$P((X, Y) \in A) = \iint_A f(x, y) dx dy$$

### 7.3. Distribuciones marginales

Las distribuciones marginales describen el comportamiento probabilístico de una sola variable (por ejemplo,  $X$ ), ignorando o promediando los resultados de la otra variable ( $Y$ ). Se obtienen directamente de la distribución conjunta (Devore, Capítulo 5, Sección 5.1).

Para variables discretas, la función de masa de probabilidad marginal de  $X$  se calcula sumando la probabilidad conjunta sobre todos los posibles valores de  $Y$ :

$$p_X(x) = \sum_y p(x, y)$$

Para variables continuas, la función de densidad de probabilidad marginal de  $X$  se obtiene integrando la densidad conjunta sobre todo el rango de  $Y$ :

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy$$

De manera simétrica, las distribuciones marginales para  $Y$  se definen como  $p_Y(y) = \sum_x p(x, y)$  en el caso discreto, y  $f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx$  en el caso continuo.

### 7.4. Combinación de variables aleatorias

Al combinar variables aleatorias, es crucial cuantificar no solo sus medias individuales, sino también cómo varían conjuntamente. La covarianza mide la relación lineal entre  $X$  y  $Y$ , y se define como el valor esperado del producto de sus desviaciones respecto a sus respectivas medias (Devore, Capítulo 5, Sección 5.2):

$$Cov(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] = E(XY) - \mu_X \mu_Y$$

El coeficiente de correlación  $\rho$  estandariza la covarianza para acotarla entre  $-1$  y  $1$ :

$$\rho_{X,Y} = \frac{Cov(X, Y)}{\sigma_X \sigma_Y}$$

Para una combinación lineal de variables aleatorias  $U = aX + bY$ , la varianza de  $U$  depende de las varianzas individuales y de su covarianza. La expresión general es (Devore, Capítulo 5, Sección 5.5):

$$V(aX + bY) = a^2 V(X) + b^2 V(Y) + 2ab Cov(X, Y)$$

Si las variables aleatorias  $X$  y  $Y$  son estadísticamente independientes, su covarianza es nula ( $Cov(X, Y) = 0$ ). En este escenario, la varianza de la combinación lineal se simplifica a la suma ponderada de las varianzas individuales:

$$V(aX + bY) = a^2V(X) + b^2V(Y)$$

### 7.4.1. Ejemplo 1: Abundancia Mineralógica en una Sección Delgada de Meteorito

Principios de petrología y análisis de secciones delgadas expuestos en *Planetary Geology* (Capítulo sobre *Mineralogy and Petrology of Meteorites*).

Un laboratorio de geoquímica isotópica analiza una sección delgada de una condrita ordinaria. El microscopio electrónico mide las fracciones normalizadas de dos minerales de silicato fundamentales: Olivino (variable aleatoria  $X$ ) y Piroxeno (variable aleatoria  $Y$ ). Debido a la presencia de matriz vítrea y otros minerales accesorios, la suma de las fracciones de Olivino y Piroxeno no puede exceder la unidad.

La función de densidad de probabilidad conjunta que modela la ocurrencia de estas abundancias en esta clase específica de meteoritos está dada por:

$$f(x, y) = \begin{cases} c(x + y) & \text{para } x > 0, y > 0, x + y < 1 \\ 0 & \text{en otro caso} \end{cases}$$

A continuación, resolvemos una secuencia de requerimientos para caracterizar completamente el sistema mineralógico:

**a) Determinación de la constante de normalización  $c$**  Para que  $f(x, y)$  sea una FDP legítima, la integral doble sobre toda la región de soporte debe ser igual a 1 (Devore, Capítulo 5, Sección 5.1). La región es un triángulo en el primer cuadrante acotado por  $x + y = 1$ :

$$\int_0^1 \int_0^{1-x} c(x + y) dy dx = 1$$

Resolvemos la integral interna respecto a  $y$ :

$$\int_0^{1-x} (x + y) dy = \left[ xy + \frac{y^2}{2} \right]_0^{1-x} = x(1-x) + \frac{(1-x)^2}{2}$$

Simplificando la expresión algebraica:

$$x - x^2 + \frac{1 - 2x + x^2}{2} = \frac{2x - 2x^2 + 1 - 2x + x^2}{2} = \frac{1 - x^2}{2}$$

Ahora integramos respecto a  $x$ :

$$c \int_0^1 \frac{1 - x^2}{2} dx = \frac{c}{2} \left[ x - \frac{x^3}{3} \right]_0^1 = \frac{c}{2} \left( 1 - \frac{1}{3} \right) = \frac{c}{2} \left( \frac{2}{3} \right) = \frac{c}{3}$$

Igualando a 1, obtenemos  $c = 3$ . La FDP conjunta es  $f(x, y) = 3(x + y)$  en la región definida.

**b) Obtención de la distribución marginal de  $X$**  La distribución marginal de  $X$  describe la probabilidad de encontrar una cierta abundancia de Olivino, independientemente de la cantidad de Piroxeno. Se obtiene integrando la conjunta sobre todos los valores posibles de  $Y$  (Devore, Sección 5.1):

$$f_X(x) = \int_0^{1-x} 3(x+y) dy$$

Utilizando el resultado de la integral interna calculado en el paso anterior:

$$f_X(x) = 3 \left( \frac{1-x^2}{2} \right) = \frac{3}{2}(1-x^2) \quad \text{para } 0 < x < 1$$

**c) Valor esperado de la fracción total de silicatos** El índice de saturación de silicatos se define como la suma de las fracciones,  $Z = X + Y$ . Calculamos su valor esperado utilizando la definición para funciones de variables conjuntas (Devore, Sección 5.2):

$$E(X+Y) = \int_0^1 \int_0^{1-x} (x+y) \cdot 3(x+y) dy dx = 3 \int_0^1 \int_0^{1-x} (x+y)^2 dy dx$$

Resolvemos la integral interna haciendo el cambio mental  $u = x + y$ :

$$\int_0^{1-x} (x+y)^2 dy = \left[ \frac{(x+y)^3}{3} \right]_{y=0}^{y=1-x} = \frac{1^3}{3} - \frac{x^3}{3} = \frac{1-x^3}{3}$$

Sustituimos en la integral externa:

$$E(X+Y) = 3 \int_0^1 \frac{1-x^3}{3} dx = \int_0^1 (1-x^3) dx = \left[ x - \frac{x^4}{4} \right]_0^1 = 1 - \frac{1}{4} = \frac{3}{4}$$

El valor esperado de la fracción total de silicatos es 0.75.

**d) Covarianza y Correlación entre Olivino y Piroxeno** Para calcular la covarianza, necesitamos  $E(X)$ ,  $E(Y)$  y  $E(XY)$ . Por simetría de la función  $f(x, y)$  respecto a  $X$  y  $Y$ , sabemos que  $E(X) = E(Y)$ .

$$E(X) = \int_0^1 x f_X(x) dx = \int_0^1 x \frac{3}{2}(1-x^2) dx = \frac{3}{2} \int_0^1 (x-x^3) dx = \frac{3}{2} \left[ \frac{x^2}{2} - \frac{x^4}{4} \right]_0^1 = \frac{3}{2} \left( \frac{1}{4} \right) = \frac{3}{8}$$

Calculamos  $E(X^2)$  para hallar la varianza de  $X$ :

$$E(X^2) = \int_0^1 x^2 \frac{3}{2}(1-x^2) dx = \frac{3}{2} \left[ \frac{x^3}{3} - \frac{x^5}{5} \right]_0^1 = \frac{3}{2} \left( \frac{2}{15} \right) = \frac{1}{5}$$

$$V(X) = E(X^2) - [E(X)]^2 = \frac{1}{5} - \left( \frac{3}{8} \right)^2 = \frac{1}{5} - \frac{9}{64} = \frac{64-45}{320} = \frac{19}{320}$$

Por simetría,  $V(Y) = 19/320$ . Ahora calculamos  $E(XY)$ :

$$E(XY) = \int_0^1 \int_0^{1-x} xy \cdot 3(x+y) dy dx = 3 \int_0^1 \int_0^{1-x} (x^2y + xy^2) dy dx$$

Integral interna:

$$\left[ \frac{x^2 y^2}{2} + \frac{xy^3}{3} \right]_0^{1-x} = \frac{x^2(1-x)^2}{2} + \frac{x(1-x)^3}{3} = \frac{x(1-x)^2}{6} [3x + 2(1-x)] = \frac{x(1-x)^2(2+x)}{6}$$

Expandiendo el polinomio:  $\frac{1}{6}(x - 2x^2 + x^3)(2+x) = \frac{1}{6}(2x - 3x^2 + x^4)$ . Integral externa:

$$E(XY) = 3 \int_0^1 \frac{1}{6}(2x - 3x^2 + x^4) dx = \frac{1}{2} \left[ x^2 - x^3 + \frac{x^5}{5} \right]_0^1 = \frac{1}{2} \left( 1 - 1 + \frac{1}{5} \right) = \frac{1}{10}$$

Finalmente, la covarianza y el coeficiente de correlación (Devore, Sección 5.2):

$$Cov(X, Y) = E(XY) - E(X)E(Y) = \frac{1}{10} - \left( \frac{3}{8} \right) \left( \frac{3}{8} \right) = \frac{32}{320} - \frac{45}{320} = -\frac{13}{320}$$

$$\rho_{X,Y} = \frac{Cov(X, Y)}{\sqrt{V(X)V(Y)}} = \frac{-13/320}{19/320} = -\frac{13}{19} \approx -0,684$$

La correlación negativa fuerte es físicamente consistente: al estar limitadas por  $X + Y < 1$ , una alta abundancia de Olivino restringe matemáticamente la cantidad máxima de Piroxeno que puede coexistir en la sección delgada.

**e) Varianza de un índice petrográfico combinado** El laboratorio define un Índice de Diferenciación Petrográfica como  $W = 2X + 3Y$ . Utilizando la regla de la varianza para combinaciones lineales (Devore, Sección 5.5):

$$V(W) = 2^2 V(X) + 3^2 V(Y) + 2(2)(3)Cov(X, Y)$$

$$V(W) = 4 \left( \frac{19}{320} \right) + 9 \left( \frac{19}{320} \right) + 12 \left( -\frac{13}{320} \right) = \frac{76 + 171 - 156}{320} = \frac{91}{320} \approx 0,284$$

Este resultado cuantifica rigurosamente cómo la incertidumbre en las mediciones minerales individuales y su correlación negativa se propagan en el índice compuesto, permitiendo a los geólogos planetarios establecer márgenes de confianza para la clasificación del meteorito.

## 7.4.2. Ejemplo 2: Detección Multi-banda de Tránsitos Exoplanetarios

En la astronomía observacional, la confirmación de exoplanetas requiere cruzar datos de diferentes instrumentos o bandas espectrales para descartar falsos positivos. Inspirados en los métodos de fotometría y validación estadística de *Astronomical Measurement* (Capítulo sobre *Transit Photometry and False Positive Probabilities*), modelaremos un escenario de detección discreta.

Un telescopio espacial analiza un campo estelar. Para una estrella objetivo específica, definimos las variables aleatorias discretas:

- $X$ : Número de señales candidatas a tránsito detectadas en la banda visual.
- $Y$ : Número de señales candidatas a tránsito detectadas en la banda infrarroja.



Basado en el rendimiento histórico del pipeline de reducción de datos, la función de masa de probabilidad conjunta  $p(x, y)$  para  $X \in \{0, 1, 2\}$  y  $Y \in \{0, 1\}$  se resume en la siguiente tabla:

|         | $X = 0$ | $X = 1$ | $X = 2$ |
|---------|---------|---------|---------|
| $Y = 0$ | 0,10    | 0,15    | 0,05    |
| $Y = 1$ | 0,20    | 0,25    | 0,25    |

A continuación, desarrollamos los pasos para evaluar la estadística de detección del sistema:

**a) Distribuciones marginales** Las distribuciones marginales describen el comportamiento de cada banda por separado, sumando las probabilidades conjuntas (Devore, Sección 5.1): Para  $X$ :

$$p_X(0) = 0,10 + 0,20 = 0,30$$

$$p_X(1) = 0,15 + 0,25 = 0,40$$

$$p_X(2) = 0,05 + 0,25 = 0,30$$

Para  $Y$ :

$$p_Y(0) = 0,10 + 0,15 + 0,05 = 0,30$$

$$p_Y(1) = 0,20 + 0,25 + 0,25 = 0,70$$

**b) Valores esperados y varianzas individuales** Calculamos los momentos de primer y segundo orden para cada variable (Devore, Capítulo 3, Sección 3.3):

$$E(X) = 0(0,30) + 1(0,40) + 2(0,30) = 1,0$$

$$E(X^2) = 0^2(0,30) + 1^2(0,40) + 2^2(0,30) = 0,40 + 1,20 = 1,60$$

$$V(X) = E(X^2) - [E(X)]^2 = 1,60 - 1,0^2 = 0,60$$

$$E(Y) = 0(0,30) + 1(0,70) = 0,70$$

$$E(Y^2) = 0^2(0,30) + 1^2(0,70) = 0,70$$

$$V(Y) = E(Y^2) - [E(Y)]^2 = 0,70 - 0,70^2 = 0,70 - 0,49 = 0,21$$

**c) Covarianza y Correlación** Para evaluar si las detecciones en ambas bandas son independientes o están correlacionadas, calculamos  $E(XY)$  sumando sobre todos los pares  $(x, y)$  donde la probabilidad es distinta de cero:

$$E(XY) = \sum_x \sum_y xy \cdot p(x, y)$$

Los únicos términos que no se anulan (donde  $x \neq 0$  y  $y \neq 0$ ) son:

$$E(XY) = (1)(1)(0,25) + (2)(1)(0,25) = 0,25 + 0,50 = 0,75$$

La covarianza es:

$$Cov(X, Y) = E(XY) - E(X)E(Y) = 0,75 - (1,0)(0,70) = 0,05$$

El coeficiente de correlación es:

$$\rho_{X,Y} = \frac{Cov(X,Y)}{\sqrt{V(X)V(Y)}} = \frac{0,05}{\sqrt{0,60 \times 0,21}} = \frac{0,05}{\sqrt{0,126}} \approx \frac{0,05}{0,355} \approx 0,141$$

La correlación positiva débil sugiere que, aunque las bandas son físicamente distintas, existen factores astrofísicos subyacentes (como la actividad estelar o el tamaño del planeta) que tienden a aumentar la tasa de detección en ambas bandas simultáneamente.

**d) Varianza de un discriminante de validación** Para separar los planetas reales de los binarios eclipsantes de fondo, el pipeline calcula un Puntaje Discriminante  $Z = 3X - 2Y$ . Las ponderaciones positivas para la banda visual y negativas para la infrarroja ayudan a filtrar ciertos tipos de falsos positivos. Necesitamos la varianza de este puntaje para calibrar los umbrales de alerta.

Aplicando la fórmula de la varianza para una combinación lineal (Devore, Sección 5.5):

$$V(Z) = V(3X - 2Y) = 3^2V(X) + (-2)^2V(Y) + 2(3)(-2)Cov(X,Y)$$

$$V(Z) = 9(0,60) + 4(0,21) - 12(0,05)$$

$$V(Z) = 5,40 + 0,84 - 0,60 = 5,64$$

La varianza del puntaje discriminante es 5.64. Conocer este valor exacto permite a los científicos de datos establecer los intervalos de confianza para el puntaje  $Z$ . Si la varianza hubiera sido calculada asumiendo erróneamente que  $X$  e  $Y$  eran independientes (ignorando el término de covarianza), el resultado habría sido 6,24, lo que llevaría a subestimar la precisión del discriminante y a un diseño ineficiente de los filtros de validación automática. Este ejercicio demuestra el poder de las distribuciones conjuntas para modelar sistemas de detección complejos en la astronomía moderna.

# Clase 8

8.1. Valores esperados en varias variables

8.2. Funciones de correlación

8.3. Covarianza

8.4. Combinación de variables aleatorias

# Clase 9

9.1. Teorema central del límite

9.2. Estadísticos

9.3. Distribución de estadísticos

9.4. Muestras

9.5. Estimación puntual: Método de momentos

# Clase 10

10.1. Método de mínimos cuadrados

10.2. Maximum likelihood