

Reporte de Estadística Inferencial en R

Costos y presupuestos en salud

Daniel Soto Villada

9 de mayo de 2026

Índice

1. Introducción	2
2. Descripción de datos y diseño muestral	2
2.1. Dataset original	2
2.2. Muestreo estratificado proporcional (70 casos)	2
2.3. Comparación de composición: original vs muestra	3
3. Variables para requisitos de la actividad	3
4. Análisis descriptivo	4
4.1. Estadísticos principales	4
4.2. Visualizaciones descriptivas	4
4.3. Interpretación descriptiva	5
5. Pruebas de hipótesis ($\alpha = 0,05$)	6
6. Correlación y regresión lineal múltiple	6
6.1. Correlación de Pearson	6
6.2. Modelo de regresión	6
6.3. Lectura del modelo	7
6.4. Diagnóstico de supuestos	8
7. Inferencia y predicción	8
8. Conclusiones	9
9. Recomendación de otros datasets	9

1. Introducción

Este reporte presenta el análisis estadístico inferencial desarrollado en R a partir del dataset *Medical Cost Personal Dataset* (`insurance.csv`), con el objetivo de estudiar factores asociados al costo anual del seguro médico (`charges`). El trabajo se organizó siguiendo la guía del curso: análisis descriptivo, pruebas de hipótesis, correlación, regresión lineal múltiple e inferencia/predicción.

El conjunto original contiene 1338 observaciones. Como la actividad exige trabajar con 70 registros, se implementó un muestreo estratificado proporcional para conservar representatividad en variables cualitativas clave.

2. Descripción de datos y diseño muestral

2.1. Dataset original

El dataset inicial incluye 7 variables:

- Cuantitativas: `age`, `bmi`, `children`, `charges`.
- Cualitativas: `sex`, `smoker`, `region`.

Resumen general reportado en el notebook:

- $n = 1338$ observaciones.
- `age`: $\min = 18$, $\text{media} \approx 39,21$, $\max = 64$.
- `bmi`: $\text{media} \approx 30,66$.
- `charges`: $\text{media} \approx 13270$, $\text{mediana} \approx 9382$, $\max \approx 63770$.

2.2. Muestreo estratificado proporcional (70 casos)

Se estratificó por la combinación `smoker` $\times$ `region`. Posteriormente, se ajustó el redondeo para obtener exactamente 70 observaciones.

Cuadro 1: Asignación muestral proporcional por estrato

smoker	region	N_{total}	p	n_{raw}	n_{sample}
no	northeast	257	0.1921	13.45	13
no	northwest	267	0.1996	13.97	14
no	southeast	273	0.2040	14.28	14
no	southwest	267	0.1996	13.97	14
yes	northeast	67	0.0501	3.51	4
yes	northwest	58	0.0433	3.03	3
yes	southeast	91	0.0680	4.76	5
yes	southwest	58	0.0433	3.03	3

Verificación: $\sum n_{sample} = 70$.

2.3. Comparación de composición: original vs muestra

Cuadro 2: Proporción por hábito de fumar

Grupo	Original	Muestra 70
No fumador	0.7952	0.7857
Fumador	0.2048	0.2143

Cuadro 3: Proporción por región

Región	Original	Muestra 70
northeast	0.2422	0.2429
northwest	0.2429	0.2429
southeast	0.2720	0.2714
southwest	0.2429	0.2429

Las proporciones son muy similares, lo que respalda que la reducción a 70 casos conserva estructura poblacional en variables categóricas relevantes.

3. Variables para requisitos de la actividad

En la muestra final se trabajó con:

- Cuantitativas continuas: `bmi`, `charges`.

- Cuantitativa discreta: `children`.
- Cualitativas nominales: `sex`, `smoker`.
- Cualitativa ordinal derivada: `risk_level` (Bajo, Medio, Alto).

Además se mantuvieron `age` y `region` para enriquecer el análisis.

4. Análisis descriptivo

4.1. Estadísticos principales

Cuadro 4: Resumen descriptivo en la muestra de 70

Variable	Media	DE	Mediana	Mínimo	Máximo
age	40.31	13.47	—	18.00	64.00
bmi	31.39	4.78	—	20.23	41.33
children	1.30	1.31	—	0	5
charges	14986.02	13819.74	10319.29	1121.87	60021.40

4.2. Visualizaciones descriptivas




Figura 1: Distribución de costos anuales (`charges`).

Espacio reservado para boxplot de `charges` por `smoker`.

Figura 2: Comparación de costos entre fumadores y no fumadores.

Espacio reservado para dispersión `age` vs `charges`.

Figura 3: Relación entre edad y costo anual.

4.3. Interpretación descriptiva

1. `charges` presenta asimetría positiva: pocos individuos concentran costos muy altos.
2. Los fumadores tienden a exhibir costos superiores a los no fumadores.
3. Se observa tendencia creciente entre edad y costo, especialmente en fumadores.

5. Pruebas de hipótesis ($\alpha = 0,05$)

Cuadro 5: Resultados inferenciales principales

Prueba	Hipótesis nula	Resultado	Decisión
Shapiro–Wilk sobre charges	La distribución es normal	$W = 0,82673, p = 1,322 \times 10^{-7}$	Rechazar H_0
Chi-cuadrado (sex vs smoker)	Independencia entre variables	$\chi^2 = 4,5372, gl = 1, p = 0,03317$	Rechazar H_0
t de Welch (bmi por sex)	Igualdad de medias de IMC	$t = -0,16483, p = 0,8696$	No rechazar H_0
Mann–Whitney (charges por smoker)	Igualdad de distribución/localización	$W = 11, p = 9,492 \times 10^{-9}$	Rechazar H_0

Síntesis: los costos no siguen normalidad en la muestra, hay evidencia de asociación entre sexo y hábito de fumar, no hay evidencia de diferencia de IMC promedio por sexo, y sí hay una diferencia marcada de costos entre fumadores y no fumadores.

6. Correlación y regresión lineal múltiple

6.1. Correlación de Pearson

Cuadro 6: Matriz de correlación (variables numéricas)

Variable	age	bmi	children	charges
age	1.000	-0.049	0.141	0.372
bmi	-0.049	1.000	-0.078	0.161
children	0.141	-0.078	1.000	0.016
charges	0.372	0.161	0.016	1.000

6.2. Modelo de regresión

Se estimó:

$$\text{charges} \sim \text{age} + \text{bmi} + \text{children} + \text{smoker} + \text{sex} + \text{region}.$$

Cuadro 7: Coeficientes del modelo lineal múltiple

Término	Estimación	Error estándar	t	p-valor
Intercept	-12071.39	5275.43	-2.288	0.0256
age	322.98	50.24	6.429	$2,2 \times 10^{-8}$
bmi	379.96	138.56	2.742	0.0080
children	392.52	508.57	0.772	0.4432
smokeryes	27743.07	1651.18	16.802	$< 2 \times 10^{-16}$
sexmale	-1582.95	1360.86	-1.163	0.2493
regionnorthwest	-5119.10	1916.69	-2.671	0.0097
regionsoutheast	-3728.34	1845.25	-2.021	0.0477
regionsouthwest	-5627.17	1872.51	-3.005	0.0038

Estadísticos globales del ajuste:

- Error estándar residual: 5380 (61 g.l.).
- $R^2 = 0,866$, R^2 ajustado = 0,8485.
- Prueba F global: $F(8, 61) = 49,29$, $p < 2,2 \times 10^{-16}$.

6.3. Lectura del modelo

- **smokeryes** es el predictor con mayor impacto: incrementa fuertemente el costo esperado.
- **age** y **bmi** también aportan incrementos significativos en costos.
- **children** y **sexmale** no resultaron significativos al 5 % en este ajuste.
- El modelo explica una proporción alta de variabilidad del costo (R^2 elevado).

6.4. Diagnóstico de supuestos




Figura 4: Diagnóstico de linealidad, homocedasticidad, normalidad de residuos e influencia.

7. Inferencia y predicción

Se evaluaron predicciones para tres perfiles:

Cuadro 8: Predicción puntual e intervalo de predicción (`predict(..., interval = "prediction")` en R). El caso marcado con [†] debe interpretarse como costo cercano a cero, no literal.

age	bmi	children	smoker	sex	region	fit	lwr	upr
25	24	0	no	female	northwest	2.93 [†]	-11509.87 [†]	11515.74
45	30	2	yes	male	southeast	37078.18	25714.43	48441.93
60	33	3	no	female	northeast	21023.48	9604.75	32442.21

[†] Valor transcrito del notebook. En modelos lineales con respuesta positiva y asimétrica, pueden aparecer predicciones no factibles; este caso se interpreta como costo esperado muy bajo (cercano a cero), no como monto literal.

Nota de interpretación: el primer perfil presenta una predicción puntual muy baja y un límite inferior negativo. Esto no implica un costo real negativo, sino una limitación conocida del modelo lineal gaussiano cuando la variable respuesta es estrictamente positiva y altamente asimétrica.

El intervalo de predicción es amplio porque incorpora variabilidad individual; por ello es más útil para planeación presupuestal que una sola estimación puntual. En una extensión metodológica, conviene evaluar modelos con transformación $\log(\text{charges})$ o alternativas con restricción de positividad.

8. Conclusiones

1. El muestreo estratificado proporcional permitió cumplir el requisito de 70 observaciones con buena representatividad de subgrupos.
2. El costo anual de salud muestra alta dispersión y asimetría positiva.
3. Ser fumador está fuertemente asociado a incrementos del costo médico, tanto descriptiva como inferencialmente.
4. El modelo lineal múltiple presentó buen ajuste global ($R^2 = 0,866$) y confirmó la relevancia de edad, IMC y tabaquismo.
5. El enfoque aplicado aporta evidencia cuantitativa para decisiones en costos y presupuestos de salud.

9. Recomendación de otros datasets

1. **Medical Expenditure Panel Survey (MEPS):** útil para inferencia sobre gasto y uso de servicios médicos.
2. **Hospital Cost Reports (CMS):** permite comparar costos y eficiencia financiera entre instituciones.