

Reporte de Estadística Inferencial en R

Costos y presupuestos en salud

Mariana Soto Villada

10 de mayo de 2026

Índice

1. Introducción	2
2. Planteamiento del problema e hipótesis	2
3. Descripción de datos y diseño muestral	2
3.1. Dataset original	2
3.2. Muestreo estratificado proporcional (70 casos)	3
3.3. Comparación de composición: original vs muestra	3
4. Variables para requisitos de la actividad	4
5. Análisis descriptivo	4
5.1. Estadísticos principales	4
5.2. Visualizaciones descriptivas	5
5.3. Interpretación descriptiva	6
6. Pruebas de hipótesis ($\alpha = 0,05$)	6
7. Correlación y regresión lineal múltiple	7
7.1. Correlación de Pearson	7
7.2. Modelo de regresión	7
7.3. Lectura del modelo	8
8. Inferencia y predicción	8
9. Conclusiones	8
10. Referencias	9

1. Introducción

Este reporte presenta el análisis estadístico inferencial desarrollado en R a partir del conjunto de datos *Medical Cost Personal Dataset* (`insurance.csv`), con el objetivo de estudiar factores asociados al costo anual del seguro médico (`costo_anual`). El trabajo se organizó siguiendo la guía del curso: análisis descriptivo, pruebas de hipótesis, correlación, regresión lineal múltiple e inferencia/predicción.

El conjunto original contiene 1338 observaciones. Como la actividad exige trabajar con 70 registros, se implementó un muestreo estratificado proporcional para conservar representatividad en variables cualitativas clave.

La base de datos fue tomada de un repositorio público de referencia para práctica estadística y se cita formalmente en la sección de referencias con formato APA (7.^a edición).

2. Planteamiento del problema e hipótesis

Problema de estudio: determinar qué variables demográficas y de hábitos de vida se asocian con incrementos en el costo anual del seguro médico y evaluar si esas asociaciones son estadísticamente significativas.

Hipótesis general:

- H_0 : no existe relación estadísticamente significativa entre las variables explicativas (edad, IMC, número de hijos, sexo, hábito de fumar y región) y el costo anual del seguro.
- H_1 : existe al menos una relación estadísticamente significativa entre las variables explicativas y el costo anual del seguro.

3. Descripción de datos y diseño muestral

3.1. Dataset original

El dataset inicial incluye 7 variables:

- Cuantitativas: edad, IMC, número de hijos, costo anual.
- Cualitativas: sexo, condición de fumador, región.

Resumen general reportado en el notebook:

- $n = 1338$ observaciones.
- Edad: min = 18, media $\approx 39,21$, max = 64.

- IMC: media $\approx 30,66$.
- Costo anual: media ≈ 13270 , mediana ≈ 9382 , max ≈ 63770 .

3.2. Muestreo estratificado proporcional (70 casos)

Se estratificó por la combinación condición de fumador $\times$ región. Posteriormente, se ajustó el redondeo para obtener exactamente 70 observaciones.

Cuadro 1: Predicción puntual e intervalo de predicción (`predict(..., interval = "prediction")` en R). El caso marcado con † debe interpretarse como costo cercano a cero, no literal.

Edad	IMC	Hijos	Fumador	Sexo	Región	Predicción	L. inf.	L. sup.
25	24	0	No	Mujer	Noroeste	2.93 †	-	11515.74
							11509.87 †	
45	30	2	Sí	Hombre	Sureste	37078.18	25714.43	48441.93
60	33	3	No	Mujer	Noreste	21023.48	9604.75	32442.21

Verificación: $\sum n_{sample} = 70$.

3.3. Comparación de composición: original vs muestra

Cuadro 2: Proporción por hábito de fumar

Grupo	Original	Muestra 70
No fumador	0.7952	0.7857
Fumador	0.2048	0.2143

Cuadro 3: Proporción por región

Región	Original	Muestra 70
Noreste	0.2422	0.2429
Noroeste	0.2429	0.2429
Sureste	0.2720	0.2714
Suroeste	0.2429	0.2429

Las proporciones son muy similares, lo que respalda que la reducción a 70 casos conserva estructura poblacional en variables categóricas relevantes.

4. Variables para requisitos de la actividad

En la muestra final se trabajó con:

- Cuantitativas continuas: IMC, costo anual.
- Cuantitativa discreta: número de hijos.
- Cualitativas nominales: sexo, condición de fumador.
- Cualitativa ordinal derivada: nivel de riesgo (Bajo, Medio, Alto).

Además se mantuvieron edad y región para enriquecer el análisis.

5. Análisis descriptivo

5.1. Estadísticos principales

Cuadro 4: Resumen descriptivo en la muestra de 70

Variable	Media	DE	Mínimo	Máximo
Edad	40.31	13.47	18.00	64.00
IMC	31.39	4.78	20.23	41.33
Número de hijos	1.30	1.31	0	5
Costo anual	14986.02	13819.74	1121.87	60021.40

5.2. Visualizaciones descriptivas




Figura 1: Distribución del costo anual del seguro.




Figura 2: Comparación del costo anual entre fumadores y no fumadores.




Figura 3: Relación entre edad y costo anual según condición de fumador.

5.3. Interpretación descriptiva

1. El costo anual presenta asimetría positiva: pocos individuos concentran costos muy altos.
2. Los fumadores tienden a exhibir costos superiores a los no fumadores.
3. Se observa tendencia creciente entre edad y costo, especialmente en fumadores.

6. Pruebas de hipótesis ($\alpha = 0,05$)

Cuadro 5: Resultados inferenciales principales

Prueba	Hipótesis nula	Resultado	Decisión
Shapiro–Wilk sobre costo anual	La distribución es normal	$W = 0,82673$, $p = 1,322 \times 10^{-7}$	Rechazar H_0
Chi-cuadrado (sexo vs fumador)	Independencia entre variables	$\chi^2 = 4,5372$, $gl = 1$, $p = 0,03317$	Rechazar H_0
t de Welch (IMC por sexo)	Igualdad de medias de IMC	$t = -0,16483$, $p = 0,8696$	No rechazar H_0
Mann–Whitney (costo anual por fumador)	Igualdad de distribución/localización	$W = 11$, $p = 9,492 \times 10^{-9}$	Rechazar H_0

Síntesis: los costos no siguen normalidad en la muestra, hay evidencia de asociación entre sexo y hábito de fumar, no hay evidencia de diferencia de IMC promedio por sexo, y sí hay una diferencia marcada de costos entre fumadores y no fumadores.

7. Correlación y regresión lineal múltiple

7.1. Correlación de Pearson

Cuadro 6: Matriz de correlación (variables numéricas)

Variable	Edad	IMC	N.º hijos	Costo anual
Edad	1.000	-0.049	0.141	0.372
IMC	-0.049	1.000	-0.078	0.161
N.º hijos	0.141	-0.078	1.000	0.016
Costo anual	0.372	0.161	0.016	1.000

7.2. Modelo de regresión

Se estimó:

$$\text{costo_anual} \sim \text{edad} + \text{imc} + \text{hijos} + \text{fumador} + \text{sexo} + \text{region}.$$

Cuadro 7: Coeficientes del modelo lineal múltiple

Término	Estimación	Error estándar	t	p-valor
Intercept	-12071.39	5275.43	-2.288	0.0256
Edad	322.98	50.24	6.429	$2,2 \times 10^{-8}$
IMC	379.96	138.56	2.742	0.0080
Número de hijos	392.52	508.57	0.772	0.4432
Fumador (Sí)	27743.07	1651.18	16.802	$< 2 \times 10^{-16}$
Sexo (Hombre)	-1582.95	1360.86	-1.163	0.2493
Región (Noroeste)	-5119.10	1916.69	-2.671	0.0097
Región (Sureste)	-3728.34	1845.25	-2.021	0.0477
Región (Suroeste)	-5627.17	1872.51	-3.005	0.0038

Estadísticos globales del ajuste:

- Error estándar residual: 5380 (61 g.l.).
- $R^2 = 0,866$, R^2 ajustado = 0,8485.

- Prueba F global: $F(8, 61) = 49,29$, $p < 2,2 \times 10^{-16}$.

7.3. Lectura del modelo

- La condición de fumador (Sí) es el predictor con mayor impacto: incrementa fuertemente el costo esperado.
- Edad e IMC también aportan incrementos significativos en costos.
- Número de hijos y sexo (Hombre) no resultaron significativos al 5 % en este ajuste.
- El modelo explica una proporción alta de variabilidad del costo (R^2 elevado).

8. Inferencia y predicción

Se evaluaron predicciones para tres perfiles:

Cuadro 8: Predicción puntual e intervalo de predicción.

Edad	IMC	Hijos	Fum.	Sexo	Región	Predicción	Límite inferior	Límite superior
25	24	0	No	Mujer	Noroeste	2.93 [†]	-11509.87 [†]	11515.74
45	30	2	Sí	Hombre	Sureste	37078.18	25714.43	48441.93
60	33	3	No	Mujer	Noreste	21023.48	9604.75	32442.21

[†] Valor transcrito del notebook. En modelos lineales con respuesta positiva y asimétrica, pueden aparecer predicciones no factibles; este caso se interpreta como costo esperado muy bajo (cercano a cero), no como monto literal.

Nota de interpretación: el primer perfil presenta una predicción puntual muy baja y un límite inferior negativo. Esto no implica un costo real negativo, sino una limitación conocida del modelo lineal gaussiano cuando la variable respuesta es estrictamente positiva y altamente asimétrica.

El intervalo de predicción es amplio porque incorpora variabilidad individual; por ello es más útil para planeación presupuestal que una sola estimación puntual. En una extensión metodológica, conviene evaluar modelos con transformación $\log(\text{costo_anual})$ o alternativas con restricción de positividad.

9. Conclusiones

1. El muestreo estratificado proporcional permitió cumplir el requisito de 70 observaciones con buena representatividad de subgrupos.

2. El costo anual de salud muestra alta dispersión y asimetría positiva.
3. Ser fumador está fuertemente asociado a incrementos del costo médico, tanto descriptiva como inferencialmente.
4. El modelo lineal múltiple presentó buen ajuste global ($R^2 = 0,866$) y confirmó la relevancia de edad, IMC y tabaquismo.
5. El enfoque aplicado aporta evidencia cuantitativa para decisiones en costos y presupuestos de salud.

10. Referencias

- stedy. (n.d.). *Machine-Learning-with-R-datasets* [Data set]. GitHub. Retrieved May 10, 2026, from <https://github.com/stedy/Machine-Learning-with-R-datasets>
- Instituto Tecnológico Metropolitano. (2026). *Guía de trabajo de campo: Estadística inferencial en Excel o RStudio* [Material de curso].