

Problemas de Astroestadística

Problem set 7: Inferencia Bayesiana

Astronomía - Universidad de Antioquia

1. Un equipo de astrónomos estudia la frecuencia de exoplanetas detectables mediante el método de tránsito en estrellas similares al Sol. Para ello, observa una muestra aleatoria de 100 estrellas y encuentra evidencia convincente de la presencia de al menos un exoplaneta en 18 de ellas.

Sea θ la proporción verdadera de estrellas de esta población que poseen un exoplaneta detectable mediante esta técnica. Suponiendo que cada observación puede modelarse como un ensayo de Bernoulli independiente, el número total de detecciones X sigue una distribución binomial, $X \sim \text{Binomial}(n, \theta)$, donde $n = 100$ y se observó $X = 18$.

Estudios previos sugieren que aproximadamente el 20% de las estrellas similares al Sol albergan exoplanetas detectables por tránsito. Para incorporar esta información previa, se asigna a θ una distribución a priori Beta $\theta \sim \text{Beta}(\alpha, \beta)$ con parámetros $\alpha = 4$ y $\beta = 16$.

- a) Escriba la función de verosimilitud para θ y gráfiquela en el intervalo $0 < \theta < 1$.
- b) Escriba la densidad de la distribución a priori e interprete el significado de los parámetros α y β .
- c) Obtenga analíticamente la distribución posterior de θ .
- d) Calcule la media, la varianza y la moda de la distribución posterior.
- e) Utilice simulación Monte Carlo para generar 10^4 muestras aleatorias de la distribución posterior.
- f) A partir de las muestras simuladas, estime un intervalo de credibilidad del 95% para θ .
- g) Estime la probabilidad posterior de que más del 20% de las estrellas de esta población posean un exoplaneta detectable, es decir, $P(\theta > 0.20 \mid \text{datos})$.
- h) Compare la interpretación del intervalo de credibilidad obtenido en el inciso anterior con la interpretación de un intervalo de confianza frecuentista del 95%.

2. **Modelo de estrellas variables** Se adjunta el archivo `cepheids_2.csv`, que contiene observaciones de un conjunto de estrellas Cefeidas (Breuval+, 2021). Para cada estrella se reportan su período de pulsación (en días), paralaje (en mas) y sus magnitudes en las bandas V e I. La relación período–luminosidad de las Cefeidas puede modelarse mediante la ecuación

$$M = a + b \log_{10}(P) + \varepsilon,$$

donde M es la magnitud absoluta, P el periodo y los errores observacionales son independientes y siguen una distribución normal $\varepsilon \sim N(0, \sigma^2)$. Suponga que la desviación estándar de los errores es conocida e igual a $\sigma = 0.3$ mag.

Para los parámetros del modelo considere distribuciones a priori normales e independientes entre sí, ambas con $\mu = 0$ y $\sigma^2 = 10^2$

- a) Lea el archivo `cepheids_2.csv` y realice un gráfico de dispersión de la magnitud absoluta M en función de $\log_{10}(P)$. Describa brevemente la tendencia observada.
- b) Escriba la función de verosimilitud para los parámetros a y b .
- c) Escriba la distribución posterior conjunta de a y b , ignorando constantes de normalización.
- d) Encuentre los valores de máxima probabilidad a posteriori (MAP) de a y b .
- e) Demuestre que la distribución posterior conjunta de (a, b) es una normal bivariada y determine su media y matriz de covarianza.
- f) Utilice el resultado anterior para generar 10^4 muestras aleatorias de la distribución posterior conjunta de (a, b) .
- g) A partir de las muestras simuladas, estime un intervalo de credibilidad del 95 % para a y b .
- h) Utilice las muestras posteriores para estimar la distribución posterior de la magnitud absoluta de una Cefeida con período $P = 12$ días. Reporte la media posterior y un intervalo de credibilidad del 95 % para la magnitud absoluta predicha.
- i) Grafique la relación período–luminosidad utilizando la recta correspondiente a los valores MAP de los parámetros. Sobre el mismo gráfico, incluya una banda de credibilidad del 95 % obtenida a partir de las simulaciones de la distribución posterior.
- j) Compare los resultados obtenidos mediante el enfoque bayesiano con los que se obtendrían usando una regresión lineal clásica por mínimos cuadrados. Discuta semejanzas y diferencias entre ambos enfoques.